SRM · 第 1 章

統計學習的基本問題

先弄清楚要回答的是哪一種問題（預測還是推論、迴歸還是分類），再用測試資料上的誤差判斷模型好不好。這一章推導全書最重要的一條式子：期望測試誤差 = 偏差平方 + 變異數 + 不可降低的誤差。

本章內容

1. 1.1 統計學習在做什麼
2. 1.2 變數的種類
3. 1.3 圖形

本章對應講義第 1 課（Basics of Statistical Learning），讀本是 Frees《Regression Modeling with Actuarial and Financial Applications》1.2 節與 James 等人《An Introduction to Statistical Learning》（以下簡稱 ISLR）2.1～2.2.2 節。考試出現的形式多半是觀念判斷題（哪一句話是對的）與箱形圖、分位數圖的簡單計算。

1.1 統計學習在做什麼

一、模型的基本形式

統計學習（statistical learning）是用過去的資料，找出一個變數如何依賴其他變數，或找出資料本身的結構。以保險為例：保險公司想依被保險人的年齡、性別、收入、信用評分、過去理賠紀錄等特徵，估計他的理賠成本。若 Y 代表理賠成本、$X_1, X_2, \ldots, X_p$ 代表這些特徵，我們想找一個函數 f 使得

$$Y = f(X_1, X_2, \ldots, X_p) + \varepsilon.$$

這裡 ε 是**誤差項**（error term）。沒有任何函數能完美描述 Y：兩個特徵完全相同的人，理賠金額仍然不同，因為有些影響因素沒有被量測，或本身就是隨機的。通常假設 $E(\varepsilon) = 0$，而且 ε 和 X 無關，所以 $f(X)$ 就是給定 X 時 Y 的條件平均 $E(Y \mid X)$。

名詞對照：X_j 稱為**解釋變數**（explanatory variable）、**自變數**（independent variable）、**預測變數**（predictor）或**特徵**（feature；講義說「特徵」通常指只有有限幾個可能值的離散變數）。Y 稱為**應變數**（dependent variable）或**反應變數**（response）。

二、可降低的誤差與不可降低的誤差

我們手上只有估計出來的 $\hat{f}$，用它預測得到 $\hat{Y} = \hat{f}(X)$。把 X 固定在某個值，預測誤差的期望平方可以拆成兩塊：

推導：預測誤差的兩個來源

固定 $X = x$，把 $\hat{f}$ 也當成已知（先不考慮重抽資料造成的變化）。因為 $Y = f(x) + \varepsilon$：

$$E\big[(Y - \hat{Y})^2\big] = E\big[(f(x) + \varepsilon - \hat{f}(x))^2\big] = E\big[(f(x) - \hat{f}(x))^2 + 2(f(x) - \hat{f}(x))\varepsilon + \varepsilon^2\big].$$

$f(x) - \hat{f}(x)$ 是固定的數，$E(\varepsilon) = 0$，所以中間的交叉項期望值為 0；$E(\varepsilon^2) = \mathrm{Var}(\varepsilon)$。因此

$$E\big[(Y - \hat{Y})^2\big] = \underbrace{\big[f(x) - \hat{f}(x)\big]^2}_{\text{可降低的誤差}} + \underbrace{\mathrm{Var}(\varepsilon)}_{\text{不可降低的誤差}}.$$

第一塊是 $\hat{f}$ 和真正的 f 差多遠，選更好的方法、蒐集更多資料可以讓它變小，所以叫**可降低的誤差**（reducible error）。第二塊來自 ε 本身，即使知道真正的 f 也消不掉，叫**不可降低的誤差**（irreducible error）。所以任何模型在新資料上的均方誤差，都不可能低於 $\mathrm{Var}(\varepsilon)$。

三、預測與推論

統計學習有兩個用途：

- **預測**（prediction）：給定一組 X（可能是過去沒看過的值），猜 Y 會是多少。這時只在乎 $\hat{Y}$ 準不準，$\hat{f}$ 長什麼樣子可以是黑盒子。通常我們無法控制 X，例如預測新保單的理賠成本。
- **推論**（inference）：想了解每個 X_j 怎麼影響 Y：哪些變數有關、影響是正是負、大小多少、關係是不是線性。這時 $\hat{f}$ 必須看得懂。若 X 是可以控制的（例如各種廣告支出），了解影響之後就能調整策略，例如改變廣告組合來提高銷售。

同一份資料可以兩種目的都有，但目的不同，選模型的標準也不同（見下面第五小節）。

四、參數方法與非參數方法

估計 f 有兩大類做法：

- **參數方法**（parametric method）：先假設 f 的函數形式，再用資料估計其中的參數。例如假設 $f(X) = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p$，問題就從「估計整個函數」

縮小成「估計 $p+1$ 個係數」。估好之後，描述這條關係只需要那幾個係數，原始資料可以丟掉。缺點是假設的形式可能錯：真正的 f 若是彎的，直線再怎麼估也貼不上。

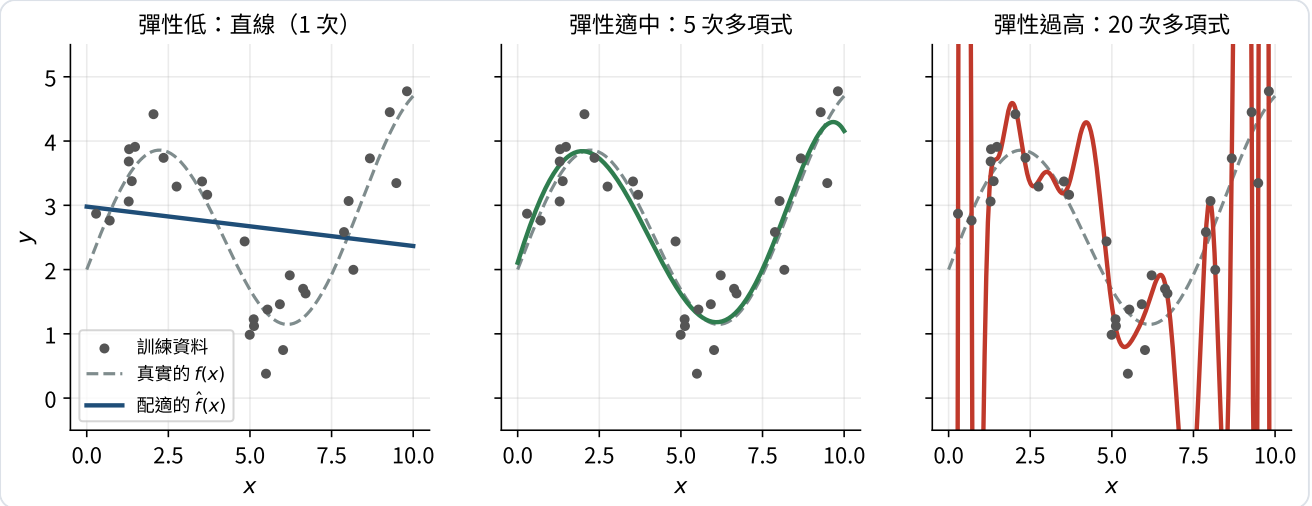
- **非參數方法**（non-parametric method）：不事先假設簡單的形式，只要求 $\hat{f}$ 盡量靠近資料點、又不要太扭曲。例子是**樣條**（spline）：三次樣條用分段的三次多項式把點接起來，接點處曲率連續（樣條不在考試範圍）。非參數方法描述關係時需要全部的資料；缺點是需要大量觀察值才估得準。

本書的 KNN（第 15 章）與決策樹（第 16 章）是非參數方法；線性迴歸與廣義線性模型是參數方法。

五、彈性與可解釋性的取捨

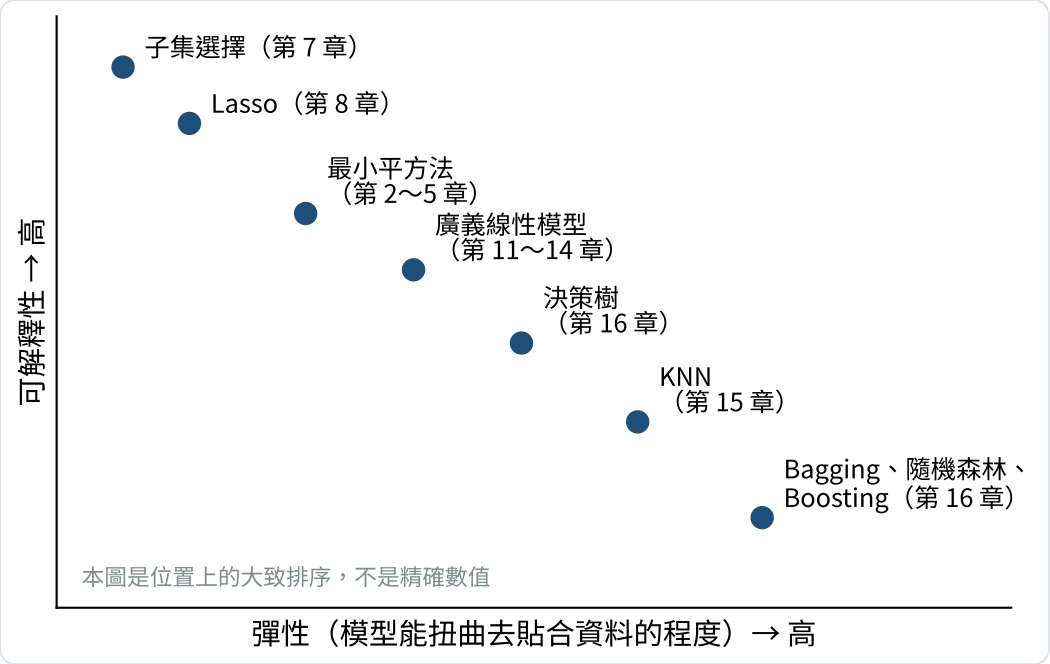
彈性高（flexible）的方法會為了貼近每一個觀察值而扭曲；**彈性低**的方法不會。直覺上彈性越高越好，但有兩個問題：

1. **貼得近不代表預測得準**。例如有 10 個觀察值，用 9 次多項式可以穿過每一個點，訓練資料上誤差為 0，但在其他 x 的預測會非常差。下圖用同一組 30 個點配適三種彈性的模型：



同一組模擬資料（灰點）配適三種彈性的模型。虛線是產生資料的真實函數。直線（左）太僵硬，抓不到彎曲；5 次多項式（中）和真實函數很接近；20 次多項式（右）為了穿過每一個點而劇烈擺動，換一組資料就完全不同。

2. **越有彈性越難解釋**。線性迴歸彈性低，但每個係數的意思一目了然；彈性高的方法往往是黑盒子。若目的是預測，看不懂沒關係；若目的是推論，就是很大的缺點。



本書各方法在「彈性」與「可解釋性」上的大致位置（仿 ISLR 圖 2.7）。越往右越能貼合複雜的形狀，但越難說明每個變數的作用。

六、監督式與非監督式學習

- **監督式學習**（supervised learning）：每筆資料都有反應變數 Y，目標是用 X 解釋或預測 Y。因為有正確答案可以對照，可以算出模型錯了多少。
- **非監督式學習**（unsupervised learning）：沒有反應變數，只是找觀察值之間的關係或資料裡的結構，例如主成分分析（第 17 章）與群集分析（第 18 章）。因為沒有正確答案，很難衡量做得好不好，所以比監督式學習困難。

七、迴歸問題與分類問題

反應變數是連續的數值，稱為**迴歸問題**（regression problem）；反應變數只有少數幾個可能值，稱為**分類問題**（classification problem），而且那些值不一定是數字，例如藥物「有效／無效」。迴歸問題配適的函數可以是任何實數；分類問題配適的函數估計的是各類別的機率。

易錯提醒

判斷是迴歸還是分類，看的是**反應變數**的型態，不是解釋變數。例如用連續的年齡預測「是否出險」是分類問題；用類別變數「地區」預測理賠金額是迴歸問題。另外，logistic 迴歸名字裡有「迴歸」，但它用在分類問題（反應是二元的）。

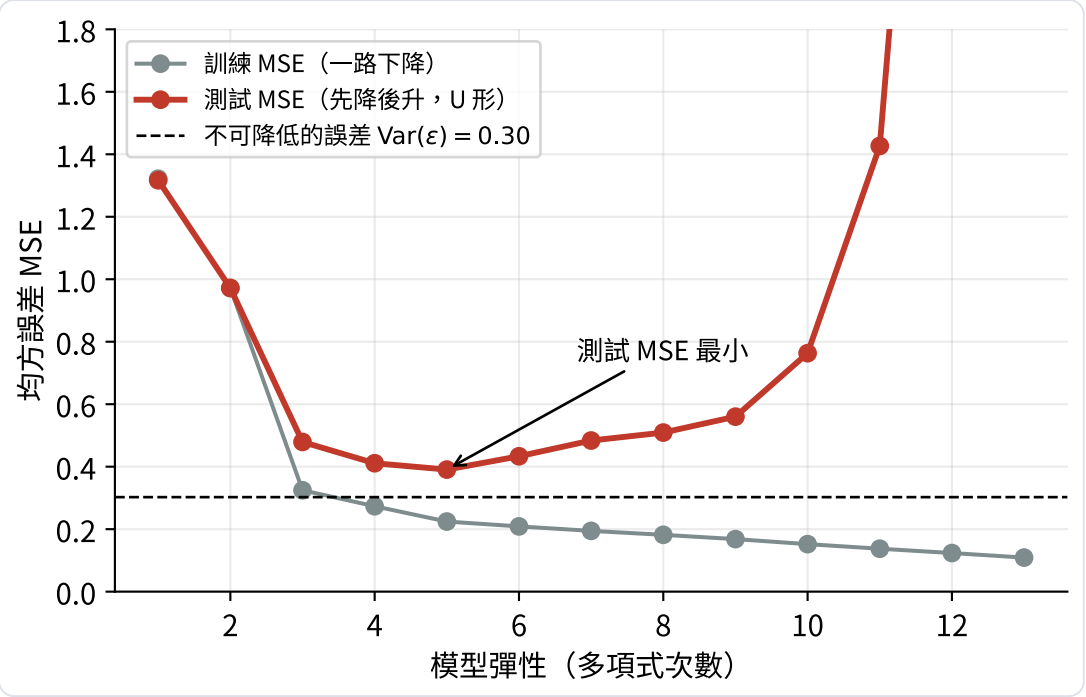
八、配適品質：訓練誤差與測試誤差

迴歸問題用**均方誤差**（mean squared error，MSE）衡量配適品質：

$$\mathrm{MSE} = \frac{1}{n}\sum_{i=1}^{n}\left(y_i - \hat{y}_i\right)^2, \qquad \hat{y}_i = \hat{f}(x_i).$$

用來估計模型的資料叫**訓練資料**（training data），沒有用來估計模型的叫**測試資料**（test data）。模型的好壞要看**測試 MSE**：在新資料上的誤差。彈性高的模型靠大量參數就能把訓練 MSE 壓得很低，但那不代表模型好。也正因如此，迴歸裡衡量訓練資料誤差的指標，分母通常比 n 小（例如第 3 章的 $s^2 = \mathrm{RSS}/(n-k-1)$），用來抵銷估計參數造成的低估。第 6 章會說明怎麼在沒有額外資料時估計測試誤差。

分類問題用**錯誤率**（error rate），也就是分錯類的比例 $\frac{1}{n}\sum I(y_i \neq \hat{y}_i)$；講義的說法是用「分對的比例」衡量，兩者互補。同樣要在測試資料上算。



用模擬資料（22 個訓練點、真實函數同上圖）重複 300 次，計算不同彈性下的平均訓練 MSE 與測試 MSE。訓練 MSE 隨彈性一路下降；測試 MSE 先降後升，呈 U 形。兩條線都不會低於虛線（不可降低的誤差 0.30）之下太多：訓練 MSE 跌破虛線，代表模型已經在記住雜訊。

九、偏差與變異數的取捨

這是本章最重要的結果。想像我們可以重複抽很多組訓練資料，每一組都估出一個 $\hat{f}$。在某個新的點 x_0，$\hat{f}(x_0)$ 會隨訓練資料而變，是一個隨機變數。

- **變異數**（variance）：$\mathrm{Var}\big(\hat{f}(x_0)\big)$，換一組訓練資料，估計值變動多大。
- **偏差**（bias）：$\mathrm{Bias}\big(\hat{f}(x_0)\big) = E\big[\hat{f}(x_0)\big] - f(x_0)$，估計值的平均和真值差多少。

推導：期望測試 MSE 的三項分解

新的觀察值 $y_0 = f(x_0) + \varepsilon_0$，其中 ε_0 和訓練資料獨立、平均 0。記 $\hat{f} = \hat{f}(x_0)$、$f = f(x_0)$、$\bar{f} = E(\hat{f})$（期望值是對「抽訓練資料」與「新的誤差」一起取）。

第一步，把 ε_0 分出來：

$$E\big[(y_0 - \hat{f})^2\big] = E\big[(f - \hat{f} + \varepsilon_0)^2\big] = E\big[(f - \hat{f})^2\big] + 2E\big[(f - \hat{f})\varepsilon_0\big] + E(\varepsilon_0^2).$$

$\hat{f}$ 只由訓練資料決定，和 ε_0 獨立，所以 $E\big[(f - \hat{f})\varepsilon_0\big] = E(f - \hat{f})\,E(\varepsilon_0) = 0$；$E(\varepsilon_0^2) = \mathrm{Var}(\varepsilon)$。

第二步，在 $f - \hat{f}$ 裡加減 $\bar{f}$：

$$E\big[(f - \hat{f})^2\big] = E\big[(f - \bar{f} + \bar{f} - \hat{f})^2\big] = (f - \bar{f})^2 + 2(f - \bar{f})\,E(\bar{f} - \hat{f}) + E\big[(\hat{f} - \bar{f})^2\big].$$

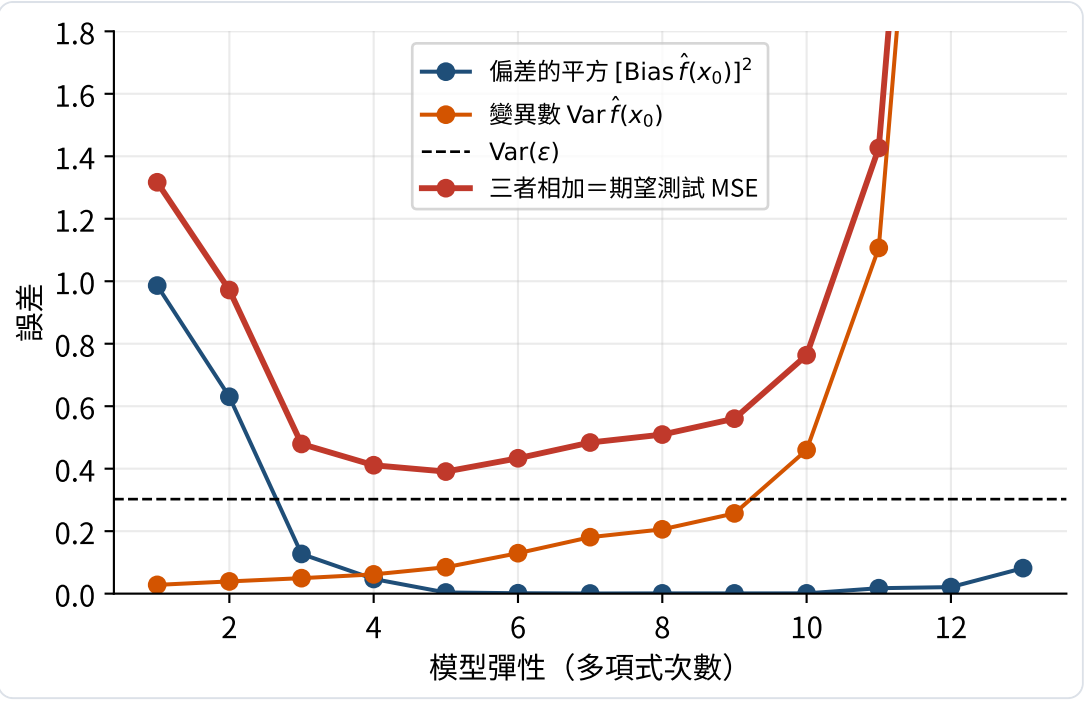
$f - \bar{f}$ 是常數，而 $E(\bar{f} - \hat{f}) = \bar{f} - \bar{f} = 0$，交叉項消失；最後一項就是 $\mathrm{Var}(\hat{f})$。合起來：

$$\boxed{E\big[(y_0 - \hat{f}(x_0))^2\big] = \mathrm{Var}\big(\hat{f}(x_0)\big) + \big[\mathrm{Bias}\big(\hat{f}(x_0)\big)\big]^2 + \mathrm{Var}(\varepsilon)}$$

把 x_0 對所有可能的測試點平均，就是整體的期望測試 MSE。

三項都不會是負的，所以期望測試 MSE 一定至少是 $\mathrm{Var}(\varepsilon)$。要讓它小，必須**同時**讓偏差與變異數都小，但兩者通常此消彼長：

- **彈性低**的方法對個別資料點不敏感，換一組資料估計值變化不大，**變異數低**；但它強加了函數形式，形式錯了就會一直偏在同一邊，**偏差高**。線性迴歸的係數在「真實關係是線性」的前提下是不偏的，但現實中的關係幾乎不可能真的是直線，所以從預測 f 的角度，線性迴歸是高偏差、低變異的方法。
- **彈性高**的方法（例如穿過每一點的樣條）幾乎沒有偏差，但只要一個點改變，整條曲線就跟著變，**變異數高**。



上一張圖的測試 MSE 拆成三塊（同一組模擬）。偏差平方隨彈性迅速下降，變異數隨彈性上升，兩者加上固定的不可降低誤差就是 U 形的測試 MSE。最低點落在「偏差已經很小、變異數還沒變大」的地方。

重點

- 期望測試 MSE = 變異數 + 偏差平方 + 不可降低的誤差。考題常把「偏差」寫成沒有平方，或把不可降低的誤差漏掉，要注意。
- 彈性增加：訓練 MSE 一定（幾乎）只降不升；偏差下降；變異數上升；測試 MSE 先降後升。
- 不可降低的誤差和模型無關，任何方法都消不掉。

考試怎麼考

典型題型是五句敘述選出對的：例如「彈性越高，訓練 MSE 越低」（對）、「彈性越高，測試 MSE 越低」（錯，是 U 形）、「非參數方法需要較多觀察值」（對）、「非監督式學習沒有反應變數」（對）、「推論時黑盒子模型沒有問題」（錯）。每一句都可以回到本節的某一小段判斷。

觀念題（6 題，仿 SOA 樣題的質性題，含跨章節）

觀念 **觀念題 C1.1-1** 仿 SOA 樣題・跨章：第 6 章・回到本節開頭

Determine which of the following statements about model flexibility is/are true.

I. As the flexibility of a fitting method increases, the training MSE generally decreases.
II. As the flexibility of a fitting method increases, the test MSE always decreases.
III. More flexible methods generally have lower bias and higher variance than less flexible methods.

(A) I and II only
(B) I and III only
(C) II and III only
(D) I, II, and III
(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

關於模型彈性，下列哪些正確？

I. 彈性越高，訓練 MSE 通常越低。
II. 彈性越高，測試 MSE 一定越低。
III. 彈性高的方法通常偏差較小、變異數較大。

答案

(B)：只有 I、III 正確

解析

I 對：彈性越高越能貼近訓練資料，訓練 MSE 一路下降（第 1 章 1.1 節的圖）。

II 錯：測試 MSE 呈 U 形，彈性過高時變異數增加的幅度超過偏差減少的幅度，測試 MSE 反而上升。第 6 章的交叉驗證就是要找 U 形的最低點。

III 對：這就是偏差與變異數的取捨。

易錯

「訓練 MSE 下降」不代表模型變好；選模型要看測試誤差或它的估計（第 6、7 章）。

觀念 **觀念題 C1.1-2** 仿 SOA 樣題・跨章：第 17,18 章・回到本節開頭

An analyst is given the following tasks:

I. Grouping policyholders into segments based on 12 rating variables, with no response variable.

II. Summarizing 10 highly correlated rating variables by a few linear combinations that capture most of their variance.

III. Predicting the number of claims of each policyholder from driver characteristics.

Determine which of the tasks are unsupervised learning problems.

(A) III only

(B) I and II only

(C) I and III only

(D) II and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

下列哪些工作屬於非監督式學習？

I. 沒有反應變數，依 12 個費率變數把保戶分群。

II. 用少數幾個線性組合概括 10 個高度相關的費率變數。

III. 由駕駛人特徵預測每位保戶的理賠件數。

答案

(B)：只有 I、II 正確

解析

非監督式學習沒有反應變數，只研究解釋變數本身的結構。

I 是群集分析（第 18 章），II 是主成分分析（第 17 章），兩者都沒有反應變數，是非監督式。

III 有明確的反應變數（理賠件數），是監督式的迴歸問題（第 13 章的計數模型）。

觀念 **觀念題 C1.1-3** 仿 SOA 樣題・跨章：第 7,10 章・回到本節開頭

Determine which of the following statements is/are true.

I. When the goal is inference, such as understanding how each rating factor relates to claim frequency, less flexible and more interpretable models are generally preferred.

II. When the goal is prediction only, a model whose form is hard to interpret can be acceptable if its test error is low.

III. For prediction, the model with the lowest training MSE should be selected.

(A) II only

(B) III only

(C) I and II only

(D) I and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

下列哪些正確？

I. 目的是推論（了解每個費率因子和理賠頻率的關係）時，通常偏好彈性較低、較好解釋的模型。

II. 只要預測時，若測試誤差低，難以解釋的模型也可以接受。

III. 做預測時，應選訓練 MSE 最低的模型。

答案

(C)：只有 I、II 正確

解析

I 對、II 對：推論需要看得懂每個變數的效果，預測只在乎新資料上的誤差，這是可解釋性與彈性的取捨。

III 錯：訓練 MSE 隨彈性一路下降，選它等於永遠選最複雜的模型，會過度配適。應該用交叉驗證（第 6 章）或 C_p、AIC、BIC、調整 R^2（第 7 章）。

觀念 **觀念題 C1.1-4** 仿 SOA 樣題 · 回到本節開頭

For a fixed point x_0, the expected test MSE can be decomposed as

$$E\big(y_0 - \hat{f}(x_0)\big)^2 = \mathrm{Var}\big(\hat{f}(x_0)\big) + \big[\mathrm{Bias}\big(\hat{f}(x_0)\big)\big]^2 + \mathrm{Var}(\varepsilon).$$

Determine which of the following statements is/are true.

I. The term $\mathrm{Var}(\varepsilon)$ can be reduced by choosing a better fitting method.

II. The expected test MSE can never be less than $\mathrm{Var}(\varepsilon)$.

III. An unbiased method always has a lower expected test MSE than a biased method.

(A) I only

(B) III only

(C) I and II only

(D) I and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

期望測試 MSE 可以拆成變異數、偏差平方與 $\mathrm{Var}(\varepsilon)$ 三項。下列哪些正確？

I. 選更好的方法可以降低 $\mathrm{Var}(\varepsilon)$。

II. 期望測試 MSE 不可能小於 $\mathrm{Var}(\varepsilon)$。

III. 不偏的方法一定比有偏的方法測試 MSE 小。

答案

(E)：只有 II 正確

解析

I 錯：$\mathrm{Var}(\varepsilon)$ 是不可降低的誤差，來自模型沒有包含的因素，任何方法都無法消除。

II 對：另外兩項都不小於 0。

III 錯：不偏的方法可能變異數很大。第 8 章的脊迴歸與 lasso 就是故意引入一點偏差，換取變異數大幅下降，使測試 MSE 變小。

觀念 **觀念題 C1.1-5** 仿 SOA 樣題・跨章：第 15 章・回到本節開頭

Determine which of the following statements about parametric and non-parametric methods is/are true.

I. Parametric methods reduce the problem of estimating f to estimating a set of parameters, after assuming a functional form for f.

II. Non-parametric methods do not make explicit assumptions about the functional form of f, but generally need many more observations to estimate f accurately.

III. K-nearest neighbors regression is a parametric method because it has a parameter K.

(A) II only

(B) III only

(C) I and III only

(D) II and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

關於參數與非參數方法，下列哪些正確？

I. 參數方法先假設 f 的形式，把估計 f 變成估計一組參數。

II. 非參數方法不明確假設 f 的形式，但通常需要多得多的觀察值。

III. K 最近鄰迴歸有一個參數 K，所以是參數方法。

答案

(E)：只有 I、II 正確

解析

I、II 對：這是 ISLR 對兩類方法的定義與代價。

III 錯：K 是調整參數（tuning parameter），決定彈性，不是描述 f 形式的參數。KNN 不假設 f 的形式，是非參數方法（第 15 章）。

易錯

「有參數」和「參數方法」是兩回事：參數方法指的是 f 的形式由有限個參數決定（例如線性迴歸的 β）。

觀念 **觀念題 C1.1-6** 仿 SOA 樣題・跨章：第 12,13 章・回到本節開頭

Determine which of the following statements is/are true.

I. Predicting whether a claim is fraudulent is a classification problem.

II. Predicting the number of claims (0, 1, 2, ...) must be treated as a classification problem because the response is discrete.

III. Logistic regression, despite its name, is typically used for classification because it estimates class probabilities.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

下列哪些正確？

I. 預測理賠是否詐欺是分類問題。

II. 理賠件數只取 0、1、2...，所以必須當成分類問題。

III. 邏輯斯迴歸雖然名為迴歸，但因為估計的是類別機率，通常用於分類。

答案

(B)：只有 I、III 正確

解析

I 對：反應是兩類（詐欺／非詐欺）。

II 錯：理賠件數是數值（計數）變數，2 件確實是 1 件的兩倍，通常用卜瓦松等計數迴歸處理（第 13 章），不是分類。

III 對：邏輯斯迴歸估計 $P(Y = 1 \mid x)$，再依門檻分類（第 12 章）。

1.2 變數的種類

變數的型態決定能用哪些模型與圖。講義的分類如下。

一、數值變數與類別變數

- **數值變數**（quantitative variable）：取值是有意義的數字，可以加減、比大小。又分**連續**（continuous，例如理賠金額、年齡）與**離散**（discrete，例如理賠件數 0、1、2、…）。
- **類別變數**（categorical variable，又稱 qualitative variable、factor）：取值是若干類別。只有兩類的叫**二元**（binary）變數，例如有沒有律師代理；類別之間有自然順序的叫**次序**（ordinal）變數，例如傷勢等級輕／中／重；沒有順序的叫**名目**（nominal）變數，例如地區、傷害代碼。

判斷的關鍵不是「看起來是不是數字」，而是「數字本身有沒有數量上的意義」。傷害代碼 101、205、310 雖然是數字，但 310 不代表比 101「多」，所以是類別變數。理賠件數雖然只取整數，但 2 件確實是 1 件的兩倍，所以是（離散的）數值變數。

二、類別變數在模型裡怎麼用

迴歸模型裡，類別變數要先轉成**指標變數**（indicator，又稱虛擬變數 dummy variable）：一個有 c 類的變數，在有截距的模型中用 $c-1$ 個 0／1 變數表示，剩下那一類是**基準類別**（reference level）。詳細的寫法與係數解讀在第 2 章 2.3 節。

> **易錯提醒**
>
> 「理賠件數」是數值（計數）變數，不是類別變數；「理賠延遲時間」是連續的數值變數。章末第 1.1 題就是考這個區分。

這一節的精選習題

★ 精選 **第 1.1 題** ・講義 p.7・回到對應概念

Which of the following are categorical variables?

1. Legal representation
2. Settlement delay
3. Injury code
4. Claim count
5. Claim size

中文題意

下列哪些是類別變數？

1. 是否有律師代理（legal representation）
2. 理賠延遲時間（settlement delay）
3. 傷害代碼（injury code）
4. 理賠件數（claim count）
5. 理賠金額（claim size）

答案

1 與 3。

解析

逐項看「取值有沒有數量上的意義」：

1. **是否有律師代理**只有「有／沒有」兩種值，是二元的類別變數。
2. **理賠延遲時間**是一段時間長度，可以是任何正數，是連續的數值變數。
3. **傷害代碼**即使寫成數字，代碼之間也沒有大小或距離的意義（代碼 310 不比 101「多」），是名目的類別變數。
4. **理賠件數**取 0、1、2、…，雖然是離散的，但 2 件確實是 1 件的兩倍，可以相加平均，是離散的數值（計數）變數。
5. **理賠金額**是連續的數值變數。

> **易錯**
>
> 不要因為「只取整數」就判成類別變數。計數資料在第 13 章會用 Poisson 等計數模型處理，正是因為它是數值。

觀念題（5 題，仿 SOA 樣題的質性題，含跨章節）

觀念 **觀念題 C1.2-1** 仿 SOA 樣題・跨章：第 2 章・回到本節開頭

Determine which of the following variables are categorical variables.

I. Injury code (101, 205, 310, ...)

II. Number of claims in a year

III. Severity of injury: mild, moderate, severe

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

下列哪些是類別變數？

I. 傷害代碼（101、205、310...）。

II. 一年的理賠件數。

III. 傷勢：輕、中、重。

答案

(B)：只有 I、III 正確

解析

I 是類別（名目）變數：代碼的數字沒有數量意義。

II 是離散的數值變數。

III 是類別（次序）變數：有自然順序，但「重」不是「輕」的某個倍數。

易錯

判斷的關鍵是數字有沒有數量上的意義，不是看起來是不是數字。

觀念 **觀念題 C1.2-2** 仿 SOA 樣題・跨章：第 2 章・回到本節開頭

A linear regression with an intercept includes a categorical variable "territory" with 5 levels. Determine which of the following statements is/are true.

I. Territory should be represented by 5 indicator variables.

II. The coefficient of the indicator for a territory measures the difference in expected response between that territory and the base territory, holding other variables constant.

III. Changing the base territory changes the fitted values of the model.

(A) I only

(B) II only

(C) III only

(D) I and II only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

有截距的線性迴歸含一個有 5 個水準的類別變數「地區」。下列哪些正確？

I. 地區應該用 5 個指標變數表示。

II. 某地區指標的係數，是在其他變數固定下，該地區和基準地區期望反應的差。

III. 換基準地區會改變模型的配適值。

答案

(B)：只有 II 正確

解析

I 錯：有截距時只能用 $5-1=4$ 個指標，放 5 個會和截距完全共線，$X'X$ 不可逆（第 2 章 2.2 節）。

II 對：這是指標係數的解讀。

III 錯：換基準類別只是換參數化方式，欄位空間不變，配適值與殘差完全相同，改變的是截距與指標係數（第 2 章習題 2.26、2.28）。

觀念 **觀念題 C1.2-3** 仿 SOA 樣題・跨章：第 7 章・回到本節開頭

Determine which of the following statements is/are true.

I. In subset selection, the indicator variables of a categorical variable with more than two levels may enter the model one at a time, so the final model may include only some of the levels.

II. An ordinal variable such as injury severity (mild, moderate, severe) can only be modeled with indicator variables.

III. A binary variable needs only one indicator variable in a model with an intercept.

(A) II only

(B) III only

(C) I and II only

(D) I and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

下列哪些正確？

I. 子集選擇時，多類別變數的指標可以一個一個進入模型，最後的模型可能只包含部分類別。

II. 次序變數（輕、中、重）只能用指標變數表示。

III. 有截距時，二元變數只需要一個指標變數。

答案

(D)：只有 I、III 正確

解析

I 對：逐步法一次加減一個參數，沒進模型的類別等於併入基準類別（第 7 章 7.1 節）。

II 錯：次序變數也可以用一個數值分數（例如 1、2、3）放進模型，這假設相鄰等級的效果差相同；用指標變數則不做這個假設，但多用參數。兩種都可以，是建模選擇。

III 對：2 類需要 $2 - 1 = 1$ 個指標。

觀念 **觀念題 C1.2-4** 仿 SOA 樣題・跨章：第 2 章・回到本節開頭

A regression model for claim severity includes driver age (continuous) and gender (binary) as well as an interaction between them. Determine which of the following statements is/are true.

I. The model allows the slope with respect to age to differ between genders.

II. The interaction term adds one parameter to the model.

III. Without the interaction term, the model forces the lines for the two genders to be parallel.

(A) III only

(B) I and II only

(C) I and III only

(D) II and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

理賠金額模型含駕駛人年齡（連續）、性別（二元）以及兩者的交互作用。下列哪些正確？

I. 模型允許兩性對年齡的斜率不同。

II. 交互作用項多一個參數。

III. 沒有交互作用項時，兩性的直線必須平行。

答案

(E)：I、II、III 都正確

解析

模型 $y = \beta_0 + \beta_1 \text{age} + \beta_2 g + \beta_3 \,\text{age} \cdot g$。$g = 0$ 的斜率是 β_1，$g = 1$ 的斜率是 $\beta_1 + \beta_3$，所以 I 對；交互作用只有 β_3 一個參數，II 對；拿掉 β_3 後兩條線斜率都是 β_1，只差截距 β_2，III 對（第 2 章 2.3 節）。

觀念 **觀念題 C1.2-5** 仿 SOA 樣題・跨章：第 11,13 章・回到本節開頭

Determine which of the following statements is/are true.

I. A claim count response variable is a quantitative variable.

II. The amount of time between the reporting and the settlement of a claim is a continuous variable.

III. Because claim counts are non-negative integers, a normal linear model can never be used for them.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

下列哪些正確？

I. 理賠件數是數值變數。

II. 從報案到結案的時間是連續變數。

III. 理賠件數是非負整數，所以絕對不能用常態線性模型。

答案

(A)：只有 I、II 正確

解析

I、II 對（第 1.1 題的分類）。

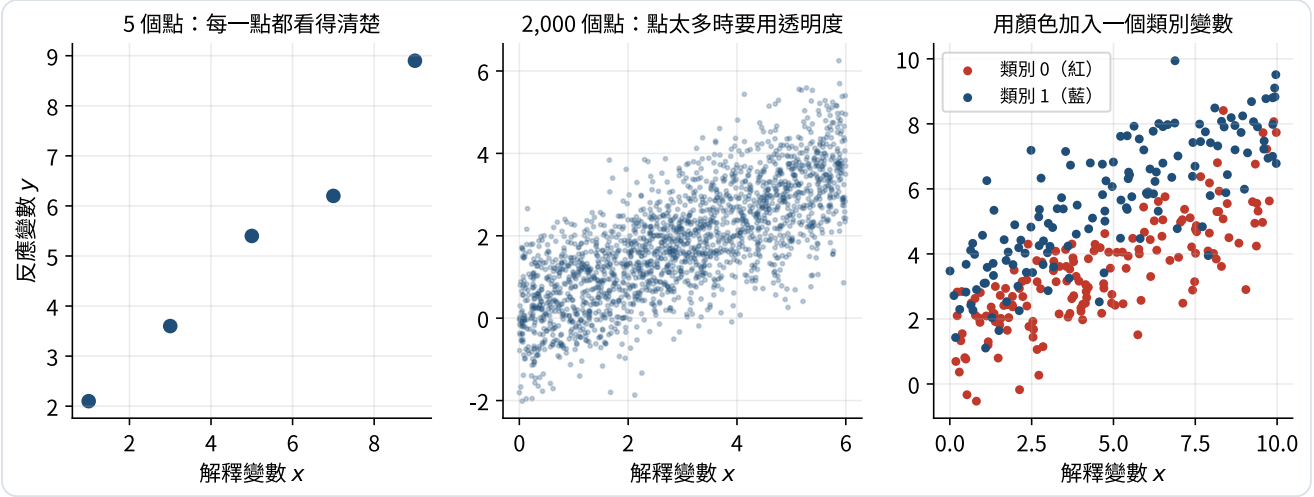
III 錯：「絕對不能」太強。常態線性模型可以用，只是假設不太適合（變異數通常隨平均增加、預測值可能為負），所以較好的選擇是卜瓦松等廣義線性模型（第 11、13 章）。

1.3 圖形

建模前先畫圖，看變數之間大致的關係、分配的形狀與有沒有異常值。講義介紹三種圖。

一、散布圖

散布圖（scatter plot）把每一筆觀察畫成平面上的一點，橫軸是解釋變數、縱軸是反應變數，用來看兩個數值變數的關係：是否大致成直線、往上還是往下、有沒有彎曲、有沒有離群的點。點很多時（例如 2,000 個），點會疊在一起，要用透明度或較小的點才看得出密度。若還有一個類別變數，可以用顏色區分：如果紅點集中在下方、藍點集中在上方，表示「藍色」那一類的反應值傾向較高；如果兩種顏色均勻混在一起，表示這個類別變數和反應關係不大。



散布圖的三種情況（仿講義圖 1.1、1.2）。左：點少時每一點都清楚。中：2,000 個點要用半透明才看得出哪裡密集。右：用顏色加入一個類別變數，藍點整體高於紅點，表示類別 1 的反應值較高。

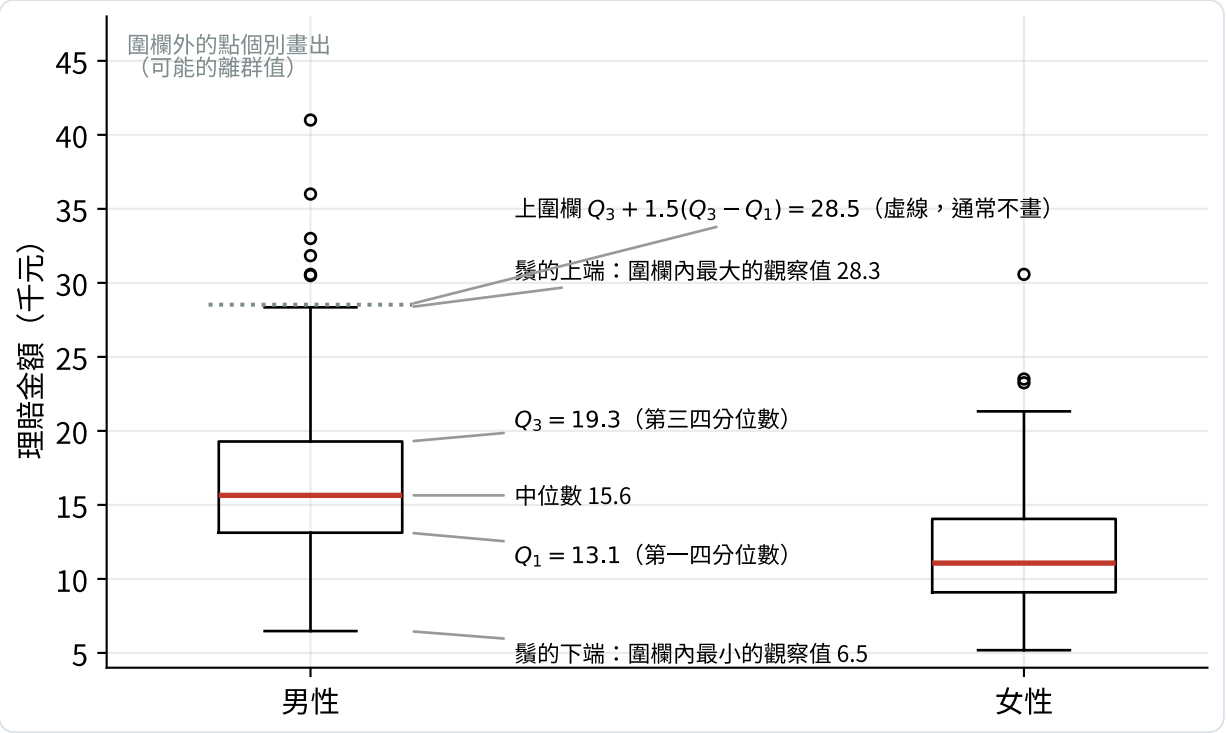
二、箱形圖

用一個類別變數解釋一個連續變數時，可以每一類各畫一個**箱形圖**（box plot）：

- 箱子中間的粗線是**中位數**；箱子下緣是**第一四分位數** Q_1，上緣是**第三四分位數** Q_3。箱子的高度 $Q_3 - Q_1$ 叫**四分位距**（interquartile range，IQR）。
- 箱子上下各有一條線，叫**圍欄**（fence）。讀本採用 Tukey 的定義：令 $h = 1.5(Q_3 - Q_1)$，下圍欄在 $Q_1 - h$，上圍欄在 $Q_3 + h$。
- 從箱子延伸出去的虛線（**鬚**，whisker）畫到圍欄**以內**最遠的觀察值，這些最靠近圍欄的點叫**相鄰點**（adjacent point）。

- 在圍欄以外的觀察值個別畫成點，稱為**可能的離群值**（potential outlier）。

不同軟體、不同作者放圍欄的位置不一樣；用 Tukey 方法時，上下圍欄和箱子的距離相等（都是 $1.5\times$IQR），但鬚的長度不一定相等，因為鬚只畫到實際存在的觀察值。



男女理賠金額的箱形圖（模擬資料，Tukey 圍欄）。男性的中位數線偏向箱子下方、上方的鬚與離群值比較長，表示分配右偏（大額理賠拉出長長的右尾）。女性的理賠整體較低。

從箱形圖讀分配形狀：中位數線若在箱子中央以下、上方的鬚比下方長，表示分配**右偏**（往高值延伸），理賠金額通常就是這樣。

例題（講義第 1.2 題的算法）

樣本 $\{1, 3, 7, 13, 25, 58, 99\}$，用 Tukey 方法求下圍欄。

講義對 7 個點取 $Q_1 = 3$（第 2 個觀察值）、$Q_3 = 58$（第 6 個觀察值）。$h = 1.5(58 - 3) = 82.5$，下圍欄 $= 3 - 82.5 = -79.5$，上圍欄 $= 58 + 82.5 = 140.5$。所有觀察值都在圍欄內，所以沒有離群值；下方的鬚畫到最小值 1，上方的鬚畫到最大值 99。

易錯提醒

四分位數有很多種算法（是否內插、用 $(n+1)p$ 還是 np 定位）。講義這一題對 7 個點取第 2 與第 6 個觀察值，相當於用 $(n+1)p$ 定位：$8\times 0.25=2$、$8\times 0.75=6$。考試若給的是不同的定義，照題目的定義算。

三、分位數圖（qq 圖）

$100q$ **百分位數**又稱 q **分位數**，例如第 40 百分位數是 0.4 分位數。**qq 圖**（quantile–quantile plot）把兩個分配的分位數兩兩配對畫在平面上，用來檢查資料是否來自某個分配。

步驟如下：

1. 把 n 個觀察值由小到大排序，得到順序統計量 $y_{(1)}\le y_{(2)}\le\cdots\le y_{(n)}$。
2. 給第 j 個順序統計量一個機率位置。講義用 $q_j=\dfrac{j}{n+1}$（其他書也有 $\frac{j-0.5}{n}$ 等寫法）。
3. 求配適分配在 q_j 的分位數 $\hat F^{-1}(q_j)$。
4. 畫點 $\left(\hat F^{-1}(q_j),\ y_{(j)}\right)$：橫軸是配適分配的分位數，縱軸是觀察值。

推導：指數分配的分位數

指數分配 $F(x)=1-e^{-x/\theta}$。設 $F(x)=q$ 解 x：

$$1-e^{-x/\theta}=q\ \Rightarrow\ e^{-x/\theta}=1-q\ \Rightarrow\ -\frac{x}{\theta}=\ln(1-q)\ \Rightarrow\ x=-\theta\ln(1-q).$$

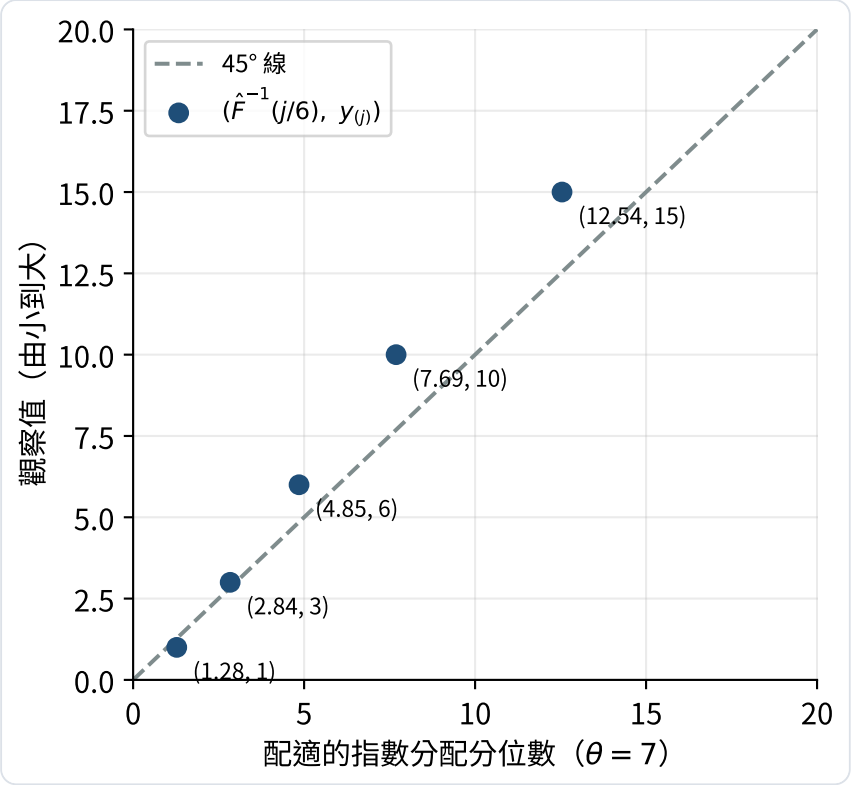
指數分配的最大概似估計是 $\hat\theta=\bar x$（因為對數概似 $-n\ln\theta-\sum x_i/\theta$ 對 θ 微分得 $-n/\theta+\sum x_i/\theta^2=0$）。

例題（講義圖 1.4）

觀察值 1、3、6、10、15 配適指數分配。$\hat{\theta} = \bar{x} = 35/5 = 7$，$n = 5$，機率位置是 $1/6, 2/6, \ldots, 5/6$。

j	$y_{(j)}$	$q_j = j/6$	$\hat{F}^{-1}(q_j) = -7\ln(1-q_j)$
1	1	0.1667	$-7\ln(5/6) = 1.276$
2	3	0.3333	$-7\ln(4/6) = 2.838$
3	6	0.5	$-7\ln(3/6) = 4.852$
4	10	0.6667	$-7\ln(2/6) = 7.690$
5	15	0.8333	$-7\ln(1/6) = 12.542$

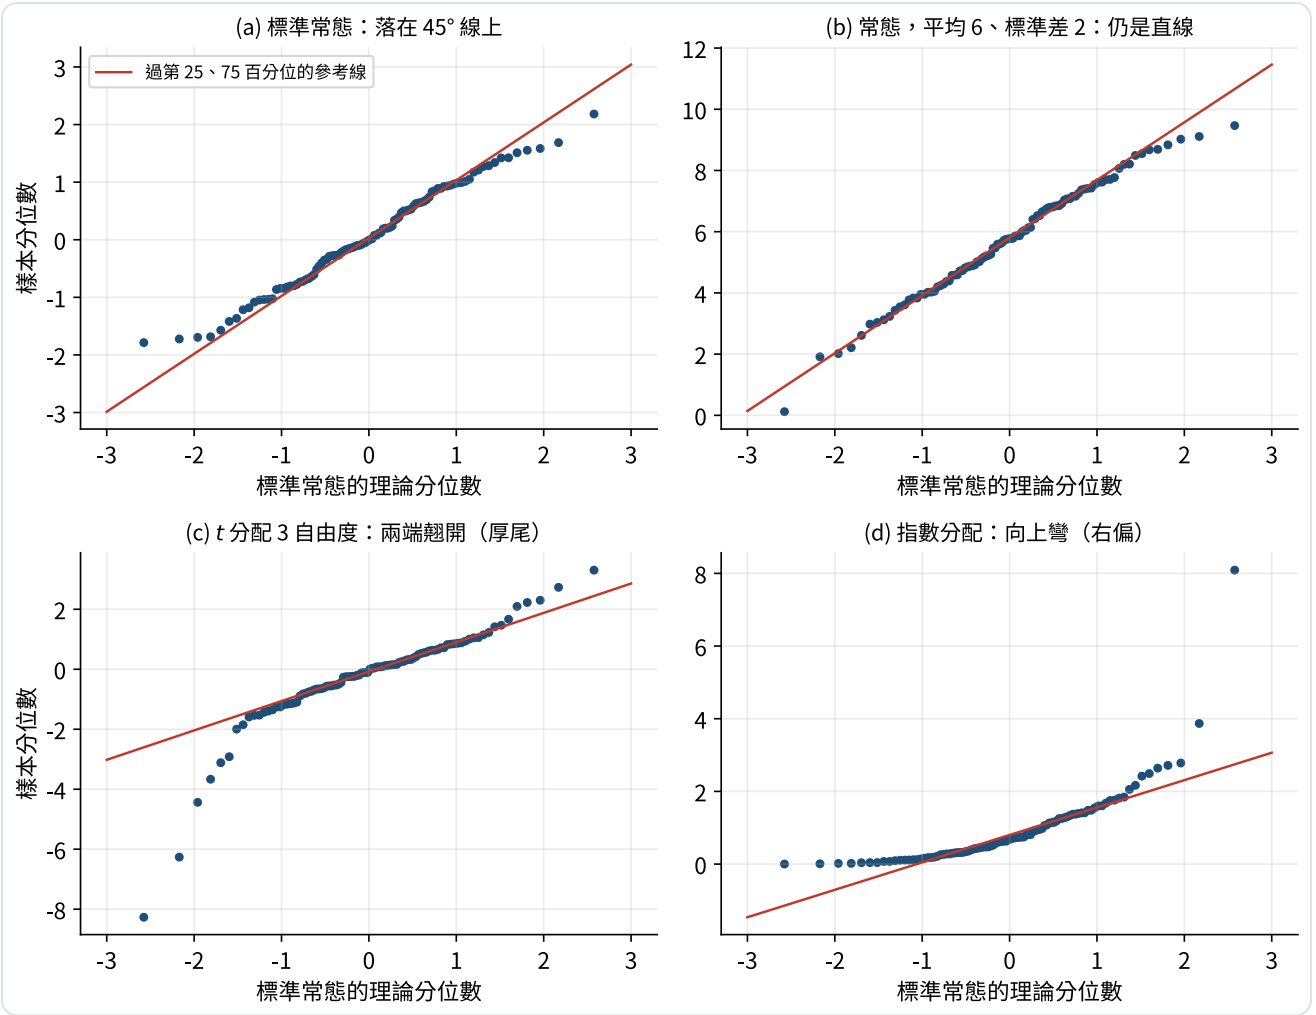
畫出 $(1.276, 1)$、$(2.838, 3)$、$(4.852, 6)$、$(7.690, 10)$、$(12.542, 15)$。



講義圖 1.4 的重畫：觀察值 1、3、6、10、15 對指數分配（$\theta = 7$）的 qq 圖。前四點大致在一條直線上，最後一點（15）偏離較多。

怎麼讀 qq 圖：

- 若配適的是**完全指定**的分配（參數都給定），點落在 **45° 線**附近就是配適得好。
- 更常見的用法是檢查資料是否屬於某個**分配族**。這時只要點落在**一條直線**上就夠了，不必是 45° 線：若點落在 $y = a + bx$ 上，表示資料像是 $F\big((x-a)/b\big)$，也就是同一族、但位置與尺度不同的分配。所以 qq 圖可以在不知道參數的情況下判斷分配族選得對不對。參考線通常畫過兩邊的第 25 與第 75 百分位數。
- 最常見的 qq 圖是**常態機率圖**（normal probability plot）：橫軸用標準常態的分位數。



講義圖 1.5 的重畫：100 個模擬值對標準常態的 qq 圖。(a) 資料本身是標準常態，點在 45° 線上。(b) 資料是平均 6、標準差 2 的常態，點仍成一直線，只是截距與斜率改變（截距約 6、斜率約 2）。(c) t 分配（3 自由度）中段和常態相近，但兩端的分位數比常態更極端，左端往下、右端往上翹，是厚尾的特徵。(d) 指數分配右偏：低分位數擠在 0 附近，高分位數拉得很長，點呈向上彎的曲線。

重點：qq 圖的形狀對照

- 一直線：分配族選對了（斜率、截距反映尺度與位置）。
- 兩端外翹（左端低於參考線、右端高於參考線）：資料的尾巴比假設的分配厚，例如 t 分配。
- 向上彎（凸）：資料右偏，例如指數、對數常態、Gamma。向下彎（凹）則是左偏。

這一節的精選習題

★ 精選 **第 1.2 題** ・講義 p.7・回到對應概念

A sample consists of the numbers $\{1, 3, 7, 13, 25, 58, 99\}$.

Determine the lower fence of a box plot using Tukey's method.

中文題意

樣本為 $\{1, 3, 7, 13, 25, 58, 99\}$。用 Tukey 的方法，求箱形圖的下圍欄。

答案

-79.5

解析

第一步：找四分位數。 7 個觀察值已排序。講義取第一四分位數為第 2 個觀察值、第三四分位數為第 6 個觀察值（以 $(n+1)p$ 定位：$8 \times 0.25 = 2$，$8 \times 0.75 = 6$），所以 $Q_1 = 3$、$Q_3 = 58$。

第二步：算圍欄寬度。 $h = 1.5(Q_3 - Q_1) = 1.5 \times (58 - 3) = 82.5$。

第三步：下圍欄。 $Q_1 - h = 3 - 82.5 = -79.5$。

順便可得上圍欄 $Q_3 + h = 58 + 82.5 = 140.5$。所有觀察值都在 $[-79.5,\ 140.5]$ 之內，所以這個樣本沒有可能的離群值；下方的鬚畫到 1，上方的鬚畫到 99。

易錯

圍欄是用來判斷離群值的界線，不一定是某個觀察值；鬚才是畫到圍欄內最遠的觀察值。另外 h 要乘 1.5，不是 IQR 本身。

觀念題（5 題，仿 SOA 樣題的質性題，含跨章節）

觀念 **觀念題 C1.3-1** 仿 SOA 樣題・跨章：第 5 章・回到本節開頭

A normal probability plot (normal qq plot) of standardized residuals is examined. Determine which of the following statements is/are true.

I. If the points lie close to a straight line, the normality assumption appears reasonable.

II. If the points at the upper right lie well above the line, the residual distribution has a heavier right tail than the normal distribution.

III. A qq plot can be used to detect serial correlation in the residuals.

(A) III only

(B) I and II only

(C) I and III only

(D) II and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

檢查標準化殘差的常態機率圖。下列哪些正確？

I. 點接近一直線時，常態假設看起來合理。

II. 右上方的點明顯在線的上方，表示右尾比常態長。

III. qq 圖可以用來偵測殘差的序列相關。

答案

(B)：只有 I、II 正確

解析

I、II 對：「哪一端離開直線往外跑，哪一邊的尾巴就比常態長」（第 5 章 5.1 節）。

III 錯：qq 圖把殘差排序後畫，原本的順序資訊不見了；序列相關要把殘差依時間順序畫（第 5 章習題 5.17）。

觀念 **觀念題 C1.3-2** 仿 SOA 樣題・回到本節開頭

For a box plot constructed with Tukey's method, determine which of the following statements is/are true.

I. The upper and lower fences are at the same distance from the box.

II. The upper and lower whiskers always have the same length.

III. Observations beyond the fences are plotted individually as potential outliers.

(A) III only

(B) I and II only

(C) I and III only

(D) II and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

用 Tukey 方法畫的箱形圖，下列哪些正確？

I. 上下圍欄和箱子的距離相同。

II. 上下鬚的長度一定相同。

III. 圍欄外的觀察值個別畫成點，視為可能的離群值。

答案

(C)：只有 I、III 正確

解析

I 對：兩個圍欄都離箱子 $1.5\times$IQR。

II 錯：鬚只畫到圍欄**以內最遠的實際觀察值**，兩側的資料不同，長度通常不同。

III 對。

觀念 **觀念題 C1.3-3** 仿 SOA 樣題・回到本節開頭

A box plot of claim sizes shows the median line close to the bottom of the box, a long upper whisker, and several points above the upper fence. Determine which of the following statements is/are true.

I. The distribution of claim sizes appears to be skewed to the right.

II. The mean claim size is likely to be greater than the median.

III. The points above the upper fence must be data errors and should be removed.

(A) I only

(B) II only

(C) III only

(D) I and II only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

理賠金額的箱形圖：中位數線靠近箱子底部、上方的鬚很長，上圍欄以上還有幾個點。下列哪些正確？

I. 分配看起來右偏。

II. 平均數可能大於中位數。

III. 上圍欄以上的點一定是資料錯誤，應該刪除。

答案

(D)：只有 I、II 正確

解析

I、II 對：右偏分配被大額理賠拉出長右尾，平均數被拉高。

III 錯：圍欄外只是「可能的」離群值。理賠金額本來就常有真實的大額案件，應該先查證，不能直接刪除（第 5 章 5.2 節對離群值的處理方式）。

觀念 **觀念題 C1.3-4** 仿 SOA 樣題・跨章：第 5 章・回到本節開頭

Determine which of the following statements is/are true.

I. A scatter plot of the response against an explanatory variable can reveal a nonlinear relationship.

II. A plot of residuals against fitted values showing a funnel shape indicates heteroscedasticity.

III. In a qq plot comparing data to a fitted normal distribution with a different mean and variance than the standard normal, the points will not lie on a straight line even if the data are normal.

(A) II only

(B) III only

(C) I and III only

(D) II and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

下列哪些正確？

I. 反應對解釋變數的散布圖可以看出非線性關係。

II. 殘差對配適值呈漏斗形，表示異質變異。

III. 資料是常態但平均與變異數不同於標準常態時，對標準常態的 qq 圖不會是直線。

答案

(E)：只有 I、II 正確

解析

I 對。II 對（第 5 章 5.1 節）。

III 錯：常態資料對標準常態畫 qq 圖仍是直線，只是截距等於平均、斜率等於標準差（第 1 章圖 1.5(b)）。不是直線才表示分配族不對。

觀念 **觀念題 C1.3-5** 仿 SOA 樣題・跨章：第 5 章・回到本節開頭

You are comparing the distributions of a continuous response across the levels of a categorical explanatory variable. Determine which of the following statements is/are true.

I. Side-by-side box plots, one for each level, are an appropriate graphical display.

II. A scatter plot with many observations may hide the density of points unless transparency or smaller symbols are used.

III. Differences in the spread of the box plots across levels may suggest that the variance of the response is not constant.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

比較一個連續反應在類別變數各水準下的分配。下列哪些正確？

I. 每個水準各畫一個並排的箱形圖是適當的圖。

II. 觀察值很多時，散布圖若不用透明度或小點，看不出點的密度。

III. 各水準箱形圖的寬度差很多，可能表示反應的變異數不固定。

答案

(D)：I、II、III 都正確

解析

I、II 對（第 1 章 1.3 節）。III 對：箱子高度（IQR）反映分散程度，各類差很多就是異質變異的徵兆，可能需要轉換或加權最小平方（第 2 章 2.3 節、第 5 章 5.1 節）。

章末其餘習題（0 題，★ 精選題已放在各節後面）