SRM · 第 1 章

統計學習的基本問題

先弄清楚要回答的是哪一種問題（預測還是推論、迴歸還是分類），再用測試資料上的誤差判斷模型好不好。這一章推導全書最重要的一條式子：期望測試誤差 = 偏差平方 + 變異數 + 不可降低的誤差。

本章內容

1. 1.1 統計學習在做什麼
2. 1.2 變數的種類
3. 1.3 圖形

本章對應講義第 1 課（Basics of Statistical Learning），讀本是 Frees《Regression Modeling with Actuarial and Financial Applications》1.2 節與 James 等人《An Introduction to Statistical Learning》（以下簡稱 ISLR）2.1～2.2.2 節。考試出現的形式多半是觀念判斷題（哪一句話是對的）與箱形圖、分位數圖的簡單計算。

1.1 統計學習在做什麼

一、模型的基本形式

統計學習（statistical learning）是用過去的資料，找出一個變數如何依賴其他變數，或找出資料本身的結構。以保險為例：保險公司想依被保險人的年齡、性別、收入、信用評分、過去理賠紀錄等特徵，估計他的理賠成本。若 Y 代表理賠成本、$X_1, X_2, \ldots, X_p$ 代表這些特徵，我們想找一個函數 f 使得

$$Y = f(X_1, X_2, \ldots, X_p) + \varepsilon.$$

這裡 ε 是**誤差項**（error term）。沒有任何函數能完美描述 Y：兩個特徵完全相同的人，理賠金額仍然不同，因為有些影響因素沒有被量測，或本身就是隨機的。通常假設 $E(\varepsilon) = 0$，而且 ε 和 X 無關，所以 $f(X)$ 就是給定 X 時 Y 的條件平均 $E(Y \mid X)$。

名詞對照：X_j 稱為**解釋變數**（explanatory variable）、**自變數**（independent variable）、**預測變數**（predictor）或**特徵**（feature；講義說「特徵」通常指只有有限幾個可能值的離散變數）。Y 稱為**應變數**（dependent variable）或**反應變數**（response）。

二、可降低的誤差與不可降低的誤差

我們手上只有估計出來的 $\hat{f}$，用它預測得到 $\hat{Y} = \hat{f}(X)$。把 X 固定在某個值，預測誤差的期望平方可以拆成兩塊：

推導：預測誤差的兩個來源

固定 $X = x$，把 $\hat{f}$ 也當成已知（先不考慮重抽資料造成的變化）。因為 $Y = f(x) + \varepsilon$：

$$E\big[(Y - \hat{Y})^2\big] = E\big[(f(x) + \varepsilon - \hat{f}(x))^2\big] = E\big[(f(x) - \hat{f}(x))^2 + 2(f(x) - \hat{f}(x))\varepsilon + \varepsilon^2\big].$$

$f(x) - \hat{f}(x)$ 是固定的數，$E(\varepsilon) = 0$，所以中間的交叉項期望值為 0；$E(\varepsilon^2) = \mathrm{Var}(\varepsilon)$。因此

$$E\big[(Y - \hat{Y})^2\big] = \underbrace{\big[f(x) - \hat{f}(x)\big]^2}_{\text{可降低的誤差}} + \underbrace{\mathrm{Var}(\varepsilon)}_{\text{不可降低的誤差}}.$$

第一塊是 $\hat{f}$ 和真正的 f 差多遠，選更好的方法、蒐集更多資料可以讓它變小，所以叫**可降低的誤差**（reducible error）。第二塊來自 ε 本身，即使知道真正的 f 也消不掉，叫**不可降低的誤差**（irreducible error）。所以任何模型在新資料上的均方誤差，都不可能低於 $\mathrm{Var}(\varepsilon)$。

三、預測與推論

統計學習有兩個用途：

- **預測**（prediction）：給定一組 X（可能是過去沒看過的值），猜 Y 會是多少。這時只在乎 $\hat{Y}$ 準不準，$\hat{f}$ 長什麼樣子可以是黑盒子。通常我們無法控制 X，例如預測新保單的理賠成本。
- **推論**（inference）：想了解每個 X_j 怎麼影響 Y：哪些變數有關、影響是正是負、大小多少、關係是不是線性。這時 $\hat{f}$ 必須看得懂。若 X 是可以控制的（例如各種廣告支出），了解影響之後就能調整策略，例如改變廣告組合來提高銷售。

同一份資料可以兩種目的都有，但目的不同，選模型的標準也不同（見下面第五小節）。

四、參數方法與非參數方法

估計 f 有兩大類做法：

- **參數方法**（parametric method）：先假設 f 的函數形式，再用資料估計其中的參數。例如假設 $f(X) = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p$，問題就從「估計整個函數」

縮小成「估計 $p+1$ 個係數」。估好之後，描述這條關係只需要那幾個係數，原始資料可以丟掉。缺點是假設的形式可能錯：真正的 f 若是彎的，直線再怎麼估也貼不上。

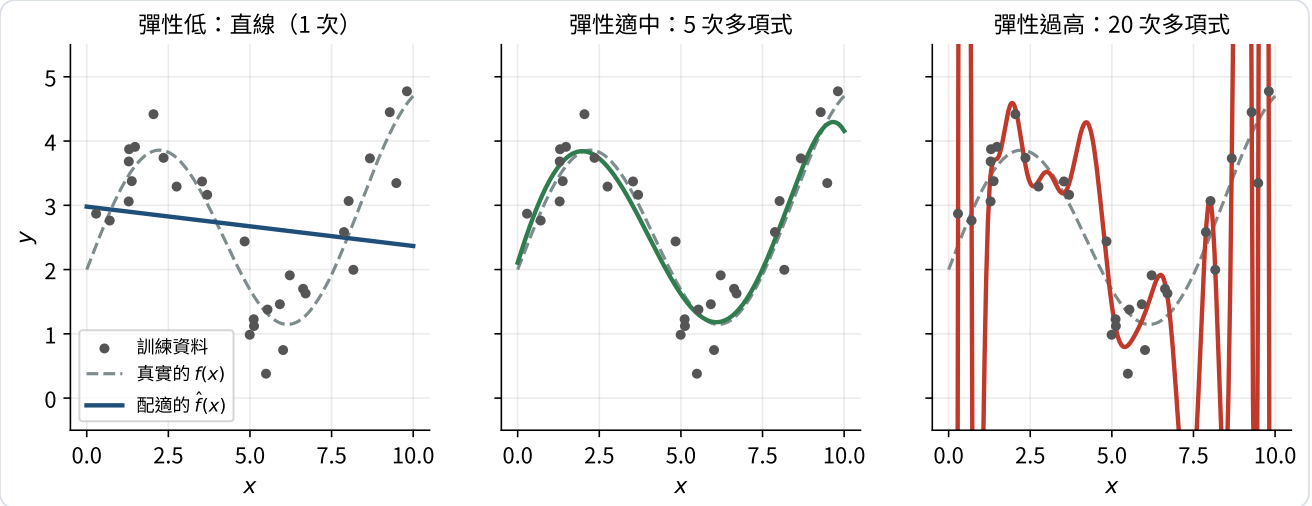
- **非參數方法**（non-parametric method）：不事先假設簡單的形式，只要求 $\hat{f}$ 盡量靠近資料點、又不要太扭曲。例子是**樣條**（spline）：三次樣條用分段的三次多項式把點接起來，接點處曲率連續（樣條不在考試範圍）。非參數方法描述關係時需要全部的資料；缺點是需要大量觀察值才估得準。

本書的 KNN（第 15 章）與決策樹（第 16 章）是非參數方法；線性迴歸與廣義線性模型是參數方法。

五、彈性與可解釋性的取捨

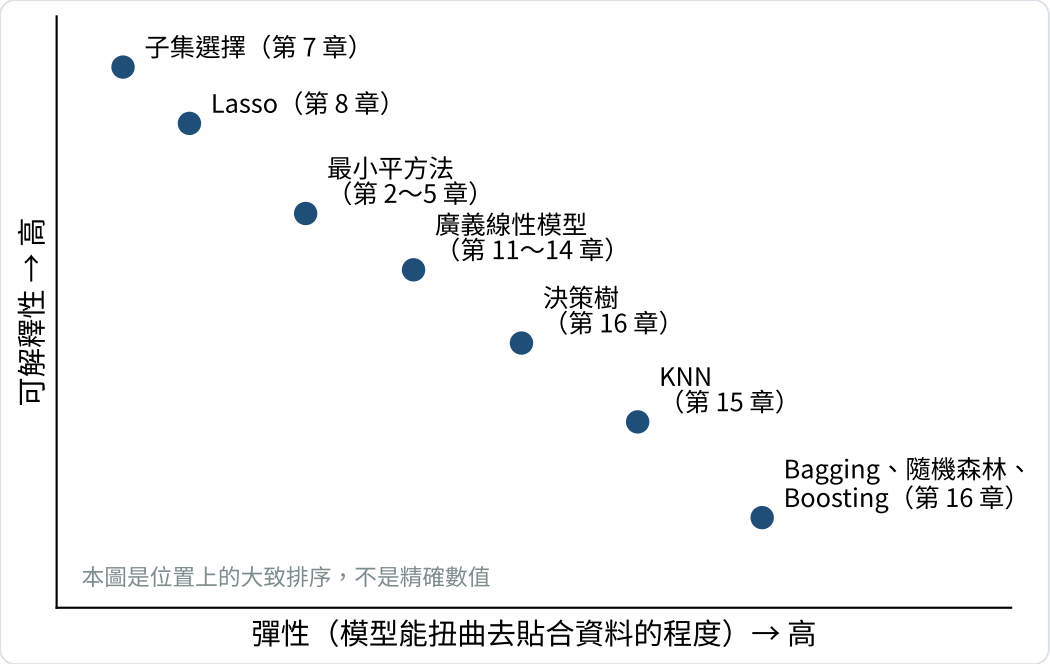
彈性高（flexible）的方法會為了貼近每一個觀察值而扭曲；**彈性低**的方法不會。直覺上彈性越高越好，但有兩個問題：

1. **貼得近不代表預測得準**。例如有 10 個觀察值，用 9 次多項式可以穿過每一個點，訓練資料上誤差為 0，但在其他 x 的預測會非常差。下圖用同一組 30 個點配適三種彈性的模型：



同一組模擬資料（灰點）配適三種彈性的模型。虛線是產生資料的真實函數。直線（左）太僵硬，抓不到彎曲；5 次多項式（中）和真實函數很接近；20 次多項式（右）為了穿過每一個點而劇烈擺動，換一組資料就完全不同。

2. **越有彈性越難解釋**。線性迴歸彈性低，但每個係數的意思一目了然；彈性高的方法往往是黑盒子。若目的是預測，看不懂沒關係；若目的是推論，就是很大的缺點。



本書各方法在「彈性」與「可解釋性」上的大致位置（仿 ISLR 圖 2.7）。越往右越能貼合複雜的形狀，但越難說明每個變數的作用。

六、監督式與非監督式學習

- **監督式學習**（supervised learning）：每筆資料都有反應變數 Y，目標是用 X 解釋或預測 Y。因為有正確答案可以對照，可以算出模型錯了多少。
- **非監督式學習**（unsupervised learning）：沒有反應變數，只是找觀察值之間的關係或資料裡的結構，例如主成分分析（第 17 章）與群集分析（第 18 章）。因為沒有正確答案，很難衡量做得好不好，所以比監督式學習困難。

七、迴歸問題與分類問題

反應變數是連續的數值，稱為**迴歸問題**（regression problem）；反應變數只有少數幾個可能值，稱為**分類問題**（classification problem），而且那些值不一定是數字，例如藥物「有效／無效」。迴歸問題配適的函數可以是任何實數；分類問題配適的函數估計的是各類別的機率。

易錯提醒

判斷是迴歸還是分類，看的是**反應變數**的型態，不是解釋變數。例如用連續的年齡預測「是否出險」是分類問題；用類別變數「地區」預測理賠金額是迴歸問題。另外，logistic 迴歸名字裡有「迴歸」，但它用在分類問題（反應是二元的）。

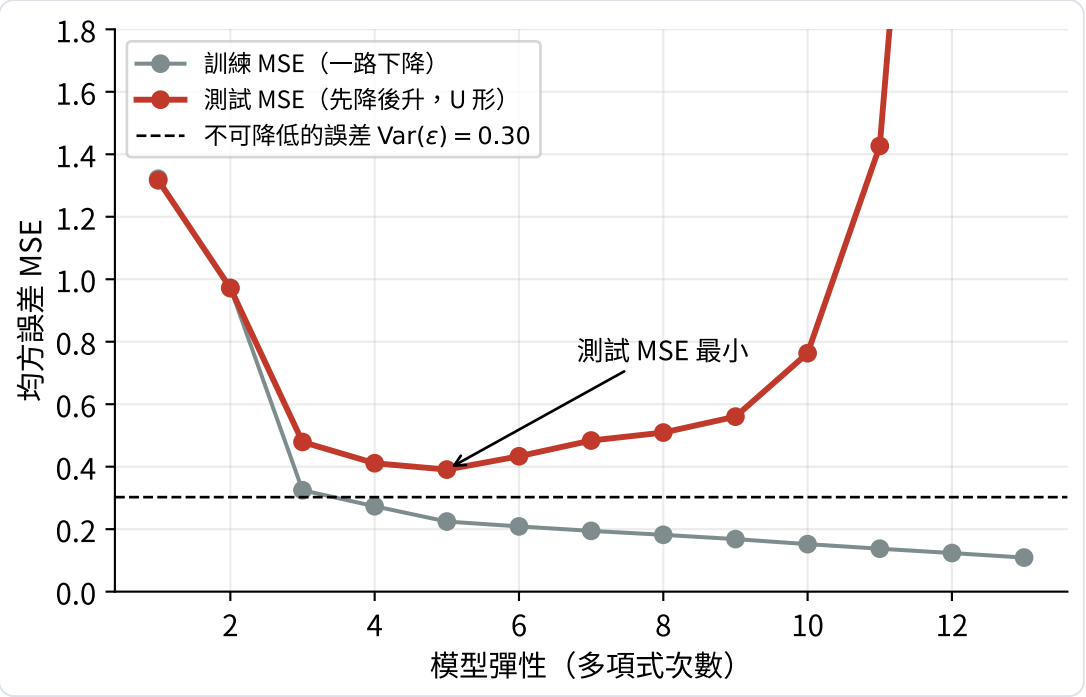
八、配適品質：訓練誤差與測試誤差

迴歸問題用**均方誤差**（mean squared error，MSE）衡量配適品質：

$$\mathrm{MSE} = \frac{1}{n}\sum_{i=1}^{n}\left(y_i - \hat{y}_i\right)^2, \qquad \hat{y}_i = \hat{f}(x_i).$$

用來估計模型的資料叫**訓練資料**（training data），沒有用來估計模型的叫**測試資料**（test data）。模型的好壞要看**測試 MSE**：在新資料上的誤差。彈性高的模型靠大量參數就能把訓練 MSE 壓得很低，但那不代表模型好。也正因如此，迴歸裡衡量訓練資料誤差的指標，分母通常比 n 小（例如第 3 章的 $s^2 = \mathrm{RSS}/(n-k-1)$），用來抵銷估計參數造成的低估。第 6 章會說明怎麼在沒有額外資料時估計測試誤差。

分類問題用**錯誤率**（error rate），也就是分錯類的比例 $\frac{1}{n}\sum I(y_i \neq \hat{y}_i)$；講義的說法是用「分對的比例」衡量，兩者互補。同樣要在測試資料上算。



用模擬資料（22 個訓練點、真實函數同上圖）重複 300 次，計算不同彈性下的平均訓練 MSE 與測試 MSE。訓練 MSE 隨彈性一路下降；測試 MSE 先降後升，呈 U 形。兩條線都不會低於虛線（不可降低的誤差 0.30）之下太多：訓練 MSE 跌破虛線，代表模型已經在記住雜訊。

九、偏差與變異數的取捨

這是本章最重要的結果。想像我們可以重複抽很多組訓練資料，每一組都估出一個 $\hat{f}$。在某個新的點 x_0，$\hat{f}(x_0)$ 會隨訓練資料而變，是一個隨機變數。

- **變異數**（variance）：$\mathrm{Var}\big(\hat{f}(x_0)\big)$，換一組訓練資料，估計值變動多大。
- **偏差**（bias）：$\mathrm{Bias}\big(\hat{f}(x_0)\big) = E\big[\hat{f}(x_0)\big] - f(x_0)$，估計值的平均和真值差多少。

推導：期望測試 MSE 的三項分解

新的觀察值 $y_0 = f(x_0) + \varepsilon_0$，其中 ε_0 和訓練資料獨立、平均 0。記 $\hat{f} = \hat{f}(x_0)$、$f = f(x_0)$、$\bar{f} = E(\hat{f})$（期望值是對「抽訓練資料」與「新的誤差」一起取）。

第一步，把 ε_0 分出來：

$$E\big[(y_0 - \hat{f})^2\big] = E\big[(f - \hat{f} + \varepsilon_0)^2\big] = E\big[(f - \hat{f})^2\big] + 2E\big[(f - \hat{f})\varepsilon_0\big] + E(\varepsilon_0^2).$$

$\hat{f}$ 只由訓練資料決定，和 ε_0 獨立，所以 $E\big[(f - \hat{f})\varepsilon_0\big] = E(f - \hat{f})\,E(\varepsilon_0) = 0$；$E(\varepsilon_0^2) = \mathrm{Var}(\varepsilon)$。

第二步，在 $f - \hat{f}$ 裡加減 $\bar{f}$：

$$E\big[(f - \hat{f})^2\big] = E\big[(f - \bar{f} + \bar{f} - \hat{f})^2\big] = (f - \bar{f})^2 + 2(f - \bar{f})\,E(\bar{f} - \hat{f}) + E\big[(\hat{f} - \bar{f})^2\big].$$

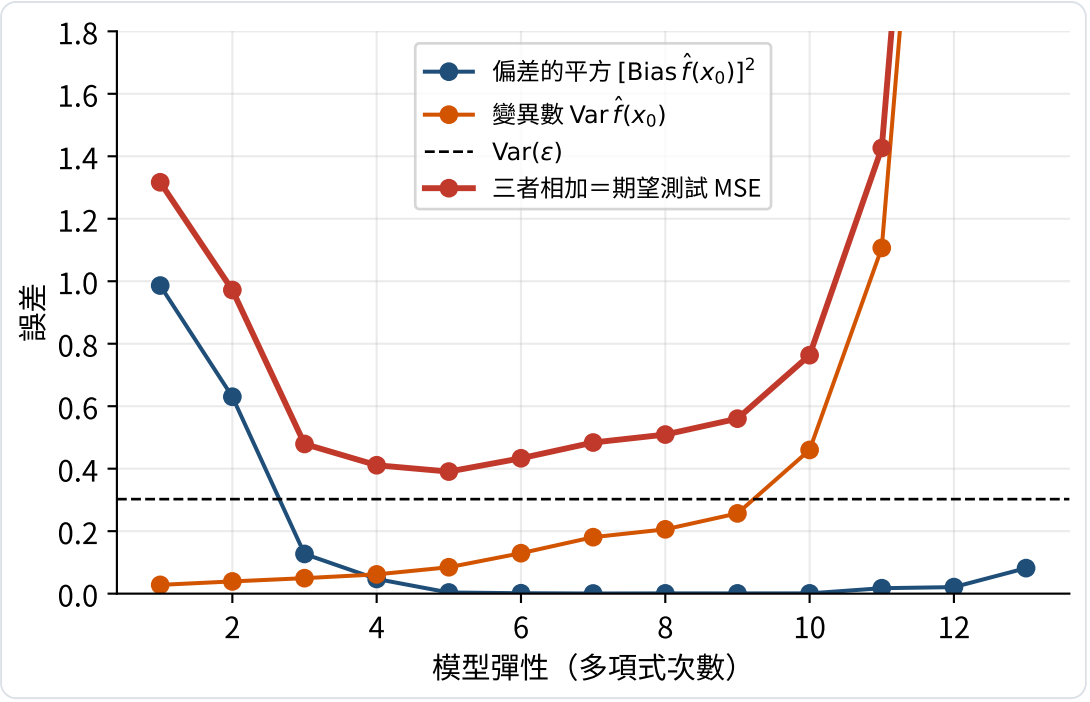
$f - \bar{f}$ 是常數，而 $E(\bar{f} - \hat{f}) = \bar{f} - \bar{f} = 0$，交叉項消失；最後一項就是 $\mathrm{Var}(\hat{f})$。合起來：

$$\boxed{E\big[(y_0 - \hat{f}(x_0))^2\big] = \mathrm{Var}\big(\hat{f}(x_0)\big) + \big[\mathrm{Bias}\big(\hat{f}(x_0)\big)\big]^2 + \mathrm{Var}(\varepsilon)}$$

把 x_0 對所有可能的測試點平均，就是整體的期望測試 MSE。

三項都不會是負的，所以期望測試 MSE 一定至少是 $\mathrm{Var}(\varepsilon)$。要讓它小，必須**同時**讓偏差與變異數都小，但兩者通常此消彼長：

- **彈性低**的方法對個別資料點不敏感，換一組資料估計值變化不大，**變異數低**；但它強加了函數形式，形式錯了就會一直偏在同一邊，**偏差高**。線性迴歸的係數在「真實關係是線性」的前提下是不偏的，但現實中的關係幾乎不可能真的是直線，所以從預測 f 的角度，線性迴歸是高偏差、低變異的方法。
- **彈性高**的方法（例如穿過每一點的樣條）幾乎沒有偏差，但只要一個點改變，整條曲線就跟著變，**變異數高**。



上一張圖的測試 MSE 拆成三塊（同一組模擬）。偏差平方隨彈性迅速下降，變異數隨彈性上升，兩者加上固定的不可降低誤差就是 U 形的測試 MSE。最低點落在「偏差已經很小、變異數還沒變大」的地方。

重點

- 期望測試 MSE = 變異數 + 偏差平方 + 不可降低的誤差。考題常把「偏差」寫成沒有平方，或把不可降低的誤差漏掉，要注意。
- 彈性增加：訓練 MSE 一定（幾乎）只降不升；偏差下降；變異數上升；測試 MSE 先降後升。
- 不可降低的誤差和模型無關，任何方法都消不掉。

考試怎麼考

典型題型是五句敘述選出對的：例如「彈性越高，訓練 MSE 越低」（對）、「彈性越高，測試 MSE 越低」（錯，是 U 形）、「非參數方法需要較多觀察值」（對）、「非監督式學習沒有反應變數」（對）、「推論時黑盒子模型沒有問題」（錯）。每一句都可以回到本節的某一小段判斷。

1.2 變數的種類

變數的型態決定能用哪些模型與圖。講義的分類如下。

一、數值變數與類別變數

- **數值變數**（quantitative variable）：取值是有意義的數字，可以加減、比大小。又分**連續**（continuous，例如理賠金額、年齡）與**離散**（discrete，例如理賠件數 0、1、2、…）。
- **類別變數**（categorical variable，又稱 qualitative variable、factor）：取值是若干類別。只有兩類的叫**二元**（binary）變數，例如有沒有律師代理；類別之間有自然順序的叫**次序**（ordinal）變數，例如傷勢等級輕／中／重；沒有順序的叫**名目**（nominal）變數，例如地區、傷害代碼。

判斷的關鍵不是「看起來是不是數字」，而是「數字本身有沒有數量上的意義」。傷害代碼 101、205、310 雖然是數字，但 310 不代表比 101「多」，所以是類別變數。理賠件數雖然只取整數，但 2 件確實是 1 件的兩倍，所以是（離散的）數值變數。

二、類別變數在模型裡怎麼用

迴歸模型裡，類別變數要先轉成**指標變數**（indicator，又稱虛擬變數 dummy variable）：一個有 c 類的變數，在有截距的模型中用 $c-1$ 個 0／1 變數表示，剩下那一類是**基準類別**（reference level）。詳細的寫法與係數解讀在第 2 章 2.3 節。

> **易錯提醒**
>
> 「理賠件數」是數值（計數）變數，不是類別變數；「理賠延遲時間」是連續的數值變數。章末第 1.1 題就是考這個區分。

這一節的精選習題

★ 精選 **第 1.1 題** ・講義 p.7・回到對應概念

下列哪些是類別變數？

1. 是否有律師代理（legal representation）
2. 理賠延遲時間（settlement delay）
3. 傷害代碼（injury code）
4. 理賠件數（claim count）
5. 理賠金額（claim size）

答案

1 與 3。

解析

逐項看「取值有沒有數量上的意義」：

1. **是否有律師代理**只有「有／沒有」兩種值，是二元的類別變數。
2. **理賠延遲時間**是一段時間長度，可以是任何正數，是連續的數值變數。
3. **傷害代碼**即使寫成數字，代碼之間也沒有大小或距離的意義（代碼 310 不比 101「多」），是名目的類別變數。
4. **理賠件數**取 0、1、2、…，雖然是離散的，但 2 件確實是 1 件的兩倍，可以相加平均，是離散的數值（計數）變數。
5. **理賠金額**是連續的數值變數。

易錯

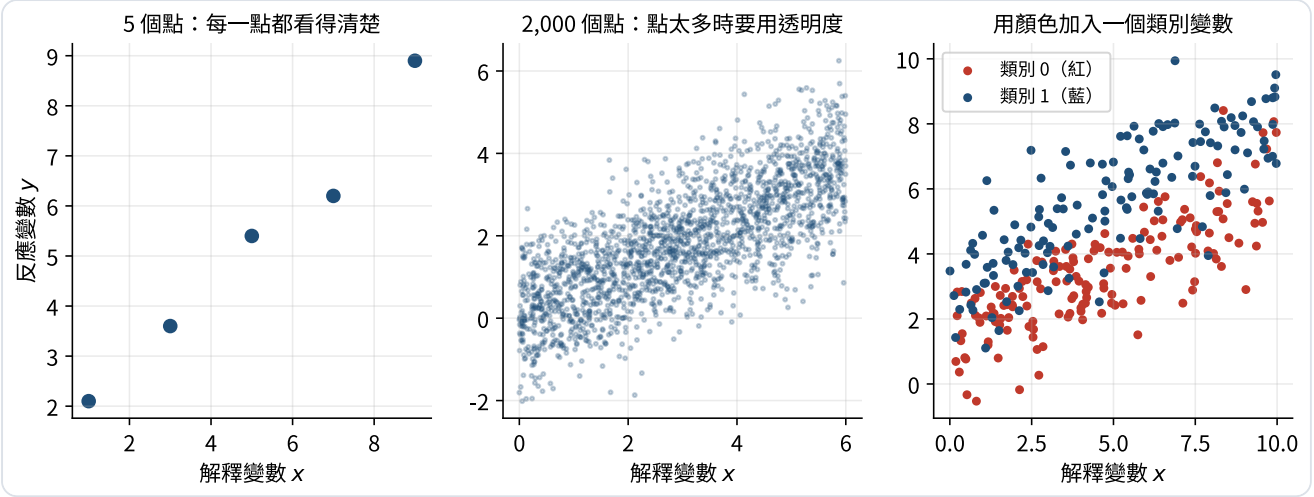
不要因為「只取整數」就判成類別變數。計數資料在第 13 章會用 Poisson 等計數模型處理，正是因為它是數值。

1.3 圖形

建模前先畫圖，看變數之間大致的關係、分配的形狀與有沒有異常值。講義介紹三種圖。

一、散布圖

散布圖（scatter plot）把每一筆觀察畫成平面上的一點，橫軸是解釋變數、縱軸是反應變數，用來看兩個數值變數的關係：是否大致成直線、往上還是往下、有沒有彎曲、有沒有離群的點。點很多時（例如 2,000 個），點會疊在一起，要用透明度或較小的點才看得出密度。若還有一個類別變數，可以用顏色區分：如果紅點集中在下方、藍點集中在上方，表示「藍色」那一類的反應值傾向較高；如果兩種顏色均勻混在一起，表示這個類別變數和反應關係不大。



散布圖的三種情況（仿講義圖 1.1、1.2）。左：點少時每一點都清楚。中：2,000 個點要用半透明才看得出哪裡密集。右：用顏色加入一個類別變數，藍點整體高於紅點，表示類別 1 的反應值較高。

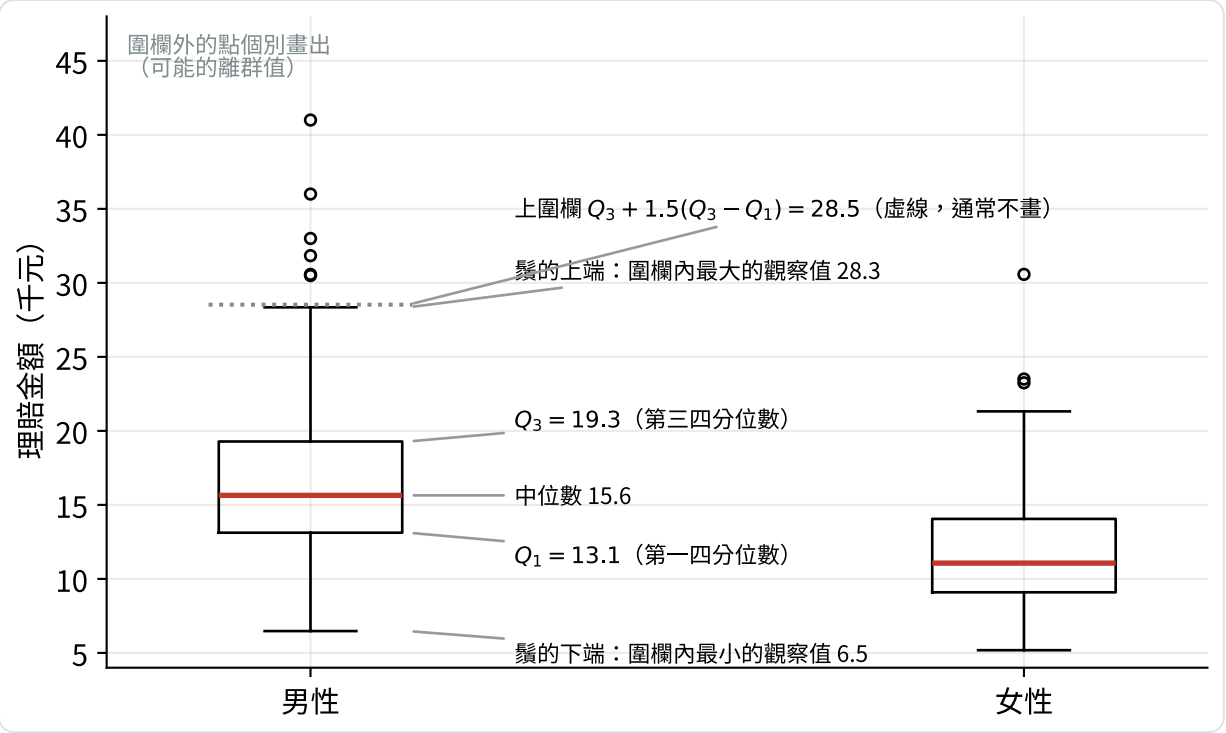
二、箱形圖

用一個類別變數解釋一個連續變數時，可以每一類各畫一個**箱形圖**（box plot）：

- 箱子中間的粗線是**中位數**；箱子下緣是**第一四分位數** Q_1，上緣是**第三四分位數** Q_3。箱子的高度 $Q_3 - Q_1$ 叫**四分位距**（interquartile range，IQR）。
- 箱子上下各有一條線，叫**圍欄**（fence）。讀本採用 Tukey 的定義：令 $h = 1.5(Q_3 - Q_1)$，下圍欄在 $Q_1 - h$，上圍欄在 $Q_3 + h$。
- 從箱子延伸出去的虛線（**鬚**，whisker）畫到圍欄**以內**最遠的觀察值，這些最靠近圍欄的點叫**相鄰點**（adjacent point）。

- 在圍欄以外的觀察值個別畫成點，稱為**可能的離群值**（potential outlier）。

不同軟體、不同作者放圍欄的位置不一樣；用 Tukey 方法時，上下圍欄和箱子的距離相等（都是 $1.5\times$IQR），但鬚的長度不一定相等，因為鬚只畫到實際存在的觀察值。



男女理賠金額的箱形圖（模擬資料，Tukey 圍欄）。男性的中位數線偏向箱子下方、上方的鬚與離群值比較長，表示分配右偏（大額理賠拉出長長的右尾）。女性的理賠整體較低。

從箱形圖讀分配形狀：中位數線若在箱子中央以下、上方的鬚比下方長，表示分配**右偏**（往高值延伸），理賠金額通常就是這樣。

例題（講義第 1.2 題的算法）

樣本 $\{1, 3, 7, 13, 25, 58, 99\}$，用 Tukey 方法求下圍欄。

講義對 7 個點取 $Q_1 = 3$（第 2 個觀察值）、$Q_3 = 58$（第 6 個觀察值）。$h = 1.5(58 - 3) = 82.5$，下圍欄 $= 3 - 82.5 = -79.5$，上圍欄 $= 58 + 82.5 = 140.5$。所有觀察值都在圍欄內，所以沒有離群值；下方的鬚畫到最小值 1，上方的鬚畫到最大值 99。

易錯提醒

四分位數有很多種算法（是否內插、用 $(n+1)p$ 還是 np 定位）。講義這一題對 7 個點取第 2 與第 6 個觀察值，相當於用 $(n+1)p$ 定位：$8\times 0.25=2$、$8\times 0.75=6$。考試若給的是不同的定義，照題目的定義算。

三、分位數圖（qq 圖）

$100q$ **百分位數**又稱 q **分位數**，例如第 40 百分位數是 0.4 分位數。**qq 圖**（quantile–quantile plot）把兩個分配的分位數兩兩配對畫在平面上，用來檢查資料是否來自某個分配。

步驟如下：

1. 把 n 個觀察值由小到大排序，得到順序統計量 $y_{(1)}\le y_{(2)}\le\cdots\le y_{(n)}$。
2. 給第 j 個順序統計量一個機率位置。講義用 $q_j=\dfrac{j}{n+1}$（其他書也有 $\frac{j-0.5}{n}$ 等寫法）。
3. 求配適分配在 q_j 的分位數 $\hat F^{-1}(q_j)$。
4. 畫點 $\left(\hat F^{-1}(q_j),\ y_{(j)}\right)$：橫軸是配適分配的分位數，縱軸是觀察值。

推導：指數分配的分位數

指數分配 $F(x)=1-e^{-x/\theta}$。設 $F(x)=q$ 解 x：

$$1-e^{-x/\theta}=q\ \Rightarrow\ e^{-x/\theta}=1-q\ \Rightarrow\ -\frac{x}{\theta}=\ln(1-q)\ \Rightarrow\ x=-\theta\ln(1-q).$$

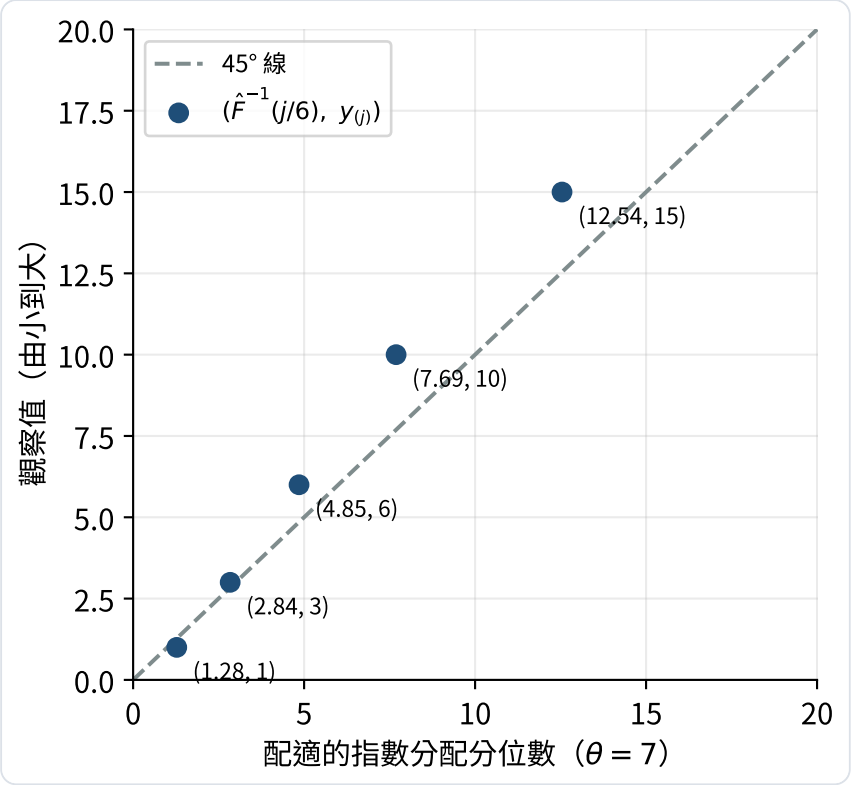
指數分配的最大概似估計是 $\hat\theta=\bar x$（因為對數概似 $-n\ln\theta-\sum x_i/\theta$ 對 θ 微分得 $-n/\theta+\sum x_i/\theta^2=0$）。

例題（講義圖 1.4）

觀察值 1、3、6、10、15 配適指數分配。$\hat{\theta} = \bar{x} = 35/5 = 7$，$n = 5$，機率位置是 $1/6, 2/6, \ldots, 5/6$。

j	$y_{(j)}$	$q_j = j/6$	$\hat{F}^{-1}(q_j) = -7\ln(1-q_j)$
1	1	0.1667	$-7\ln(5/6) = 1.276$
2	3	0.3333	$-7\ln(4/6) = 2.838$
3	6	0.5	$-7\ln(3/6) = 4.852$
4	10	0.6667	$-7\ln(2/6) = 7.690$
5	15	0.8333	$-7\ln(1/6) = 12.542$

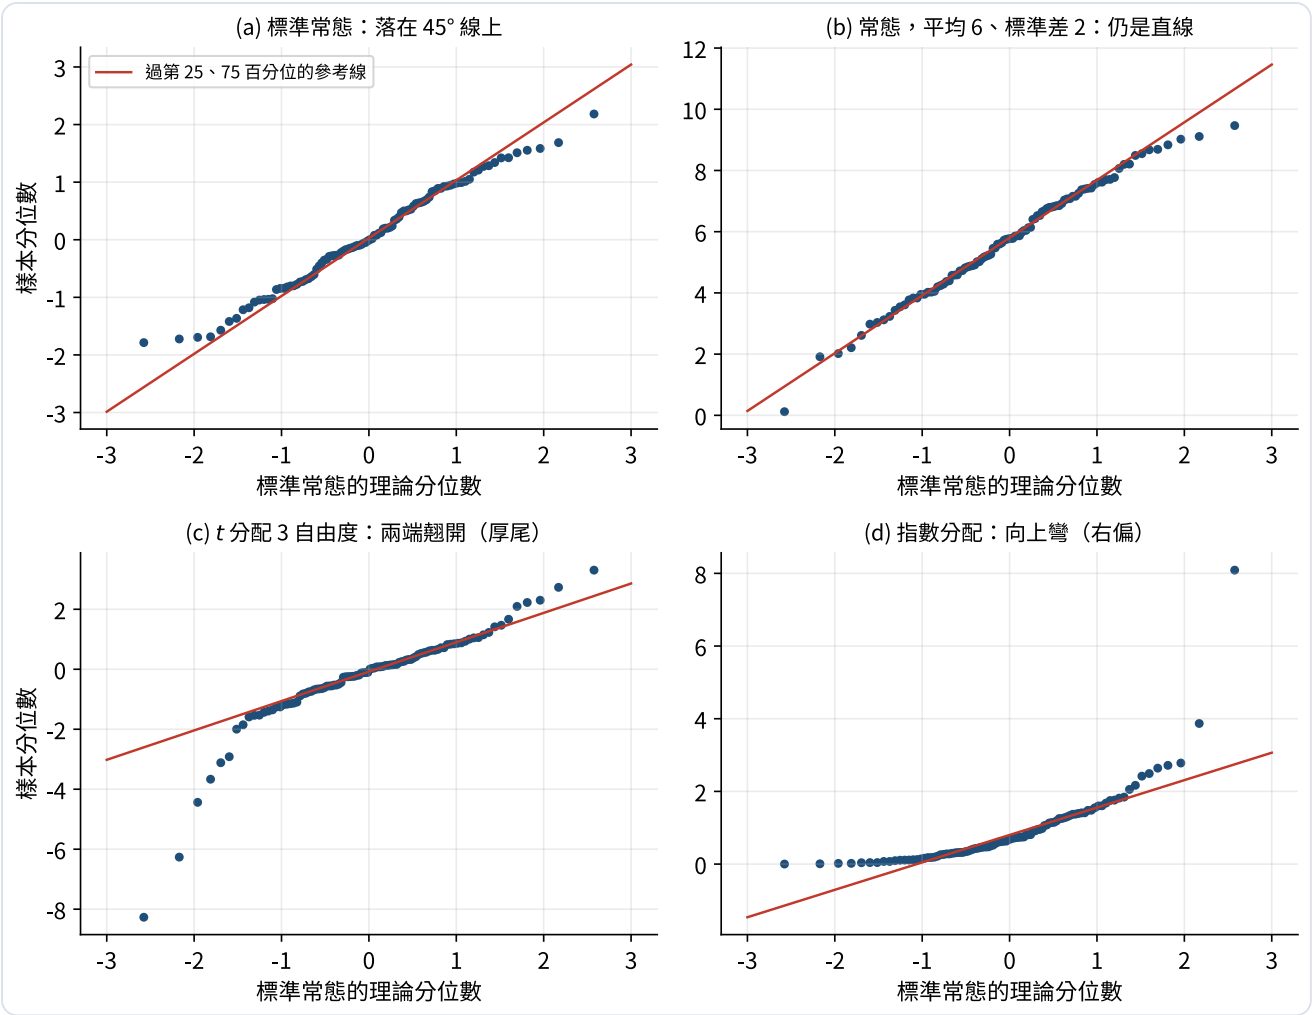
畫出 $(1.276, 1)$、$(2.838, 3)$、$(4.852, 6)$、$(7.690, 10)$、$(12.542, 15)$。



講義圖 1.4 的重畫：觀察值 1、3、6、10、15 對指數分配（$\theta = 7$）的 qq 圖。前四點大致在一條直線上，最後一點（15）偏離較多。

怎麼讀 qq 圖：

- 若配適的是**完全指定**的分配（參數都給定），點落在 **45° 線**附近就是配適得好。
- 更常見的用法是檢查資料是否屬於某個**分配族**。這時只要點落在**一條直線**上就夠了，不必是 45° 線：若點落在 $y = a + bx$ 上，表示資料像是 $F\big((x-a)/b\big)$，也就是同一族、但位置與尺度不同的分配。所以 qq 圖可以在不知道參數的情況下判斷分配族選得對不對。參考線通常畫過兩邊的第 25 與第 75 百分位數。
- 最常見的 qq 圖是**常態機率圖**（normal probability plot）：橫軸用標準常態的分位數。



講義圖 1.5 的重畫：100 個模擬值對標準常態的 qq 圖。(a) 資料本身是標準常態，點在 45° 線上。(b) 資料是平均 6、標準差 2 的常態，點仍成一直線，只是截距與斜率改變（截距約 6、斜率約 2）。(c) t 分配（3 自由度）中段和常態相近，但兩端的分位數比常態更極端，左端往下、右端往上翹，是厚尾的特徵。(d) 指數分配右偏：低分位數擠在 0 附近，高分位數拉得很長，點呈向上彎的曲線。

重點：qq 圖的形狀對照

- 一直線：分配族選對了（斜率、截距反映尺度與位置）。
- 兩端外翹（左端低於參考線、右端高於參考線）：資料的尾巴比假設的分配厚，例如 t 分配。
- 向上彎（凸）：資料右偏，例如指數、對數常態、Gamma。向下彎（凹）則是左偏。

這一節的精選習題

★ 精選 **第 1.2 題** ・講義 p.7・回到對應概念

樣本為 $\{1, 3, 7, 13, 25, 58, 99\}$。用 Tukey 的方法，求箱形圖的下圍欄。

答案

-79.5

解析

第一步：找四分位數。 7 個觀察值已排序。講義取第一四分位數為第 2 個觀察值、第三四分位數為第 6 個觀察值（以 $(n+1)p$ 定位：$8 \times 0.25 = 2$，$8 \times 0.75 = 6$），所以 $Q_1 = 3$、$Q_3 = 58$。

第二步：算圍欄寬度。 $h = 1.5(Q_3 - Q_1) = 1.5 \times (58 - 3) = 82.5$。

第三步：下圍欄。 $Q_1 - h = 3 - 82.5 = -79.5$。

順便可得上圍欄 $Q_3 + h = 58 + 82.5 = 140.5$。所有觀察值都在 $[-79.5,\ 140.5]$ 之內，所以這個樣本沒有可能的離群值；下方的鬚畫到 1，上方的鬚畫到 99。

易錯

圍欄是用來判斷離群值的界線，不一定是某個觀察值；鬚才是畫到圍欄內最遠的觀察值。另外 h 要乘 1.5，不是 IQR 本身。

章末其餘習題（0 題，★ 精選題已放在各節後面）