概念 01

從資料到函數：預測、推論與學習方式

一家保險公司知道投保人的行駛里程，想預估明年賠款。把每張保單當成一列觀察，里程、車齡等特徵組成 X，賠款為反應變數 Y。先問問題：是要估新客戶的損失，還是要解釋哪些因素與損失相關？前者是**預測**（prediction），後者是**推論**（inference）。一個預測很準的模型，並不自動識別降低里程的因果效果。

寫成 $Y = f(X) + \varepsilon$，並設 $E(\varepsilon \mid X) = 0$。這不是說每張保單都恰好賠 $f(X)$，而是相同條件下，正負偏差平均抵銷。若在 $X = x$ 時報一個數字 a，平方損失期望為

$$E[(Y - a)^2 \mid x] = \operatorname{Var}(Y \mid x) + [E(Y \mid x) - a]^2.$$

把 $Y - a$ 拆成 $Y - E(Y \mid x)$ 和 $E(Y \mid x) - a$，交叉項的條件期望為零。第一項不隨 a 改變，第二項在 $a = E(Y \mid x)$ 時最小。所以平方損失下的最佳預測就是條件平均。

監督式學習（supervised learning）有已知反應：賠款金額用迴歸，是否理賠用分類。無監督式學習沒有指定反應，例如用客戶特徵分群，不能直接拿「預測的賠款對不對」評分。參數法先假定函數形式再估少數係數；非參數法不指定同一固定形式，但仍有平滑、距離等假設。線性模型容易解釋，若關係彎曲可能欠擬合；讓曲線通過每一筆訓練資料又可能把雜訊學進去。**即：先決定想預測什麼、用什麼標準算錯，再決定模型需要多靈活。**

概念 02

用新資料評分：可約誤差、不可約誤差與偏差 - 變異數

固定一個新的 x，用訓練集 D 算出 $\hat{f}_D(x)$。換一批訓練資料就可能得到另一條線，因此「預測的變異數」是對重抽訓練集而說，不是同一組資料內賠款的樣本變異數。

令 $m = E_D[\hat{f}_D(x)]$。對獨立的新觀察，將 $Y - \hat{f}_D = (Y - f) + (f - m) + (m - \hat{f}_D)$ 展開平方。前後兩個中心化項取期望為零，新觀察的雜訊與訓練集獨立，使交叉項消失：

$$E[(Y - \hat{f}_D(x))^2 \mid x] = \underbrace{\mathrm{Var}(Y \mid x)}_{\text{不可約}} + \underbrace{(m - f(x))^2}_{\text{偏差平方}} + \underbrace{\mathrm{Var}_D(\hat{f}_D(x))}_{\text{估計變異數}}.$$

例如真實條件平均是 10，模型平均預測為 8、模型預測變異數是 3、個體雜訊變異數是 5，測試 MSE 為 $4 + 3 + 5 = 12$。即使完美掌握平均，最後仍有 5 的個體不確定性。複雜模型通常較能貼合真實曲線，但也容易追著訓練集的偶然起伏跑。

資料集上的均方誤差為 $\mathrm{MSE} = n^{-1}\sum_i (y_i - \hat{y}_i)^2$。若模型族彼此包含且都將訓練平方和最小化，加入自由度不會提高訓練 MSE；測試 MSE 則常先降後升，並非數學上永遠呈 U 形。分類的零一損失改用 $n^{-1}\sum_i \mathbf{1}(y_i \neq \hat{y}_i)$。選模型要用沒參與配適的觀察評分，詳見第 6 章。

CA 複習例 | 為什麼要想像重新抽資料？ 在同一批通勤資料上，直線與五次多項式都能估一條曲線。把訓練資料換掉再估，直線通常變動較小；高次多項式可能為了穿過幾筆特殊日期而明顯改形。不是拿一批資料上的殘差大小判定「模型的變異」。先固定同一個要預測的出發條件，再比較各次估出的預測值。

概念 03

變數的尺度與類型

量化變數（quantitative variable）有可比較的數量。連續量例如賠款金額，離散計數例如出險次數；次數為整數，不因取值離散就變成類別。**類別變數**（categorical variable）用值表示群組，名目尺度沒有自然排序，順序尺度有順序但間距未必相等。

「傷害代號 4」若只代表一種傷害，代號 4 與 2 的差不是「多兩單位的傷害」。若將代號直接當連續解釋變數，會強迫模型把編碼順序視為效果大小。二元反應也可編成 0、1 來估機率，並不因此變成普通的連續反應。

數值摘要：樣本平均為 $\bar{x} = n^{-1}\sum x_i$。中心化偏差的和被固定為零，故通常用 $s_x^2 = \sum (x_i - \bar{x})^2/(n-1)$ 估母體變異數。共變異數將平方改為兩變數偏差的乘積：$s_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y})/(n-1)$。為避免元與千元的不同影響，用 $r = s_{xy}/(s_x s_y)$ 標準化成相關係數。零相關只排除線性連動，不保證獨立。

★ 精選 · 1.1

法律代理（有 / 無）、結案延遲時間、傷害代碼、理賠件數與賠款金額，哪些應視為類別？

參考解答

法律代理與傷害代碼，即第 1、3 項。

解析

前者是二元身分，後者用數字當標籤；延遲是時間，件數是可加總的計數，金額有可解釋的距離。

概念 04

散布圖、箱型圖與 Q–Q 圖：從圖讀出什麼？

散布圖把每一組 (x_i, y_i) 放在同一平面，用方向、彎曲、扇形與孤立點判斷關係；第三個類別可用顏色區別。圖形能指出應再檢查的模式，不能單憑斜率證明因果。

箱型圖（box plot）以中位數分割資料，中間一半落在第一與第三四分位數之間。四分位距 $IQR = Q_3 - Q_1$ 是對少數極端值較不敏感的散布尺度。Tukey 內圍籬為 $Q_1 - 1.5IQR$ 與 $Q_3 + 1.5IQR$；鬚端是圍籬內最遠的**實際觀察值**，不是圍籬數字。各軟體求四分位數的規則略異，作答要沿用題目的規則。

分位數對分位數圖（Q–Q plot）將排序後的資料 $y_{(j)}$ 與理論分位數 $F^{-1}(j/(n+1))$ 配對。若理論族與資料只差位置和尺度，點應近似直線，不一定是 45 度；若連參數也指定正確且兩軸尺度相同，才期待貼近對角線。若縱軸是樣本、橫軸是常態理論分位，左尾向下、右尾向上，比直線張得更開，提示樣本厚尾。

指數分配若平均為 θ，由 $q = 1 - e^{-x/\theta}$ 得 $1 - q = e^{-x/\theta}$，取對數後 $x = -\theta \log(1-q)$。這一步把「第幾百分位」換成可以和觀察金額比較的數值。**即：箱型圖看單組資料的中間與尾端，Q–Q 圖看整個分配形狀是否相合。**

★ 精選 · 1.2

資料 1、3、7、13、25、58、99。用講義的 Tukey 四分位數計法求箱型圖下圍籬。

參考解答

-79.5。中位數為 13，兩側各三點的中位數分別為 3、58，因此 $Q_1 - 1.5(Q_3 - Q_1) = 3 - 1.5(55) = -79.5$。

解析

題目要圍籬，不是鬚端。樣本最小值 1 在圍籬內，圖上鬚端為 1。

TERMS

本章中英術語

中文	English	解題時的意思
反應變數	response variable	要解釋或預測的結果。
偏差	bias	重複取樣時，估計的平均與真值之差。
四分位距	interquartile range	涵蓋中間一半觀察值的跨度。