SRM · 第 2 章

線性迴歸：估計參數

線性迴歸用一條線（或一個平面）描述反應變數的條件平均。本章從零推導最小平方估計式，先做一個解釋變數，再推廣到矩陣形式，最後介紹類別變數、交互作用、多項式、加權最小平方與變數轉換。

本章內容

1. 2.1 模型與假設、簡單線性迴歸
2. 2.2 多元線性迴歸與矩陣形式
3. 2.3 其他模型形式

本章對應講義第 2 課，讀本是 Frees 1.3、2.1～2.2、3.1～3.2 節與 ISLR 3.1～3.2、3.3.2、3.3.3 節。講義作者說考試很少要你親手算迴歸係數（計算機可以直接算），但題目常給**摘要統計量**要你算斜率、截距或某一筆的殘差，所以每一條公式的來由都要清楚。

2.1 模型與假設、簡單線性迴歸

一、線性迴歸模型

我們有 n 筆觀察值，每一筆包含一個反應值 y_i 與 k 個解釋變數的值 $x_{i1}, \ldots, x_{ik}$。**線性迴歸模型**假設

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_k x_{ik} + \varepsilon_i, \qquad i = 1, \ldots, n.$$

β_0 是截距，$\beta_1, \ldots, \beta_k$ 是斜率（又稱迴歸係數），ε_i 是誤差項。注意：除了 k 個斜率，還有截距，所以總共要估計 $k+1$ **個參數**。這個 $k+1$ 會在後面每一章的自由度裡出現（例如 $n-k-1$）。

> 名詞：Frees 用 k 表示解釋變數個數，ISLR 用 p；Frees 把估計值寫成拉丁字母 b_j，ISLR 寫成 $\hat{\beta}_j$。兩者意思一樣，本筆記混用。

「線性」指的是對參數線性，不是對 x 線性。$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \varepsilon$ 仍是線性迴歸，因為它是 β 的線性組合；但 $y = \beta_0 e^{\beta_1 x} + \varepsilon$ 不是。

二、誤差項的三個假設

把 ε_i 當成隨機變數，標準假設是：

1. $E(\varepsilon_i) = 0$，且 $\mathrm{Var}(\varepsilon_i) = \sigma^2$ 對所有 i 都相同。變異數相同這個假設叫**同質變異**（homoscedasticity）。
2. ε_i 彼此**獨立**。
3. ε_i 服從**常態分配**。

合起來就是 $\varepsilon_i \overset{\text{iid}}{\sim} N(0, \sigma^2)$。在這些假設下，給定任何一組解釋變數值，$y$ 服從平均 $\beta_0 + \sum_j \beta_j x_j$、變異數 σ^2 的常態分配。第 5 章會教怎麼檢查這三個假設。

三、最小平方法

估計 β 的方法是選一組 $b_0, b_1, \ldots, b_k$，讓**殘差平方和**最小：

$$\mathrm{SSE}(b_0, \ldots, b_k) = \sum_{i=1}^{n} \left(y_i - b_0 - b_1 x_{i1} - \cdots - b_k x_{ik} \right)^2.$$

這就是**普通最小平方法**（ordinary least squares，OLS）。為什麼用平方？一是正負誤差不會互相抵銷；二是平方可以微分，能解出封閉形式；三是在常態誤差下，最小平方估計正好就是最大概似估計（下面推導）。

推導：常態誤差下，最小平方估計 = 最大概似估計

$y_i \sim N(\mu_i, \sigma^2)$，$\mu_i = \beta_0 + \sum_j \beta_j x_{ij}$，彼此獨立。對數概似函數為

$$\ell(\beta, \sigma^2) = \sum_{i=1}^{n} \ln\Big[\frac{1}{\sqrt{2\pi\sigma^2}} e^{-(y_i-\mu_i)^2/(2\sigma^2)}\Big] = -\frac{n}{2}\ln(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i-\mu_i)^2.$$

不論 σ^2 是多少，β 只出現在最後一項，而且前面有負號。所以讓 ℓ 最大的 β，就是讓 $\sum(y_i-\mu_i)^2$ 最小的 β，也就是最小平方估計。

四、簡單線性迴歸的公式

只有一個解釋變數（$k=1$）時，Frees 稱為**基本線性迴歸**（basic linear regression），ISLR 稱為**簡單線性迴歸**（simple linear regression），舊考題也有人叫「兩變數迴歸」。模型是 $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$。

先定義三個**中心化的平方和**（之後每一章都會用到）：

$$S_{xx} = \sum_{i=1}^{n}(x_i-\bar{x})^2, \qquad S_{yy} = \sum_{i=1}^{n}(y_i-\bar{y})^2, \qquad S_{xy} = \sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y}).$$

推導：簡單線性迴歸的最小平方估計

目標函數 $Q(b_0, b_1) = \sum_i (y_i - b_0 - b_1 x_i)^2$。

第一步，對 b_0 偏微分並令為 0：

$$\frac{\partial Q}{\partial b_0} = -2\sum_i (y_i - b_0 - b_1 x_i) = 0 \;\Rightarrow\; \sum_i y_i - n b_0 - b_1 \sum_i x_i = 0 \;\Rightarrow\; b_0 = \bar{y} - b_1 \bar{x}.$$

第二步，對 b_1 偏微分並令為 0：

$$\frac{\partial Q}{\partial b_1} = -2\sum_i x_i (y_i - b_0 - b_1 x_i) = 0.$$

把 $b_0 = \bar{y} - b_1 \bar{x}$ 代入，括號變成 $(y_i - \bar{y}) - b_1 (x_i - \bar{x})$：

$$\sum_i x_i \big[(y_i - \bar{y}) - b_1 (x_i - \bar{x}) \big] = 0.$$

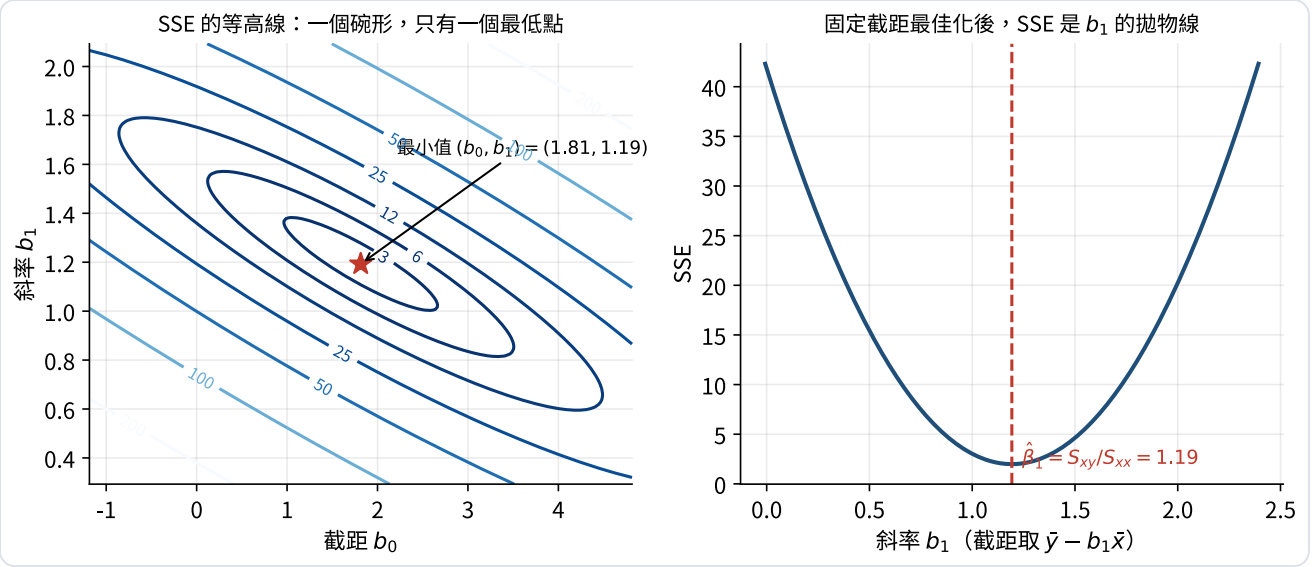
因為 $\sum_i (y_i - \bar{y}) = 0$、$\sum_i (x_i - \bar{x}) = 0$，把前面的 x_i 換成 $x_i - \bar{x}$ 不改變總和（多出來的 $\bar{x}\sum(\cdot)$ 等於 0）：

$$\sum_i (x_i - \bar{x})(y_i - \bar{y}) - b_1 \sum_i (x_i - \bar{x})^2 = 0 \;\Rightarrow\; b_1 = \frac{S_{xy}}{S_{xx}}.$$

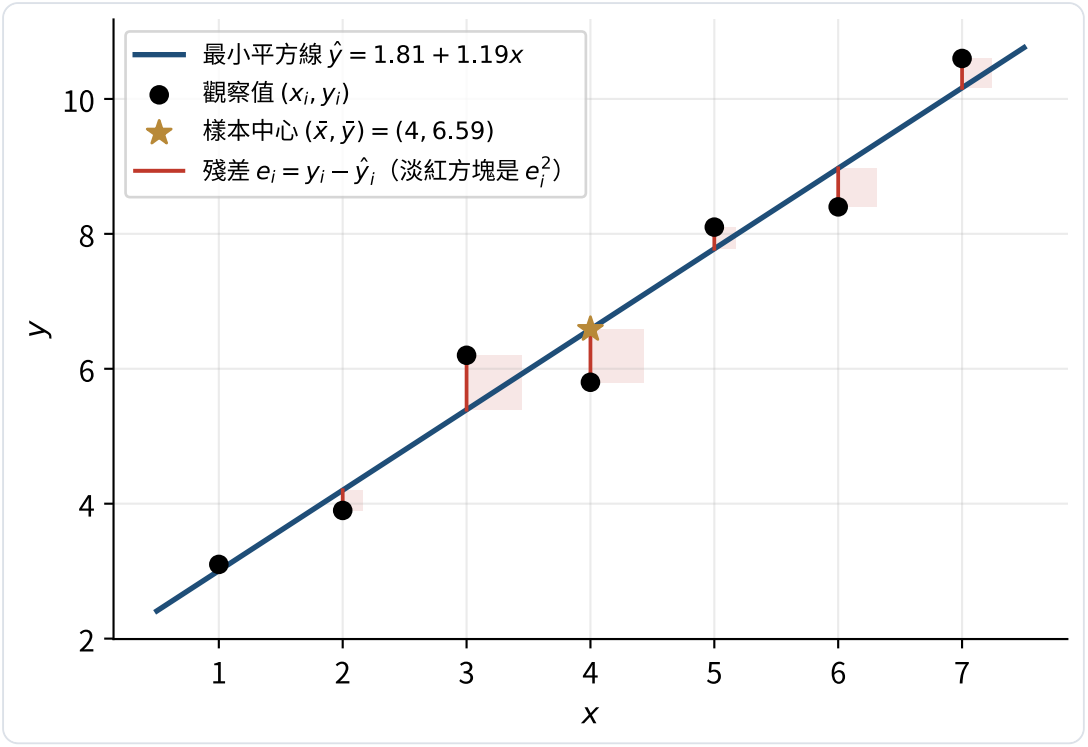
第三步，確認是最小值： $\partial^2 Q / \partial b_1^2 = 2\sum x_i^2 > 0$，且海森矩陣行列式 $4\big(n\sum x_i^2 - (\sum x_i)^2\big) = 4 n S_{xx} > 0$（只要 x 不全相同），所以是唯一的最小值。

結論：

$$\boxed{\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}, \qquad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}}$$



左：七筆資料的 SSE 對 (b_0, b_1) 的等高線，是一個碗形，最低點（紅星）就是最小平方估計。右：把截距固定為 $\bar{y} - b_1\bar{x}$ 之後，SSE 只是 b_1 的拋物線，頂點在 S_{xy}/S_{xx}。



最小平方線與殘差。紅色線段是每一筆的殘差，淡紅方塊的面積是殘差平方；最小平方線讓這些方塊的總面積最小。直線一定通過樣本中心（金色星號）。

五、斜率的其他寫法

用共變異數與變異數： 樣本共變異數 $\mathrm{cv}_{xy} = S_{xy}/(n-1)$，樣本變異數 $s_x^2 = S_{xx}/(n-1)$。兩者相除，$n-1$ 消掉：

$$\hat{\beta}_1 = \frac{\mathrm{cv}_{xy}}{s_x^2}.$$

因為分母會消掉，用除以 n 的有偏版本也可以。

用原始和計算（考題最常給的形式）： 展開乘積，

$$S_{xy}=\sum x_iy_i-\bar{x}\sum y_i-\bar{y}\sum x_i+n\bar{x}\bar{y}=\sum x_iy_i-n\bar{x}\bar{y}=\sum x_iy_i-\frac{(\sum x_i)(\sum y_i)}{n},$$

$$S_{xx}=\sum x_i^2-n\bar{x}^2=\sum x_i^2-\frac{(\sum x_i)^2}{n}.$$

所以

$$\hat{\beta}_1=\frac{\sum x_iy_i-n\bar{x}\bar{y}}{\sum x_i^2-n\bar{x}^2}.$$

用相關係數： 樣本相關係數 $r_{xy}=\dfrac{\mathrm{cv}_{xy}}{s_xs_y}=\dfrac{S_{xy}}{\sqrt{S_{xx}S_{yy}}}$。代回去，

$$\hat{\beta}_1=\frac{r_{xy}s_xs_y}{s_x^2}=r_{xy}\frac{s_y}{s_x}.$$

斜率和相關係數同號；相關係數沒有單位，乘上 s_y/s_x 才有「y 的單位／x 的單位」。

易錯提醒

- 用 $r\,s_y/s_x$ 時，迴歸的方向決定誰在分子：y 對 x 迴歸，s_y 在分子。
- 原始和的公式分母是 $\sum x_i^2-n\bar{x}^2$，**不是** $\sum x_i^2-\bar{x}^2$（章末第 2.15 題就是考這個）。
- 題目給的 $\sum y_i^2$ 算斜率用不到，是拿來算後面章節的 S_{yy} 或 R^2 的。

例題 2-1（自編，沿用講義 2A 的算法）

資料 $x=1,2,3,4,5$，$y=2,4,5,4,5$。求 $\hat{\beta}_0,\hat{\beta}_1$。

$\bar{x}=3$、$\bar{y}=4$。$\sum x_i^2=55$、$\sum x_iy_i=66$。$S_{xx}=55-5(3^2)=10$，$S_{xy}=66-5(3)(4)=6$。$\hat{\beta}_1=6/10=0.6$，$\hat{\beta}_0=4-0.6(3)=2.2$。迴歸線 $\hat{y}=2.2+0.6x$。

例題 2-2（講義 Quiz 2-1 的資料）

新產品前四個月營收（百萬）為 27、34、48、59，以月份 $x = 1, 2, 3, 4$ 迴歸。

$\bar{x} = 2.5$、$\bar{y} = 42$。$S_{xx} = (-1.5)^2 + (-0.5)^2 + 0.5^2 + 1.5^2 = 5$。$S_{xy} = (-1.5)(-15) + (-0.5)(-8) + (0.5)(6) + (1.5)(17) = 22.5 + 4 + 3 + 25.5 = 55$。$\hat{\beta}_1 = 55/5 = 11$，$\hat{\beta}_0 = 42 - 11(2.5) = 14.5$。每多一個月，營收平均多 1,100 萬。

例題 2-3（換單位的技巧，講義 2C 的做法）

四輛車的里程（千英里）7、10、11、12，總理賠成本（千元）0.6、2、1、1.6。預測里程 5,000 英里的理賠。

先把千去掉計算：$\bar{x} = 10$、$\bar{y} = 1.3$；$\sum x^2 = 414$，$S_{xx} = 414 - 4(100) = 14$；$\sum xy = 54.4$，$S_{xy} = 54.4 - 4(10)(1.3) = 2.4$。$\hat{\beta}_1 = 2.4/14 = 0.171429$（千元／千英里，也就是元／英里）。$\hat{\beta}_0 = 1.3 - 0.171429(10) = -0.414286$（千元）$= -414.29$ 元。預測：$-414.29 + 0.171429 \times 5000 = 442.86$ 元。注意 $x = 5$ 已經在資料範圍（7～12）之外，這是外插。

六、配適值、殘差與它們的性質

配適值（fitted value）$\hat{y}_i = \hat{\beta}_0 + \sum_j \hat{\beta}_j x_{ij}$；**殘差**（residual）$\hat{\varepsilon}_i = e_i = y_i - \hat{y}_i$。殘差是看得到的；誤差 $\varepsilon_i = y_i - E(y_i)$ 看不到，因為真正的 β 不知道。

由正規方程式（上面兩個偏微分等於 0 的式子）直接可得：

1. $\sum_i e_i = 0$：殘差總和為 0（來自對 b_0 的條件，所以**模型必須有截距**）。
2. $\sum_i x_i e_i = 0$：殘差和解釋變數不相關（來自對 b_1 的條件）。
3. 迴歸線通過 $(\bar{x}, \bar{y})$：由 $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$。
4. $\sum \hat{y}_i = \sum y_i$，所以配適值的平均等於 $\bar{y}$。

這一節的精選習題

★ 精選 **第 2.1 題** ・講義 p.16・回到對應概念

You are given the linear regression model $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ to fit to the following data:

x	-2	-1	**0**	**1**	**2**
y	3	5	8	9	10

Determine the least squares estimate of β_0.

中文題意

以模型 $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ 配適下列資料，求 β_0 的最小平方估計。

（數據、圖表與選項見上方英文題目。）

答案

$\hat{\beta}_0 = 7$

解析

截距公式 $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$。

- $\bar{x} = (-2 - 1 + 0 + 1 + 2)/5 = 0$。
- $\bar{y} = (3 + 5 + 8 + 9 + 10)/5 = 35/5 = 7$。

因為 $\bar{x} = 0$，$\hat{\beta}_1 \bar{x} = 0$，不論斜率多少，$\hat{\beta}_0 = \bar{y} = 7$。

（若要斜率：$S_{xx} = 4 + 1 + 0 + 1 + 4 = 10$，$S_{xy} = (-2)(-4) + (-1)(-2) + 0 + 1(2) + 2(3) = 18$，$\hat{\beta}_1 = 1.8$。）

易錯

x 已經中心化（平均為 0）時，截距就是 $\bar{y}$。這是考題常用的捷徑。

★ 精選 **第 2.2 題** ・講義 p.17・回到對應概念

You are fitting a linear regression model $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ to 18 observations. You are given the following:

(i) $\sum_{i=1}^{18} x_i = 216$
(ii) $\sum_{i=1}^{18} x_i^2 = 3092$
(iii) $\sum_{i=1}^{18} y_i = 252$
(iv) $\sum_{i=1}^{18} y_i^2 = 4528$
(v) $\sum_{i=1}^{18} x_i y_i = 3364$

Determine the least squares estimate of β_1.

中文題意

以 $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ 配適 18 筆觀察值。已知 $\sum x_i = 216$、$\sum x_i^2 = 3092$、$\sum y_i = 252$、$\sum y_i^2 = 4528$、$\sum x_i y_i = 3364$。求 β_1 的最小平方估計。

答案

$\hat{\beta}_1 = 0.68$

解析

第一步：中心化平方和。

$$S_{xx} = \sum x_i^2 - \frac{(\sum x_i)^2}{n} = 3092 - \frac{216^2}{18} = 3092 - 2592 = 500.$$

第二步：中心化交叉乘積和。

$$S_{xy} = \sum x_i y_i - \frac{(\sum x_i)(\sum y_i)}{n} = 3364 - \frac{216 \times 252}{18} = 3364 - 3024 = 340.$$

第三步： $\hat{\beta}_1 = S_{xy}/S_{xx} = 340/500 = 0.68$。

易錯

> $\sum y_i^2$ 用不到。不能直接拿 $\sum x_i y_i / \sum x_i^2$ 當斜率，那是「沒有截距」的迴歸斜率。

★ 精選 **第 2.6 題** ・講義 p.18・回到對應概念

[SRM Sample Question #23] Toby observes the following coffee prices in his company cafeteria:

- 12 ounces for 1.00
- 16 ounces for 1.20
- 20 ounces for 1.40

The cafeteria announces that they will begin to sell any amount of coffee for a price that is the value predicted by a simple linear regression using least squares of the current prices on size.

Toby and his co-worker Karen want to determine how much they would save each day, using the new pricing, if, instead of each buying a 24-ounce coffee, they bought a 48-ounce coffee and shared it.

Calculate the amount they would save.

(A) It would cost them 0.40 more.

(B) It would cost the same.

(C) They would save 0.40.

(D) They would save 0.80.

(E) They would save 1.20.

中文題意

（SRM 樣題 #23）員工餐廳的咖啡價格：12 盎司 1.00、16 盎司 1.20、20 盎司 1.40。餐廳宣布任何容量的價格都改成「以最小平方法將現有價格對容量做簡單線性迴歸」的預測值。Toby 和 Karen 原本各買一杯 24 盎司，若改成合買一杯 48 盎司再分著喝，每天能省多少？

(A) 多花 0.40　(B) 一樣　(C) 省 0.40　(D) 省 0.80　(E) 省 1.20

答案

(C) 省 0.40

解析

第一步：求迴歸線。 三點 $(12, 1.00), (16, 1.20), (20, 1.40)$ 剛好在一條直線上：每多 4 盎司貴 0.20，斜率 $0.20/4 = 0.05$。截距由 $1.00 = \beta_0 + 0.05(12)$ 得 $\beta_0 = 0.40$。點都在線上時，最小平方線就是那條線（SSE = 0 已是最小）。

用公式驗算：$\bar{x} = 16$、$\bar{y} = 1.2$，$S_{xx} = 16 + 0 + 16 = 32$，$S_{xy} = (-4)(-0.2) + 0 + 4(0.2) = 1.6$，$\hat{\beta}_1 = 1.6/32 = 0.05$，$\hat{\beta}_0 = 1.2 - 0.05(16) = 0.40$。

第二步：比較兩種買法。 - 各買 24 盎司：$2 \times (0.40 + 0.05 \times 24) = 2 \times 1.60 = 3.20$。 - 合買 48 盎司：$0.40 + 0.05 \times 48 = 2.80$。

省 $3.20 - 2.80 = 0.40$，正好是一個截距：多買一杯就多付一次固定的 0.40。

★ 精選 **第 2.7 題** ・講義 p.18・回到對應概念

[MAS-I-F18:29] An ordinary least squares model with one variable (Advertising) and an intercept was fit to the following observed data in order to estimate Sales:

Observation	Advertising	Sales
1	5.5	100
2	5.8	110
3	6.0	112
4	5.9	115
5	6.2	117

Calculate the residual for the third observation.

(A) Less than -2

(B) At least -2, but less than 0

(C) At least 0, but less than 2

(D) At least 2, but less than 4

(E) At least 4

中文題意

（MAS-I 2018 秋 #29）以一個變數（廣告費）加截距的普通最小平方模型估計銷售額，資料如下。求第三筆觀察的殘差。

（數據、圖表與選項見上方英文題目。）

答案

(B)，殘差約 -1.657

解析

第一步：平均數。 $\sum x = 29.4$，$\bar{x} = 5.88$；$\sum y = 554$，$\bar{y} = 110.8$。

第二步：S_{xx} 與 S_{xy}。 離差 $x_i-\bar{x}$：$-0.38,-0.08,0.12,0.02,0.32$；$y_i-\bar{y}$：$-10.8,-0.8,1.2,4.2,6.2$。

$$S_{xx}=0.1444+0.0064+0.0144+0.0004+0.1024=0.268,$$

$$S_{xy}=4.104+0.064+0.144+0.084+1.984=6.38.$$

第三步：係數。 $\hat{\beta}_1=6.38/0.268=23.806$；$\hat{\beta}_0=110.8-23.806\times 5.88=-29.179$。

第四步：第三筆的配適值與殘差。 $\hat{y}_3=-29.179+23.806\times 6.0=113.657$，$e_3=112-113.657=-1.657$，落在 $[-2,0)$。

★ 精選 **第 2.10 題** · 講義 p.19 · 回到對應概念

You are fitting the linear regression model $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$. You are given:

(i) $\sum_{i=1}^{28} x_i = 392$

(ii) $\sum_{i=1}^{28} y_i = 924$

(iii) $\sum_{i=1}^{28} x_i y_i = 13{,}272$

(iv) $\hat{\beta}_0 = -23$

Determine $\sum_{i=1}^{28} x_i^2$.

中文題意

配適 $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$，共 28 筆。已知 $\sum x_i = 392$、$\sum y_i = 924$、$\sum x_i y_i = 13{,}272$、$\hat{\beta}_0 = -23$。求 $\sum x_i^2$。

答案

$5{,}572$

解析

這題是反過來用公式。

第一步：平均數。 $\bar{x} = 392/28 = 14$，$\bar{y} = 924/28 = 33$。

第二步：由截距反推斜率。 $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$，所以 $-23 = 33 - 14\hat{\beta}_1$，$\hat{\beta}_1 = 56/14 = 4$。

第三步：S_{xy}。 $S_{xy} = \sum x_i y_i - n\bar{x}\bar{y} = 13{,}272 - 28(14)(33) = 13{,}272 - 12{,}936 = 336$。

第四步：由斜率反推 S_{xx}。 $\hat{\beta}_1 = S_{xy}/S_{xx}$，$S_{xx} = 336/4 = 84$。

第五步：回到原始平方和。 $S_{xx} = \sum x_i^2 - n\bar{x}^2$，$\sum x_i^2 = 84 + 28(14^2) = 84 + 5{,}488 = 5{,}572$。

★ 精選 **第 2.19 題** · 講義 p.21 · 回到對應概念

In a simple regression model $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, you are given

$$\sum x_i = 30 \qquad \sum y_i = 450 \qquad \sum x_i^2 = 270$$

$$\sum x_i y_i = 8100 \qquad n = 15 \qquad x_5 = 3 \qquad y_5 = 40$$

Calculate the fifth residual, $\hat{\varepsilon}_5$.

中文題意

簡單迴歸 $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$，$n = 15$，$\sum x_i = 30$、$\sum y_i = 450$、$\sum x_i^2 = 270$、$\sum x_i y_i = 8100$。第五筆 $x_5 = 3$、$y_5 = 40$。求第五個殘差 $\hat{\varepsilon}_5$。

答案

$\hat{\varepsilon}_5 = -24.29$

解析

第一步： $\bar{x} = 2$，$\bar{y} = 30$。

$$S_{xx} = 270 - \frac{30^2}{15} = 270 - 60 = 210,$$

$$S_{xy} = 8100 - \frac{30 \times 450}{15} = 8100 - 900 = 7200.$$

第二步： $\hat{\beta}_1 = 7200/210 = 34.2857$。 **第三步：** $\hat{y}_5 = \bar{y} + \hat{\beta}_1(x_5 - \bar{x}) = 30 + 34.2857 \times (3 - 2) = 64.2857$。 **第四步：** $\hat{\varepsilon}_5 = y_5 - \hat{y}_5 = 40 - 64.2857 = -24.29$。

觀念題（5 題，仿 SOA 樣題的質性題，含跨章節）

觀念 **觀念題 C2.1-1** 仿 SOA 樣題・回到本節開頭

For the linear regression model $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, determine which of the following are standard assumptions.

I. The errors ε_i have mean 0.

II. The errors ε_i have constant variance σ^2.

III. The explanatory variable x is normally distributed.

(A) III only

(B) I and II only

(C) I and III only

(D) II and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

下列哪些是線性迴歸 $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ 的標準假設？

I. 誤差平均為 0。

II. 誤差變異數固定為 σ^2。

III. 解釋變數 x 服從常態分配。

答案

(B)：只有 I、II 正確

解析

I、II 對（另外還有誤差彼此獨立；做推論時再加上常態）。

III 錯：x 被視為固定、非隨機的數，對它的分配沒有任何假設。要常態的是**誤差**，不是解釋變數。

觀念 **觀念題 C2.1-2** 仿 SOA 樣題・回到本節開頭

For a least squares regression with an intercept, determine which of the following statements is/are true.

I. The residuals sum to zero.

II. The fitted regression line passes through $(\bar{x}, \bar{y})$.

III. $\sum_i x_i e_i = 0$, where e_i is the ith residual.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

有截距的最小平方迴歸，下列哪些正確？

I. 殘差和為 0。

II. 迴歸線通過 $(\bar{x}, \bar{y})$。

III. $\sum_i x_i e_i = 0$。

答案

(D)：I、II、III 都正確

解析

三個都是正規方程式的直接結果：對 b_0 偏微分得 $\sum e_i = 0$（I），除以 n 得 $\bar{y} = b_0 + b_1 \bar{x}$（II）；對 b_1 偏微分得 $\sum x_i e_i = 0$（III）。（第 2 章 2.1 節）

觀念 **觀念題 C2.1-3** 仿 SOA 樣題・跨章：第 3 章・回到本節開頭

For a simple linear regression of y on x with least squares slope b_1 and sample correlation r, determine which of the following statements is/are true.

I. b_1 has the same sign as r.

II. The least squares slope of the regression of x on y is $1/b_1$.

III. If every y_i is multiplied by 10, b_1 is multiplied by 10 and R^2 is unchanged.

(A) II only

(B) III only

(C) I and II only

(D) I and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

簡單迴歸的斜率 b_1 與樣本相關係數 r，下列哪些正確？

I. b_1 和 r 同號。

II. x 對 y 迴歸的斜率是 $1/b_1$。

III. 所有 y_i 乘以 10，b_1 乘以 10，R^2 不變。

答案

(D)：只有 I、III 正確

解析

I 對：$b_1 = r\, s_y/s_x$，$s_x, s_y > 0$。

II 錯：x 對 y 的斜率是 $r\, s_x/s_y$。兩個斜率的乘積是 r^2，只有 $|r| = 1$ 時才互為倒數。

III 對：s_y 乘 10 所以 b_1 乘 10；$R^2 = r^2$（第 3 章 3.2 節），相關係數不受尺度影響。

觀念 **觀念題 C2.1-4** 仿 SOA 樣題・跨章：第 3 章・回到本節開頭

Determine which of the following statements is/are true.

I. The least squares estimates can only be computed if the errors are normally distributed.

II. Normality of the errors is needed for the t statistics of the coefficients to have exactly a t distribution in small samples.

III. If the errors are normal, the least squares estimates of the β's are also the maximum likelihood estimates.

(A) III only

(B) I and II only

(C) I and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

下列哪些正確？

I. 誤差必須是常態才能算最小平方估計。

II. 小樣本時，係數的 t 統計量要剛好服從 t 分配，需要誤差常態。

III. 誤差常態時，最小平方估計也是 β 的最大概似估計。

答案

(E)：只有 II、III 正確

解析

I 錯：最小平方只是讓殘差平方和最小，任何資料都算得出來。

II 對：t 分配的推導用到 $\mathbf{b}$ 常態、$\text{Error SS}/\sigma^2$ 為卡方且兩者獨立（第 3 章 3.3 節）。

III 對：常態概似的對數是 $-\mathrm{RSS}/(2\sigma^2)$ 加上與 β 無關的項，最大化概似等於最小化 RSS（第 7 章 7.2 節 AIC 的推導也用到這點）。

觀念 **觀念題 C2.1-5** 仿 SOA 樣題・回到本節開頭

Determine which of the following statements is/are true for a simple linear regression.

I. Predictions for values of x far outside the observed range are unreliable.

II. A fitted slope of zero implies that x and y are independent.

III. If the sample correlation between x and y is zero, the least squares slope is zero.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

簡單迴歸中，下列哪些正確？

I. 對遠超出觀察範圍的 x 做預測不可靠。

II. 配適斜率為 0 表示 x 與 y 獨立。

III. 樣本相關係數為 0 時，最小平方斜率為 0。

答案

(B)：只有 I、III 正確

解析

I 對：外插時模型形式未經資料檢驗，而且預測的變異數隨 $(x-\bar{x})^2$ 變大（第 9 章）。

II 錯：斜率 0 只表示沒有**線性**關係。例如 $y=x^2$、x 對稱分布在 0 附近時，斜率約為 0，但 y 完全由 x 決定。

III 對：$b_1 = r\, s_y / s_x$。

2.2 多元線性迴歸與矩陣形式

一、設計矩陣

$k > 1$ 時，把資料排成矩陣。第一欄全是 1（代表截距），其餘每一欄是一個解釋變數：

$$X = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1k} \\ 1 & x_{21} & x_{22} & \cdots & x_{2k} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{nk} \end{pmatrix}_{n \times (k+1)}, \qquad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix}, \qquad \mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}.$$

X 叫**設計矩陣**（design matrix；名稱來自實驗設計，實驗者可以選 x 的值，保險資料通常不行）。模型寫成 $\mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}$。

二、正規方程式與最小平方解

推導：矩陣形式的最小平方估計

$\text{SSE}(\mathbf{b}) = (\mathbf{y} - X\mathbf{b})'(\mathbf{y} - X\mathbf{b})$。展開（注意 $\mathbf{b}'X'\mathbf{y}$ 是純量，等於它的轉置 $\mathbf{y}'X\mathbf{b}$）：

$$\text{SSE}(\mathbf{b}) = \mathbf{y}'\mathbf{y} - 2\mathbf{b}'X'\mathbf{y} + \mathbf{b}'X'X\mathbf{b}.$$

用向量微分規則 $\partial(\mathbf{b}'\mathbf{a})/\partial\mathbf{b} = \mathbf{a}$、$\partial(\mathbf{b}'A\mathbf{b})/\partial\mathbf{b} = 2A\mathbf{b}$（$A$ 對稱）：

$$\frac{\partial\,\text{SSE}}{\partial\mathbf{b}} = -2X'\mathbf{y} + 2X'X\mathbf{b} = \mathbf{0} \;\Rightarrow\; X'X\mathbf{b} = X'\mathbf{y}.$$

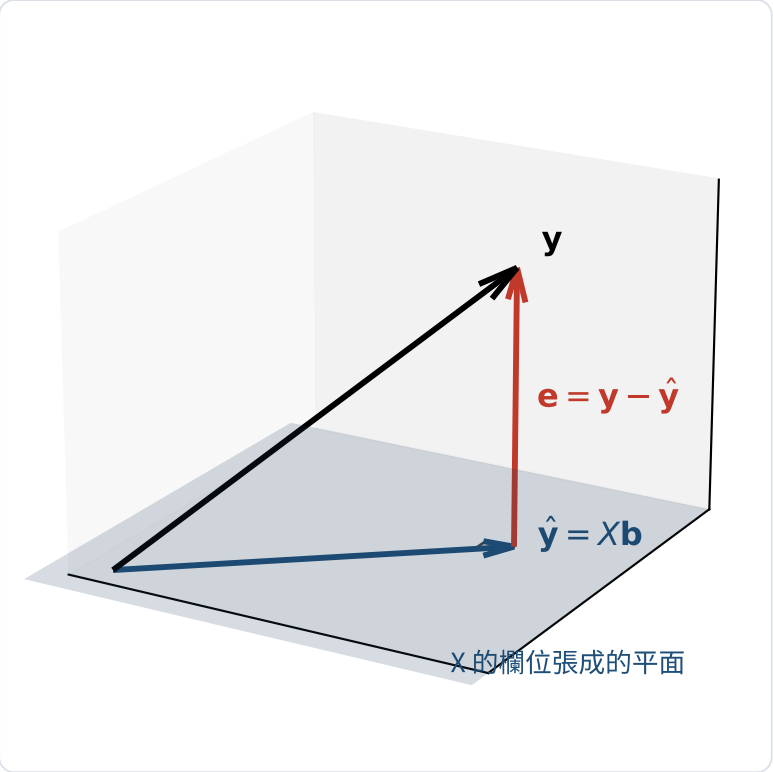
這組方程式叫**正規方程式**（normal equations）。若 $X'X$ 可逆，

$$\boxed{\hat{\boldsymbol{\beta}} = (X'X)^{-1}X'\mathbf{y}}$$

二階導數 $2X'X$ 是正定矩陣（$\mathbf{v}'X'X\mathbf{v} = \|X\mathbf{v}\|^2 > 0$，只要 X 的欄線性獨立），所以是最小值。

配適值向量 $\hat{\mathbf{y}} = X\hat{\boldsymbol{\beta}} = X(X'X)^{-1}X'\mathbf{y} = H\mathbf{y}$，其中 $H = X(X'X)^{-1}X'$ 叫**帽子矩陣**（hat matrix，因為它替 $\mathbf{y}$ 戴上帽子）。第 5 章會用它的對角線元素衡量槓桿。

幾何意義。 正規方程式可以改寫成 $X'(\mathbf{y} - X\hat{\beta}) = X'\mathbf{e} = \mathbf{0}$：殘差向量和 X 的每一欄都垂直。也就是說，$\hat{\mathbf{y}}$ 是 $\mathbf{y}$ 在 X 的欄位所張成空間上的**正交投影**，殘差是垂直於那個空間的部分。因為第一欄全是 1，$\mathbf{1}'\mathbf{e} = \sum e_i = 0$，所以多元迴歸的殘差總和也是 0。



最小平方的幾何：$\hat{\mathbf{y}}$ 是 $\mathbf{y}$ 在 X 欄位空間（藍色平面）上的投影，殘差 $\mathbf{e}$ 和平面垂直。在平面上所有的點裡，$\hat{\mathbf{y}}$ 離 $\mathbf{y}$ 最近，所以 $\|\mathbf{e}\|^2 = \text{SSE}$ 最小。

例題 2-4：用 $(X'X)^{-1}$ 求單一係數

考題常給 $(X'X)^{-1}$，你只需要再算 $X'\mathbf{y}$。$X'\mathbf{y}$ 的第 j 個元素是「第 j 欄和 $\mathbf{y}$ 的內積」：第一個元素是 $\sum y_i$，第二個是 $\sum x_{i1}y_i$，依此類推。若只問 $\hat{\beta}_j$，只要拿 $(X'X)^{-1}$ 的第 j 列（從第 0 列算起）乘 $X'\mathbf{y}$，不必算整個向量。章末 2.20～2.24 題都是這一型。

三、$X'X$ 不可逆：共線性

若 X 的某一欄可以寫成其他欄的線性組合（**完全共線**），$X'X$ 是奇異矩陣，沒有反矩陣，係數無法唯一決定：同一組配適值可以由無限多組係數產生。即使只是「接近」共線，$X'X$ 接近奇異，反矩陣的元素很大，係數估計會非常不穩定，資料稍微變動係數就大幅改變。第 5 章 5.3 節會用變異數膨脹因子（VIF）衡量。

四、類別變數與指標變數

一個有 m 類的類別變數，在有截距的模型裡要放 $m-1$ **個指標變數**（indicator variable，又稱虛擬變數 dummy variable）。每個指標對應一類：屬於那一類為 1，否則為 0。沒有指標的那一類叫**基準類別**（base level、reference level）。

- 為什麼不能放 m 個？因為每筆資料恰好屬於一類，m 個指標加起來永遠等於 1，正好等於截距那一欄，造成完全共線，$X'X$ 不可逆。這叫**虛擬變數陷阱**。
- 基準類別要選哪一類？講義建議選**最常出現**的那一類。若選一個幾乎沒有人屬於的類別當基準，其他指標加起來幾乎總是 1，又接近共線，計算不穩定。
- 只有兩類的變數（例如性別）只需要一個二元指標。

係數怎麼解讀： 截距是基準類別（且其他變數為 0）的平均反應；指標 j 的係數是「第 j 類相對於基準類別」的平均差。換基準類別時，係數會變，但每一類的配適值不變（章末 2.26、2.28 題）。

> **例題 2-5：五個年齡層**
>
> 年齡分 5 層，設第 1 層為基準，放 $D_2, \ldots, D_5$ 四個指標。模型 $E(y) = \beta_0 + \beta_2 D_2 + \cdots + \beta_5 D_5$。則第 1 層平均為 β_0，第 3 層平均為 $\beta_0 + \beta_3$，β_3 是「第 3 層比第 1 層高多少」。

這一節的精選習題

★ 精選 **第 2.22 題** ・講義 p.23・回到對應概念

[120-82-94:11] An automobile insurance company wants to use gender ($x_1 = 0$ if female, 1 if male) and traffic penalty points (x_2) to predict the number of claims (y). The observed values of these variables for a sample of six motorists are given by:

Motorist	x_1	x_2	y
1	0	0	1
2	0	1	0
3	0	2	2
4	1	0	1
5	1	1	3
6	1	2	5

You are to use the following model:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i, \qquad i = 1, 2, \ldots, 6$$

You have determined

$$(X'X)^{-1} = \frac{1}{12}\begin{pmatrix} 7 & -4 & -3 \\ -4 & 8 & 0 \\ -3 & 0 & 3 \end{pmatrix}$$

Determine $\hat{\beta}_2$.

(A) -0.25

(B) 0.25

(C) 1.25

(D) 2.00

(E) 4.25

中文題意

（舊考題 120-82-94:11）汽車保險公司用性別（$x_1 = 0$ 女、1 男）與違規點數 x_2 預測理賠次數 y。六位駕駛人：

模型 $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i$，已知 $(X'X)^{-1} = \frac{1}{12}\begin{pmatrix} 7 & -4 & -3 \\ -4 & 8 & 0 \\ -3 & 0 & 3 \end{pmatrix}$。求 $\hat{\beta}_2$。

(A) -0.25　(B) 0.25　(C) 1.25　(D) 2.00　(E) 4.25

（數據、圖表與選項見上方英文題目。）

答案

(C) 1.25

解析

第一步：$X'\mathbf{y}$。 $\sum y = 12$；$\sum x_1 y = 1 + 3 + 5 = 9$；$\sum x_2 y = 0(1) + 1(0) + 2(2) + 0(1) + 1(3) + 2(5) = 17$。

第二步： 取反矩陣第 2 列 $\frac{1}{12}(-3, 0, 3)$：

$$\hat{\beta}_2 = \frac{-3(12) + 0(9) + 3(17)}{12} = \frac{15}{12} = 1.25.$$

（另外兩個係數：$\hat{\beta}_0 = \frac{7(12) - 4(9) - 3(17)}{12} = -0.25$，$\hat{\beta}_1 = \frac{-4(12) + 8(9)}{12} = 2$。干擾選項 (A)、(D) 就是它們。）

觀念題（5 題，仿 SOA 樣題的質性題，含跨章節）

觀念 **觀念題 C2.2-1** 仿 SOA 樣題・跨章：第 5 章・回到本節開頭

For a multiple regression $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$, determine which of the following statements is/are true.

I. β_1 is the expected change in y for a one-unit increase in x_1, holding x_2 constant.

II. The least squares estimate b_1 equals the slope of the simple regression of y on x_1.

III. Adding x_2 to a model that already contains x_1 can change the sign of the coefficient of x_1.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

多元迴歸 $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$，下列哪些正確？

I. β_1 是 x_2 固定時 x_1 增加一單位 y 的期望變化。

II. b_1 等於 y 對 x_1 簡單迴歸的斜率。

III. 在含 x_1 的模型加入 x_2，可能讓 x_1 的係數變號。

答案

(B)：只有 I、III 正確

解析

I 對：這是多元迴歸係數的解讀。

II 錯：只有 x_1 與 x_2（中心化後）正交時才相等。一般情況下，b_1 只用到 x_1 中和 x_2 無關的部分（第 5 章 5.3 節的 FWL 定理）。

III 對：若 x_1 與 x_2 相關，單獨用 x_1 時它的係數同時吸收了 x_2 的效果，控制 x_2 後可能反轉（遺漏變數偏誤）。

觀念 **觀念題 C2.2-2** 仿 SOA 樣題・跨章：第 5 章・回到本節開頭

Determine which of the following statements about the matrix $X'X$ in least squares regression is/are true.

I. If the number of observations is less than the number of coefficients, $X'X$ is not invertible.

II. If one explanatory variable is a linear combination of the others, $X'X$ is not invertible.

III. If $X'X$ is not invertible, the fitted values $\hat{\mathbf{y}}$ are not unique.

(A) II only

(B) III only

(C) I and II only

(D) I and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

關於最小平方中的 $X'X$，下列哪些正確？

I. 觀察筆數少於係數個數時，$X'X$ 不可逆。

II. 某個解釋變數是其他變數的線性組合時，$X'X$ 不可逆。

III. $X'X$ 不可逆時，配適值 $\hat{\mathbf{y}}$ 不唯一。

答案

(C)：只有 I、II 正確

解析

I 對：X 的秩最多是 n，小於係數個數 $k+1$ 時欄必定線性相依。

II 對：完全共線（第 5 章 5.3 節）。

III 錯：$\hat{\mathbf{y}}$ 是 $\mathbf{y}$ 在 X 欄位空間上的投影，永遠唯一；不唯一的是係數 $\mathbf{b}$（$\mathbf{b}+t\mathbf{v}$ 都是解）。

觀念 **觀念題 C2.2-3** 仿 SOA 樣題・回到本節開頭

Least squares estimates satisfy the normal equations $X'(\mathbf{y} - X\mathbf{b}) = \mathbf{0}$. Determine which of the following statements is/are true.

I. The residual vector is orthogonal to every column of X.

II. The residual vector is orthogonal to the vector of fitted values.

III. The residuals sum to zero even if the model has no intercept.

(A) I only

(B) II only

(C) III only

(D) I and II only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

最小平方解滿足正規方程式 $X'(\mathbf{y} - X\mathbf{b}) = \mathbf{0}$。下列哪些正確？

I. 殘差向量和 X 的每一欄垂直。

II. 殘差向量和配適值向量垂直。

III. 即使沒有截距，殘差和也為 0。

答案

(D)：只有 I、II 正確

解析

I 對：正規方程式逐列讀出來就是 $\sum_i e_i x_{ij} = 0$。

II 對：$\hat{\mathbf{y}}'\mathbf{e} = \mathbf{b}'X'\mathbf{e} = 0$。

III 錯：殘差和為 0 來自「X 有一欄全為 1」。沒有截距時這一欄不存在，殘差和一般不為 0。

觀念 **觀念題 C2.2-4** 仿 SOA 樣題・跨章：第 1 章・回到本節開頭

A categorical variable with c levels is used in a linear regression. Determine which of the following statements is/are true.

I. If the model has an intercept, including indicators for all c levels makes $X'X$ singular.

II. If the model has no intercept, indicators for all c levels can be included.

III. An interaction between two binary indicator variables adds one parameter to the model.

(A) III only

(B) I and II only

(C) I and III only

(D) II and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

含 c 個水準的類別變數放進線性迴歸。下列哪些正確？

I. 有截距時放 c 個指標，$X'X$ 不可逆。

II. 沒有截距時可以放 c 個指標。

III. 兩個二元指標變數的交互作用多一個參數。

答案

(E)：I、II、III 都正確

解析

I 對：c 個指標相加等於截距那一欄（每筆恰有一個指標為 1），完全共線，俗稱虛擬變數陷阱。

II 對：拿掉截距後 c 個指標線性獨立，每個係數就是該類的平均。

III 對：x_1x_2 只是一欄，一個係數（第 2 章習題 2.26）。

觀念 **觀念題 C2.2-5** 仿 SOA 樣題・跨章：第 5 章・回到本節開頭

Let $H = X(X'X)^{-1}X'$ for a regression with k explanatory variables and an intercept. Determine which of the following statements is/are true.

I. $\hat{\mathbf{y}} = H\mathbf{y}$, and H is symmetric and idempotent.

II. The trace of H is $k + 1$.

III. The covariance matrix of the residual vector is $\sigma^2 I$.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

$H = X(X'X)^{-1}X'$，模型有 k 個解釋變數與截距。下列哪些正確？

I. $\hat{\mathbf{y}} = H\mathbf{y}$，$H$ 對稱且冪等。

II. H 的跡為 $k + 1$。

III. 殘差向量的共變異矩陣為 $\sigma^2 I$。

答案

(A)：只有 I、II 正確

解析

I、II 對（第 5 章 5.1 節的推導）。

III 錯：$\sigma^2 I$ 是**誤差**的共變異矩陣；殘差的是 $\sigma^2(I - H)$，變異數比 σ^2 小，而且殘差彼此相關。

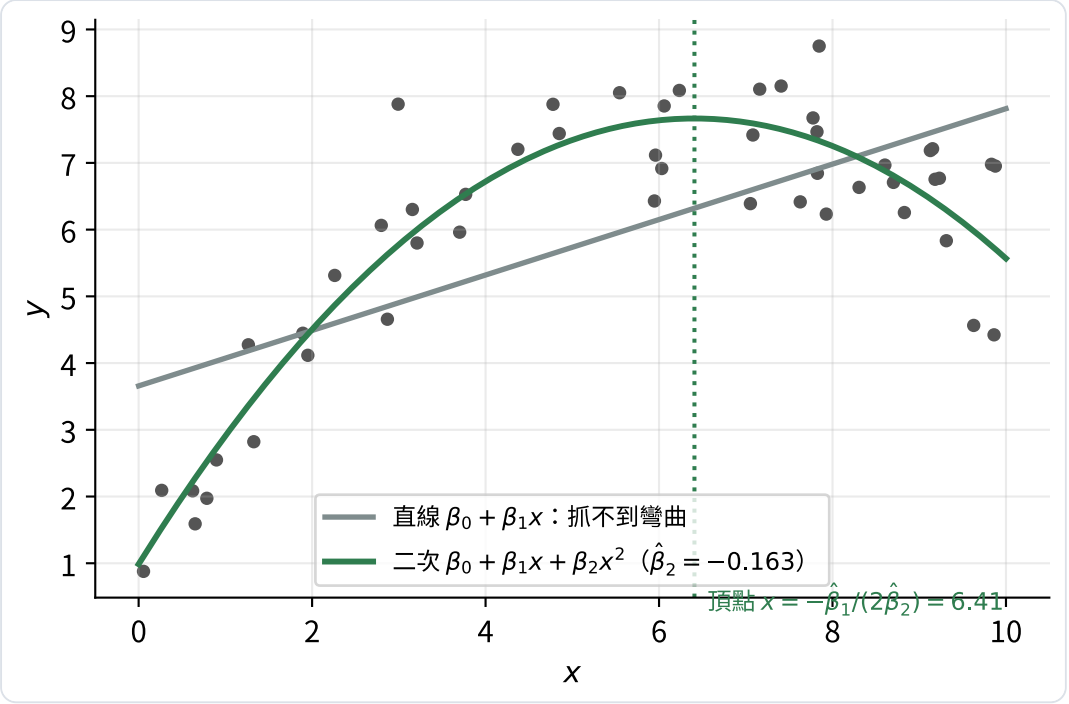
2.3 其他模型形式

線性迴歸只要求對參數線性，所以可以把各種非線性的關係放進來。

一、多項式

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \beta_3 x_i^3 + \varepsilon_i.$$

把 x, x^2, x^3 當成三個不同的解釋變數，照常做最小平方。注意此時 β_1 不再是「x 增加 1 單位的效果」：二次模型 $\beta_0 + \beta_1 x + \beta_2 x^2$ 的邊際效果是 $\dfrac{dE(y)}{dx} = \beta_1 + 2\beta_2 x$，會隨 x 改變。$\beta_2 < 0$ 時曲線開口向下，頂點在 $x = -\beta_1/(2\beta_2)$。



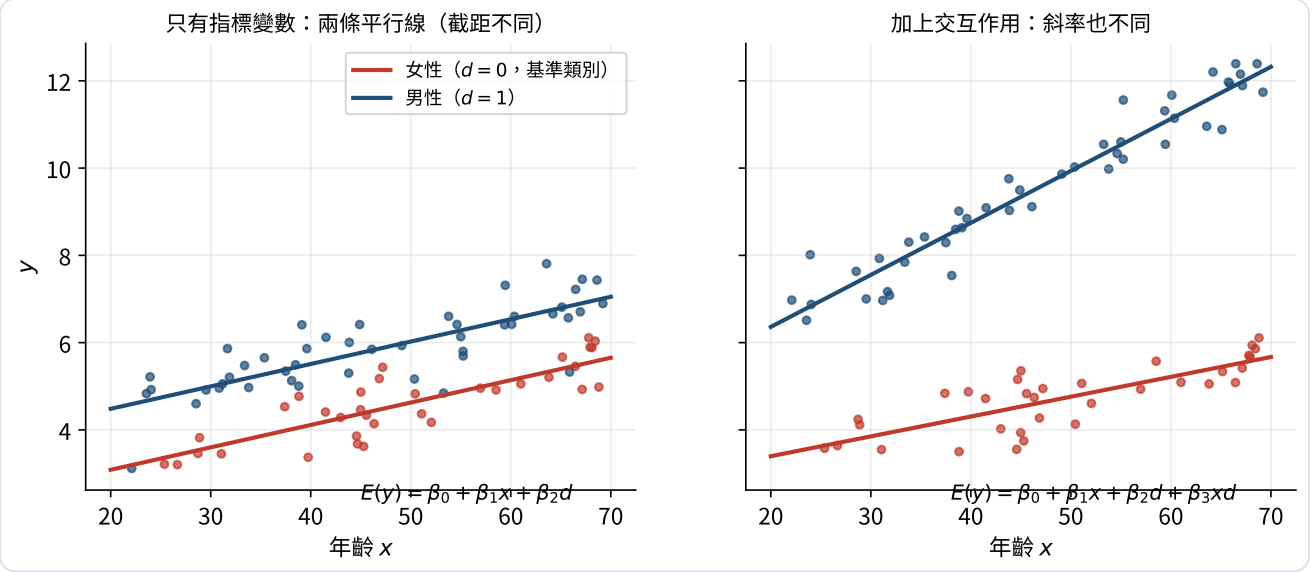
彎曲的資料：直線系統性地在兩端高估、中間低估；加入 x^2 之後抓到了彎曲。

二、交互作用

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i1} x_{i2} + \varepsilon_i.$$

交互作用（interaction）項 $x_1 x_2$ 讓一個變數的效果依另一個變數而定：$\partial E(y)/\partial x_1 = \beta_1 + \beta_3 x_2$。最常見的是連續變數乘上指標變數。若 d 是性別指標（女性 0、男性 1）、x 是年齡：

- 只有指標：$E(y) = \beta_0 + \beta_1 x + \beta_2 d$。女性的線是 $\beta_0 + \beta_1 x$，男性的線是 $(\beta_0 + \beta_2) + \beta_1 x$，兩條**平行**，男性整體高 β_2。
- 加交互作用：$E(y) = \beta_0 + \beta_1 x + \beta_2 d + \beta_3 x d$。女性斜率 β_1，男性斜率 $\beta_1 + \beta_3$，兩條線**斜率不同**。



指標變數與交互作用。左：指標變數只讓截距不同，兩條線平行。右：加入年齡×性別的交互作用後，男性的斜率比女性大 β_3。

計算參數個數時，交互作用項各算一個參數（章末 2.25 題）。

三、對解釋變數做轉換

例如 $y_i = \beta_0 + \beta_1 e^{x_i} + \varepsilon_i$：先算出 $z_i = e^{x_i}$，再對 z 做普通的迴歸。對 $\ln x$、$\sqrt{x}$ 等也一樣。

四、加權最小平方

若同質變異不成立，而且我們**事先知道**變異數怎麼變：$\mathrm{Var}(\varepsilon_i) = \sigma^2 / w_i$（$\sigma^2$ 本身可以不知道）。w_i 叫第 i 筆的**精確度**：$w_i = 0$ 表示完全沒有資訊（只能丟掉），$w_i \to \infty$ 表示是精確值。

推導：加權最小平方估計

把第 i 筆的所有變數（包括截距那一欄的 1）都乘上 $\sqrt{w_i}$：

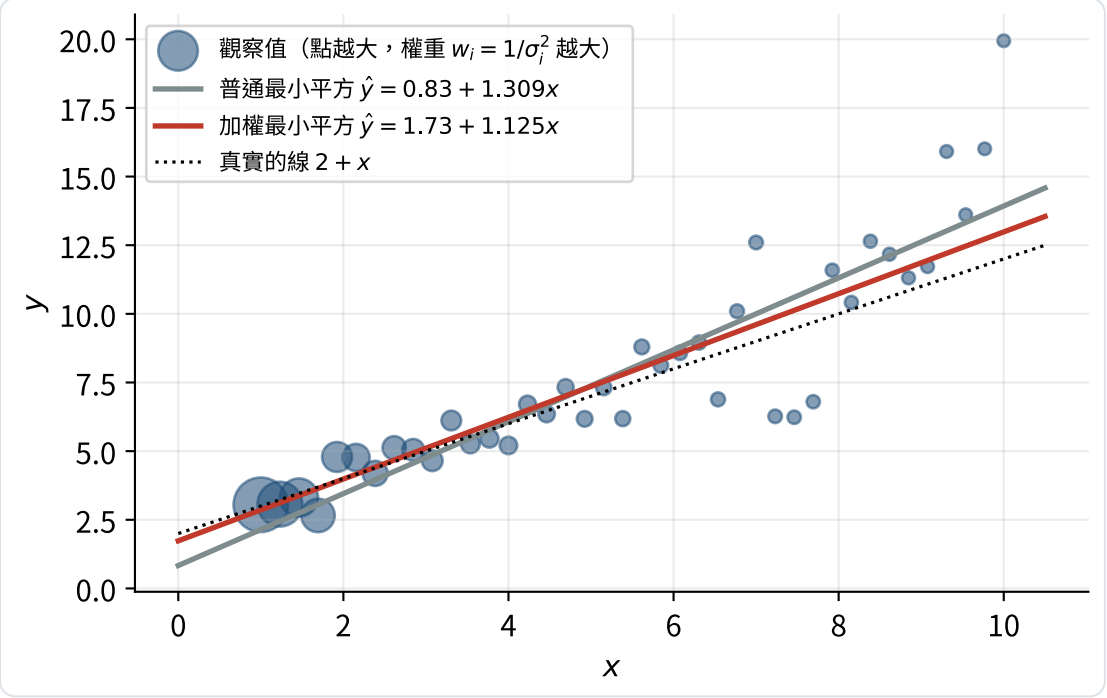
$$\sqrt{w_i}\,y_i = \beta_0\sqrt{w_i} + \beta_1\sqrt{w_i}\,x_{i1} + \cdots + \sqrt{w_i}\,\varepsilon_i.$$

新的誤差 $\sqrt{w_i}\,\varepsilon_i$ 的變異數是 $w_i \cdot \sigma^2/w_i = \sigma^2$，對每一筆都相同，同質變異成立了。令 $W = \mathrm{diag}(w_1, \ldots, w_n)$，轉換後的資料是 $W^{1/2}X$ 與 $W^{1/2}\mathbf{y}$，套用普通最小平方公式：

$$\hat{\boldsymbol{\beta}}_W = \left[(W^{1/2}X)'(W^{1/2}X)\right]^{-1}(W^{1/2}X)'W^{1/2}\mathbf{y} = (X'WX)^{-1}X'W\mathbf{y}.$$

等價地，它最小化的是加權平方和 $\sum_i w_i(y_i - \mathbf{x}_i'\mathbf{b})^2$：變異數大的觀察值權重小。

這叫**加權最小平方估計**（weighted least squares，WLS）。例如 y_i 是 n_i 個保單的平均理賠，平均數的變異數是 σ^2/n_i，就取 $w_i = n_i$。



變異數隨 x 增加的資料（右邊幾個點特別偏高）。普通最小平方把每一點一視同仁，被右邊雜訊大的點拉高；加權最小平方給雜訊小的左邊點較大權重，估計更接近真實的線。

五、對反應變數做轉換：對數

若 y 的變異數隨 y 變大而變大（散布圖呈喇叭形），或 y 右偏，常對 y 取對數：

$$\ln y_i = \beta_0 + \beta_1 x_i + \varepsilon_i \quad \Longleftrightarrow \quad y_i = e^{\beta_0+\beta_1 x_i+\varepsilon_i} = e^{\beta_0+\beta_1 x_i} \cdot e^{\varepsilon_i}.$$

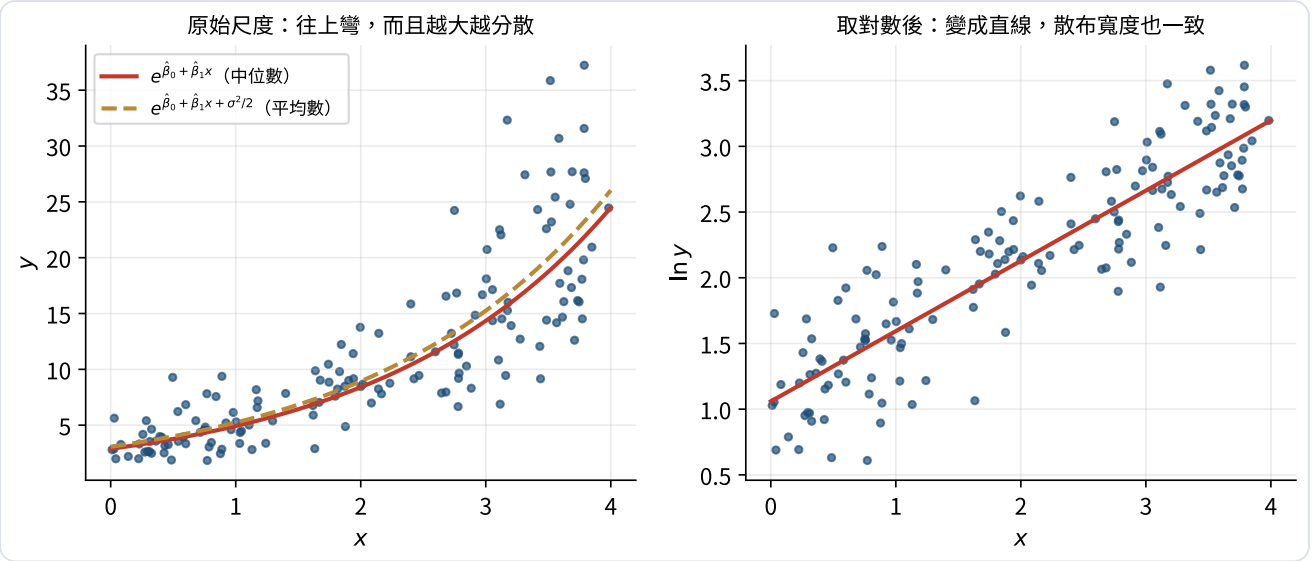
在原始尺度上，誤差是乘法的：x 每增加 1，y 的典型值乘上 e^{β_1}（β_1 小時約增加 $100\beta_1\%$）。$\ln y$ 為常態表示 y 為**對數常態**，而對數常態是右偏的，所以取對數也能去掉偏態。

推導：轉換回原尺度時的平均數

若 $\ln y \mid x \sim N(\mu, \sigma^2)$，$\mu = \beta_0 + \beta_1 x$。對數常態的平均數是

$$E(y \mid x) = E(e^{\ln y}) = e^{\mu+\sigma^2/2},$$

（常態的動差母函數 $E(e^{tZ}) = e^{t\mu+t^2\sigma^2/2}$ 取 $t = 1$）。而 e^{μ} 是 y 的**中位數**（$P(\ln y \le \mu) = 0.5$）。所以直接把 $\widehat{\ln y}$ 取指數，得到的是中位數的估計，會低估平均數。講義與考題通常直接用 $e^{\hat\beta_0+\hat\beta_1 x}$ 當預測值（章末 2.12 題）。



乘法誤差的資料。左：原始尺度上曲線往上彎、而且越大越分散；紅線是 $e^{\hat\beta_0+\hat\beta_1 x}$（中位數），金色虛線多乘了 $e^{\sigma^2/2}$（平均數）。右：取對數後成為直線，散布寬度一致，符合同質變異。

六、Box–Cox 冪轉換

一般化的轉換族是 **Box–Cox 冪轉換**（Box–Cox power transformation）：

$$y^{(\lambda)} = \begin{cases} \dfrac{y^\lambda - 1}{\lambda}, & \lambda \neq 0 \\ \ln y, & \lambda = 0 \end{cases} \qquad (y > 0).$$

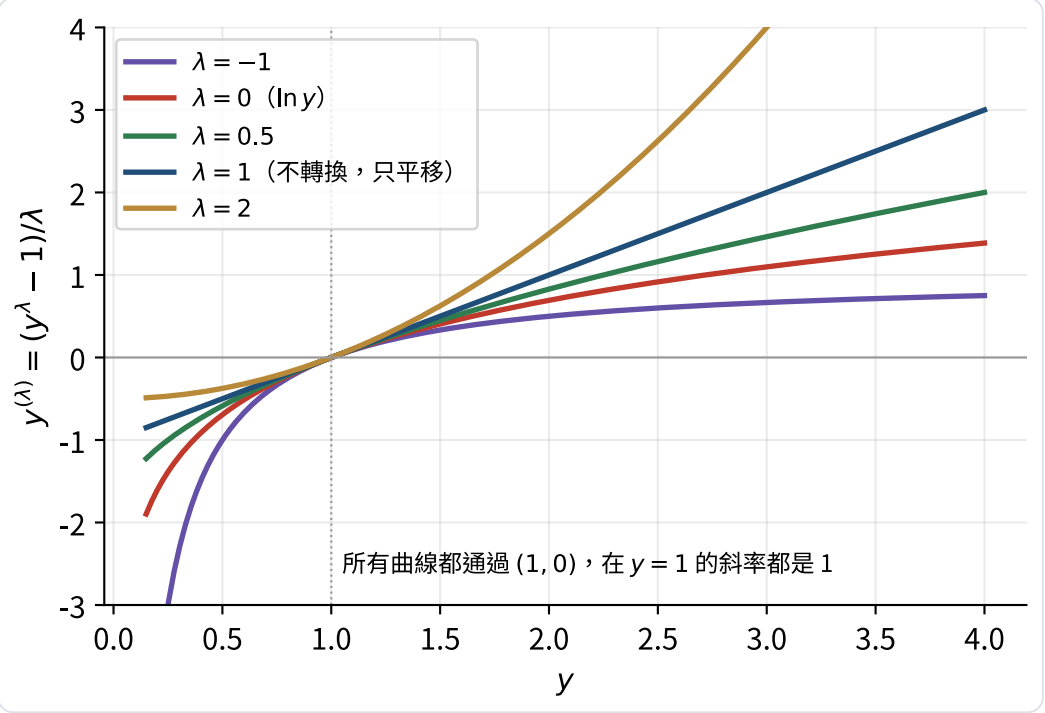
它包含任何次方（正、負）與對數。減 1 再除以 λ 不會實質改變迴歸（只改變截距與係數的尺度），用 y^λ 也一樣；這樣寫的唯一目的是讓 $\lambda \to 0$ 時連續地接到 $\ln y$：

推導：$\lambda \to 0$ 時 $y^{(\lambda)} \to \ln y$

$y^\lambda = e^{\lambda \ln y} = 1 + \lambda \ln y + \dfrac{(\lambda \ln y)^2}{2} + \cdots$，所以

$$\frac{y^\lambda - 1}{\lambda} = \ln y + \frac{\lambda (\ln y)^2}{2} + \cdots \xrightarrow{\lambda \to 0} \ln y.$$

（也可以用羅必達法則：分子分母對 λ 微分，得 $y^\lambda \ln y / 1 \to \ln y$。）



Box–Cox 轉換族。$\lambda = 1$ 只是平移，不改變形狀；$\lambda < 1$ 會壓縮大的值（$\lambda = 0.5$ 是平方根、$\lambda = 0$ 是對數、$\lambda = -1$ 是倒數），可以用來修正右偏與喇叭形的變異。所有曲線都通過 $(1, 0)$。

本章公式總表（講義表 2.1）

- 簡單迴歸：$\hat\beta_1 = \dfrac{S_{xy}}{S_{xx}} = r_{xy}\dfrac{s_y}{s_x}$，$\hat\beta_0 = \bar y - \hat\beta_1 \bar x$。
- 多元迴歸：$\hat{\boldsymbol\beta} = (X'X)^{-1}X'\mathbf{y}$。
- 有截距的任何迴歸：$\sum e_i = 0$。
- 加權最小平方：$\hat{\boldsymbol\beta}_W = (X'WX)^{-1}X'W\mathbf{y}$。
- Box–Cox：$y^{(\lambda)} = (y^\lambda - 1)/\lambda$，$\lambda = 0$ 時為 $\ln y$。

這一節的精選習題

★ 精選 **第 2.12 題** ・講義 p.19・回到對應概念

The following model relates Y to X:

$$Y_i = \exp(\beta_0 + \beta_1 X_i + \varepsilon_i)$$

For 10 observations, you are given:

(i) $\sum X_i = 13.5$

(ii) $\sum \ln Y_i = 9.681$

(iii) $\sum X_i^2 = 19.57$

(iv) $\sum (\ln Y_i)^2 = 9.690$

(v) $\sum X_i \ln Y_i = 13.697$

Calculate the prediction of Y when $X = 2$.

(A) 3.2

(B) 3.6

(C) 4.0

(D) 4.4

(E) 4.8

中文題意

模型 $Y_i = \exp(\beta_0 + \beta_1 X_i + \varepsilon_i)$。10 筆觀察：$\sum X_i = 13.5$、$\sum \ln Y_i = 9.681$、$\sum X_i^2 = 19.57$、$\sum (\ln Y_i)^2 = 9.690$、$\sum X_i \ln Y_i = 13.697$。求 $X = 2$ 時 Y 的預測值。

(A) 3.2　(B) 3.6　(C) 4.0　(D) 4.4　(E) 4.8

答案

(B) 約 3.566

解析

取對數：$\ln Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$，是 $\ln Y$ 對 X 的普通線性迴歸。令 $Z_i = \ln Y_i$。

第一步： $\bar{X} = 1.35$，$\bar{Z} = 0.9681$。

$$S_{XX} = 19.57 - \frac{13.5^2}{10} = 19.57 - 18.225 = 1.345,$$

$$S_{XZ} = 13.697 - \frac{13.5 \times 9.681}{10} = 13.697 - 13.06935 = 0.62765.$$

第二步： $\hat{\beta}_1 = 0.62765 / 1.345 = 0.46665$；$\hat{\beta}_0 = 0.9681 - 0.46665 \times 1.35 = 0.33812$。

第三步：預測 $\ln Y$，再轉回去。 $\widehat{\ln Y}(2) = 0.33812 + 0.46665 \times 2 = 1.27142$，$\hat{Y} = e^{1.27142} = 3.566$。

易錯

- 這裡的預測值直接取 $e^{\widehat{\ln Y}}$，是 Y 的中位數估計。若要平均數還要乘 $e^{\sigma^2/2}$（本章 2.3 節），題目沒有給 σ^2，也沒有要求。
- 不能先把 $\sum \ln Y$ 換成 $\ln \sum Y$，對數只能逐筆取。

★ 精選 **第 2.25 題** ・講義 p.24・回到對應概念

[S-F15:35] You are given a regression model of liability claims with the following potential explanatory variables only:

- Vehicle price, which is a continuous variable modeled with a third order polynomial
- Average driver age, which is a continuous variable modeled with a first order polynomial
- Number of drivers, which is a categorical variable with four levels
- Gender, which is a categorical variable with two levels

There is only one interaction in the model, which is between gender and average driver age.

Determine the maximum number of parameters in this model.

(A) Less than 9

(B) 9

(C) 10

(D) 11

(E) At least 12

中文題意

（S-F15:35）責任險理賠的迴歸模型只有下列可能的解釋變數：

- 車價：連續變數，用三次多項式
- 平均駕駛人年齡：連續變數，用一次項
- 駕駛人數：類別變數，4 個水準
- 性別：類別變數，2 個水準

模型中唯一的交互作用是性別與平均駕駛人年齡。求這個模型最多有幾個參數。

（數據、圖表與選項見上方英文題目。）

答案

(C) 10

解析

逐項數參數：

項目	參數	個數
截距	β_0	1
車價三次多項式	p, p^2, p^3 的係數	3
平均年齡	a 的係數	1
駕駛人數（4 水準）	$4-1$ 個指標	3
性別（2 水準）	$2-1$ 個指標	1
性別 × 年齡	交互作用	1
合計		**10**

易錯

有截距時 m 個水準只能放 $m-1$ 個指標；多項式的每一次方各一個參數；交互作用另算一個。

★ 精選 **第 2.26 題** ・講義 p.25・回到對應概念

[MAS-I-S18:37] You fit a linear model using the following two-level categorical variables:

$$X_1 = \begin{cases} 1 & \text{if Account} \\ 0 & \text{if Monoline} \end{cases} \qquad X_2 = \begin{cases} 1 & \text{if Multi-Car} \\ 0 & \text{if Single Car} \end{cases}$$

with the equation $E[Y] = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2$. This model produced the following parameter estimates:

$$\hat{\beta}_0 = -0.10 \qquad \hat{\beta}_1 = -0.25 \qquad \hat{\beta}_2 = 0.58 \qquad \hat{\beta}_3 = -0.20$$

Another actuary modeled the same underlying data, but coded the variables differently as such:

$$X_1 = \begin{cases} 0 & \text{if Account} \\ 1 & \text{if Monoline} \end{cases} \qquad X_2 = \begin{cases} 0 & \text{if Multi-Car} \\ 1 & \text{if Single Car} \end{cases}$$

with the equation $E[Y] = \alpha_0 + \alpha_1 X_1 + \alpha_2 X_2 + \alpha_3 X_1 X_2$.

Afterwards you make a comparison of the individual parameter estimates in the two models. Calculate how many pairs of coefficient estimates $(\hat{\alpha}_j, \hat{\beta}_j)$ switched signs, and how many pairs of estimates stayed identically the same, when results of the two models are compared.

(A) 1 sign change, 0 identical estimates

(B) 1 sign change, 1 identical estimate

(C) 2 sign changes, 0 identical estimates

(D) 2 sign changes, 1 identical estimate

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

（MAS-I 2018 春 #37）用兩個二元類別變數配適線性模型：$X_1 = 1$ 為 Account、0 為 Monoline；$X_2 = 1$ 為 Multi-Car、0 為 Single Car。模型

$E(Y) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2$，估計值 $\hat{\beta}_0 = -0.10$、$\hat{\beta}_1 = -0.25$、$\hat{\beta}_2 = 0.58$、$\hat{\beta}_3 = -0.20$。

另一位精算師用同一份資料，但把兩個變數的編碼都反過來（$X_1 = 0$ 為 Account、1 為 Monoline；$X_2 = 0$ 為 Multi-Car、1 為 Single Car），模型 $E(Y) = \alpha_0 + \alpha_1 X_1 + \alpha_2 X_2 + \alpha_3 X_1 X_2$。

比較 $(\hat{\alpha}_j, \hat{\beta}_j)$ 四對係數：有幾對變號？有幾對完全相同？

(A) 1 對變號、0 對相同　(B) 1 對變號、1 對相同　(C) 2 對變號、0 對相同
(D) 2 對變號、1 對相同　(E) 以上皆非

答案

(E)：3 對變號、1 對相同

解析

新的編碼 $U = 1 - X_1$、$V = 1 - X_2$。兩個模型描述的是同樣四個格子的平均，所以每一格的配適值必須相同。代入 $X_1 = 1 - U$、$X_2 = 1 - V$：

$$\beta_0 + \beta_1(1-U) + \beta_2(1-V) + \beta_3(1-U)(1-V)$$

$$= (\beta_0 + \beta_1 + \beta_2 + \beta_3) - (\beta_1 + \beta_3)U - (\beta_2 + \beta_3)V + \beta_3 UV.$$

對照係數：- $\alpha_0 = -0.10 - 0.25 + 0.58 - 0.20 = 0.03$（由負變正，變號）- $\alpha_1 = -(\beta_1 + \beta_3) = -(-0.25 - 0.20) = 0.45$（由負變正，變號）- $\alpha_2 = -(\beta_2 + \beta_3) = -(0.58 - 0.20) = -0.38$（由正變負，變號）- $\alpha_3 = \beta_3 = -0.20$（完全相同）

3 對變號、1 對相同，不在 (A)～(D) 裡。

也可以用四個格子驗算：Account + Multi-Car 的平均，原模型 $-0.10 - 0.25 + 0.58 - 0.20 = 0.03$；新模型這一格 $U = V = 0$，平均 $\alpha_0 = 0.03$，一致。

易錯

> 交互作用係數不會因為兩個變數同時反向編碼而改變；但只反轉其中一個時，交互作用係數會變號。

觀念題（5 題，仿 SOA 樣題的質性題，含跨章節）

觀念 **觀念題 C2.3-1** 仿 SOA 樣題・回到本節開頭

A model $y = \beta_0 + \beta_1 x + \beta_2 x^2 + \varepsilon$ is fitted by least squares. Determine which of the following statements is/are true.

I. The model is a linear regression model.

II. β_1 is the expected change in y for a one-unit increase in x.

III. Polynomials of high degree can behave erratically near the boundary of the observed x values.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

以最小平方配適 $y = \beta_0 + \beta_1 x + \beta_2 x^2 + \varepsilon$。下列哪些正確？

I. 這是線性迴歸模型。

II. β_1 是 x 增加一單位 y 的期望變化。

III. 高次多項式在觀察範圍的邊界附近可能變化劇烈。

答案

(B)：只有 I、III 正確

解析

I 對：「線性」指對**參數**線性，x^2 只是另一欄解釋變數。

II 錯：x 增加一單位的效果是 $\beta_1 + \beta_2(2x+1)$，依 x 的位置而定；x 與 x^2 不能「一個固定、另一個變」。

III 對：高次多項式的彈性高、變異數大，邊界附近尤其明顯（第 6 章交叉驗證的圖）。

觀念 **觀念題 C2.3-2** 仿 SOA 樣題・回到本節開頭

The model $\ln y = \beta_0 + \beta_1 x + \varepsilon$, $\varepsilon \sim N(0, \sigma^2)$, is fitted. Determine which of the following statements is/are true.

I. A one-unit increase in x multiplies the median of y by e^{β_1}.

II. $E(y \mid x) = e^{\beta_0 + \beta_1 x}$.

III. Taking logs of the response can reduce heteroscedasticity when the variance of y grows with its mean.

(A) III only

(B) I and II only

(C) I and III only

(D) II and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

配適 $\ln y = \beta_0 + \beta_1 x + \varepsilon$，$\varepsilon$ 常態。下列哪些正確？

I. x 增加一單位，y 的中位數乘以 e^{β_1}。

II. $E(y \mid x) = e^{\beta_0 + \beta_1 x}$。

III. y 的變異數隨平均增加時，取對數可以減輕異質變異。

答案

(C)：只有 I、III 正確

解析

I 對：$\ln y$ 的中位數是 $\beta_0 + \beta_1 x$，取指數得 y 的中位數 $e^{\beta_0 + \beta_1 x}$。

II 錯：y 是對數常態，$E(y \mid x) = e^{\beta_0 + \beta_1 x + \sigma^2/2}$，多一個 $e^{\sigma^2/2}$（第 2 章 2.3 節）。

III 對：乘法型的誤差取對數後變成加法型、變異數固定。

觀念 **觀念題 C2.3-3** 仿 SOA 樣題・跨章：第 5 章・回到本節開頭

The variance of the error of observation i is σ^2/w_i with known w_i. Determine which of the following statements is/are true.

I. Weighted least squares uses weights inversely proportional to the variances of the errors.

II. If y_i is the average of n_i independent claims with common variance, an appropriate weight is n_i.

III. Ordinary least squares estimates are biased when the errors are heteroscedastic, and weighted least squares removes this bias.

(A) I only

(B) II only

(C) III only

(D) I and II only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

第 i 筆誤差的變異數為 σ^2/w_i，w_i 已知。下列哪些正確？

I. 加權最小平方的權重和誤差變異數成反比。

II. y_i 是 n_i 個獨立、變異數相同的理賠的平均時，適當的權重是 n_i。

III. 異質變異時普通最小平方的估計有偏，加權最小平方消除了偏誤。

答案

(D)：只有 I、II 正確

解析

I 對：權重是變異數的倒數（不是標準差的倒數，第 5 章 5.1 節的提醒）。

II 對：平均數的變異數是 σ^2/n_i。

III 錯：異質變異不影響普通最小平方的**不偏性**（推導 $E(\mathbf{b}) = \boldsymbol{\beta}$ 只用到 $E(\boldsymbol{\varepsilon}) = \mathbf{0}$）。問題在於它不再是變異數最小的估計，而且通常的標準誤公式錯

了。加權最小平方改善的是效率。

觀念 **觀念題 C2.3-4** 仿 SOA 樣題・回到本節開頭

The Box–Cox family transforms a positive response y to $(y^{\lambda}-1)/\lambda$ for $\lambda \neq 0$ and $\ln y$ for $\lambda = 0$. Determine which of the following statements is/are true.

I. $\lambda = 0$ corresponds to the log transformation.

II. $\lambda = 1$ corresponds to no transformation other than a shift.

III. The Box–Cox transformation can be applied directly to responses that take negative values.

(A) II only

(B) III only

(C) I and III only

(D) II and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

Box–Cox 轉換：$\lambda \neq 0$ 時 $(y^{\lambda}-1)/\lambda$，$\lambda = 0$ 時 $\ln y$。下列哪些正確？

I. $\lambda = 0$ 是對數轉換。

II. $\lambda = 1$ 除了平移外沒有轉換。

III. Box–Cox 可以直接用在有負值的反應。

答案

(E)：只有 I、II 正確

解析

I 對：$\lambda \to 0$ 時 $(y^{\lambda}-1)/\lambda \to \ln y$，這正是減 1 再除以 λ 的用意。

II 對：$\lambda = 1$ 得 $y - 1$。

III 錯：非整數次方與對數都要求 $y > 0$；有負值時要先平移。

觀念 **觀念題 C2.3-5** 仿 SOA 樣題・跨章：第 4 章・回到本節開頭

Salary y is modeled on experience x_1 and a gender indicator x_2: $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2 + \varepsilon$. Determine which of the following statements is/are true.

I. To test whether the relationship between salary and experience is identical for both genders, test $\beta_2 = \beta_3 = 0$ with a partial F test.

II. The t test of $\beta_3 = 0$ alone is sufficient to test whether the two relationships are identical.

III. When the interaction $x_1 x_2$ is included, the main effect x_2 is usually kept in the model as well.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

薪資對年資 x_1 與性別指標 x_2：$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2 + \varepsilon$。下列哪些正確？

I. 檢定兩性的薪資—年資關係是否相同，要用部分 F 檢定 $\beta_2 = \beta_3 = 0$。

II. 只用 $\beta_3 = 0$ 的 t 檢定就夠了。

III. 放了交互作用 $x_1 x_2$，通常也保留主效果 x_2。

答案

(B)：只有 I、III 正確

解析

I 對：「關係相同」表示截距與斜率都相同，兩個限制要一起檢定（第 4 章習題 4.25）。

II 錯：$\beta_3 = 0$ 只檢定斜率相同，兩條線仍可能截距不同（平行但不重合）。

III 對：階層原則（hierarchical principle）。只放交互作用、不放主效果，會強迫 $x_1 = 0$ 時兩性的平均相同，通常沒有道理。

章末其餘習題（18 題，★ 精選題已放在各節後面）

練習 **第 2.3 題** ・講義 p.17・回到對應概念

[SRM Sample Question #17] The regression model is $y = \beta_0 + \beta_1 x + \varepsilon$. There are six observations. The summary statistics are:

$$\sum y_i = 8.5 \qquad \sum x_i = 6 \qquad \sum x_i^2 = 16 \qquad \sum x_i y_i = 15.5 \qquad \sum y_i^2 = 17.25$$

Calculate the least squares estimate of β_1.

(A) 0.1

(B) 0.3

(C) 0.5

(D) 0.7

(E) 0.9

中文題意

（SRM 樣題 #17）迴歸模型 $y = \beta_0 + \beta_1 x + \varepsilon$，共 6 筆觀察。摘要統計：$\sum y_i = 8.5$、$\sum x_i = 6$、$\sum x_i^2 = 16$、$\sum x_i y_i = 15.5$、$\sum y_i^2 = 17.25$。求 β_1 的最小平方估計。

(A) 0.1　(B) 0.3　(C) 0.5　(D) 0.7　(E) 0.9

答案

(D) 0.7

解析

$$S_{xx} = 16 - \frac{6^2}{6} = 16 - 6 = 10, \qquad S_{xy} = 15.5 - \frac{6 \times 8.5}{6} = 15.5 - 8.5 = 7.$$

$\hat{\beta}_1 = 7/10 = 0.7$。

練習 **第 2.4 題** ・講義 p.17・回到對應概念

[SRM Sample Question #47] You are given the following summary statistics:

$$\bar{x} = 3.500 \qquad \bar{y} = 2.840 \qquad \sum(x_i - \bar{x})^2 = 10.820$$

$$\sum(x_i - \bar{x})(y_i - \bar{y}) = 2.677 \qquad \sum(y_i - \bar{y})^2 = 1.125$$

Determine the equation of the regression line, using the least squares method.

(A) $y = 1.97 + 0.25x$

(B) $y = 0.78 + 0.59x$

(C) $y = 0.57 + 0.65x$

(D) $y = 0.39 + 0.70x$

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

（SRM 樣題 #47）已知 $\bar{x} = 3.500$、$\bar{y} = 2.840$、$\sum(x_i - \bar{x})^2 = 10.820$、$\sum(x_i - \bar{x})(y_i - \bar{y}) = 2.677$、$\sum(y_i - \bar{y})^2 = 1.125$。用最小平方法求迴歸線。

(A) $y = 1.97 + 0.25x$　(B) $y = 0.78 + 0.59x$　(C) $y = 0.57 + 0.65x$　(D) $y = 0.39 + 0.70x$　(E) 以上皆非

答案

(A)

解析

$\hat{\beta}_1 = S_{xy}/S_{xx} = 2.677/10.820 = 0.2474$。$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x} = 2.840 - 0.2474 \times 3.5 = 2.840 - 0.8659 = 1.974$。迴歸線 $\hat{y} = 1.97 + 0.25x$。

易錯

$S_{yy} = 1.125$ 是干擾資訊。(B) ~ (D) 的斜率都接近 S_{xy}/S_{yy} 或相關係數一類的錯誤組合，不要用 S_{yy} 當分母（那是 x 對 y 迴歸的斜率）。

練習 **第 2.5 題** ・講義 p.17・回到對應概念

[SRM Sample Question #53] Determine which of the following statements is NOT true about the equation $Y = \beta_0 + \beta_1 X + \varepsilon$.

(A) β_0 is the expected value of Y.

(B) β_1 is the average increase in Y associated with a one-unit increase in X.

(C) The error term, ε, is typically assumed to be independent of X and Y.

(D) The equation defines the population regression line.

(E) The method of least squares is commonly used to estimate the coefficients β_0 and β_1.

中文題意

（SRM 樣題 #53）關於方程式 $Y = \beta_0 + \beta_1 X + \varepsilon$，下列何者**不正確**？

(A) β_0 是 Y 的期望值。

(B) β_1 是 X 增加一單位時 Y 的平均增加量。

(C) 誤差項 ε 通常假設和 X、Y 獨立。

(D) 這條方程式定義了母體迴歸線。

(E) 最小平方法常用來估計 β_0 與 β_1。

答案

(A)

解析

- (A) 錯。$E(Y) = \beta_0 + \beta_1 E(X)$，所以 β_0 是 $X = 0$ 時 Y 的期望值 $E(Y \mid X = 0)$，不是 Y 的期望值（除非 $E(X) = 0$）。對應到估計式就是 $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$，不是 $\bar{y}$。
- (B) 對：$E(Y \mid X = x + 1) - E(Y \mid X = x) = \beta_1$。
- (C) 這是 ISLR 原文的說法，官方答案視為正確。嚴格說，ε 和 X 獨立，但不可能和 Y 獨立（Y 裡面就含有 ε，$\mathrm{Cov}(Y, \varepsilon) = \sigma^2$）。考試照官方答案選 (A)。

- (D) 對：含未知參數的式子描述的是母體；用估計值的 $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ 才是樣本迴歸線。
- (E) 對。

練習 **第 2.8 題** ・講義 p.18・回到對應概念

You are fitting the linear regression model $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ to the following data:

x	2	5	8	11	13	15	16	18
y	-10	-9	-4	0	4	5	6	8

Determine the least squares estimate of β_1.

中文題意

以 $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ 配適下列資料，求 β_1 的最小平方估計。

（數據、圖表與選項見上方英文題目。）

答案

$\hat{\beta}_1 = 1.2273$

解析

$\bar{x} = 88/8 = 11$，$\bar{y} = 0/8 = 0$。

$x_i - \bar{x}$：$-9, -6, -3, 0, 2, 4, 5, 7$。$S_{xx} = 81 + 36 + 9 + 0 + 4 + 16 + 25 + 49 = 220$。因為 $\bar{y} = 0$，$S_{xy} = \sum (x_i - \bar{x}) y_i = (-9)(-10) + (-6)(-9) + (-3)(-4) + 0 + 2(4) + 4(5) + 5(6) + 7(8) = 90 + 54 + 12 + 0 + 8 + 20 + 30 + 56 = 270$。

$\hat{\beta}_1 = 270/220 = 1.2273$（截距 $0 - 1.2273 \times 11 = -13.5$）。

練習 **第 2.9 題** ・講義 p.18・回到對應概念

You are fitting the linear regression model $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ to the following data:

x	3	5	7	8	9	10
y	2	5	7	8	9	11

Determine the fitted value of y corresponding to $x = 6$.

中文題意

以 $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ 配適下列資料，求 $x = 6$ 的配適值。

（數據、圖表與選項見上方英文題目。）

答案

5.794

解析

$\bar{x} = 42/6 = 7$，$\bar{y} = 42/6 = 7$。

$x_i - \bar{x}$：$-4, -2, 0, 1, 2, 3$；$y_i - \bar{y}$：$-5, -2, 0, 1, 2, 4$。$S_{xx} = 16 + 4 + 0 + 1 + 4 + 9 = 34$；$S_{xy} = 20 + 4 + 0 + 1 + 4 + 12 = 41$。$\hat{\beta}_1 = 41/34 = 1.2059$。

迴歸線通過 $(\bar{x}, \bar{y}) = (7, 7)$，所以

$$\hat{y}(6) = \bar{y} + \hat{\beta}_1 (6 - \bar{x}) = 7 + 1.2059 \times (-1) = 5.794.$$

易錯

用「中心點＋斜率×距離」的寫法，不必先算截距，也比較不會出錯。

練習 **第 2.11 題** ・講義 p.19・回到對應概念

[3-F84:5] You are fitting the linear regression model $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ to 10 points of data. You are given:

$$\sum x_i = 100 \qquad \sum y_i = 200 \qquad \sum x_i y_i = 2000 \qquad \sum x_i^2 = 2000 \qquad \sum y_i^2 = 5000$$

Calculate the least-squares estimate of β_1.

(A) 0.0

(B) 0.1

(C) 0.2

(D) 0.3

(E) 0.4

中文題意

（舊考題 3-F84:5）以 $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ 配適 10 筆。已知 $\sum x_i = 100$、$\sum y_i = 200$、$\sum x_i y_i = 2000$、$\sum x_i^2 = 2000$、$\sum y_i^2 = 5000$。求 β_1 的最小平方估計。

(A) 0.0　(B) 0.1　(C) 0.2　(D) 0.3　(E) 0.4

答案

(A) 0.0

解析

$S_{xy} = 2000 - \dfrac{100 \times 200}{10} = 2000 - 2000 = 0$；$S_{xx} = 2000 - \dfrac{100^2}{10} = 1000 > 0$。$\hat{\beta}_1 = 0/1000 = 0$。

易錯

斜率為 0 只代表樣本中沒有**線性**關係，不代表 x 和 y 無關（例如 $y = x^2$ 對稱分布在 0 附近時，S_{xy} 也可能為 0）。

練習 **第 2.13 題** ・講義 p.20・回到對應概念

[3L-S05:27] Given the following information:

$$\sum x_i = 144 \qquad \sum y_i = 1{,}742 \qquad \sum x_i^2 = 2{,}300$$

$$\sum y_i^2 = 312{,}674 \qquad \sum x_i y_i = 26{,}696 \qquad n = 12$$

Determine the least squares equation for the following model:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

(A) $\hat{y}_i = -0.73 + 12.16 x_i$

(B) $\hat{y}_i = -8.81 + 12.16 x_i$

(C) $\hat{y}_i = 283.87 + 10.13 x_i$

(D) $\hat{y}_i = 10.13 + 12.16 x_i$

(E) $\hat{y}_i = 23.66 + 10.13 x_i$

中文題意

（舊考題 3L-S05:27）已知 $\sum x_i = 144$、$\sum y_i = 1742$、$\sum x_i^2 = 2300$、$\sum y_i^2 = 312{,}674$、$\sum x_i y_i = 26{,}696$、$n = 12$。求模型 $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ 的最小平方方程式。

(A) $\hat{y} = -0.73 + 12.16x$　(B) $\hat{y} = -8.81 + 12.16x$　(C) $\hat{y} = 283.87 + 10.13x$　(D) $\hat{y} = 10.13 + 12.16x$　(E) $\hat{y} = 23.66 + 10.13x$

答案

(E)

解析

$\bar{x} = 12$, $\bar{y} = 145.1667$。

$$S_{xx} = 2300 - \frac{144^2}{12} = 2300 - 1728 = 572,$$

$$S_{xy} = 26{,}696 - \frac{144 \times 1742}{12} = 26{,}696 - 20{,}904 = 5{,}792.$$

$\hat{\beta}_1 = 5792/572 = 10.126$; $\hat{\beta}_0 = 145.1667 - 10.126 \times 12 = 23.66$。

練習 **第 2.14 題** ・講義 p.20・回到對應概念

[120-F90:6] You are estimating the linear regression model $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$. You are given

i	1	2	3	4	5
x_i	6.8	7.0	7.1	7.2	7.4
y_i	0.8	1.2	0.9	0.9	1.5

Determine $\hat{\beta}_1$.

(A) 0.8

(B) 0.9

(C) 1.0

(D) 1.1

(E) 1.2

中文題意

（舊考題 120-F90:6）估計 $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$，資料如下。求 $\hat{\beta}_1$。

(A) 0.8　(B) 0.9　(C) 1.0　(D) 1.1　(E) 1.2

（數據、圖表與選項見上方英文題目。）

答案

(B) 0.9

解析

$\bar{x} = 35.5/5 = 7.1$，$\bar{y} = 5.3/5 = 1.06$。

$x_i - \bar{x}$：$-0.3, -0.1, 0, 0.1, 0.3$；$y_i - \bar{y}$：$-0.26, 0.14, -0.16, -0.16, 0.44$。 $S_{xx} = 0.09 + 0.01 + 0 + 0.01 +$

$0.09 = 0.20$。 $S_{xy} = 0.078 - 0.014 + 0 - 0.016 + 0.132 = 0.18$。
$\hat{\beta}_1 = 0.18 / 0.20 = 0.9$。

練習 **第 2.15 題** ・講義 p.20・回到對應概念

[120-S90:11] Which of the following are valid expressions for b, the slope coefficient in the simple linear regression of y on x?

I. $\dfrac{(\sum x_i y_i) - \bar{y}\sum x_i}{(\sum x_i^2) - \bar{x}\sum x_i}$

II. $\dfrac{(\sum x_i y_i) - \bar{y}\sum x_i}{\sum x_i^2 - \bar{x}^2}$

III. $\dfrac{\sum x_i(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

（舊考題 120-S90:11）下列哪些是簡單線性迴歸中 y 對 x 的斜率 b 的正確表示式？

I. $\dfrac{\sum x_i y_i - \bar{y}\sum x_i}{\sum x_i^2 - \bar{x}\sum x_i}$　II. $\dfrac{\sum x_i y_i - \bar{y}\sum x_i}{\sum x_i^2 - \bar{x}^2}$　III. $\dfrac{\sum x_i(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$

(A) 只有 I、II　(B) 只有 I、III　(C) 只有 II、III　(D) I、II、III　(E) 以上皆非

答案

(B)

解析

- **I 正確。** 分子 $\sum x_i y_i - \bar{y}\sum x_i = \sum x_i y_i - n\bar{x}\bar{y} = S_{xy}$；分母 $\sum x_i^2 - \bar{x}\sum x_i = \sum x_i^2 - n\bar{x}^2 = S_{xx}$。
- **II 錯誤。** 分母少了 n：應為 $\sum x_i^2 - n\bar{x}^2$，而 $\sum x_i^2 - \bar{x}^2$ 只扣了一次。

- **III 正確。** 分母就是 S_{xx}。分子 $\sum x_i(y_i-\bar{y}) = \sum (x_i-\bar{x})(y_i-\bar{y}) + \bar{x}\sum(y_i-\bar{y}) = S_{xy} + 0$。

易錯

中心化只要做在其中一個變數上就夠了：$\sum (x_i-\bar{x})(y_i-\bar{y}) = \sum x_i(y_i-\bar{y}) = \sum (x_i-\bar{x})y_i$。

練習 **第 2.16 題** ・講義 p.21・回到對應概念

[Old exam] For the linear regression model $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ with 30 observations, you are given:

(i) $r_{xy} = 0.5$

(ii) $s_x = 7$

(iii) $s_y = 5$

where r_{xy} is the sample correlation coefficient. Calculate the estimated value of β_1.

(A) 0.4

(B) 0.5

(C) 0.6

(D) 0.7

(E) 0.8

中文題意

（舊考題）簡單線性迴歸 30 筆觀察，樣本相關係數 $r_{xy} = 0.5$、$s_x = 7$、$s_y = 5$。求 $\hat{\beta}_1$。

(A) 0.4　(B) 0.5　(C) 0.6　(D) 0.7　(E) 0.8

答案

(A)，$\hat{\beta}_1 = 0.357$

解析

$\hat{\beta}_1 = r_{xy}\dfrac{s_y}{s_x} = 0.5 \times \dfrac{5}{7} = 0.357$，最接近 0.4。

易錯

寫成 $0.5 \times 7/5 = 0.7$ 就選到 (D)，那是 x 對 y 迴歸的斜率。

練習 **第 2.17 題** ・講義 p.21・回到對應概念

[110-S83:14] In a bivariate distribution the regression of the variable y on the variable x is $1500 + b(x - 68)$ for some constant b. If the correlation coefficient is 0.81 and if the standard deviations of y and x are 220 and 2.5 respectively, then what is the expected value of y, to the nearest unit, when x is 70?

(A) 1357

(B) 1515

(C) 1517

(D) 1643

(E) 1738

中文題意

（舊考題 110-S83:14）在一個雙變數分配中，y 對 x 的迴歸為 $1500 + b(x - 68)$，b 是某個常數。相關係數 0.81，y 與 x 的標準差分別為 220 與 2.5。$x = 70$ 時 y 的期望值（取到個位）是多少？

(A) 1357　(B) 1515　(C) 1517　(D) 1643　(E) 1738

答案

(D) 1643

解析

迴歸寫成「中心點」形式：$x = 68$ 時 $E(y) = 1500$，所以 $(\bar{x}, \bar{y}) = (68, 1500)$。斜率 $b = r\dfrac{s_y}{s_x} = 0.81 \times \dfrac{220}{2.5} = 71.28$。$E(y \mid x = 70) = 1500 + 71.28 \times (70 - 68) = 1500 + 142.56 = 1642.56 \approx 1643$。

練習 **第 2.18 題** ・講義 p.21・回到對應概念

[120-82-97:7] You are given the following information about a simple regression model fit to 10 observations:

$$\sum x_i = 20 \qquad \sum y_i = 100 \qquad s_x = 2 \qquad s_y = 8$$

You are also given that the correlation coefficient $r_{xy} = -0.98$. Determine the predicted value of y when $x = 5$.

(A) -10

(B) -2

(C) 11

(D) 30

(E) 37

中文題意

（舊考題 120-82-97:7）簡單迴歸 10 筆：$\sum x_i = 20$、$\sum y_i = 100$、$s_x = 2$、$s_y = 8$，相關係數 $r = -0.98$。求 $x = 5$ 時的預測值。

(A) -10　(B) -2　(C) 11　(D) 30　(E) 37

答案

(B)，預測值 -1.76

解析

$\bar{x} = 2$，$\bar{y} = 10$。斜率 $\hat{\beta}_1 = r\dfrac{s_y}{s_x} = -0.98 \times \dfrac{8}{2} = -3.92$。$\hat{y}(5) = \bar{y} + \hat{\beta}_1(5 - \bar{x}) = 10 - 3.92 \times 3 = -1.76$，最接近 -2。

練習 **第 2.20 題** ・講義 p.22・回到對應概念

[120-F89:13] You are given:

Period	y	x_1	x_2
1	1.3	6	4.5
2	1.5	7	4.6
3	1.8	7	4.5
4	1.6	8	4.7
5	1.7	8	4.6

You are to use the following regression model:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i, \qquad i = 1, 2, \ldots, 5$$

You have determined:

$$(X'X)^{-1} = \begin{pmatrix} 1522.73 & 26.87 & -374.67 \\ 26.87 & 0.93 & -7.33 \\ -374.67 & -7.33 & 93.33 \end{pmatrix}.$$

Calculate $\hat{\varepsilon}_2$.

(A) -0.2

(B) -0.1

(C) 0.0

(D) 0.1

(E) 0.2

中文題意

（舊考題 120-F89:13）資料如下，模型 $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i$。

已知 求 $\hat{\varepsilon}_2$。

(A) -0.2 (B) -0.1 (C) 0.0 (D) 0.1 (E) 0.2

（數據、圖表與選項見上方英文題目。）

答案

(D)（以題目給的矩陣算出 0.095）

解析

第一步：$X'\mathbf{y}$。 三個元素依序是 $\sum y_i$、$\sum x_{i1}y_i$、$\sum x_{i2}y_i$：

$$X'\mathbf{y} = \begin{pmatrix} 1.3+1.5+1.8+1.6+1.7 \\ 6(1.3)+7(1.5)+7(1.8)+8(1.6)+8(1.7) \\ 4.5(1.3)+4.6(1.5)+4.5(1.8)+4.7(1.6)+4.6(1.7) \end{pmatrix} = \begin{pmatrix} 7.9 \\ 57.3 \\ 36.19 \end{pmatrix}.$$

第二步：$\hat{\boldsymbol{\beta}} = (X'X)^{-1}X'\mathbf{y}$。 - $\hat{\beta}_0 = 1522.73(7.9) + 26.87(57.3) - 374.67(36.19) = 9.9107$ - $\hat{\beta}_1 = 26.87(7.9) + 0.93(57.3) - 7.33(36.19) = 0.2893$ - $\hat{\beta}_2 = -374.67(7.9) - 7.33(57.3) + 93.33(36.19) = -2.2893$

第三步：第二筆殘差。 $\hat{y}_2 = 9.9107 + 0.2893(7) - 2.2893(4.6) = 1.4050$，$\hat{\varepsilon}_2 = 1.5 - 1.4050 = 0.095$，選 (D)。

易錯

這題對四捨五入非常敏感。x_2 幾乎沒有變化，$X'X$ 接近奇異，反矩陣元素很大（1522.73），只要矩陣只給兩位小數，係數就會偏一點。用精確的反矩陣算，係數是 $(9.8667,\ 0.3333,\ -2.3333)$，殘差是 0.033。官方答案依題目給的矩陣選 (D)。這正是 2.2 節說的「接近共線時係數不穩定」。

練習 **第 2.21 題** ・講義 p.22・回到對應概念

You are fitting the following data to a linear regression model of the form $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \varepsilon_i$:

y	5	3	10	4	3	5
x_1	0	1	0	1	0	1
x_2	1	0	1	1	0	1
x_3	0	1	1	0	0	0

You are given that

$$(X'X)^{-1} = \frac{1}{30}\begin{pmatrix} 26 & -10 & -18 & -12 \\ -10 & 20 & 0 & 0 \\ -18 & 0 & 24 & 6 \\ -12 & 0 & 6 & 24 \end{pmatrix}.$$

Determine the least squares estimate of β_1.

中文題意

以 $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \varepsilon_i$ 配適下列資料：

已知 求 $\hat{\beta}_1$。

（數據、圖表與選項見上方英文題目。）

答案

$\hat{\beta}_1 = -2$

解析

只需要 $(X'X)^{-1}$ 的第 1 列（從第 0 列算起）乘 $X'\mathbf{y}$。

第一步：$X'\mathbf{y}$。 - $\sum y_i = 5+3+10+4+3+5 = 30$ - $\sum x_{i1}y_i = 3+4+5 = 12$（$x_1 = 1$ 的是第 2、4、6 筆） - $\sum x_{i2}y_i = 5+10+4+5 = 24$（第 1、3、4、6 筆） - $\sum x_{i3}y_i = 3+10 = 13$（第 2、3 筆）

第二步： $\hat{\beta}_1 = \frac{1}{30}\big[-10(30) + 20(12) + 0(24) + 0(13)\big] = \frac{-300 + 240}{30} = -2$。

（完整的係數向量是 $(2.4,\ -2,\ 3.8,\ 3.2)$。）

練習 **第 2.23 題** ・講義 p.23・回到對應概念

You are fitting the following data to the linear regression model $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \varepsilon_i$:

y	1	2	6	5	1	2	3
x_1	0	0	1	-1	0	1	1
x_2	0	-1	0	0	1	-1	0
x_3	1	1	4	0	0	0	1

You are given that

$$(X'X)^{-1} = \frac{1}{30}\begin{pmatrix} 7 & 0 & 1.5 & -2.5 \\ 0 & 12 & 3 & -3 \\ 1.5 & 3 & 11.25 & -0.75 \\ -2.5 & -3 & -0.75 & 3.25 \end{pmatrix}.$$

Determine the fitted value of y for $x_1 = x_2 = x_3 = 1$.

中文題意

以 $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \varepsilon_i$ 配適：

已知 求 $x_1 = x_2 = x_3 = 1$ 時的配適值。

（數據、圖表與選項見上方英文題目。）

答案

1.9

解析

第一步：$X'\mathbf{y}$。 - $\sum y = 1+2+6+5+1+2+3 = 20$ - $\sum x_1 y = 6 - 5 + 2 + 3 = 6$ - $\sum x_2 y = -2 + 1 - 2 = -3$ - $\sum x_3 y = 1 + 2 + 24 + 3 = 30$

第二步：係數。

$$\hat{\boldsymbol{\beta}} = \frac{1}{30}\begin{pmatrix} 7(20)+0(6)+1.5(-3)-2.5(30) \\ 0+12(6)+3(-3)-3(30) \\ 1.5(20)+3(6)+11.25(-3)-0.75(30) \\ -2.5(20)-3(6)-0.75(-3)+3.25(30) \end{pmatrix} = \frac{1}{30}\begin{pmatrix} 60.5 \\ -27 \\ -8.25 \\ 31.75 \end{pmatrix} = \begin{pmatrix} 2.0167 \\ -0.9 \\ -0.275 \\ 1.0583 \end{pmatrix}.$$

第三步： 在 $x_1 = x_2 = x_3 = 1$，$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 + \hat{\beta}_2 + \hat{\beta}_3 = \dfrac{60.5 - 27 - 8.25 + 31.75}{30} = \dfrac{57}{30} = 1.9$。

易錯

更快的做法：配適值 $= \mathbf{x}_0'(X'X)^{-1}X'\mathbf{y}$，$\mathbf{x}_0 = (1,1,1,1)'$，先把反矩陣四列相加得 $(6, 12, 15, -3)/30$，再和 $X'\mathbf{y} = (20, 6, -3, 30)$ 做內積：$(120 + 72 - 45 - 90)/30 = 57/30 = 1.9$。

練習 **第 2.24 題** ・講義 p.24・回到對應概念

[Old exam] You are examining the relationship between the number of fatal car accidents on a tollway each month and three other variables: precipitation, traffic volume, and the occurrence of a holiday weekend during the month. You are using the following model:

$$y = \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \varepsilon$$

where y = the number of fatal car accidents, x_1 = precipitation, in inches, x_2 = traffic volume, and x_3 = 1 if a holiday weekend occurs during the month, and 0 otherwise.

The following data were collected for a 12-month period:

Month	y	x_1	x_2	x_3
1	1	3	1	1
2	3	2	1	1
3	1	2	1	0
4	2	5	2	1
5	4	4	2	1
6	1	1	2	0
7	3	0	2	1
8	2	1	2	1
9	0	1	3	1
10	2	2	3	1
11	1	1	4	0
12	3	4	4	1

You have determined:

$$(X'X)^{-1} = \frac{1}{6506}\begin{pmatrix} 257 & -82 & -446 \\ -82 & 254 & -364 \\ -446 & -364 & 2622 \end{pmatrix}$$

Determine $\hat{\beta}_1$.

(A) -0.07

(B) 0.15

(C) 0.24

(D) 0.70

(E) 1.30

中文題意

（舊考題）研究收費公路每月死亡車禍數 y 與三個變數的關係：降雨量 x_1（英吋）、交通流量 x_2、當月是否有連假 x_3（是 1、否 0）。模型**沒有截距**：$y = \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \varepsilon$。12 個月資料：

已知 $(X'X)^{-1} = \frac{1}{6506}\begin{pmatrix} 257 & -82 & -446 \\ -82 & 254 & -364 \\ -446 & -364 & 2622 \end{pmatrix}$。求 $\hat{\beta}_1$。

(A) -0.07　(B) 0.15　(C) 0.24　(D) 0.70　(E) 1.30

（數據、圖表與選項見上方英文題目。）

答案

(C) 0.24

解析

沒有截距，所以 X 只有三欄，$X'\mathbf{y} = (\sum x_1 y, \sum x_2 y, \sum x_3 y)'$。

- $\sum x_1 y = 3 + 6 + 2 + 10 + 16 + 1 + 0 + 2 + 0 + 4 + 1 + 12 = 57$
- $\sum x_2 y = 1 + 3 + 1 + 4 + 8 + 2 + 6 + 4 + 0 + 6 + 4 + 12 = 51$

- $\sum x_3 y = 1+3+2+4+3+2+0+2+3 = 20$（$x_3 = 1$ 的月份：1、2、4、5、7、8、9、10、12）

$$\hat{\beta}_1 = \frac{257(57) - 82(51) - 446(20)}{6506} = \frac{14{,}649 - 4{,}182 - 8{,}920}{6506} = \frac{1547}{6506} = 0.2378.$$

易錯

模型沒有截距時，X 沒有全是 1 的那一欄，$X'\mathbf{y}$ 也沒有 $\sum y$；而且殘差總和不一定為 0。

練習 **第 2.27 題** ・講義 p.26・回到對應概念

[MAS-I-S19:32] You are fitting a linear regression model of the form:

$$\mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}; \qquad \varepsilon_i \sim N(0, \sigma^2)$$

and are given the following values used in this model:

$$X = \begin{pmatrix} 1 & 0 & 1 & 9 \\ 1 & 1 & 1 & 15 \\ 1 & 1 & 1 & 8 \\ 0 & 1 & 1 & 7 \\ 0 & 1 & 1 & 6 \\ 0 & 0 & 1 & 6 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 21 \\ 32 \\ 19 \\ 17 \\ 15 \\ 15 \end{pmatrix}, \quad (X'X)^{-1}X'\mathbf{y} = \begin{pmatrix} 0.297 \\ -0.032 \\ 3.943 \\ 1.854 \end{pmatrix},$$

(The question also gives $X'X$, $(X'X)^{-1}$, the hat matrix $H = X(X'X)^{-1}X'$, the fitted values $X(X'X)^{-1}X'\mathbf{y}$, and $\hat{\sigma}^2 = 0.012657$.)

Calculate the modeled estimate of the intercept parameter.

(A) Less than 0

(B) At least 0, but less than 1

(C) At least 1, but less than 2

(D) At least 2, but less than 3

(E) At least 3

中文題意

（MAS-I 2019 春 #32）配適線性迴歸 $\mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}$，$\varepsilon_i \sim N(0, \sigma^2)$，已知另外還給了 $X'X$、$(X'X)^{-1}$、帽子矩陣、配適值與 $\hat{\sigma}^2 = 0.012657$。求截距參數的估計值。

（數據、圖表與選項見上方英文題目。）

答案

(E)，截距為 3.943

解析

截距對應的是設計矩陣中**全為 1 的那一欄**。看 X 的四欄：第一欄是 $(1,1,1,0,0,0)$、第二欄是 $(0,1,1,1,1,0)$，都是指標變數；**第三欄全是 1**；第四欄是連續變數。

所以截距是係數向量的第三個元素 3.943，至少 3。

易錯

不要反射性地把第一個係數 0.297 當截距。題目給的大量矩陣（帽子矩陣、$\hat{\sigma}^2$）都用不到，是干擾資訊。

練習 **第 2.28 題** ・講義 p.27・回到對應概念

[MAS-I-S19:29] Tim uses an ordinary least squares regression model to predict salary based on Experience and Gender. Gender is a qualitative variable and is coded as follows:

$$\text{Gender} = \begin{cases} 1 & \text{if Male} \\ 0 & \text{if Female} \end{cases}$$

His analysis results in the following output:

Coefficients	Estimate	Std. Error	t-value	$\Pr(>\|t\|)$
Intercept	18169.300	212.2080	85.62027	2.05E−14
Experience	1110.233	59.8224	18.55881	1.75E−08
Gender	169.550	162.9177	10.38285	2.62E−06

Abby uses the same data set but codes gender as follows:

$$\text{Gender} = \begin{cases} 1 & \text{if Female} \\ 0 & \text{if Male} \end{cases}$$

Calculate the value of the Intercept in Abby's model.

(A) At most 18,169.3

(B) Greater than 18,169.3, but at most 18,400.0

(C) Greater than 18,400.0, but at most 18,600.0

(D) Greater than 18,600.0

(E) The answer cannot be computed from the information given

中文題意

（MAS-I 2019 春 #29）Tim 用普通最小平方迴歸，以年資與性別預測薪資，性別編碼為男 1、女 0。結果：截距 18,169.300、年資 1,110.233、性別 169.550。Abby 用同一份資料，但性別編碼為女 1、男 0。求 Abby 模型的截距。

(A) 至多 18,169.3　(B) 大於 18,169.3、至多 18,400.0　(C) 大於 18,400.0、至多 18,600.0　(D) 大於 18,600.0　(E) 無法由題目資訊算出

答案

(B)，18,338.85

解析

Tim 的模型：女性（$g = 0$）的線是 $18{,}169.30 + 1{,}110.233 \cdot$ 年資，男性多 169.55。

Abby 的模型以男性為基準：截距必須是**男性**在年資 0 時的平均，也就是 Tim 模型裡男性的截距：

$$18{,}169.30 + 169.55 = 18{,}338.85.$$

她的性別係數則是 -169.55（女性比男性低 169.55），年資係數不變。

易錯

換基準類別只是換一種記帳方式：每一類的配適值不變，截距變成新基準類別的平均，指標係數變號。另外，題目表中性別的 t 值 10.38 和 $169.550/162.9177 = 1.04$ 對不上（原題如此），但不影響截距的計算。