概念 01

以一條線估計條件平均：斜率、截距與殘差

若要估計保單在給定年齡或曝險下的平均損失，先區別母體模型與擬合線。母體模型為 $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$，假設 $E(\varepsilon_i \mid X) = 0$，則條件平均是直線；單一觀察仍會偏離這條線。樣本殘差 $e_i = y_i - \hat{y}_i$ 可算，真實誤差通常不可觀察。斜率是 x 每增一單位時條件平均的變動，單位是「反應單位 / 解釋變數單位」；截距是 $x = 0$ 時的平均，若零遠離觀察範圍，別把外插值當作已證實的經濟效果。

最小平方法（ordinary least squares）選擇截距 a 與斜率 b，使 $Q = \sum_i (y_i - a - b x_i)^2$ 最小。對 a 微分：$-2\sum_i (y_i - a - b x_i) = 0$，故 $a = \bar{y} - b\bar{x}$；直線必經樣本中心。代回後，殘差是 $(y_i - \bar{y}) - b(x_i - \bar{x})$。再對 b 微分並令零：

$$0 = -2 \sum_i (x_i - \bar{x})[(y_i - \bar{y}) - b(x_i - \bar{x})].$$

定義 $S_{xx} = \sum_i (x_i - \bar{x})^2$、$S_{xy} = \sum_i (x_i - \bar{x})(y_i - \bar{y})$。若 $S_{xx} > 0$，目標沿斜率方向有正曲率，唯一解為

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = r_{xy}\frac{s_y}{s_x}, \qquad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

第二個斜率寫法來自 $r = S_{xy}/\sqrt{S_{xx}S_{yy}}$；相關係數沒有單位，要乘回標準差比例才有斜率的單位。若全部 x 相同，分母為零，資料無法區分斜率和截距。

只有摘要統計時，展開乘積得到 $S_{xy} = \sum x_i y_i - \frac{(\sum x_i)(\sum y_i)}{n}$；同理 $S_{xx} = \sum x_i^2 - \frac{(\sum x_i)^2}{n}$。給新值 x_0，預測平均為 $\bar{y} + \hat{\beta}_1(x_0 - \bar{x})$。若資料中有此筆 y_0，才可算出其殘差。**即：先找到資料中心，再由共同移動相對於 x 自身移動的比例確定斜率。**

★ 精選 · 2.1 · 講義 p.16

令解釋值依序為 −2、−1、0、1、2，反應為 3、5、8、9、10；含截距迴歸的截距是多少？

參考解答

7。因 $\bar{x} = 0$，$\hat{\beta}_0 = \bar{y} = 35/5$。

解析

當解釋值已中心化，斜率不影響截距估值。

★ 精選 · 2.2 · 講義 p.17

18 筆資料有 $\sum x = 216, \sum x^2 = 3092, \sum y = 252, \sum xy = 3364$；求斜率。

參考解答

$S_{xx} = 3092 - 216^2/18 = 500$；$S_{xy} = 3364 - 216(252)/18 = 340$，故斜率 0.68。

解析

須先中心化，不能直接用原始乘積與平方總和相除。

★ 精選 · 2.6 · 講義 p.18

12、16、20 盎司的咖啡各售 1.00、1.20、1.40。直線定價下，把兩杯 24 改成一杯 48 省多少？

參考解答

單杯價 $0.40 + 0.05x$，兩杯各 24 比一杯 48 多付一次截距，省 0.40（C）。

解析

總容量不變只抵銷斜率項，固定成本按杯數收取。

★ 精選 · 2.7 · 講義 p.18

廣告費 5.5、5.8、6、5.9、6.2 對應銷售 100、110、112、115、117，求第三筆殘差。

參考解答

$S_{xy}=6.38, S_{xx}=0.268$，斜率 23.806、截距 −29.179；$e_3=112-113.657=-1.657$（B）。

解析

殘差一律用實際減預測；此人低於線。

★ 精選 · 2.10 · 講義 p.19

28 筆資料 $\sum x = 392, \sum y = 924, \sum xy = 13272$，估計截距 −23；求 $\sum x^2$。

參考解答

中心為 (14,33)，故斜率 4。$S_{xy} = 336$，所以 $S_{xx} = 84$，總平方和為 $84 + 28(14)^2 = 5572$。

解析

已知截距時可反推斜率，再從中心化平方和回到原始平方和。

★ 精選 · 2.19 · 講義 p.21

15 筆觀察 $\sum x = 30, \sum x^2 = 270, \sum y = 450, \sum xy = 8100$，第 5 點 (3,40)，求其殘差。

參考解答

$b = (8100 - 900)/(270 - 60) = 240/7$；$\hat{y}_5 = 30 + 240/7$，殘差 $-170/7 \approx -24.29$。

解析

先依資料估計中心與斜率，再取觀察減預測。

概念 02

多元迴歸：設計矩陣、編碼與加權

多元線性迴歸把一筆資料寫成 $x_i^\top = (1, x_{i1}, \dots, x_{ip})$，第一欄 1 使每列都有相同截距。堆疊後 $y = X\beta + \varepsilon$。此處 β_j 解釋為其餘預測變數固定時，x_j 增一單位帶來的條件平均差；相關並不足以建立因果。

把平方損失展開：$Q(b) = y^\top y - 2b^\top X^\top y + b^\top X^\top X b$。梯度是 $2X^\top X b - 2X^\top y$，設為零得到常態方程式 $X^\top X \hat\beta = X^\top y$。當各欄線性獨立且 $n \geq p+1$，解唯一：

$$\hat\beta = (X^\top X)^{-1} X^\top y, \qquad \hat y = X\hat\beta, \qquad X^\top e = 0.$$

最後一式說明殘差與設計矩陣每一欄正交；含截距才推出 $\sum e_i = 0$。矩陣題先確認哪一欄全為一，那一欄對應的係數才是截距。若只問第 j 個係數，取逆矩陣第 j 列乘 $X^\top y$ 即可。

一個分 m 類的變數，若有截距，應放 $m-1$ 個指標，參考組全部為零。放齊 m 欄會因各欄之和等於截距欄而完全共線。改變參考組會改截距與組別係數，不會改每一組的擬合值。若有交互作用，$\beta_0 + \beta_1 x + \beta_2 d + \beta_3 x d$ 在 $d=0$ 時斜率為 β_1，$d=1$ 時為 $\beta_1 + \beta_3$。

若觀察誤差彼此不相關而變異不同，可讓較精確觀察有較高權重。最小化 $Q_W = (y - Xb)^\top W (y - Xb)$，得到 $\hat\beta_W = (X^\top W X)^{-1} X^\top W y$；理想權重與各誤差變異數的倒數成比例。含截距時滿足的是加權殘差和為零，不是一般殘差和必為零。**即：X 記錄每一筆資料「哪些規則適用」，加權記錄各筆資料「提供多少精確資訊」。**

★ 精選 · 2.22 · 講義 p.23

以性別指標和違規分數預測索賠次數，$X^\top y = (12, 9, 17)^\top$；逆矩陣最後一列為 $(-3, 0, 3)/12$，求違規分數的斜率。

參考解答

$[-3(12) + 3(17)]/12 = 1.25$（C）。

解析

這是給定性別後的條件差；不能從索賠與違規分數的單變數相關直接讀取。

★ 精選 · 2.25 · 講義 p.24

車價用三次多項式、年齡用一次項、駕駛人數分四類、性別分兩類；只另含性別與年齡交互作用。含截距共幾項？

參考解答

$1+3+1+3+1+1=10$（C）。

解析

四類用三個指標；交互作用取一個額外係數。

★ 精選 · 2.26 · 講義 p.25

兩二元指標與交互作用的係數為 (−0.10,−0.25,0.58,−0.20)。兩指標同時反向編碼，問多少係數變號或相同。

參考解答

新係數 $(0.03, 0.45, -0.38, -0.20)$：三個變號、一個不變（E）。

解析

代入 $x_j = 1 - z_j$ 展開；交互作用係數保留，兩主效果還須含交互項貢獻。

概念 03

替代模型形式：變數轉換、交互作用與曲線

「線性」描述模型對未知係數是否線性，不要求曲線對原始 x 筆直。例如 $\beta_0+\beta_1 x+\beta_2 x^2$ 仍可把 x, x^2 當兩個已知欄位做最小平方；其邊際斜率為 $\beta_1+2\beta_2 x$。若希望在 c 改斜率又保持連續，以 $(x-c)_+=\max(0,x-c)$ 作額外欄位：$\beta_0+\beta_1 x+\beta_2(x-c)_+$，右側斜率為 $\beta_1+\beta_2$，左右在 c 取值相同。

正值反應常有偏態或變異隨均值上升。可先把反應轉換再做迴歸；例如 $\log Y=\beta_0+\beta_1 x+\varepsilon$，x 增一單位使典型水準乘 e^{β_1}。反轉 $e^{\widehat{\log Y}}$ 並不一般等於 $E(Y\mid X)$：若對數誤差為零均值常態，條件平均另乘 $e^{\sigma^2/2}$。選轉換後模型應按原目標尺度檢查預測，而非只看轉換尺度的殘差。

Box–Cox 冪次轉換（Box–Cox transformation）對 $y>0$ 定義為

$$g_\lambda(y)=\begin{cases}(y^\lambda-1)/\lambda, & \lambda\neq 0,\\ \log y, & \lambda=0.\end{cases}$$

因 $y^\lambda=e^{\lambda\log y}=1+\lambda\log y+O(\lambda^2)$，故當 $\lambda\to 0$ 時自然銜接對數。轉換可改善線性與變異穩定性，但不能無條件解決遺漏變數或自相關。**即：讓資料更接近模型的形狀，同時記住現在預測的是哪個尺度。**

★ 精選 · 2.12 · 講義 p.19

10 筆 $\sum x = 13.5, \sum \log y = 9.681, \sum x^2 = 19.57, \sum x \log y = 13.697$。擬合對數直線，x=2 的逆轉換預測？

參考解答

$b = (13.697 - 13.5 \times 9.681/10)/(19.57 - 13.5^2/10) = 0.46665$；$a = 0.3381$，逆轉換約 3.566（B）。

解析

這是先預測對數再取指數；若要求算術條件平均，需要誤差分布資訊。

TERMS

本章中英術語

中文	English	解題時的意思
殘差	residual	觀察值減去它的擬合值。
最小平方法	ordinary least squares	選擇使殘差平方和最小的係數。
設計矩陣	design matrix	以列表示觀察、以欄表示模型項的矩陣。

練習 · 2.3 · 講義 p.17

6 筆觀察有 $\sum y = 8.5, \sum x = 6, \sum x^2 = 16, \sum xy = 15.5, \sum y^2 = 17.25$，求斜率。

參考解答

$S_{xy} = 15.5 - 6(8.5)/6 = 7$，$S_{xx} = 16 - 36/6 = 10$，斜率 0.7（D）。

解析

y 的平方和對求斜率不是必要資料。

練習 · 2.4 · 講義 p.17

已知 $\bar{x}=3.5, \bar{y}=2.84, S_{xx}=10.820, S_{xy}=2.677, S_{yy}=1.125$，求迴歸線。

參考解答

$b = 2.677/10.820 = 0.2474$，$a = 2.84 - 3.5b = 1.9741$，即 $\hat{y} \approx 1.97 + 0.25x$（A）。

解析

先求斜率，再讓迴歸線通過樣本中心。

練習 · 2.5 · 講義 p.17

母體模型的截距是否必為所有 Y 的平均？誤差是否必與 Y 獨立？

參考解答

一般截距是 $E(Y \mid X=0)$，不是 $E(Y)$；教材指定辨識截距敘述（A）。也不能假設誤差與 Y 獨立。

解析

由 $Y = X\beta + \varepsilon$ 可知，外生時 $\mathrm{Cov}(Y, \varepsilon \mid X) = \mathrm{Var}(\varepsilon \mid X)$，非零誤差本來就是 Y 的一部分。

練習 · 2.8 · 講義 p.18

八筆觀察經中心化得 $S_{xx}=220, S_{xy}=270$，求最小平方斜率。

參考解答

$270/220 = 1.2273$。

解析

此題 $\bar{y}=0$；可直接以 $\sum x_i y_i$ 算中心化乘積和。

練習 · 2.9 · 講義 p.18

六組點 (3,2)、(5,5)、(7,7)、(8,8)、(9,9)、(10,11)，在 x=6 預測 y。

參考解答

兩者平均皆 7；$S_{xx}=34, S_{xy}=41$，故 $7+(41/34)(6-7)=5.7941$。

解析

用中心化形式，可省去單獨算截距。

練習 · 2.11 · 講義 p.19

10 點有 $\sum x = 100, \sum y = 200, \sum xy = 2000, \sum x^2 = 2000$；求斜率。

參考解答

$S_{xy} = 2000 - 100(200)/10 = 0$，分母非零，斜率零（A）。

解析

無樣本線性趨勢不等於沒有任何非線性關係。

練習 · 2.13 · 講義 p.20

12 組摘要 $\sum x = 144, \sum y = 1742, \sum x^2 = 2300, \sum xy = 26696$，求直線。

參考解答

$b = (26696 - 144(1742)/12)/(2300 - 144^2/12) = 10.1259$；$a = 23.6562$（E）。

解析

斜率和截距須使用同一個 x 與 y 的方向。

練習 · 2.14 · 講義 p.20

x 為 6.8、7、7.1、7.2、7.4，y 為 0.8、1.2、0.9、0.9、1.5，估斜率。

參考解答

$S_{xx} = 0.20, S_{xy} = 0.18$，故 0.9（B）。

解析

原始 x 值很接近時，平方和的中心化影響特別大。

練習 · 2.15 · 講義 p.20

判別斜率的三種等價式：I 以中心化分子分母；II 分母用 $\sum x_i^2 - \bar{x}^2$；III 分子用 $\sum x_i(y_i - \bar{y})$、分母用 S_{xx}。

參考解答

I、III 正確（B）。II 缺少 n，分母應為 $\sum x_i^2 - n\bar{x}^2$。

解析

III 與標準分子相差 $\bar{x}\sum(y_i - \bar{y}) = 0$。

練習 · 2.16 · 講義 p.21

相關係數 0.5，x、y 的樣本標準差各 7、5，求 y 對 x 的斜率。

參考解答

$0.5(5/7) = 0.3571$，選最接近的 0.4（A）。

解析

相關沒有單位，回歸方向決定哪個標準差在分子。

練習 · 2.17 · 講義 p.21

迴歸為 $1500 + b(x - 68)$，相關 0.81，y、x 標準差為 220、2.5，求 x=70 的預測。

參考解答

$b = 0.81(220/2.5) = 71.28$；預測 $1500 + 2(71.28) = 1642.56$，約 1643（D）。

解析

中心化的括號中只代入離參考值的距離 2。

練習 · 2.18 · 講義 p.21

10 筆觀察 $\sum x = 20, \sum y = 100, s_x = 2, s_y = 8, r = -0.98$，預測 x=5 的 y。

參考解答

$b = -3.92$，故 $\hat{y} = 10 - 3.92(5 - 2) = -1.76$，選接近 −2（B）。

解析

負相關造成高於 x 平均的預測低於 y 平均。

練習 · 2.20 · 講義 p.22

兩個解釋變數擬合後係數為 (9.9107, 0.2893, −2.2893)，第二個觀察 (7,4.6) 的反應為 1.5；求殘差。

參考解答

$1.5-[9.9107+0.2893(7)-2.2893(4.6)]\approx 0.095$（D）。

解析

係數由 $(X^\top X)^{-1}X^\top y$ 得到；最後要算的不是係數而是指定殘差。

練習 · 2.21 · 講義 p.22

四欄設計矩陣中 $X^\top y = (30, 12, 24, 13)^\top$，乘逆矩陣所得係數向量為 $(72, -60, 30, 114)^\top/30$，求第一個非截距係數。

參考解答

$\hat\beta_1 = -60/30 = -2$。

解析

每列對應一個參數；想求一個係數，只用對應那列即可。

練習 · 2.23 · 講義 p.23

三個解釋變數的擬合係數依序為 $(60.5, -91.8, -8.25, 31.75)/30$。在三個 x 都等於 1 的點求預測。

參考解答

四個係數相加後除以 30：$-7.8/30 = -0.26$。

解析

含截距的新設計列是 $(1, 1, 1, 1)$，不是三維向量。

練習 · 2.24 · 講義 p.24

用雨量、流量與假日指標預測事故，模型不含截距。$X^\top y=(57,51,20)^\top$，逆矩陣首列 $(257,-82,-446)/6506$；求雨量係數。

參考解答

$[257(57)-82(51)-446(20)]/6506=0.2378$（C）。

解析

不含截距時，首欄的係數就是第一個解釋變數係數。

練習 · 2.27 · 講義 p.26

題示係數向量中第三項為 3.943，設計矩陣第三欄全為 1。求截距。

參考解答

截距為 3.943（E）。

解析

看常數欄的位置，不要預設截距總是第一個數字。

練習 · 2.28 · 講義 p.27

舊式以男性為 1、女性為 0，截距 18169.3，男性係數 169.55。改以女性為 1，截距變為多少？

參考解答

$18169.30 + 169.55 = 18338.85$（B）。

解析

新參考類別是男性，在相同且為零的經驗值上取舊模型男性預測即可。