概念 01

平方和與殘差標準誤：先辨別分母

同樣的損失資料可以量兩種誤差。只用平均數預測時，總平方和 $TSS = \sum (y_i - \bar{y})^2$；允許迴歸線後，殘差平方和 $RSS = \sum (y_i - \hat{y}_i)^2$。後者是估計誤差變異的材料，卻不能直接除以 n：含截距及 p 個斜率的普通最小平方用掉 $p+1$ 個自由度，殘差不能任意變動，而須滿足 $X^\top e = 0$。因此殘差均方與殘差標準誤（residual standard error）為

$$s^2 = \frac{RSS}{n-p-1}, \qquad s = \sqrt{s^2}.$$

在滿秩、條件平均正確且條件誤差共變異矩陣為 $\sigma^2 I$ 時，$e = (I-H)\varepsilon$，其中 $H = X(X^\top X)^{-1}X^\top$ 是投影矩陣。故 $E(RSS \mid X) = \sigma^2 \operatorname{tr}(I-H) = (n-p-1)\sigma^2$。這解釋了分母從哪裡來。$s$ 用原反應的單位，例如元；s^2 用平方元。預測競賽報告的訓練 MSE 通常除以 n，兩種 MSE 用途不同。

★ 精選 · 3.1 · 講義 p.40

實際值 (2,5,6,8,4)，擬合值 (4,3,9,3,6)。求 SSE。

參考解答

$(-2)^2+2^2+(-3)^2+5^2+(-2)^2=46$（E）。

解析

殘差可負，平方和不可負。

★ 精選 · 3.3 · 講義 p.40

簡單迴歸 10 筆，$R^2=0.6, \sum y=30, \sum y^2=690$，求誤差變異估計。

參考解答

$TSS=690-30^2/10=600$，$RSS=240$，$s^2=240/8=30$（B）。

解析

先恢復平方和，再按模型自由度除。

概念 02

決定係數：模型比只猜平均少掉多少平方誤差？

將 $y_i - \bar{y} = e_i + (\hat{y}_i - \bar{y})$ 平方後加總。交叉項為零，因殘差與擬合值正交，並且含截距使殘差和為零。因此 $TSS = RSS + RegSS$，其中 $RegSS = \sum(\hat{y}_i - \bar{y})^2$。**決定係數（coefficient of determination）**

$$R^2 = \frac{RegSS}{TSS} = 1 - \frac{RSS}{TSS}.$$

例如 $R^2 = 0.6$ 是指同一樣本內，使用模型相對只用均值，減少六成平方誤差；不代表六成個案被預測正確、不代表因果，也不保證未來資料準。對一般含截距 OLS，新增變數可將新係數設零，舊模型仍可達，所以訓練 R^2 不會下降。不含截距或樣本外時，前述分解與範圍不可照搬。

簡單迴歸裡 $\hat{y}_i - \bar{y} = \hat{\beta}_1(x_i - \bar{x})$，故 $RegSS = \hat{\beta}_1^2 S_{xx} = S_{xy}^2 / S_{xx}$。除以 $TSS = S_{yy}$，得 $R^2 = r_{xy}^2$。只限含截距、一個斜率，且資料確實有變異；平方已失去方向資訊。

★ 精選 · 3.4 · 講義 p.40

迴歸、誤差自由度為 4、20，均方為 1058.32、84.58；求 R^2。

參考解答

$4233.28/(4233.28+1691.6)=0.7145$。

解析

平方和等於均方乘該來源的自由度。

★ 精選 · 3.12 · 講義 p.42

反應樣本變異 1.5，五筆資料的前四個殘差為 0.4、−0.3、0、−0.7。求 R^2。

參考解答

第五個殘差為 0.6，$RSS = 1.1, TSS = 4(1.5) = 6$，故 0.8167（A）。

解析

含截距時殘差和為零，可以反推缺失值。

概念 03

係數的標準誤、信賴區間與 t 檢定

問「斜率有多不確定」時，估的是 $\hat{\beta}$ 在重複抽樣時的變異，並非殘差標準差本身。將模型代回 OLS：

$$\hat{\beta} = \beta + (X^\top X)^{-1} X^\top \varepsilon,$$

所以在 $\mathrm{Var}(\varepsilon \mid X) = \sigma^2 I$ 下，線性組合的共變異矩陣為 $\sigma^2 (X^\top X)^{-1}$。把未知的 σ^2 換成 s^2；第 j 個對角元素開平方才是係數標準誤。簡單迴歸給

$$SE(\hat{\beta}_1) = \frac{s}{\sqrt{S_{xx}}}, \qquad SE(\hat{\beta}_0) = s\sqrt{\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}}, \qquad \widehat{\mathrm{Cov}}(\hat{\beta}_0, \hat{\beta}_1) = -\frac{s^2 \bar{x}}{S_{xx}}.$$

x 分散越廣越能看出斜率；若 $x = 0$ 遠離樣本中心，截距反而難估。對比 $c^\top \beta$ 的估計變異為 $s^2 c^\top (X^\top X)^{-1} c$。例如差值變異是 $V_1 + V_2 - 2C_{12}$，不可把標準誤直接相減。

檢定 $H_0 : \beta_j = b_0$ 時，$t = (\hat{\beta}_j - b_0)/SE(\hat{\beta}_j)$。在條件常態、模型正確等經典假設下，虛無假設成立時 $t \sim t_{n-p-1}$。雙尾 p 值為 $2P(T \geq |t_{obs}|)$；單尾則依事前方向取一個尾巴。$100(1-\alpha)\%$ 區間為 $\hat{\beta}_j \pm t_{1-\alpha/2,n-p-1} SE$。**即：先量出與虛無值差多少，再換算成幾個標準誤，最後才查尾端機率。**

★ 精選 · 3.15 · 講義 p.43

Box–Cox 反應 $Y^* = 2(\sqrt{Y} - 1)$ 於指定特徵下均值 19、變異數 4；求原尺度的期望。

參考解答

$Y = (Y^*/2 + 1)^2$，故 $E(Y) = (19^2 + 4)/4 + 19 + 1 = 111.25$。

解析

反轉非線性轉換後取期望，須保留變異數項。

★ 精選 · 3.16 · 講義 p.44

簡單迴歸誤差平方和 4296、誤差自由度 9，$S_{xx}=120$；求 95% 斜率區間寬度。

參考解答

$s^2=477.333$，寬 $2(2.262)\sqrt{477.333/120}=9.023$（A）。

解析

寬度是誤差幅度的兩倍。

★ 精選 · 3.21 · 講義 p.45

已知誤差變異數 4，逆 Gram 矩陣給兩斜率對角項 0.7、0.2，交叉項 0.4，求差值變異數。

參考解答

$4(0.7+0.2-2\times0.4)=0.4$。

解析

共變異會抵銷一部分差值變異。

★ 精選 · 3.29 · 講義 p.48

六筆簡單迴歸 $b = 1.15, SE = 0.043$；雙尾檢定母體斜率為 1。

參考解答

$t = 0.15/0.043 = 3.488$，自由度 4，$0.02 < p < 0.05$（C）。

解析

分子先扣虛無值 1，不能直接用估計值除以 SE。

概念 04

新增變數圖與偏相關：扣掉共同解釋變數之後還有什麼？

若房屋面積與屋齡相關，單看保費和屋齡的散點圖不等於模型中的屋齡效果。令 Z 包含截距和其他解釋變數，分別將 y 與 x_j 對 Z 取殘差 v、u。把 v 對 u 畫圖即新增變數圖（added-variable plot），斜率 $u^\top v / u^\top u$ 等於完整模型的第 j 個係數。理由是原平方誤差先對 Z 最小化後，只剩 $\|v - u\beta_j\|^2$ 待最小化。

偏相關是 $r_{partial} = u^\top v / (\|u\|\|v\|)$。全部變數模型的 RSS 為 $v^\top v(1 - r_{partial}^2)$，而 $SE(\hat{\beta}_j) = s/\sqrt{u^\top u}$，代入檢定 $\beta_j = 0$ 的 t 值，得到

$$t = r_{partial}\sqrt{\frac{n-p-1}{1-r_{partial}^2}}, \qquad r_{partial} = \frac{t}{\sqrt{t^2 + n - p - 1}}.$$

偏相關保留正負且介於 −1 與 1，t 值可任意大。即：把其他變數已能解釋的部分先移走，再比較剩下的兩組起伏。

★ 精選 · 3.39 · 講義 p.51

以前一題的 t 值計算偏相關。

參考解答

$-2.6821/\sqrt{2.6821^2+2} = -0.8846$。

解析

用完整模型的殘差自由度，符號與 t 相同。

★ 精選 · 3.42 · 講義 p.52

48 筆、三斜率，偏相關 0.6540，求 t。

參考解答

$t = 0.654\sqrt{44/(1-0.654^2)} = 5.7345$。

解析

平方後解方程可能有正負兩根，應與偏相關同號。

TERMS

本章中英術語

中文	English	解題時的意思
殘差標準誤	residual standard error	用剩餘自由度估計誤差尺度。
決定係數	coefficient of determination	相對於只猜平均值，模型解釋的平方變異比例。
偏相關	partial correlation	先排除控制變數後，兩個剩餘部分的相關。

練習 · 3.2 · 講義 p.40

殘差平方和 12，迴歸平方和 108，求決定係數。

參考解答

$108/(108+12) = 0.9$。

解析

總變異由已解釋和未解釋兩部分組成。

練習 · 3.5 · 講義 p.41

五組 X 依序為 6.8、7、7.1、7.2、7.4；對應 Y 為 0.8、1.2、0.9、0.9、1.5。簡單含截距迴歸的決定係數是多少？可對照題 2.14。

參考解答

$S_{xx}=0.2, S_{xy}=0.18, S_{yy}=0.332$，故 $R^2=0.18^2/(0.2\times 0.332)=0.488$（C）。

解析

單變數含截距才可用相關平方。

練習 · 3.6 · 講義 p.41

14 週股票價格迴歸市場指數，$RegSS = 677.1142, TSS = 949.388$；解釋多少變異？

參考解答

約 71.32%（最接近 C）。

解析

解釋變異指訓練樣本平方和比例，不是上漲機率。

練習 · 3.7 · 講義 p.41

$RSS = 230, R^2 = 0.64$，求總平方和。

參考解答

$230/(1-0.64) = 638.89$（B）。

解析

殘差占未解釋比例 36%。

練習 · 3.8 · 講義 p.41

簡單迴歸中，解釋比例等於 $RegSS/TSS$？殘差標準誤以 $n-1$ 自由度估變異嗎？

參考解答

前兩種解釋比例敘述正確，後者錯；I、II（A）。

解析

估變異用 s^2，簡單迴歸自由度 $n-2$。

練習 · 3.9 · 講義 p.42

銀行資料中 $s_x^2 = 87.5, s_y^2 = 3.5, s_{xy} = 17$，求 R^2。

參考解答

$17^2/(87.5 \times 3.5) = 0.9437$（E）。

解析

共變異要平方，分母用兩變異的乘積。

練習 · 3.10 · 講義 p.42

八筆資料 $\bar{y}=100, \sum y_i^2=81004, \sum \hat{y}_i^2=80525$，求 R^2。

參考解答

$TSS=1004, RegSS=525$，$R^2=525/1004=0.523$（D）。

解析

含截距時擬合值與反應的平均相同。

練習 · 3.11 · 講義 p.42

五筆簡單迴歸的反應為 1 至 5，$s^2 = 1$，求決定係數。

參考解答

$TSS = 10, RSS = (5-2)1 = 3$，所以 0.7（E）。

解析

已給的是殘差均方，須乘自由度。

練習 · 3.13 · 講義 p.42

50 筆、四個解釋變數，$TSS = 996, s^2 = 2.47$。

參考解答

$RSS = 45(2.47) = 111.15$，$R^2 = 0.8884$（D）。

解析

截距也占一個自由度。

練習 · 3.14 · 講義 p.43

反應為 2.441、3.627、5.126、7.266、10.570，$RSS = 1.772$，求 R^2。

參考解答

$TSS \approx 41.361$，故 $1 - 1.772/41.361 = 0.9572$（E）。

解析

平方和中心化，不可直接拿原始平方總和當分母。

練習 · 3.17 · 講義 p.44

簡單迴歸 $RSS = 967$，誤差自由度 5，$S_{xx} = 2000$；求斜率標準誤。

參考解答

$\sqrt{(967/5)/2000} = 0.311$（C）。

解析

標準誤是估計變異數的平方根。

練習 · 3.18 · 講義 p.44

係數估計量絕對值 2.503，SE=1.042，誤差自由度 15；框出雙尾 p 值。

參考解答

$|t| = 2.402$ 介於 2.131 與 2.602，故 $0.02 < p < 0.05$（C）。

解析

雙尾檢定的顯著水準須均分到兩尾。

練習 · 3.19 · 講義 p.45

32 筆資料、三個解釋變數，以 10% 雙尾門檻判讀截距與三係數，絕對 t 值依序為 7.416、2.500、1.328、7.250。

參考解答

自由度 28，臨界值約 1.701；截距、第一與第三斜率顯著（D）。

解析

比較絕對值；顯著並非效果大。

練習 · 3.20 · 講義 p.45

20 筆資料含截距、五個斜率，要以 10% 雙尾檢定找不顯著係數。

參考解答

t 臨界值 $t_{0.95,14} = 1.7613$，題表中的第 1、2、4 個斜率未達門檻（C）。

解析

自由度要減去六個參數。

練習 · 3.22 · 講義 p.46

$s^2 = 280.1167$，兩對角項均 0.0087，交叉項 −0.0020，求斜率差標準誤。

參考解答

$\sqrt{280.1167(0.0087 + 0.0087 + 0.004)} = 2.4483$（C）。

解析

共變異是負值時，差值反而更不確定。

練習 · 3.23 · 講義 p.46

30 筆、四個參數；用 $y^\top y = 7995$、係數 (5.22,1.62,0.21,−0.45)、$X^\top y = (261.5, 4041.5, 6177.5, 5707)$ 與逆矩陣目標對角項 0.0035，求 95% 區間寬。

參考解答

$RSS = y^\top y - \hat{\beta}^\top X^\top y = 1353.615$；$SE = \sqrt{(RSS/26)(0.0035)} = 0.4269$，寬 1.755（E）。

解析

常態方程式使 RSS 的矩陣式可以簡化。

練習 · 3.24 · 講義 p.46

$RSS = 282.82$、自由度 11；兩斜率對角項為 2.14、0.03，交叉項 0.11。求差值 SE。

參考解答

$\sqrt{(282.82/11)(2.14 + 0.03 - 2(0.11))} = 7.081$。

解析

先求殘差均方，再乘設計帶來的變異比例。

練習 · 3.25 · 講義 p.47

20 筆簡單迴歸 $RSS=7832, S_{xx}=10668, b=-1.104$，求 95% 區間。

參考解答

$SE=\sqrt{7832/(18\times 10668)}=0.2020$；$-1.104\pm 2.101(0.2020)=(-1.53,-0.68)$，約 (−1.52,−0.68)。

解析

使用樣本斜率作中心，雙尾各占 2.5%。

練習 · 3.26 · 講義 p.47

8 筆簡單迴歸 $RSS = 2394, S_{xx} = 1.62, b = -35.69$，求 90% 區間。

參考解答

$SE = \sqrt{399/1.62} = 15.694$，故 $-35.69 \pm 1.943(15.694) = (-66.2, -5.2)$（B）。

解析

90% 雙尾取第 95 百分位。

練習 · 3.27 · 講義 p.47

十人中四人屬指標組，擬合斜率 4，$RSS = 92$；求 t。

參考解答

$S_{xx} = 6(0.4)^2 + 4(0.6)^2 = 2.4$，$SE = \sqrt{(92/8)/2.4} = 2.189$，t=1.827（D）。

解析

二元斜率是兩組平均差，仍需用組內雜訊評估顯著性。

練習 · 3.28 · 講義 p.48

12 筆簡單迴歸 $b = 0.4, SE = 0.181$；雙尾檢定零斜率。

參考解答

$t = 2.210$、自由度 10，$0.05 < p < 0.10$（D）。

解析

在 10% 會拒絕，在 5% 不拒絕。

練習 · 3.30 · 講義 p.48

$n=20, RSS=5348, S_{xx}=2266, \bar{x}=100$，截距估計 68.73。求 95% 下界。

參考解答

$SE=\sqrt{(5348/18)(1/20+100^2/2266)}=36.415$；下界約 −7.77（D）。

解析

x=0 遠離中心，截距會很不精確。

練習 · 3.31 · 講義 p.49

大樣本斜率 −1.03，標準誤 0.06，求近似 95% 區間。

參考解答

$-1.03 \pm 1.96(0.06) = (-1.1476, -0.9124)$（A）。

解析

負數區間仍由小至大排列。

練習 · 3.32 · 講義 p.49

六筆簡單迴歸 $RSS = 25, S_{xx} = 50, b = 4$，求 95% 上界。

參考解答

$4 + 2.7764\sqrt{(25/4)/50} = 4.9816$（A）。

解析

注意給的是平方和，不是標準差。

練習 · 3.33 · 講義 p.49

十筆簡單迴歸 $RSS = 2.79, S_{xx} = 180, \bar{x} = 6$，求 95% 截距區間寬度。

參考解答

$2(2.306)\sqrt{(2.79/8)(1/10 + 36/180)} = 1.4918$（E）。

解析

截距 SE 除了斜率不確定性，也含樣本平均的不確定性。

練習 · 3.34 · 講義 p.49

$RSS = 1.8739$、誤差自由度 9，目標對角項 0.15284；求 95% 區間的半寬。

參考解答

$2.2622\sqrt{(1.8739/9)(0.15284)} = 0.4036$（E）。

解析

誤差幅度只乘一次臨界值；若問全寬才倍增。

練習 · 3.35 · 講義 p.50

斜率 −2、虛無值 1；誤差均方 4、逆矩陣該對角項 $2/3$。計算 t。

參考解答

$SE = \sqrt{4(2/3)} = 1.633$，t 約 −1.837（C）。

解析

比較的是 −2 與 1 的差，不是 −2 與 0。

練習 · 3.36 · 講義 p.50

15 筆、三斜率；目標估計 1.372，SE=0.258，求 95% 區間。

參考解答

$1.372 \pm 2.201(0.258) = (0.804, 1.940)$。

解析

自由度是 11，而非 15。

練習 · 3.37 · 講義 p.50

以 48 個月的牙科理賠擬合線性模型，截距、工作日數、週末日數、平均會員數的雙尾 p 值分別為 0.0303、0.0330、0.5649、約 0。按 5% 水準，應刪哪一項？（A）截距；（B）工作日數；（C）週末日數；（D）平均會員數；（E）都不刪。

參考解答

僅週末日數的 p 值高於 0.05，其他題列變數達顯著門檻（C）。

解析

已給 p 值就直接比較；未顯著不等於效果必為零。

練習 · 3.38 · 講義 p.51

五筆、三參數；$b_2 = -40.50, SE = 15.10$，左尾檢定零值。

參考解答

$t = -2.6821$，自由度 2，$0.05 < p < 0.10$（D）。

解析

單尾與雙尾使用同樣統計量，但 p 值不同。

練習 · 3.40 · 講義 p.51

估計線為 $b_0 + 600b_1$，兩係數變異 1.89952、0.00001，共變異 −0.00364。求 SE。

參考解答

$\sqrt{1.89952 + 600^2(0.00001) + 1200(-0.00364)} = 1.06373$（A）。

解析

這是平均反應估計的不確定性，單一新觀察另含個別誤差。

練習 · 3.41 · 講義 p.51

斜率 −12、其變異估計 2.79655；88 筆、三參數，求偏相關。

參考解答

$t = -12/\sqrt{2.79655} = -7.176$，$r = t/\sqrt{t^2 + 85} = -0.6142$。

解析

偏相關是已排除其他解釋變數線性影響後的相關。