SRM · 第 5 章

線性迴歸：模型診斷

配適出迴歸之後，要回頭檢查：線性、常態、變異數固定、獨立這四個假設成不成立？有沒有個別的點把整條線拉走？解釋變數之間是不是幾乎共線？本章的工具全部建立在殘差、帽子矩陣與輔助迴歸上，每一條公式都會從頭推導。

本章內容

1. 5.1 驗證模型假設：殘差與帽子矩陣
2. 5.2 離群值與影響點
3. 5.3 解釋變數的共線性與 VIF

本章對應講義第 5 課，讀本是 Frees《Regression Modeling with Actuarial and Financial Applications》2.5、5.3～5.7 節與 ISLR 3.3.3 節。考試常見的計算只有幾種：標準化殘差、槓桿、Cook 距離、VIF 與係數標準誤；觀念題則是「看殘差圖判斷哪個假設被違反」。

5.1 驗證模型假設：殘差與帽子矩陣

一、帽子矩陣 H

第 2 章推導過最小平方估計 $\mathbf{b} = (X'X)^{-1}X'\mathbf{y}$。配適值是

$$\hat{\mathbf{y}} = X\mathbf{b} = X(X'X)^{-1}X'\mathbf{y} = H\mathbf{y}, \qquad H = X(X'X)^{-1}X'.$$

H 是 $n \times n$ 的矩陣，它把 $\mathbf{y}$「戴上帽子」變成 $\hat{\mathbf{y}}$，所以叫**帽子矩陣**（hat matrix）。殘差是

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = (I - H)\mathbf{y}.$$

H 只由解釋變數 X 決定，和 $\mathbf{y}$ 無關。把 $\hat{y}_i = \sum_j h_{ij} y_j$ 逐項寫開，就看得出 H 第 i 列的意義：**第 i 個配適值是所有反應值的加權和，權重是 H 的第 i 列**。其中對角元素 $h_{ii} = \dfrac{\partial \hat{y}_i}{\partial y_i}$ 是第 i 筆觀察「自己對自己配適值的影響」，叫做第 i 筆觀察的**槓桿**（leverage）。

推導：H 的五個性質

1. **對稱**（symmetric）：$H' = \left(X(X'X)^{-1}X'\right)' = X\left((X'X)^{-1}\right)'X' = X(X'X)^{-1}X' = H$，因為 $X'X$ 對稱，它的反矩陣也對稱。
2. **冪等**（idempotent）：$H^2 = X(X'X)^{-1}\underbrace{X'X(X'X)^{-1}}_{=I}X' = X(X'X)^{-1}X' = H$。投影兩次和投影一次一樣。
3. $HX = X$：$HX = X(X'X)^{-1}X'X = X$。X 的欄已經在欄位空間裡，投影不會改變它。特別是有截距時，X 的第一欄是 $\mathbf{1}$，所以 $H\mathbf{1} = \mathbf{1}$：H 每一列的和都是 1。
4. $I - H$ **也對稱、冪等，且** $(I-H)X = 0$：$(I-H)^2 = I - 2H + H^2 = I - H$；$(I-H)X = X - X = 0$。
5. **跡等於參數個數**：利用 $\operatorname{tr}(AB) = \operatorname{tr}(BA)$，

   $$\operatorname{tr}(H) = \operatorname{tr}\left(X(X'X)^{-1}X'\right) = \operatorname{tr}\left((X'X)^{-1}X'X\right) = \operatorname{tr}(I_{k+1}) = k+1.$$

   所以所有槓桿的總和是 $\sum_i h_{ii} = k+1$，平均槓桿是 $(k+1)/n$。

幾何上，H 是把 $\mathbf{y}$ 垂直投影到 X 欄位空間的矩陣（第 2 章 2.2 節的圖），$I - H$ 則投影到和欄位空間垂直的方向。

二、殘差的變異數

模型假設 $\mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}$，$\operatorname{Var}(\boldsymbol{\varepsilon}) = \sigma^2 I$。誤差 ε_i 的變異數是 σ^2，但**殘差 e_i 的變異數比 σ^2 小**，而且每一筆不一樣。

推導：$\mathrm{Var}(\mathbf{e}) = \sigma^2(I - H)$

先把殘差寫成誤差的函數。由性質 4，$(I - H)X\boldsymbol{\beta} = 0$，所以

$$\mathbf{e} = (I - H)\mathbf{y} = (I - H)(X\boldsymbol{\beta} + \boldsymbol{\varepsilon}) = (I - H)\boldsymbol{\varepsilon}.$$

於是 $E(\mathbf{e}) = (I - H)E(\boldsymbol{\varepsilon}) = \mathbf{0}$。對常數矩陣 A，$\mathrm{Var}(A\boldsymbol{\varepsilon}) = A\,\mathrm{Var}(\boldsymbol{\varepsilon})A'$，因此

$$\mathrm{Var}(\mathbf{e}) = (I - H)(\sigma^2 I)(I - H)' = \sigma^2(I - H)(I - H) = \sigma^2(I - H),$$

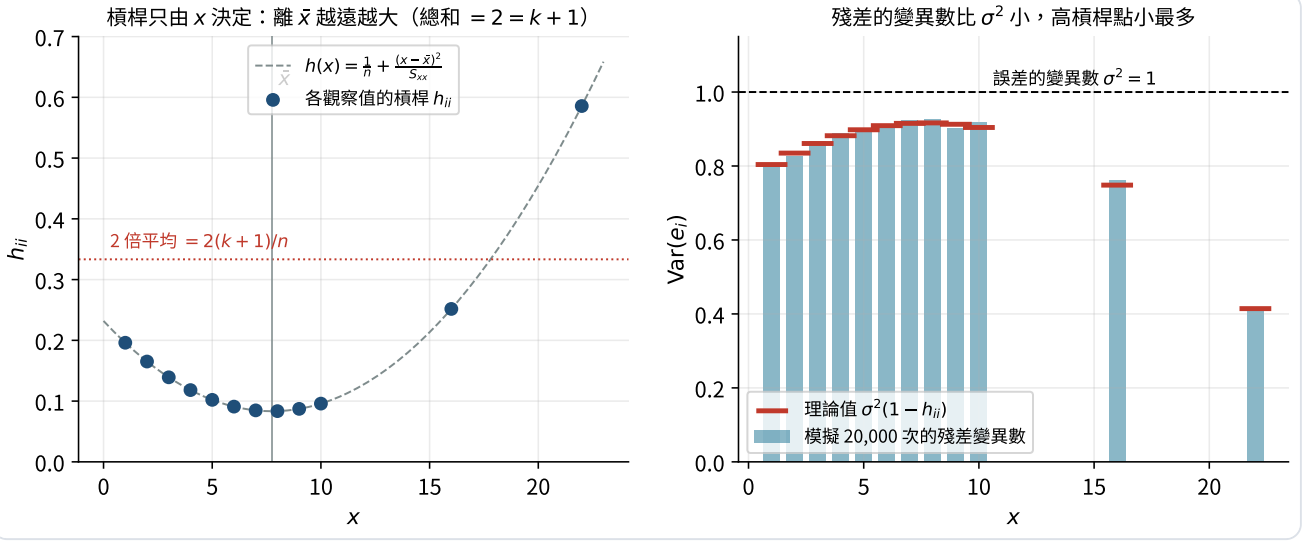
最後一步用了 $I - H$ 對稱且冪等。逐項讀出來：

$$\mathrm{Var}(e_i) = \sigma^2(1 - h_{ii}), \qquad \mathrm{Cov}(e_i, e_j) = -\sigma^2 h_{ij} \quad (i \neq j).$$

σ^2 用殘差變異數 $s^2 = \text{Error SS}/(n - k - 1)$ 估計，所以 $\widehat{\mathrm{Var}}(e_i) = s^2(1 - h_{ii})$。這段推導考試不會直接考，但它解釋了下面所有公式為什麼長這樣。

為什麼殘差的變異數比較小，而且槓桿越大越小

配適線是用資料本身算出來的，它會「遷就」每一個點，把殘差拉向 0。一個點的槓桿 h_{ii} 越大，它對自己配適值的拉力越強：h_{ii} 接近 1 時，配適線幾乎被迫穿過這個點，殘差幾乎一定接近 0，變異數 $\sigma^2(1 - h_{ii})$ 也接近 0。所以**高槓桿點的殘差小，並不代表它配得好**，只代表它把線拉到了自己身上。這也是殘差要先標準化再比較的原因。



簡單迴歸，12 個固定的 x 值（最後兩個 16、22 遠離其他點），真實 $\sigma^2 = 1$。左：槓桿 $h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}$ 是 x 的二次函數，在 $\bar{x}$ 最小；12 個槓桿加總剛好是 $k + 1 = 2$。右：重複產生 20,000 組 $\mathbf{y}$、每組都重新配適，各點殘差的實際變異數（長條）和理論值 $1 - h_{ii}$（紅線）完全吻合；$x = 22$ 那一點的殘差變異數只剩 0.41。

例題 5A

三個參數（含截距）、6 筆觀察的迴歸，帽子矩陣的前兩列前兩行為 $h_{11} = 0.458$、$h_{12} = 0.376$、$h_{22} = 0.411$，迴歸標準誤 $s = 1.389$，前兩個殘差為 -0.893、0.883。(1) 求 $e_1 + e_2$ 的估計變異數；(2) 求前兩個標準化殘差。

(1) $\widehat{\mathrm{Var}}(\mathbf{e}) = s^2(I - H)$，所以 $\widehat{\mathrm{Var}}(e_1) = 0.542 s^2$、$\widehat{\mathrm{Var}}(e_2) = 0.589 s^2$、$\widehat{\mathrm{Cov}}(e_1, e_2) = -0.376 s^2$（注意非對角是**負的** h_{12}）。

$$\widehat{\mathrm{Var}}(e_1 + e_2) = s^2\big(0.542 + 0.589 + 2(-0.376)\big) = 1.389^2(0.379) = 0.7312.$$

(2) $r_1 = \dfrac{-0.893}{1.389\sqrt{0.542}} = -0.873$，$r_2 = \dfrac{0.883}{1.389\sqrt{0.589}} = 0.828$。

三、簡單迴歸的槓桿

推導：$h_{ij} = \frac{1}{n} + \frac{(x_i - \bar{x})(x_j - \bar{x})}{S_{xx}}$

簡單迴歸的配適值是 $\hat{y}_i = \bar{y} + b_1(x_i - \bar{x})$，其中 $b_1 = \frac{\sum_j (x_j - \bar{x})(y_j - \bar{y})}{S_{xx}} = \frac{\sum_j (x_j - \bar{x}) y_j}{S_{xx}}$（因為 $\sum_j (x_j - \bar{x})\bar{y} = 0$）。代入：

$$\hat{y}_i = \sum_j \frac{1}{n} y_j + (x_i - \bar{x}) \sum_j \frac{(x_j - \bar{x})}{S_{xx}} y_j = \sum_j \left[\frac{1}{n} + \frac{(x_i - \bar{x})(x_j - \bar{x})}{S_{xx}} \right] y_j.$$

方括號就是 h_{ij}。取 $j = i$：

$$h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum_j (x_j - \bar{x})^2} \qquad (5.1)$$

檢查總和：$\sum_i h_{ii} = 1 + S_{xx}/S_{xx} = 2 = k + 1$，和性質 5 一致。

(5.1) 說明：**槓桿只看解釋變數離平均多遠**，跟反應值無關。$x_i = \bar{x}$ 時槓桿最小，等於 $1/n$。

四、三種標準化殘差

殘差的平均已經是 0，標準化只要除以標準差。分母有三種選法：

1. e_i / s：最簡單，但不精確。s 估計的是誤差 ε_i 的標準差，不是殘差 e_i 的。
2. **標準化殘差**（standardized residual）：除以殘差自己的估計標準差，

$$r_i = \frac{e_i}{s\sqrt{1 - h_{ii}}}.$$

3. **學生化殘差**（studentized residual）：分母改用刪掉第 i 筆後重新配適的殘差標準誤 $s_{(i)}$，

$$r_i^* = \frac{e_i}{s_{(i)}\sqrt{1 - h_{ii}}}.$$

   如果 y_i 特別離譜，它會把 s 撐大，反而讓自己的 r_i 看起來沒那麼大；刪掉它再估 s 就避開了這個問題。常態假設下 r_i^* 服從 t 分配，所以叫「學生化」。

刪掉第 i 筆後只剩 $n-1$ 筆觀察、仍有 $k+1$ 個參數，所以 $s_{(i)}$ 的自由度是 $n-k-2$，$r_i^* \sim t_{n-k-2}$。

兩種殘差的換算只要記住：**分子相同，分母只差 s 與 $s_{(i)}$**，

$$r_i^* = r_i \cdot \frac{s}{s_{(i)}}.$$

推導：不必重新配適也能算 $s_{(i)}$

下面 5.2 節會推導，刪掉第 i 筆之後，其他點的殘差變成 $e_j + h_{ij}c$，其中 $c = e_i/(1-h_{ii})$。所以刪掉後的誤差平方和是

$$\text{SSE}_{(i)} = \sum_{j \neq i} (e_j + h_{ij}c)^2 = \sum_{\text{全部 } j} (e_j + h_{ij}c)^2 - (e_i + h_{ii}c)^2.$$

第一項展開：$\sum_j e_j^2 + 2c\sum_j h_{ij}e_j + c^2\sum_j h_{ij}^2$。因為 $H\mathbf{e} = H(I-H)\mathbf{y} = \mathbf{0}$，中間項是 0；因為 H 對稱冪等，$\sum_j h_{ij}^2 = (H^2)_{ii} = h_{ii}$。第二項 $e_i + h_{ii}c = e_i\big(1 + \frac{h_{ii}}{1-h_{ii}}\big) = c$。於是

$$\text{SSE}_{(i)} = \text{SSE} + c^2 h_{ii} - c^2 = \text{SSE} - \frac{e_i^2}{1-h_{ii}}.$$

除以自由度 $n-k-2$：

$$s_{(i)}^2 = \frac{(n-k-1)s^2 - e_i^2/(1-h_{ii})}{n-k-2} = s^2 \cdot \frac{n-k-1-r_i^2}{n-k-2},$$

所以

$$r_i^* = r_i \cdot \frac{s}{s_{(i)}} = r_i \sqrt{\frac{n-k-2}{n-k-1-r_i^2}}.$$

r_i^* 是 r_i 的遞增函數，兩者排名一樣；$|r_i|$ 大時 r_i^* 更極端。

易錯提醒

- 標準化殘差的分母是 $s\sqrt{1-h_{ii}}$，**不是** s，也不是 $s(1-h_{ii})$。
- 殘差的共變異數是 $-\sigma^2 h_{ij}$，前面有負號。
- 有些題目同時給 s、$s_{(i)}$ 與 r_i，數字不一定滿足上面的恆等式（題目只想考定義），照 $r_i^* = r_i\, s/s_{(i)}$ 算即可。

例題 5-1

迴歸標準誤 $s = 67$、第一個殘差 $e_1 = 3.2$、第一筆的槓桿 $h_{11} = 0.04$。求第一個標準化殘差。

$$r_1 = \frac{3.2}{67\sqrt{1-0.04}} = \frac{3.2}{65.645} = 0.04875。$$

五、用殘差檢查四個假設

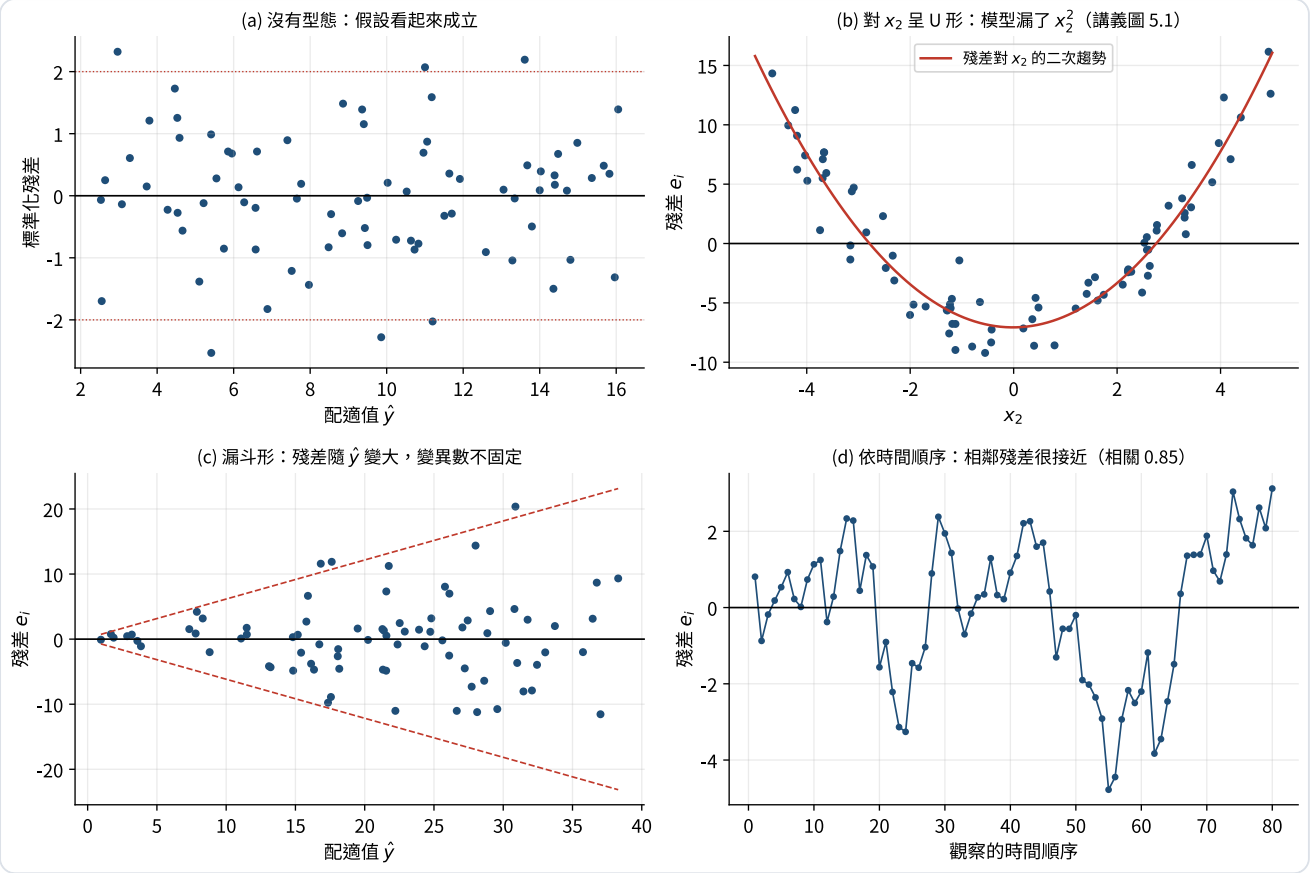
線性迴歸假設：

1. 反應是解釋變數的**線性**函數。
2. 反應（誤差）服從**常態**分配。
3. 變異數固定，叫**同質變異**（homoscedastic）；不固定叫**異質變異**（heteroscedastic）。
4. 觀察值彼此**獨立**。

每個假設都有對應的殘差圖：

假設	畫什麼	假設成立時	違反時的樣子
線性	殘差（或 y）對每個解釋變數	沒有型態	彎曲，例如 U 形
常態	標準化殘差的常態機率圖（qq 圖）	點落在 45° 線上	兩端彎離直線
變異數固定	殘差或標準化殘差對配適值 $\hat{y}$	上下寬度一樣	漏斗形

假設	畫什麼	假設成立時	違反時的樣子
獨立	殘差依預期有相關的順序（例如時間）排列	前後沒有關聯	相鄰殘差很接近、成段起伏



四種殘差圖（模擬資料，各 80 筆）。(a) 正確的模型：標準化殘差在 0 上下隨機散布，幾乎都在 ± 2 之內。(b) 真實模型含 x_2^2，但配適時沒放：殘差對 x_2 呈 U 形。(c) 誤差的標準差和 $\hat{y}$ 成正比：殘差像漏斗一樣越來越寬。(d) 誤差有時間上的相關：依時間順序畫，相鄰殘差的相關係數是 0.85，殘差成段地在 0 以上或以下。

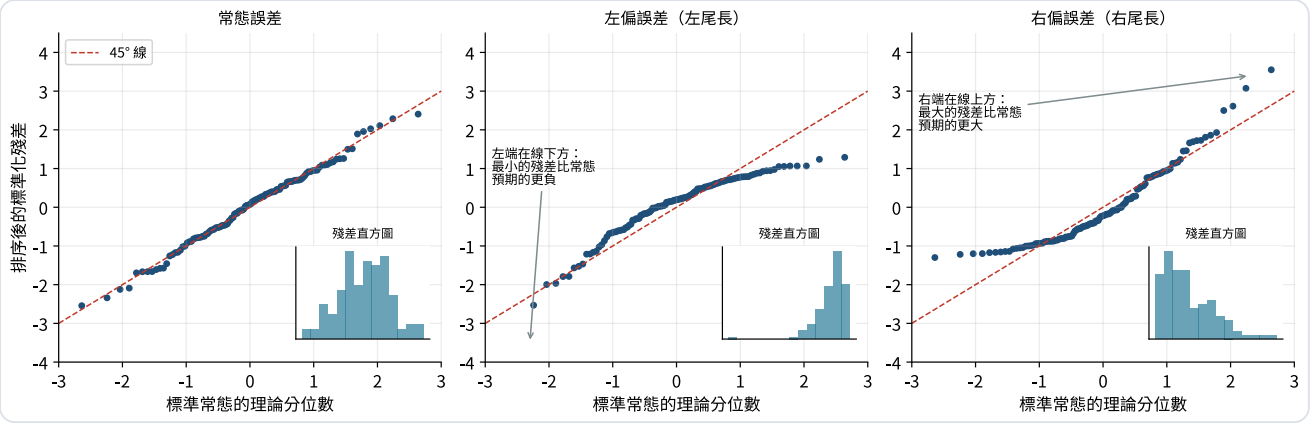
處理方法：

- **非線性**：加入平方項、交互作用，或轉換變數（第 2 章 2.3 節）。
- **異質變異**：若知道各觀察的變異數，用**加權最小平方**（第 2 章 2.3 節），也可以先對 y 取對數等轉換。
- **非常態**：轉換反應變數，或改用其他分配族（第 11 章起的廣義線性模型）。
- **不獨立**：改用時間序列模型（第 19 章起）。

加權最小平方的權重

權重是**變異數**的倒數，不是標準差的倒數。第 2 章推導過，加權最小平方要讓 $\sqrt{w_i}\,\varepsilon_i$ 的變異數相同，所以 $w_i \propto 1/\sigma_i^2$。

常態性用 qq 圖（第 1 章 1.3 節）：把排序後的標準化殘差對標準常態的分位數作圖。



同一個線性模型、三種誤差分配的標準化殘差 qq 圖（各 120 筆，右下角是直方圖）。常態誤差的點貼著 45° 線。左偏誤差在左端彎到線下方：最小的殘差比常態預期的更負，左尾比較長。右偏誤差在右端翹到線上方：最大的殘差比常態預期的更大。判讀口訣：**哪一端離開直線往外跑，哪一邊的尾巴就比常態長**。

這一節的精選習題

★ 精選 **第 5.1 題** ・講義 p.86・回到對應概念

You are given the following hat matrix:

$$H = \begin{pmatrix} 0.5932 & 0.4407 & 0.1356 & -0.1695 \\ 0.4407 & 0.3559 & 0.1864 & 0.0169 \\ 0.1356 & 0.1864 & 0.2881 & 0.3898 \\ -0.1695 & 0.0169 & 0.3898 & 0.7627 \end{pmatrix},$$

The residual standard deviation is 0.7235.

Calculate the estimated variance of the second residual $\hat{\varepsilon}_2$.

中文題意

已知帽子矩陣 殘差標準差為 0.7235。求第二個殘差 e_2 的估計變異數。

（數據、圖表與選項見上方英文題目。）

答案

$\widehat{\mathrm{Var}}(e_2) = 0.3372$

解析

$\widehat{\mathrm{Var}}(\mathbf{e}) = s^2(I - H)$，第二個對角元素用 $h_{22} = 0.3559$：

$$\widehat{\mathrm{Var}}(e_2) = s^2(1 - h_{22}) = 0.7235^2(1 - 0.3559) = 0.52345 \times 0.6441 = 0.3372.$$

順便檢查：對角和 $0.5932 + 0.3559 + 0.2881 + 0.7627 = 2$，是個兩參數模型（截距 + 一個變數）的帽子矩陣。

易錯

要用 $1 - h_{22}$，不是 h_{22}，也不是第二列其他元素。

★ 精選 **第 5.2 題** · 講義 p.86 · 回到對應概念

For a linear regression with 11 observations and 2 variables plus an intercept, you are given:

- $\sum (y_i - \hat{y}_i)^2 = 32$
- $y_3 - \hat{y}_3 = 1.2$

The leverage of the third observation is 0.6. Calculate the standardized third residual.

中文題意

11 筆觀察、2 個解釋變數加截距的線性迴歸，已知 $\sum (y_i - \hat{y}_i)^2 = 32$、$y_3 - \hat{y}_3 = 1.2$，第三筆觀察的槓桿是 0.6。求第三個標準化殘差。

答案

$r_3 = 0.9487$

解析

誤差自由度 $n - (k+1) = 11 - 3 = 8$，所以

$$s^2 = \frac{32}{8} = 4, \qquad s = 2.$$

$$r_3 = \frac{e_3}{s\sqrt{1 - h_{33}}} = \frac{1.2}{2\sqrt{1 - 0.6}} = \frac{1.2}{2(0.63246)} = 0.9487.$$

易錯

自由度是 $n - k - 1 = 8$，不是 $n = 11$ 或 $n - 1 = 10$。

★ 精選 **第 5.3 題** · 講義 p.86 · 回到對應概念

For a linear regression with 25 observations and 3 variables plus an intercept,

(i) The residual standard error is 22.4.

(ii) If the 21st observation is removed, the residual standard error is 17.2.

(iii) The standardized residual for the 21st observation is 0.83.

Calculate the studentized residual for the 21st observation.

中文題意

25 筆觀察、3 個解釋變數加截距的線性迴歸：(i) 殘差標準誤 22.4；(ii) 刪掉第 21 筆後，殘差標準誤為 17.2；(iii) 第 21 筆的標準化殘差為 0.83。求第 21 筆的學生化殘差。

答案

$r^*_{21} = 1.0809$

解析

兩者分子都是 e_{21}、都乘 $\sqrt{1-h_{21,21}}$，只差 s 換成 $s_{(21)}$：

$$r^*_{21} = \frac{e_{21}}{s_{(21)}\sqrt{1-h}} = r_{21}\cdot\frac{s}{s_{(21)}} = 0.83 \times \frac{22.4}{17.2} = 1.0809.$$

補充：依 5.1 節的恆等式，$s^2_{(i)} = s^2\dfrac{n-k-1-r_i^2}{n-k-2} = 22.4^2\cdot\dfrac{21-0.6889}{20}$，$s_{(21)}$ 應約 22.57。標準化殘差只有 0.83 的點，刪掉後 s 不可能從 22.4 掉到 17.2。題目的數字只是用來練定義。

易錯

不要把 $s/s_{(i)}$ 倒過來乘。$s_{(i)}$ 比 s 小時，學生化殘差比標準化殘差大。

★ 精選 **第 5.5 題** · 講義 p.87 · 回到對應概念

A regression model has the form $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$. It is based on 4 observations of x_i: $\{3, 7, 11, 15\}$. You are given

$$(X'X)^{-1} = \begin{pmatrix} 1.2625 & -0.1125 \\ -0.1125 & 0.0125 \end{pmatrix}.$$

Calculate the hat matrix, the matrix H for which $\hat{\mathbf{y}} = H\mathbf{y}$.

中文題意

迴歸模型 $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$，4 筆觀察的 x_i 為 $\{3, 7, 11, 15\}$。已知 求帽子矩陣 H（使 $\hat{\mathbf{y}} = H\mathbf{y}$ 的矩陣）。

（數據、圖表與選項見上方英文題目。）

答案

$$H = \begin{pmatrix} 0.7 & 0.4 & 0.1 & -0.2 \\ 0.4 & 0.3 & 0.2 & 0.1 \\ 0.1 & 0.2 & 0.3 & 0.4 \\ -0.2 & 0.1 & 0.4 & 0.7 \end{pmatrix}$$

解析

方法一：矩陣相乘。 先算 $X(X'X)^{-1}$，第 i 列是 $(1, x_i)(X'X)^{-1} = (1.2625 - 0.1125x_i,\ -0.1125 + 0.0125x_i)$：

$$X(X'X)^{-1} = \begin{pmatrix} 0.925 & -0.075 \\ 0.475 & -0.025 \\ 0.025 & 0.025 \\ -0.425 & 0.075 \end{pmatrix}.$$

再右乘 $X' = \begin{pmatrix} 1 & 1 & 1 & 1 \\ 3 & 7 & 11 & 15 \end{pmatrix}$，$h_{ij} = a_i + b_i x_j$。例如第一列：$0.925 - 0.075(3) = 0.7$、$0.925 - 0.075(7) = 0.4$、$0.925 - 0.075(11) = 0.1$、$0.925 - 0.075(15) = -0.2$。其餘各列同理。

方法二：用 (5.1) 的 h_{ij} 公式檢查。 $\bar{x} = 9$，$S_{xx} = 36 + 4 + 4 + 36 = 80$，

$$h_{ij} = \frac{1}{4} + \frac{(x_i - 9)(x_j - 9)}{80}.$$

$h_{11} = 0.25 + 36/80 = 0.7$，$h_{12} = 0.25 + (-6)(-2)/80 = 0.4$，$h_{14} = 0.25 + (-6)(6)/80 = -0.2$，$h_{22} = 0.25 + 4/80 = 0.3$，$h_{23} = 0.25 + (-2)(2)/80 = 0.2$，全部吻合。

檢查：對稱；每列和為 1（有截距）；對角和 $0.7 + 0.3 + 0.3 + 0.7 = 2 = k + 1$。兩端的 $x = 3, 15$ 槓桿 0.7，中間兩點 0.3。

> **易錯**
>
> H 是 $n \times n$（這裡 4×4），不是 2×2。

觀念題（6 題，仿 SOA 樣題的質性題，含跨章節）

觀念 **觀念題 C5.1-1** 仿 SOA 樣題・跨章：第 2 章・回到本節開頭

In a linear regression with independent errors of variance σ^2, let e_i be the ith residual and h_{ii} the ith leverage. Determine which of the following statements is/are true.

I. The residuals are independent of one another.

II. $\mathrm{Var}(e_i) = \sigma^2(1 - h_{ii})$.

III. The standardized residual is $e_i / \left(s\sqrt{1 - h_{ii}}\right)$.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

誤差獨立、變異數 σ^2。下列哪些正確？

I. 殘差彼此獨立。

II. $\mathrm{Var}(e_i) = \sigma^2(1 - h_{ii})$。

III. 標準化殘差是 $e_i / \left(s\sqrt{1 - h_{ii}}\right)$。

答案

(C)：只有 II、III 正確

解析

I 錯：$\mathrm{Var}(\mathbf{e}) = \sigma^2(I - H)$，$\mathrm{Cov}(e_i, e_j) = -\sigma^2 h_{ij}$，一般不為 0。殘差受 n 個正規方程式限制（例如和為 0），不可能獨立。

II、III 對（第 5 章 5.1 節）。

觀念 **觀念題 C5.1-2** 仿 SOA 樣題・跨章：第 1,19 章・回到本節開頭

Determine which of the following residual patterns correctly indicate the stated problem.

I. A plot of residuals against fitted values that fans out as the fitted values increase indicates heteroscedasticity.
II. A U-shaped pattern in a plot of residuals against x_j indicates that a quadratic term in x_j may be missing.
III. Long runs of residuals above or below zero when plotted in time order indicate positive serial correlation.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

下列殘差型態與問題的對應，哪些正確？

I. 殘差對配適值越來越開 → 異質變異。
II. 殘差對 x_j 呈 U 形 → 可能漏了 x_j^2。
III. 依時間順序的殘差長時間在 0 的同一側 → 正的序列相關。

答案

(D)：I、II、III 都正確

解析

三者都對，對應第 5 章 5.1 節的四格殘差圖 (b)(c)(d)。序列相關會在第 19 章時間數列再詳細處理。

觀念 **觀念題 C5.1-3** 仿 SOA 樣題・回到本節開頭

Let r_i be the standardized residual and r_i^* the studentized residual of observation i. Determine which of the following statements is/are true.

I. r_i^* always has a smaller absolute value than r_i.

II. r_i^* uses the residual standard error computed with observation i removed.

III. When $|r_i|$ is large, $|r_i^*|$ is larger than $|r_i|$.

(A) III only

(B) I and II only

(C) I and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

r_i 為標準化殘差，r_i^* 為學生化殘差。下列哪些正確？

I. $|r_i^*|$ 一定比 $|r_i|$ 小。

II. r_i^* 用刪掉第 i 筆後的殘差標準誤。

III. $|r_i|$ 大時，$|r_i^*|$ 比 $|r_i|$ 大。

答案

(E)：只有 II、III 正確

解析

由 $r_i^* = r_i\sqrt{\dfrac{n-k-2}{n-k-1-r_i^2}}$（第 5 章 5.1 節）：$r_i^2 > 1$ 時根號內大於 1，$|r_i^*| > |r_i|$；$r_i^2 < 1$ 時相反。

I 錯（只有 $|r_i| < 1$ 時成立）。II 對。III 對：離譜的點會撐大 s，刪掉它再估 $s_{(i)}$，它的殘差就顯得更極端。

觀念 **觀念題 C5.1-4** 仿 SOA 樣題・回到本節開頭

Determine which of the following statements is/are true.

I. The leverage h_{ii} depends on the response values y.

II. An observation with high leverage tends to have a small residual even if it does not follow the pattern of the other observations.

III. If $h_{ii} = 1$, the ith residual is 0.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

下列哪些正確？

I. 槓桿 h_{ii} 和反應值 y 有關。

II. 高槓桿的點即使不符合其他點的型態，殘差也傾向很小。

III. $h_{ii} = 1$ 時第 i 個殘差為 0。

答案

(C)：只有 II、III 正確

解析

I 錯：$H = X(X'X)^{-1}X'$ 只由 X 決定。

II 對：高槓桿的點把配適線拉向自己（第 5 章 5.2 節的圖 (c)：標準化殘差只有 -2.62，但斜率大幅改變）。

III 對：$\text{Var}(e_i) = \sigma^2(1 - h_{ii}) = 0$，配適線必定通過該點。

觀念 **觀念題 C5.1-5** 仿 SOA 樣題・跨章：第 1 章・回到本節開頭

A normal qq plot of the standardized residuals is examined. Determine which of the following statements is/are true.

I. Points at the lower left lying well below the reference line indicate a heavier left tail than the normal distribution.

II. Points at both ends bending away from the line (low end below, high end above) suggest heavier tails than the normal distribution.

III. The qq plot directly shows whether the variance of the errors is constant.

(A) III only

(B) I and II only

(C) I and III only

(D) II and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

標準化殘差的常態 qq 圖。下列哪些正確？

I. 左下的點明顯在參考線下方，表示左尾比常態長。

II. 兩端都離開直線（低端在下、高端在上），表示比常態厚尾。

III. qq 圖可以直接看出誤差變異數是否固定。

答案

(B)：只有 I、II 正確

解析

I、II 對（第 1 章 1.3 節與第 5 章 5.1 節的 qq 圖）。

III 錯：qq 圖只看殘差的分配，不知道每個殘差對應的配適值；異質變異要看殘差對配適值的圖。

觀念 **觀念題 C5.1-6** 仿 SOA 樣題・跨章：第 2,19 章・回到本節開頭

Match each problem to a remedy. Determine which of the following pairings is/are appropriate.

I. Serial correlation in the residuals — delete the observations with the largest residuals.

II. Heteroscedasticity with known relative variances — weighted least squares.

III. A curved relationship between y and x_j — add polynomial terms in x_j or transform x_j.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

下列問題與處理方式的配對，哪些適當？

I. 殘差有序列相關 → 刪掉殘差最大的觀察值。

II. 異質變異且相對變異數已知 → 加權最小平方。

III. y 與 x_j 的關係彎曲 → 加 x_j 的多項式或轉換 x_j。

答案

(C)：只有 II、III 正確

解析

I 不適當：序列相關是觀察值之間的關聯，刪點解決不了，應改用時間數列模型（第 19 章起）。

II、III 適當（第 2 章 2.3 節、第 5 章 5.1 節）。

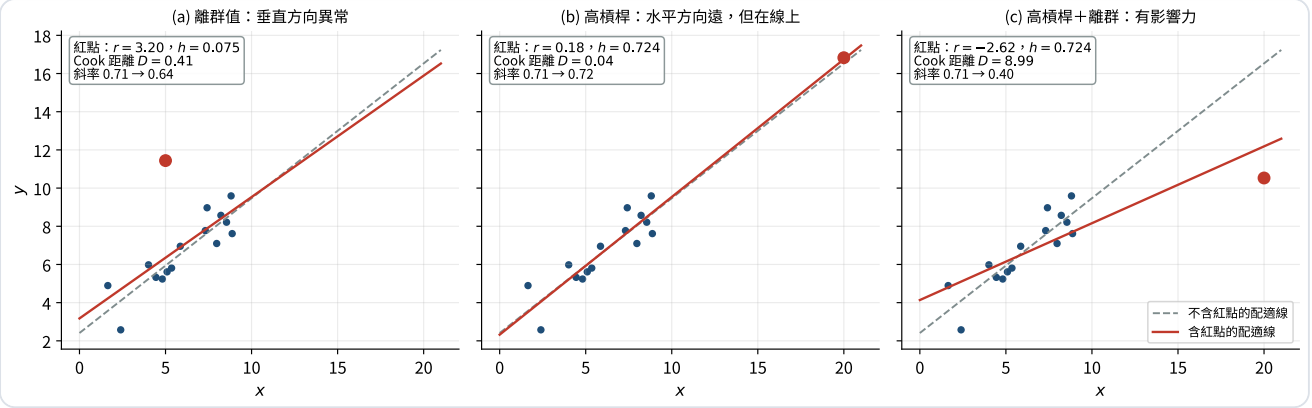
5.2 離群值與影響點

一、兩種「不尋常」

一筆觀察可以在兩個方向上不尋常：

1. **垂直方向**：反應值特別高或特別低，殘差的絕對值特別大。這種點叫**離群值**（outlier）。誤差常態時，標準化殘差的絕對值很少超過 3（超過 2 的約 5%），所以 $|r_i| > 2$ 或 > 3 常用來標記離群值。
2. **水平方向**：解釋變數的組合遠離其他點，也就是**槓桿高**。這種點在 $\mathbf{b}$ 的計算裡權重大，有可能成為**影響點**（influential point）。

但「槓桿高」只是「有可能影響很大」。真正決定一個點有多大影響的是**兩者同時存在**：位置遠（槓桿高）而且不在其他點的趨勢上（殘差大）。下圖把三種情形放在一起比較。



15 個正常的點（藍）加上一個紅點，灰虛線是不含紅點的配適線，紅線是含紅點的配適線。(a) 紅點是離群值但槓桿低（$h = 0.075$），斜率只從 0.71 變成 0.64，Cook 距離 0.41。(b) 紅點槓桿高（$h = 0.724$），但剛好落在其他點的趨勢上，標準化殘差只有 0.18，加不加它斜率幾乎不變，Cook 距離 0.04。(c) 同樣的高槓桿位置但偏離趨勢：配適線被拉向紅點，斜率從 0.71 掉到 0.40，Cook 距離 8.99。注意 (c) 的紅點因為把線拉近自己，標準化殘差反而只有 -2.62，並不顯得特別「離群」。

離群值的處理方法：

1. 保留在模型裡，但加以說明。
2. 從資料中刪除。
3. 建立一個只在離群值為 1 的指標變數。

二、槓桿的性質

推導：$\frac{1}{n} \le h_{ii} \le 1$（有截距時）

上界：H 對稱冪等，所以 $h_{ii} = (H^2)_{ii} = \sum_j h_{ij}h_{ji} = \sum_j h_{ij}^2 = h_{ii}^2 + \sum_{j \ne i} h_{ij}^2 \ge h_{ii}^2$。由 $h_{ii} \ge h_{ii}^2$ 得 $0 \le h_{ii} \le 1$。$h_{ii} = 1$ 時其他 h_{ij} 全為 0，$\hat{y}_i = y_i$，殘差必為 0。

下界：有截距時，X 的欄位空間可以拆成「常數向量 $\mathbf{1}$」和「中心化後的解釋變數」兩個互相垂直的部分，所以

$$H = \frac{1}{n}\mathbf{1}\mathbf{1}' + H_c,$$

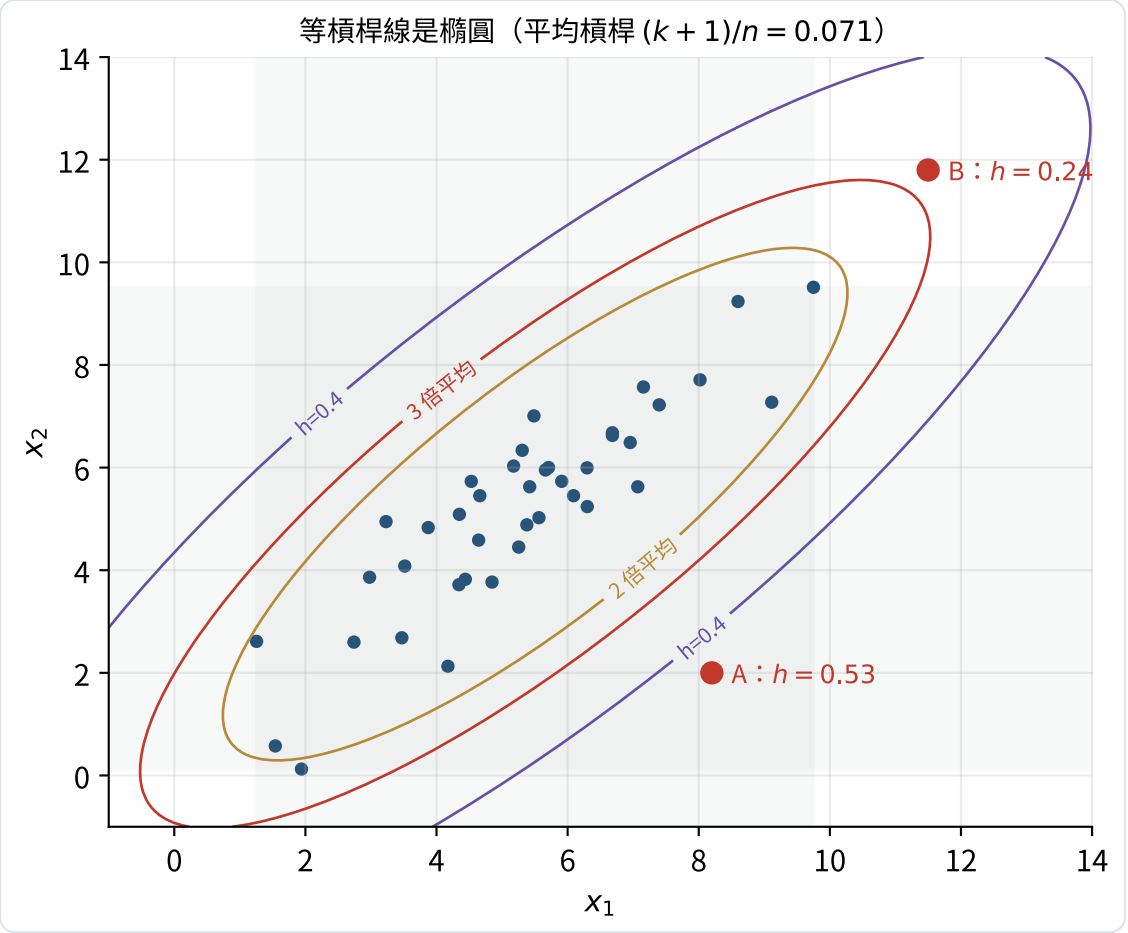
其中 H_c 是投影到中心化解釋變數空間的矩陣，對角元素非負。因此 $h_{ii} = \frac{1}{n} + (H_c)_{ii} \ge \frac{1}{n}$。簡單迴歸的 (5.1) 就是這個式子的特例，$(H_c)_{ii} = (x_i - \bar{x})^2 / S_{xx}$。

所以槓桿的範圍與總和是

$$\frac{1}{n} \le h_{ii} \le 1, \qquad \sum_{i=1}^{n} h_{ii} = k + 1, \qquad \text{平均} = \frac{k+1}{n}.$$

經驗法則：**槓桿超過平均的 2 倍或 3 倍**，這筆觀察對結果的貢獻就不成比例，應該回頭檢查資料。

多個解釋變數時，$(H_c)_{ii} = (\mathbf{x}_i - \bar{\mathbf{x}})'(X_c'X_c)^{-1}(\mathbf{x}_i - \bar{\mathbf{x}})$ 是 $\mathbf{x}_i$ 到資料中心的**馬氏距離**（Mahalanobis distance），它會考慮解釋變數之間的相關。因此一個點即使每個變數個別都在正常範圍內，只要它的**組合**不尋常，槓桿仍然可能很高。



40 筆相關的 (x_1, x_2)（相關約 0.9）加上兩點 A、B。等槓桿線是沿著資料方向拉長的橢圓。A 的 $x_1 = 8.2$、$x_2 = 2.0$ 都在各自的觀察範圍內（灰色帶狀區），但違反了「x_1 大則 x_2 也大」的模式，槓桿高達 0.53，是平均 0.071 的 7 倍多。B 兩個變數都超出範圍，但順著資料的方向，槓桿只有 0.24。

高槓桿點的處理方法：

1. 保留在模型裡，但加以說明。
2. 從資料中刪除。
3. 把造成高槓桿的變數換成另一個變數。
4. 對解釋變數做非線性轉換（例如取對數，把拉得很遠的點收回來）。

三、Cook 距離

Cook 距離（Cook's distance）同時考慮離群程度與槓桿。令 $\hat{y}_{j(i)}$ 是刪掉第 i 筆後重新配適、對第 j 筆的配適值。定義

$$D_i = \frac{\sum_{j=1}^{n} \left(\hat{y}_j - \hat{y}_{j(i)}\right)^2}{(k+1)s^2} = r_i^2 \left(\frac{h_{ii}}{(k+1)(1-h_{ii})}\right) \qquad (5.2)$$

第一個式子是定義：刪掉第 i 筆後，**所有**配適值改變了多少，平方加總後除以一個標準化常數。第二個式子是可以直接計算的形式：標準化殘差的平方（離群程度）乘上一個只跟槓桿有關的因子。要從定義得到第二個式子，關鍵是「刪掉一筆後 $\mathbf{b}$ 怎麼變」。

推導：刪掉一筆觀察後的係數，以及 Cook 距離的公式

記 $A = X'X$，$\mathbf{x}_i'$ 是 X 的第 i 列，$h_{ii} = \mathbf{x}_i' A^{-1} \mathbf{x}_i$。刪掉第 i 筆後，

$$X_{(i)}' X_{(i)} = A - \mathbf{x}_i \mathbf{x}_i', \qquad X_{(i)}' \mathbf{y}_{(i)} = X'\mathbf{y} - \mathbf{x}_i y_i.$$

第一步：反矩陣。 Sherman–Morrison 公式（秩 1 修正的反矩陣，可以直接乘開驗證）：

$$(A - \mathbf{x}_i \mathbf{x}_i')^{-1} = A^{-1} + \frac{A^{-1}\mathbf{x}_i \mathbf{x}_i' A^{-1}}{1 - h_{ii}}.$$

驗證： 把左邊的矩陣乘上右邊，應該得到單位矩陣 I。記 $\mathbf{x} = \mathbf{x}_i$、$h = h_{ii} = \mathbf{x}' A^{-1} \mathbf{x}$（一個數）：

$$(A - \mathbf{x}\mathbf{x}')\left(A^{-1} + \frac{A^{-1}\mathbf{x}\mathbf{x}'A^{-1}}{1-h}\right) = I + \frac{\mathbf{x}\mathbf{x}'A^{-1}}{1-h} - \mathbf{x}\mathbf{x}'A^{-1} - \frac{\mathbf{x}(\mathbf{x}'A^{-1}\mathbf{x})\mathbf{x}'A^{-1}}{1-h}.$$

最後一項中間的 $\mathbf{x}'A^{-1}\mathbf{x} = h$，所以後三項都是 $\mathbf{x}\mathbf{x}'A^{-1}$ 的倍數，係數合起來是 $\frac{1}{1-h} - 1 - \frac{h}{1-h} = \frac{1 - (1-h) - h}{1-h} = 0$，乘積就是 I。 **第二步：新的係數。** 乘開，並用 $A^{-1}X'\mathbf{y} = \mathbf{b}$、$\mathbf{x}_i'\mathbf{b} = \hat{y}_i$：

$$\mathbf{b}_{(i)} = \mathbf{b} - A^{-1}\mathbf{x}_i y_i + \frac{A^{-1}\mathbf{x}_i \hat{y}_i}{1-h_{ii}} - \frac{A^{-1}\mathbf{x}_i h_{ii} y_i}{1-h_{ii}} = \mathbf{b} - A^{-1}\mathbf{x}_i \, \frac{y_i(1-h_{ii}) - \hat{y}_i + h_{ii}y_i}{1-h_{ii}},$$

分子化簡成 $y_i - \hat{y}_i = e_i$，所以

$$\mathbf{b} - \mathbf{b}_{(i)} = \frac{A^{-1}\mathbf{x}_i \, e_i}{1 - h_{ii}}.$$

第三步：配適值的改變。 $\hat{\mathbf{y}} - \hat{\mathbf{y}}_{(i)} = X(\mathbf{b} - \mathbf{b}_{(i)})$，平方和為

$$\sum_j (\hat{y}_j - \hat{y}_{j(i)})^2 = (\mathbf{b} - \mathbf{b}_{(i)})' X'X (\mathbf{b} - \mathbf{b}_{(i)}) = \frac{e_i^2}{(1-h_{ii})^2} \, \mathbf{x}_i' A^{-1} A A^{-1} \mathbf{x}_i = \frac{e_i^2 h_{ii}}{(1-h_{ii})^2}.$$

第四步：除以 $(k+1)s^2$ 並拆成兩個因子。

$$D_i = \frac{e_i^2 h_{ii}}{(k+1)s^2 (1-h_{ii})^2} = \underbrace{\frac{e_i^2}{s^2(1-h_{ii})}}_{r_i^2} \cdot \frac{h_{ii}}{(k+1)(1-h_{ii})}.$$

副產品： 刪掉第 i 筆後對 y_i 的預測誤差（刪除殘差，也叫 PRESS 殘差）是

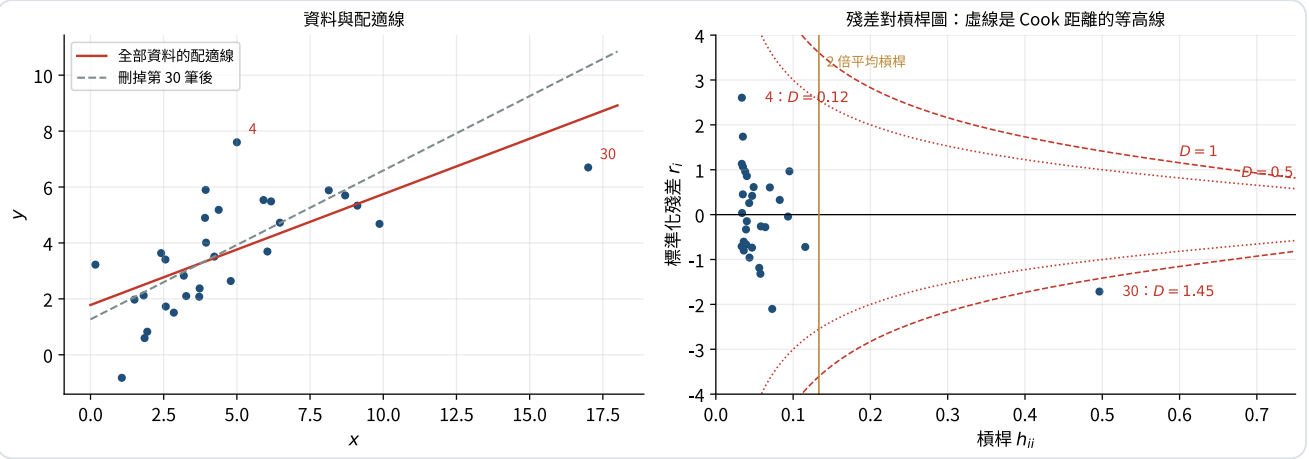
$$y_i - \hat{y}_{i(i)} = e_i + \mathbf{x}_i'(\mathbf{b} - \mathbf{b}_{(i)}) = e_i + \frac{h_{ii}e_i}{1-h_{ii}} = \frac{e_i}{1-h_{ii}},$$

其他點的殘差則變成 $y_j - \hat{y}_{j(i)} = e_j + h_{ji}e_i/(1-h_{ii})$，這就是 5.1 節計算 $s_{(i)}$ 用到的式子。第 6 章的留一交叉驗證也會用到 $e_i/(1-h_{ii})$。

$\dfrac{h_{ii}}{1-h_{ii}}$ 隨 h_{ii} 急速增加：$h_{ii}=0.5$ 時是 1，$h_{ii}=0.9$ 時是 9，$h_{ii}=0.975$ 時是 39。所以槓桿接近 1 的點，即使殘差很小，Cook 距離也可能很大（習題 5.16）。

D_i 多大算大

- 粗略的估算：r_i^2 平均約 1（標準常態的變異數），平均槓桿 $(k+1)/n$，忽略分母的 $1-h_{ii}$ 後第二個因子約 $1/n$，所以 D_i 的「正常值」大約是 $1/n$。比這個大很多就該檢查。
- 另一種看法：$D_i = \dfrac{(\mathbf{b}-\mathbf{b}_{(i)})'X'X(\mathbf{b}-\mathbf{b}_{(i)})}{(k+1)s^2}$ 和檢定 $\boldsymbol{\beta}=\mathbf{b}_{(i)}$ 的 F 統計量同形，可以和 $F_{k+1,\,n-k-1}$ 分配比較。F 分配的中位數略小於 1（例如 $F_{2,28}$ 的中位數是 0.71），所以 $D_i > 1$ 表示刪掉這一點後的係數 $\mathbf{b}_{(i)}$ 落在原本 50% 信賴區域的外面。考題說「unity threshold」就是用 1 當門檻。



左：30 筆資料，第 30 筆的 $x=17$ 遠離其他點且在趨勢下方；第 4 筆是普通的離群值。右：殘差對槓桿圖（R 的 `plot(lm)` 第 5 張），虛線是 $D=0.5$ 與 $D=1$ 的等高線 $r = \pm\sqrt{D(k+1)(1-h)/h}$。第 4 筆標準化殘差最大，但槓桿低，$D=0.12$；第 30 筆殘差不算大，但槓桿約 0.5，$D=1.45$ 超過 1。刪掉它，配適線明顯改變（左圖虛線）。

例題 5B

例題 5A 中 $k+1=3$，$r_1=-0.873$、$h_{11}=0.458$；$r_2=0.828$、$h_{22}=0.411$。

$$D_1=(-0.873)^2\cdot\frac{0.458}{3(1-0.458)}=0.762\times 0.2817=0.2148,$$

$$D_2=(0.828)^2\cdot\frac{0.411}{3(1-0.411)}=0.686\times 0.2326=0.1596.$$

例題 5-2

4 個解釋變數加截距、100 筆觀察，第一個標準化殘差 1.24、槓桿 0.48。求 D_1。

$k+1=5$。觀察筆數用不到。$D_1=1.24^2\cdot\frac{0.48}{5(0.52)}=1.5376\times 0.36923=0.2839$。

考試技巧

- 比較**同一個模型**裡哪一點影響最大時，s^2 與 $k+1$ 是共同的倍數，可以略去，只比較 $\frac{e_i^2 h_{ii}}{(1-h_{ii})^2}$（用原始殘差），或 $\frac{r_i^2 h_{ii}}{1-h_{ii}}$（用標準化殘差）。
- 題目給原始殘差時，Cook 距離的分母有 $(1-h_{ii})^2$；給標準化殘差時只有一次方。
- 判斷哪些點超過門檻，先算槓桿大、殘差也大的點；若一點的槓桿與 $|r_i|$ 都比另一個已經低於門檻的點小，它一定也低於門檻（習題 5.11）。

這一節的精選習題

★ 精選 **第 5.8 題** · 講義 p.88 · 回到對應概念

Use the following information for questions 5.8 and 5.9: A regression model with 5 variables and an intercept is fitted to 60 observations. The first 5 diagonal elements of the hat matrix are $\{0.1612, 0.0808, 0.2159, 0.0259, 0.1307\}$.

For which of the first 5 observations is leverage greater than 2 times average?

中文題意

（5.8、5.9 共用）5 個解釋變數加截距的迴歸模型配適 60 筆觀察，帽子矩陣的前 5 個對角元素為 $\{0.1612, 0.0808, 0.2159, 0.0259, 0.1307\}$。前 5 筆觀察中，哪些槓桿超過平均的 2 倍？

答案

只有第 3 筆

解析

平均槓桿 $= \dfrac{k+1}{n} = \dfrac{6}{60} = 0.1$，2 倍是 0.2。五個槓桿中只有 $h_{33} = 0.2159 > 0.2$。

易錯

參數個數 $k+1=6$ 包含截距，不是 5。

★ 精選 **第 5.11 題** ・講義 p.88・回到對應概念

[MAS-I-F19:31] In order to predict individual candidates' test scores a regression was performed using one independent variable, Hours of Study, plus an intercept. Below is a partial table of data and model results:

Candidate	Test Score	Hours of Study	Leverage	Standardized Residuals
1	2,041	538	0.6205	-1.3477
2	2,502	548	0.2018	-0.4171
3	2,920	528	0.6486	-1.1121
4	2,284	608	0.2807	1.1472

Calculate the number of observations above that are influential using Cook's Distance with a unity threshold.

(A) 0

(B) 1

(C) 2

(D) 3

(E) 4

中文題意

（MAS-I 2019 秋 #31）為預測考生分數，以一個自變數「讀書時數」加截距做迴歸。部分資料與結果如下：

以 Cook 距離、門檻 1（unity threshold）判斷，上表中有幾筆是影響點？

(A) 0　(B) 1　(C) 2　(D) 3　(E) 4

（數據、圖表與選項見上方英文題目。）

答案

(C) 2 筆（考生 1、3）

解析

簡單迴歸 $k+1=2$，$D_i = r_i^2 \dfrac{h_{ii}}{2(1-h_{ii})}$：

$$D_1 = 1.3477^2 \cdot \frac{0.6205}{2(0.3795)} = 1.8163 \times 0.8175 = 1.485 > 1$$

$$D_3 = 1.1121^2 \cdot \frac{0.6486}{2(0.3514)} = 1.2368 \times 0.9229 = 1.141 > 1$$

$$D_4 = 1.1472^2 \cdot \frac{0.2807}{2(0.7193)} = 1.3161 \times 0.1951 = 0.257 < 1$$

考生 2 的槓桿（0.2018）與 $|r|$（0.4171）都比考生 4 小，所以 $D_2 < D_4 < 1$，不必算（實際 $D_2 = 0.022$）。

易錯

用標準化殘差時分母是 $(1-h_{ii})$ 一次方；用原始殘差的公式 $(1-h)^2$ 就會高估。

★ 精選 **第 5.13 題** · 講義 p.89 · 回到對應概念

A regression model with 3 variables and an intercept is fitted to 48 observations. You are given

(i) $\hat{\varepsilon}_1 = 7.624$

(ii) The standard error of the regression is 4.823.

(iii) Cook's distance for the first observation is 0.804.

Determine the leverage of the first observation.

中文題意

3 個解釋變數加截距的迴歸模型配適 48 筆觀察：(i) $e_1 = 7.624$；(ii) 迴歸標準誤 4.823；(iii) 第一筆觀察的 Cook 距離 0.804。求第一筆觀察的槓桿。

答案

$h_{11} = 0.4252$

解析

$k+1 = 4$。用原始殘差的形式：

$$D_1 = \frac{e_1^2 h_{11}}{(k+1)s^2(1-h_{11})^2} \;\Rightarrow\; 0.804 = \frac{58.1254\,h}{4(23.2613)(1-h)^2} = \frac{58.1254\,h}{93.0452(1-h)^2}.$$

移項：$0.804(93.0452)(1-h)^2 = 58.1254h$，即

$$74.8084(1-h)^2 = 58.1254h \;\Rightarrow\; 74.8084h^2 - 207.7422h + 74.8084 = 0.$$

公式解：

$$h = \frac{207.7422 \pm \sqrt{207.7422^2 - 4(74.8084)^2}}{2(74.8084)} = \frac{207.7422 \pm 144.1238}{149.6168} = 0.4252 \text{ 或 } 2.3518.$$

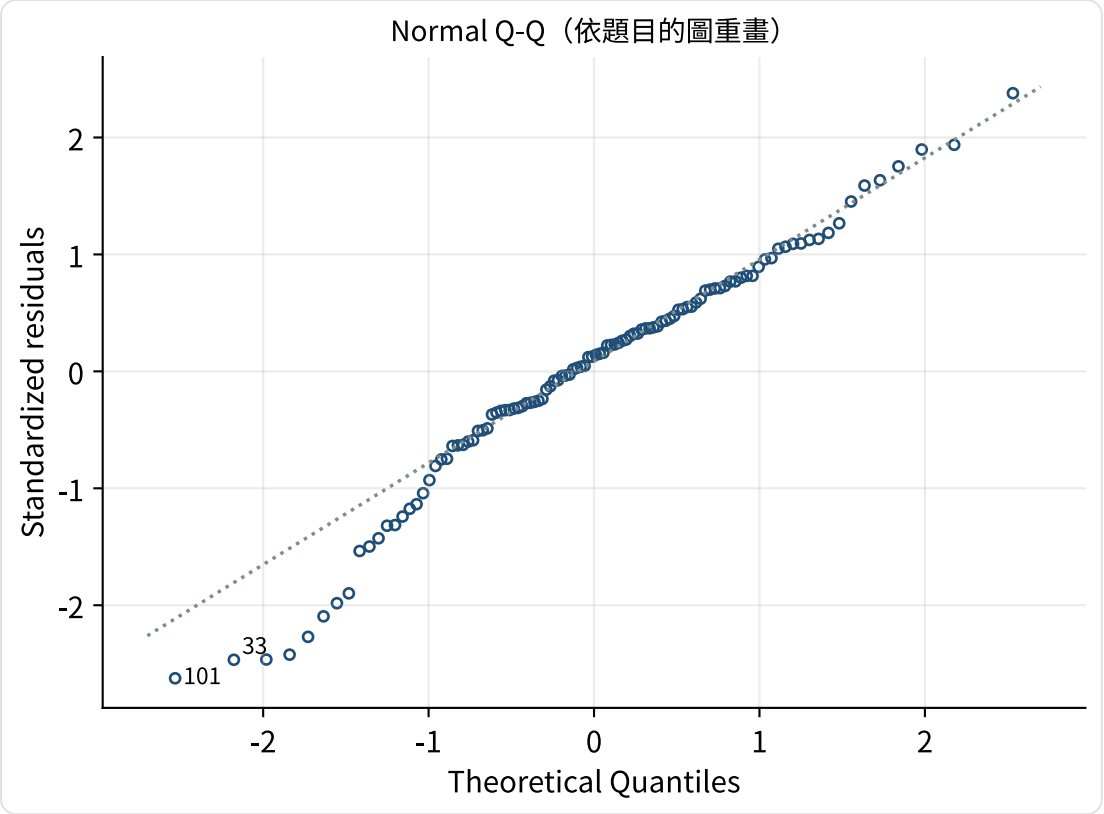
槓桿必須在 $1/n$ 與 1 之間，取 $h_{11} = 0.4252$。（兩根的乘積是 1，因為二次式的首項係數和常數項相同。）

易錯

> e_1^2 和 s^2 都要平方；$(1-h)^2$ 展開成 $1-2h+h^2$，一次項係數是 $-2(74.8084)-58.1254$。

★ 精選 **第 5.17 題** ・講義 p.91・回到對應概念

[S-F17:37] You are given the following residual qq plot for a fitted linear regression model:



Normal Q-Q plot of the standardized residuals (redrawn from the exam figure; the two lowest points are labeled 101 and 33).

I. The distribution of residuals is skewed to the left.

II. The residuals are serially correlated.

III. Observations 33 and 101 are influential points.

Determine which of the above statements can be concluded to be true from the above chart.

(A) I only

(B) II only

(C) III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

（SRM 2017 秋 #37）某線性迴歸模型的殘差 qq 圖如下：

I. 殘差的分配左偏。

II. 殘差有序列相關。

III. 觀察值 33 與 101 是影響點。

從圖可以斷定哪些敘述正確？

(A) 只有 I　(B) 只有 II　(C) 只有 III　(D) I、II、III　(E) 以上皆非

（數據、圖表與選項見上方英文題目。）

答案

(A) 只有 I

解析

I. 正確。左端（低分位數）的點落在線的下方：最小的那些標準化殘差比常態預期的更負，左尾比常態長，也就是左偏。右端貼著線，沒有對應的長右尾。

II. 無法判斷。qq 圖把殘差**排序**後畫，原本的順序資訊已經丟掉；要看序列相關必須依時間（或其他自然順序）畫殘差。題目連資料有沒有順序都沒說。

III. 無法判斷。影響點需要高槓桿（以及大殘差），qq 圖只顯示殘差大小，沒有槓桿的資訊。33、101 只能說是殘差特別小（可能的離群值）。

易錯

離群值（殘差大）不等於影響點（Cook 距離大）。

觀念題（6 題，仿 SOA 樣題的質性題，含跨章節）

觀念 **觀念題 C5.2-1** 仿 SOA 樣題・回到本節開頭

Determine which of the following statements is/are true.

I. A high leverage point is always an influential point.

II. Leverage measures how far the explanatory variables of an observation are from those of the other observations.

III. An outlier is an observation whose response is unusual given its explanatory variables, so that its residual is large in absolute value.

(A) III only

(B) I and II only

(C) I and III only

(D) II and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

下列哪些正確？

I. 高槓桿點一定是影響點。

II. 槓桿衡量觀察值的解釋變數離其他觀察值多遠。

III. 離群值是在給定解釋變數下反應值不尋常、殘差絕對值很大的觀察值。

答案

(D)：只有 II、III 正確

解析

I 錯：高槓桿的點若剛好落在其他點的趨勢上，拿掉它配適線幾乎不變（第 5 章 5.2 節的圖 (b)，Cook 距離只有 0.04）。影響力需要高槓桿**加上**偏離趨勢。

II、III 對。

觀念 **觀念題 C5.2-2** 仿 SOA 樣題・跨章：第 2 章・回到本節開頭

For a linear regression with k explanatory variables, an intercept, and n observations, determine which of the following statements is/are true.

I. The leverages sum to $k+1$.

II. Each leverage is at least $1/n$.

III. An observation whose value of each explanatory variable lies within the range of the other observations cannot have high leverage.

(A) II only

(B) III only

(C) I and III only

(D) II and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

k 個解釋變數、有截距、n 筆觀察。下列哪些正確？

I. 槓桿總和為 $k+1$。

II. 每個槓桿至少 $1/n$。

III. 一個觀察值若每個解釋變數都在其他觀察值的範圍內，就不可能是高槓桿。

答案

(E)：只有 I、II 正確

解析

I、II 對（第 5 章 5.2 節的推導）。

III 錯：多個解釋變數時，槓桿看的是**組合**到資料中心的馬氏距離。每個變數個別都正常、組合卻違反變數間相關型態的點，槓桿可能很高（第 5 章 5.2 節的圖：點 A 的槓桿 0.53）。

觀念 **觀念題 C5.2-3** 仿 SOA 樣題・跨章：第 6 章・回到本節開頭

Cook's distance is $D_i = \dfrac{\sum_j (\hat{y}_j - \hat{y}_{j(i)})^2}{(k+1)s^2} = r_i^2 \dfrac{h_{ii}}{(k+1)(1-h_{ii})}$. Determine which of the following statements is/are true.

I. D_i combines a measure of outlyingness and a measure of leverage.

II. D_i measures how much all the fitted values change when observation i is deleted.

III. D_i can be large even when the standardized residual is small, if h_{ii} is close to 1.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

關於 Cook 距離，下列哪些正確？

I. 結合了離群程度與槓桿。

II. 衡量刪掉第 i 筆後所有配適值改變多少。

III. h_{ii} 接近 1 時，標準化殘差很小也可能有很大的 D_i。

答案

(D)：I、II、III 都正確

解析

I、II 對：分別是 (5.2) 的第二個與第一個式子。III 對：$h/(1-h)$ 在 $h \to 1$ 時發散（第 5 章習題 5.16：殘差最小的第 2 筆，$h = 0.975$，$D = 27.7$）。另外，刪除殘差 $e_i/(1-h_{ii})$ 也是第 6 章 LOOCV 捷徑公式的核心。

觀念 **觀念題 C5.2-4** 仿 SOA 樣題・回到本節開頭

Determine which of the following is NOT a reasonable way of handling a high leverage point.

(A) Include it in the model and comment on it.

(B) Delete it from the data.

(C) Replace the explanatory variable causing the high leverage with another variable.

(D) Use a nonlinear transformation of an explanatory variable.

(E) Lower the significance level used for the t tests of the coefficients.

中文題意

下列哪一個**不是**處理高槓桿點的合理方式？

(A) 保留並加以說明。

(B) 刪除。

(C) 把造成高槓桿的變數換成另一個變數。

(D) 對解釋變數做非線性轉換。

(E) 把係數 t 檢定的顯著水準調低。

答案

(E)

解析

(A)～(D) 是常見的四種方式（第 5 章 5.2 節）。例如對右偏的解釋變數取對數，可以把拉得很遠的點收回來。

(E) 改顯著水準和槓桿無關，不會改變那一點對配適的影響。

觀念 **觀念題 C5.2-5** 仿 SOA 樣題・跨章：第 6 章・回到本節開頭

Determine which of the following statements is/are true.

I. In a simple linear regression, the observation with the largest leverage is the one with the largest $|y_i - \bar{y}|$.

II. The deleted residual $y_i - \hat{y}_{(i)}$ equals $e_i/(1 - h_{ii})$ for least squares regression.

III. Deleting an influential observation substantially changes the estimated coefficients.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

下列哪些正確？

I. 簡單迴歸中槓桿最大的觀察值是 $|y_i - \bar{y}|$ 最大的那筆。

II. 最小平方的刪除殘差 $y_i - \hat{y}_{(i)} = e_i/(1 - h_{ii})$。

III. 刪掉影響點會大幅改變係數估計。

答案

(C)：只有 II、III 正確

解析

I 錯：$h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}$，看的是 $|x_i - \bar{x}|$，和 y 無關。

II 對（第 5 章 5.2 節與第 6 章 6.2 節的兩種推導）。III 對：這就是「影響點」的意思，Cook 距離正是在量這件事。

觀念 **觀念題 C5.2-6** 仿 SOA 樣題・回到本節開頭

Determine which of the following statements about rules of thumb for unusual observations is/are true.

I. Every observation in a correctly specified model has Cook's distance less than 1.

II. An observation whose leverage exceeds 2 or 3 times $(k+1)/n$ deserves review.

III. With normal errors, standardized residuals greater than 3 in absolute value should be rare.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

關於異常觀察值的經驗法則，下列哪些正確？

I. 設定正確的模型中，每個觀察值的 Cook 距離都小於 1。

II. 槓桿超過 $(k+1)/n$ 的 2 或 3 倍應該檢查。

III. 誤差常態時，標準化殘差絕對值超過 3 的應該很少。

答案

(C)：只有 II、III 正確

解析

I 錯：門檻 1 只是經驗法則，不是保證；模型正確時仍可能因為一個極端的設計點而有 $D_i > 1$。

II、III 對（第 5 章 5.2 節）。

5.3 解釋變數的共線性與 VIF

一、完全共線

若一個解釋變數是其他解釋變數的線性組合，就叫**共線**（collinear）。例如 4 筆觀察，$\mathbf{y} = (1, 4, 6, 9)$、$x_1 = (0, 1, 2, 3)$、$x_2 = 2x_1 = (0, 2, 4, 6)$。

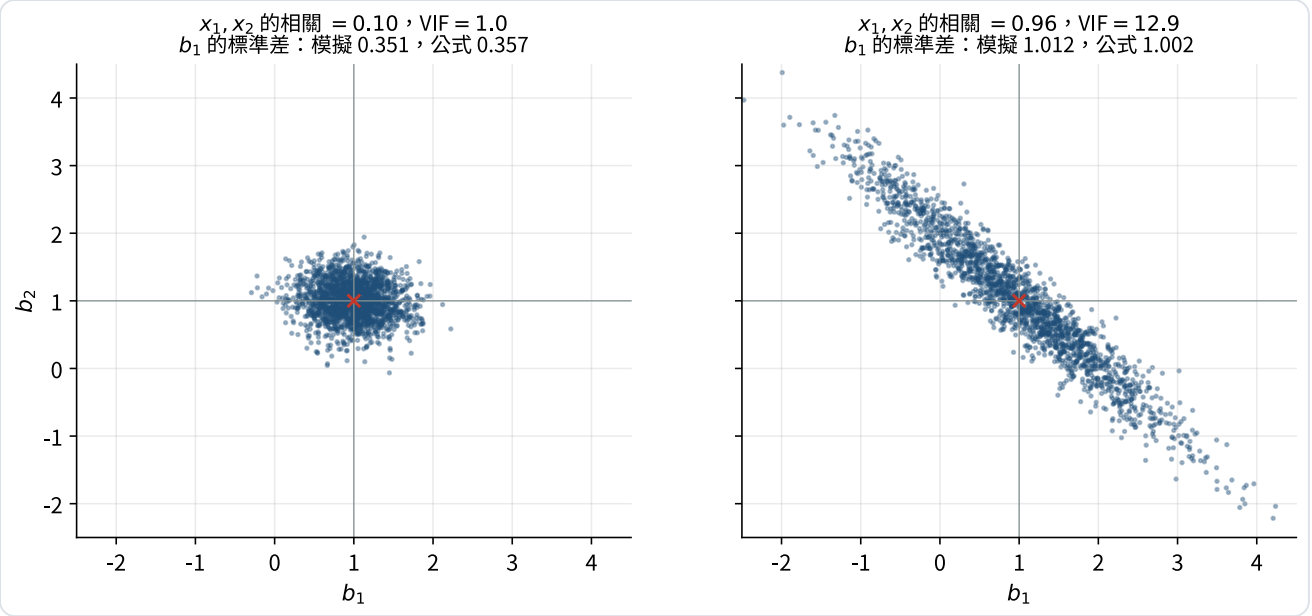
只用 x_1 配適：$\bar{x}_1 = 1.5$、$\bar{y} = 5$、$S_{xy} = (-1.5)(-4) + (-0.5)(-1) + (0.5)(1) + (1.5)(4) = 13$、$S_{xx} = 5$，所以 $b_1 = 2.6$、$b_0 = 5 - 2.6(1.5) = 1.1$。

同時放 x_1、x_2 時，模型只看得到 $\beta_1 x_1 + \beta_2 x_2 = (\beta_1 + 2\beta_2)x_1$，所以任何滿足 $b_1 + 2b_2 = 2.6$ 的組合（例如 $b_1 = 2.6, b_2 = 0$，或 $b_1 = 0, b_2 = 1.3$）配適值完全一樣，最小平方解有無限多個。用矩陣說：X 的欄線性相依，存在非零的 $\mathbf{v} = (0, 2, -1)'$ 使 $X\mathbf{v} = \mathbf{0}$，於是 $X'X\mathbf{v} = \mathbf{0}$，$X'X$ 不可逆，(2.4) 的 $\mathbf{b} = (X'X)^{-1}X'\mathbf{y}$ 算不出來；$\mathbf{b} + t\mathbf{v}$ 對任何 t 都是解。

二、近似共線：配適不受影響，係數變得不穩定

實務上更常見的是**近似共線**（near collinearity）：$X'X$ 的行列式接近 0。這時 $(X'X)^{-1}$ 的元素很大，而第 3 章推導過 $\mathrm{Var}(\mathbf{b}) = \sigma^2(X'X)^{-1}$，所以**係數的標準誤很大**、$t$ 統計量很小、p 值很大。

> **共線性傷害的是係數，不是配適**
>
> 常有人以為近似共線會讓殘差標準差變大，其實不會。共線性不會讓配適變差：只要 X 的欄位空間不變，$\hat{\mathbf{y}}$、s、R^2、預測值都不受影響（上面的例子不管怎麼分配 b_1, b_2，配適值都一樣）。受害的是**個別係數的估計與解讀**：標準誤變大，係數的正負號與大小在不同樣本間大幅擺動，可能每個 t 都不顯著、整體 F 卻顯著（第 4 章 4.1 節）。



真實模型 $y = 1 + x_1 + x_2 + \varepsilon$（$\sigma = 2$，50 筆），固定 X、重複抽 2,000 次 ε，畫出每次的 (b_1, b_2)。左：x_1, x_2 幾乎不相關，估計值集中在真值 (1,1) 周圍。右：相關 0.96，(b_1, b_2) 沿著 $b_1 + b_2 \approx 2$ 的方向散成一條長帶（兩者的和估得準，個別的值估不準），b_1 的標準差從 0.36 放大到 1.00。兩邊的模擬標準差都和下面 (5.4) 式算出的公式值吻合。

三、變異數膨脹因子 VIF

檢查變數 x_j 是否和其他變數共線：把 x_j 當反應、對其他所有解釋變數（含截距）做迴歸，這叫**輔助迴歸**（auxiliary regression）。令它的決定係數為 $R^2_{(j)}$，定義**變異數膨脹因子**（variance inflation factor）

$$\mathrm{VIF}_j = \frac{1}{1 - R^2_{(j)}} \qquad (5.3)$$

因為 $0 \le R^2_{(j)} < 1$，$\mathrm{VIF}_j \ge 1$；越大表示 x_j 越能被其他變數線性表示。**VIF 超過 10 表示嚴重共線**（有些作者用 5）。x_j 和其他變數完全無關（正交）時 $R^2_{(j)} = 0$、$\mathrm{VIF}_j = 1$。

VIF 和係數的標準誤有直接的關係：

$$s_{b_j} = s \, \frac{\sqrt{\mathrm{VIF}_j}}{s_{x_j}\sqrt{n-1}} \qquad (5.4)$$

其中 s_{b_j} 與 s 都來自 y 對全部 k 個變數的完整迴歸，s_{x_j} 是 x_j 的樣本標準差（所以 $s_{x_j}^2 (n-1) = \sum_i (x_{ij} - \bar{x}_j)^2$）。名稱的由來就在這裡：和 x_j 跟其他變數無關的情形相比，b_j 的**變異數**放大 VIF_j 倍，標準誤放大 $\sqrt{\mathrm{VIF}_j}$ 倍。

推導：(5.4) 式（Frisch–Waugh–Lovell 定理）

把 X 分成 x_j 這一欄和其他欄 X_{-j}（含截距）。令 $M = I - X_{-j}(X'_{-j}X_{-j})^{-1}X'_{-j}$ 是「對 X_{-j} 取殘差」的矩陣，它對稱冪等，而且 $MX_{-j} = 0$。

第一步：b_j 只取決於 x_j 中和其他變數無關的部分。 完整迴歸寫成 $\mathbf{y} = X_{-j}\mathbf{b}_{-j} + \mathbf{x}_j b_j + \mathbf{e}$。兩邊乘 M：$MX_{-j} = 0$；殘差 $\mathbf{e}$ 和 X 所有欄垂直，所以 $M\mathbf{e} = \mathbf{e}$。得 $M\mathbf{y} = M\mathbf{x}_j b_j + \mathbf{e}$。再左乘 $\mathbf{x}'_j$，因為 $\mathbf{x}'_j\mathbf{e} = 0$：

$$b_j = \frac{\mathbf{x}'_j M\mathbf{y}}{\mathbf{x}'_j M\mathbf{x}_j} = \frac{\tilde{\mathbf{x}}'_j\mathbf{y}}{\tilde{\mathbf{x}}'_j\tilde{\mathbf{x}}_j}, \qquad \tilde{\mathbf{x}}_j = M\mathbf{x}_j.$$

$\tilde{\mathbf{x}}_j$ 正是輔助迴歸（x_j 對其他變數）的殘差。

第二步：變異數。 b_j 是 $\mathbf{y}$ 的線性組合，係數向量 $\tilde{\mathbf{x}}_j/(\tilde{\mathbf{x}}'_j\tilde{\mathbf{x}}_j)$，所以

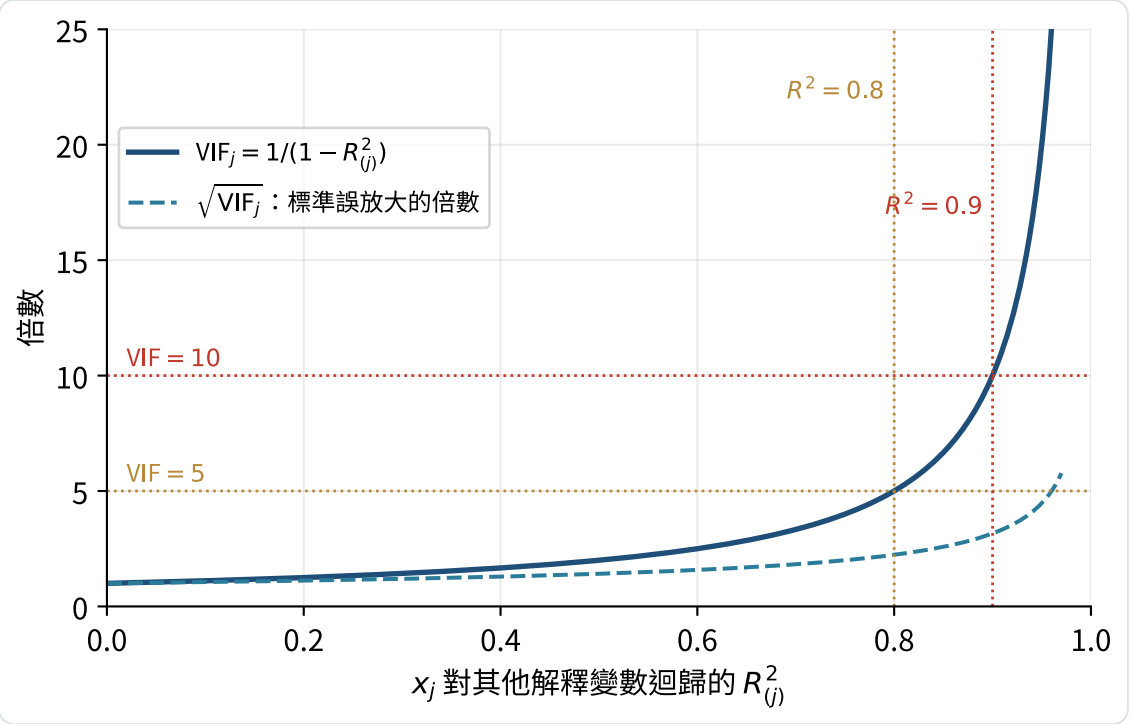
$$\mathrm{Var}(b_j) = \sigma^2 \frac{\tilde{\mathbf{x}}'_j\tilde{\mathbf{x}}_j}{(\tilde{\mathbf{x}}'_j\tilde{\mathbf{x}}_j)^2} = \frac{\sigma^2}{\tilde{\mathbf{x}}'_j\tilde{\mathbf{x}}_j}.$$

第三步：$\tilde{\mathbf{x}}'_j\tilde{\mathbf{x}}_j$ 是輔助迴歸的 Error SS。 它等於 $\text{Total SS}_j(1 - R^2_{(j)})$，而 $\text{Total SS}_j = \sum_i (x_{ij} - \bar{x}_j)^2 = (n-1)s^2_{x_j}$。所以

$$\mathrm{Var}(b_j) = \frac{\sigma^2}{(n-1)s^2_{x_j}(1 - R^2_{(j)})} = \frac{\sigma^2\,\mathrm{VIF}_j}{(n-1)s^2_{x_j}},$$

用 s 代替 σ、開根號就是 (5.4)。$k = 1$ 時 $\mathrm{VIF} = 1$，回到第 3 章的 $s_{b_1} = s/\sqrt{S_{xx}}$。

實用的副產品： $s_{b_j} = \dfrac{s}{\sqrt{\text{輔助迴歸的 Error SS}}}$。題目若直接給輔助迴歸的 Error SS，不必先算 VIF（習題 5.25）。



VIF 是 $R^2_{(j)}$ 的函數。$R^2_{(j)} = 0.8$ 時 VIF $= 5$，$R^2_{(j)} = 0.9$ 時 VIF $= 10$；超過之後急速上升。虛線是 $\sqrt{\mathrm{VIF}}$，即係數標準誤被放大的倍數：VIF $= 10$ 時標準誤是無共線時的 3.16 倍。

計算 $R^2_{(j)}$ 的幾種常見給法：

- 輔助迴歸的 ANOVA 表：$R^2_{(j)} = \dfrac{\text{Reg SS}}{\text{Reg SS} + \text{Error SS}}$，所以 $\mathrm{VIF}_j = \dfrac{\text{Total SS}}{\text{Error SS}}$。
- 只有兩個解釋變數：輔助迴歸是簡單迴歸，$R^2_{(j)} = r^2_{12}$（第 3 章 3.2 節），$\mathrm{VIF}_1 = \mathrm{VIF}_2 = \dfrac{1}{1 - r^2_{12}}$。
- 輔助迴歸的 F 統計量：用第 4 章的 $R^2 = \dfrac{qF}{qF + \text{誤差自由度}}$。

例題 5-3

21 筆觀察的 $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \varepsilon$。懷疑 x_3 和其他變數共線，x_3 對 x_1, x_2 迴歸的 F 統計量是 6.48。求 VIF_3。

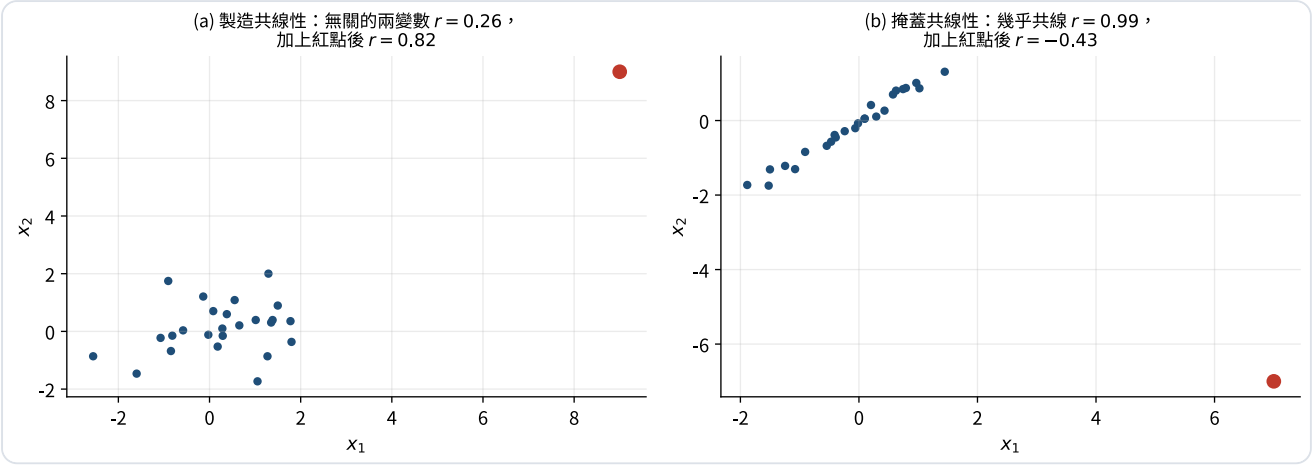
輔助迴歸有 2 個解釋變數、誤差自由度 $21 - 3 = 18$。分子分母同除以 Total SS：

$$6.48 = \frac{\text{Reg SS}/2}{\text{Error SS}/18} = 9 \cdot \frac{R^2}{1 - R^2} \;\Rightarrow\; \frac{R^2}{1 - R^2} = 0.72 \;\Rightarrow\; R^2 = \frac{0.72}{1.72}.$$

$\text{VIF}_3 = \dfrac{1}{1 - R^2} = 1 + \dfrac{R^2}{1 - R^2} = 1.72$。（$\text{VIF} = 1 + R^2/(1 - R^2)$ 是個好用的捷徑。）

四、槓桿、抑制變數與正交變數

高槓桿點可能製造或掩蓋共線性。 相關係數對極端點很敏感，一個遠離其他點的觀察就足以改變 $R^2_{(j)}$。



(a) 25 筆幾乎不相關的 (x_1, x_2)（$r = 0.26$），加上一個在 (9,9) 的高槓桿點後 $r = 0.82$：VIF 從 1.07 變成 3.05，看起來像共線，其實是一個點造成的。(b) 25 筆幾乎完全共線的資料（$r = 0.99$），加上一個在 $(7, -7)$ 的點後 $r = -0.43$，共線性被藏起來了。

共線的變數不一定要刪。 一個變數即使和其他變數有些相關，仍可能改善模型。**抑制變數**（suppressor variable）是一個加入後會提高**其他**變數顯著性的變數。典型的情形：x_2 本身和 y 無關，但和 x_1 中的「雜訊」有關，放進模型後就把 x_1 的雜訊扣掉了。

抑制變數的數值例子（模擬，100 筆）

令 s, w 是獨立的標準常態，$x_1 = s + w$、$x_2 = w$、$y = s + \varepsilon$。y 只和 s 有關，x_2 和 y 的相關係數只有 -0.03，單獨用 x_2 迴歸 $t = -0.29$，毫無用處。

- 只用 x_1：$b_1 = 0.41$，$t = 4.64$，$R^2 = 0.18$。
- 用 x_1, x_2：$b_1 = 0.99$，$t = 9.06$；$b_2 = -1.00$，$t = -7.07$；$R^2 = 0.46$。

x_1, x_2 的相關是 0.75（VIF $= 2.3$），但加入 x_2 後 x_1 的 t 值幾乎翻倍，R^2 增加超過一倍。因為 $x_1 - x_2 = s$，兩者一起用就能還原真正有用的訊號。

正交變數是共線的反面。 兩個列數相同的矩陣 X_1, X_2 若 $X_1' X_2 = 0$ 就叫**正交**（orthogonal）。若某個解釋變數（中心化後）和其他解釋變數都正交，它的 $R^2_{(j)} = 0$、VIF $= 1$。此時 $X'X$ 是分塊對角矩陣，$(X'X)^{-1}$ 也是，所以 $\mathbf{b} = (X'X)^{-1}X'\mathbf{y}$ 各塊分開計算：**加入或刪除一個正交變數，不會改變其他係數的估計值**。第 8 章的主成分迴歸就是先造出互相正交的變數。缺點是這些新變數通常很難解釋。

本章公式總表

- 帽子矩陣：$H = X(X'X)^{-1}X'$，$\hat{\mathbf{y}} = H\mathbf{y}$，$\mathbf{e} = (I-H)\mathbf{y}$。
- 殘差的變異數：$\widehat{\mathrm{Var}}(e_i) = (1-h_{ii})s^2$；共變異數 $-h_{ij}s^2$。
- 標準化殘差：$r_i = \dfrac{e_i}{s\sqrt{1-h_{ii}}}$；學生化殘差：$r_i^* = \dfrac{e_i}{s_{(i)}\sqrt{1-h_{ii}}} = r_i\dfrac{s}{s_{(i)}}$。
- 離群值：標準化殘差的絕對值大。槓桿：h_{ii}。
- 槓桿的性質：$\dfrac{1}{n} \le h_{ii} \le 1$，$\sum_i h_{ii} = k+1$；超過平均 $(k+1)/n$ 的 2～3 倍算高。
- 簡單迴歸的槓桿：$h_{ii} = \dfrac{1}{n} + \dfrac{(x_i-\bar{x})^2}{\sum_j (x_j-\bar{x})^2}$。
- Cook 距離：$D_i = \dfrac{\sum_j (\hat{y}_j - \hat{y}_{j(i)})^2}{(k+1)s^2} = r_i^2\dfrac{h_{ii}}{(k+1)(1-h_{ii})} = \dfrac{e_i^2 h_{ii}}{(k+1)s^2(1-h_{ii})^2}$。
- VIF：$\mathrm{VIF}_j = \dfrac{1}{1-R^2_{(j)}} = \dfrac{\text{輔助迴歸 Total SS}}{\text{輔助迴歸 Error SS}}$；兩個變數時 $\dfrac{1}{1-r_{12}^2}$。
- 係數標準誤：$s_{b_j} = s\dfrac{\sqrt{\mathrm{VIF}_j}}{s_{x_j}\sqrt{n-1}} = \dfrac{s}{\sqrt{\text{輔助迴歸 Error SS}}}$。

這一節的精選習題

★ 精選 **第 5.21 題** · 講義 p.92 · 回到對應概念

[S-F15:40] You are given the following information related to the linear model:

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \varepsilon$$

Auxiliary regression	Regression SS (2 df)	Error SS (503 df)
$x_1 = \gamma_0 + \gamma_1 x_2 + \gamma_2 x_3 + \varepsilon$	24.74	226.34
$x_2 = \delta_0 + \delta_1 x_1 + \delta_2 x_3 + \varepsilon$	3.73	3.04
$x_3 = \eta_0 + \eta_1 x_1 + \eta_2 x_2 + \varepsilon$	214,258	85,883

Calculate the variance inflation factor for the variable which exhibits the greatest collinearity in the original model.

(A) Less than 1.0

(B) At least 1.0, but less than 2.0

(C) At least 2.0, but less than 3.0

(D) At least 3.0, but less than 4.0

(E) At least 4.0

中文題意

（SRM 2015 秋 #40）線性模型 $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \varepsilon$。三個輔助迴歸的 ANOVA 表：

求原模型中共線性最強的變數的 VIF。

（數據、圖表與選項見上方英文題目。）

答案

(D) $\mathrm{VIF}_3 = 3.495$

解析

共線性最強的是輔助迴歸 R^2 最大的變數。$R^2 = \dfrac{\text{Reg SS}}{\text{Reg SS} + \text{Error SS}}$，$\text{VIF} = \dfrac{\text{Total SS}}{\text{Error SS}}$：

變數	$R^2_{(j)}$	VIF
x_1	$24.74/251.08 = 0.0985$	$251.08/226.34 = 1.109$
x_2	$3.73/6.77 = 0.5510$	$6.77/3.04 = 2.227$
x_3	$214{,}258/300{,}141 = 0.7139$	$300{,}141/85{,}883 = 3.495$

x_3 的 VIF 最大，3.495。

易錯

平方和的**絕對大小**沒有意義（x_3 的單位大），要看比例。另外，題目問的是「共線性最強的那個變數」的 VIF，不是三個 VIF 的總和或最小值。

★ 精選 **第 5.25 題** · 講義 p.93 · 回到對應概念

(Continuation of 5.24) Calculate the standard error of b_3.

中文題意

（接 5.24）求 b_3 的標準誤。

答案

$s_{b_3} = 0.1858$

解析

方法一：(5.4)。 $s = \sqrt{142.4/(50-4)} = \sqrt{3.0957} = 1.7594$；$s_{x_3}\sqrt{n-1} = \sqrt{\sum(x_{i3}-\bar{x}_3)^2} = \sqrt{115.4} = 10.7424$。

$$s_{b_3} = s\,\frac{\sqrt{\mathrm{VIF}_3}}{s_{x_3}\sqrt{n-1}} = 1.7594 \times \frac{\sqrt{1.2865}}{10.7424} = 1.7594 \times \frac{1.1342}{10.7424} = 0.1858.$$

方法二：輔助迴歸的 Error SS。 由 5.3 節的推導 $s_{b_3} = s/\sqrt{\text{輔助迴歸 Error SS}}$：

$$s_{b_3} = \frac{1.7594}{\sqrt{89.7}} = \frac{1.7594}{9.4710} = 0.1858,$$

不必經過 VIF。

易錯

s 來自 y 的完整迴歸，自由度 $50-4=46$；$s_{x_3}\sqrt{n-1}$ 合起來就是 $\sqrt{115.4}$，不要再多除一次 $\sqrt{49}$。

觀念題（6 題，仿 SOA 樣題的質性題，含跨章節）

觀念 **觀念題 C5.3-1** 仿 SOA 樣題・回到本節開頭

Determine which of the following statements about the variance inflation factor is/are true.

I. $\text{VIF}_j = 1/(1 - R^2_{(j)})$, where $R^2_{(j)}$ is from the regression of x_j on the other explanatory variables.

II. A large VIF increases the residual standard error s of the regression.

III. A VIF greater than 10 is commonly taken to indicate severe collinearity.

(A) II only

(B) III only

(C) I and II only

(D) I and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

關於 VIF，下列哪些正確？

I. $\text{VIF}_j = 1/(1 - R^2_{(j)})$，$R^2_{(j)}$ 來自 x_j 對其他解釋變數的迴歸。

II. VIF 大會讓迴歸的殘差標準誤 s 變大。

III. VIF 超過 10 通常視為嚴重共線。

答案

(D)：只有 I、III 正確

解析

I、III 對。

II 錯：VIF 放大的是 b_j 的變異數，$s_{b_j} = s\sqrt{\text{VIF}_j}/(s_{x_j}\sqrt{n-1})$；$s$ 本身只和配適有關，共線性不影響配適（第 5 章 5.3 節的提醒）。

觀念 **觀念題 C5.3-2** 仿 SOA 樣題・跨章：第 9 章・回到本節開頭

Two explanatory variables in a linear regression are highly collinear. Determine which of the following statements is/are true.

I. The standard errors of their coefficients are inflated.

II. Their estimated coefficients may have signs opposite to what is expected.

III. Predictions for new observations whose explanatory variables follow the same collinear pattern are not materially affected.

(A) III only

(B) I and II only

(C) I and III only

(D) II and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

兩個解釋變數高度共線。下列哪些正確？

I. 它們係數的標準誤被放大。

II. 估計係數可能和預期的正負號相反。

III. 對於解釋變數符合同樣共線型態的新觀察值，預測不會受到實質影響。

答案

(E)：I、II、III 都正確

解析

I、II 對：(b_1, b_2) 沿著 $b_1 + b_2 \approx$ 常數的方向大幅擺動（第 5 章 5.3 節的模擬圖），個別係數甚至會變號。

III 對：兩者的和估得很準，新觀察值若也符合「x_1 大則 x_2 大」，預測只用到估得準的那個組合。若新觀察值違反共線型態（高槓桿），預測才會很不穩（第 9 章）。

觀念 **觀念題 C5.3-3** 仿 SOA 樣題・跨章：第 8 章・回到本節開頭

An explanatory variable x_3 is orthogonal to the other explanatory variables (after centering). Determine which of the following statements is/are true.

I. Adding x_3 to the model does not change the other estimated coefficients.

II. Adding x_3 to the model does not change the standard errors of the other estimated coefficients.

III. $\text{VIF}_3 = 1$.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

x_3（中心化後）和其他解釋變數正交。下列哪些正確？

I. 加入 x_3 不改變其他係數的估計。

II. 加入 x_3 不改變其他係數的標準誤。

III. $\text{VIF}_3 = 1$。

答案

(B)：只有 I、III 正確

解析

I 對：$X'X$ 分塊對角，各塊分開求解（第 5 章 5.3 節）。III 對：$R^2_{(3)} = 0$。

II 錯：$(X'X)^{-1}$ 中其他變數的對角元素不變，但標準誤是 $s\sqrt{c_{jj}}$，加入 x_3 會改變 s（Error SS 與自由度都變）。第 8 章的主成分迴歸就是利用正交性。

觀念 **觀念題 C5.3-4** 仿 SOA 樣題・跨章：第 3 章・回到本節開頭

A regression has exactly two explanatory variables, x_1 and x_2, with sample correlation r. Determine which of the following statements is/are true.

I. $\text{VIF}_1 = \text{VIF}_2 = 1/(1-r^2)$.

II. If $r = 0.9$, both VIFs are about 5.26.

III. Multiplying x_1 by 100 increases VIF_1.

(A) III only

(B) I and II only

(C) I and III only

(D) II and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

只有兩個解釋變數 x_1, x_2，樣本相關 r。下列哪些正確？

I. $\text{VIF}_1 = \text{VIF}_2 = 1/(1-r^2)$。

II. $r = 0.9$ 時兩個 VIF 約 5.26。

III. x_1 乘以 100 會讓 VIF_1 變大。

答案

(B)：只有 I、II 正確

解析

I 對：輔助迴歸是簡單迴歸，$R^2 = r^2$（第 5 章習題 5.19、5.20）。II 對：$1/(1-0.81) = 5.263$。

III 錯：改變單位不改變相關係數，也不改變 $R^2_{(j)}$，VIF 不變；改變的是 b_1 與它的標準誤（同比例縮小）。

觀念 **觀念題 C5.3-5** 仿 SOA 樣題・回到本節開頭

Determine which of the following statements is/are true.

I. Removing a collinear variable from a model always worsens its predictions.

II. A single high leverage observation can create the appearance of collinearity between two otherwise unrelated variables.

III. A single high leverage observation can hide collinearity that is present in the rest of the data.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

下列哪些正確？

I. 從模型拿掉一個共線的變數，預測一定變差。

II. 一個高槓桿點可能讓兩個原本無關的變數看起來共線。

III. 一個高槓桿點可能掩蓋其餘資料中存在的共線性。

答案

(C)：只有 II、III 正確

解析

I 錯：共線的變數提供的額外資訊很少，拿掉它常常幾乎不影響預測，甚至因為變異數下降而改善測試誤差（第 7 章的變數選擇）。

II、III 對（第 5 章 5.3 節的圖：相關從 0.26 變 0.82，或從 0.99 變 -0.43）。

觀念 **觀念題 C5.3-6** 仿 SOA 樣題・跨章：第 8 章・回到本節開頭

Determine which of the following statements is/are true.

I. A suppressor variable is an explanatory variable that increases the significance of other variables when it is included in the model.

II. Principal components regression replaces the original explanatory variables with orthogonal linear combinations of them.

III. Ridge regression can reduce the variance of the coefficient estimates when the explanatory variables are collinear.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

下列哪些正確？

I. 抑制變數是加入後會提高其他變數顯著性的解釋變數。

II. 主成分迴歸用原變數的正交線性組合取代原變數。

III. 解釋變數共線時，脊迴歸可以降低係數估計的變異數。

答案

(D)：I、II、III 都正確

解析

I 對（第 5 章 5.3 節的數值例子）。II、III 對：這是第 8 章收縮與降維的兩種處理共線性的方法。主成分彼此正交，VIF 都是 1，但不好解釋；脊迴歸以一點偏差換取變異數下降。

章末其餘習題（17 題，★ 精選題已放在各節後面）

練習 **第 5.4 題** ・講義 p.87・回到對應概念

[MAS-I-F18:35] You are fitting a linear regression model of the form:

$$\mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}; \qquad \varepsilon_i \sim N(0, \sigma^2)$$

and are given the following values used in this model:

$$X = \begin{pmatrix} 1 & 0 & 1 & 9 \\ 1 & 1 & 1 & 15 \\ 1 & 1 & 1 & 8 \\ 1 & 1 & 0 & 7 \\ 1 & 1 & 0 & 6 \\ 1 & 0 & 0 & 6 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 19 \\ 32 \\ 19 \\ 17 \\ 13 \\ 15 \end{pmatrix}, \quad (X'X)^{-1}X'\mathbf{y} = \begin{pmatrix} 2.335 \\ 0.297 \\ -0.196 \\ 1.968 \end{pmatrix},$$

$$H = X(X'X)^{-1}X' = \begin{pmatrix} 0.684 & 0.070 & 0.247 & -0.171 & -0.146 & 0.316 \\ 0.070 & 0.975 & -0.044 & 0.108 & -0.038 & -0.070 \\ 0.247 & -0.044 & 0.797 & 0.063 & 0.184 & -0.247 \\ -0.171 & 0.108 & 0.063 & 0.418 & 0.411 & 0.171 \\ -0.146 & -0.038 & 0.184 & 0.411 & 0.443 & 0.146 \\ 0.316 & -0.070 & -0.247 & 0.171 & 0.146 & 0.684 \end{pmatrix}.$$

(The question also gives $X'X$ and $(X'X)^{-1}$.) Calculate the residual for the fifth observation.

(A) Less than -1

(B) At least -1, but less than 0

(C) At least 0, but less than 1

(D) At least 1, but less than 2

(E) At least 2

中文題意

（MAS-I 2018 秋 #35）配適線性迴歸 $\mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}$，$\varepsilon_i \sim N(0, \sigma^2)$，已知（題目也給了 $X'X$ 與 $(X'X)^{-1}$，這裡用不到。）求第五筆觀察的殘差。

（數據、圖表與選項見上方英文題目。）

答案

(A) $e_5 = -1.442$

解析

方法一：用 H 的第五列。 $\hat{y}_5 = \sum_j h_{5j} y_j$：

$$\hat{y}_5 = -0.146(19) - 0.038(32) + 0.184(19) + 0.411(17) + 0.443(13) + 0.146(15)$$

$$= -2.774 - 1.216 + 3.496 + 6.987 + 5.759 + 2.190 = 14.442.$$

$e_5 = y_5 - \hat{y}_5 = 13 - 14.442 = -1.442$。

方法二：用係數。 第五列 $\mathbf{x}_5' = (1, 1, 0, 6)$：

$$\hat{y}_5 = 2.335 + 0.297(1) - 0.196(0) + 1.968(6) = 14.440,$$

$e_5 = -1.440$，差別只是係數四捨五入。精確計算 $e_5 = -1.443$。

易錯

殘差是**觀察減配適**，$13 - 14.442$，符號別弄反。

練習 **第 5.6 題** ・講義 p.87・回到對應概念

A linear regression based on 52 observations has 5 explanatory variables plus an intercept. You are given:

(i) The residual standard error is 8.25.

(ii) The studentized first residual is 0.895.

(iii) The standardized first residual is 0.823.

Calculate the residual standard error if the first observation is removed.

(A) 7.59

(B) 7.91

(C) 8.18

(D) 8.60

(E) 8.97

中文題意

52 筆觀察、5 個解釋變數加截距的線性迴歸：(i) 殘差標準誤 8.25；(ii) 第一個學生化殘差 0.895；(iii) 第一個標準化殘差 0.823。求刪掉第一筆觀察後的殘差標準誤。

(A) 7.59　(B) 7.91　(C) 8.18　(D) 8.60　(E) 8.97

答案

(A) $s_{(1)} = 7.586$

解析

$r_1 = \dfrac{e_1}{s\sqrt{1-h_{11}}}$、$r_1^* = \dfrac{e_1}{s_{(1)}\sqrt{1-h_{11}}}$，相除得 $\dfrac{r_1^*}{r_1} = \dfrac{s}{s_{(1)}}$：

$$s_{(1)} = \frac{s\, r_1}{r_1^*} = \frac{8.25(0.823)}{0.895} = 7.586.$$

和 5.3 一樣，這組數字不滿足 $s^2_{(i)} = s^2 \frac{n-k-1-r_i^2}{n-k-2}$（依恆等式應約 8.28），考試照定義算即可。

易錯

學生化殘差較大，表示分母 $s_{(1)}$ 較小，所以答案要小於 8.25；選到大於 8.25 的就是比例倒過來了。

練習 **第 5.7 題** ・講義 p.88・回到對應概念

For a linear model with 4 observations

(i) The hat matrix is

$$H = \begin{pmatrix} 0.35 & 0.45 & 0.05 & 0.15 \\ 0.45 & 0.65 & -0.15 & 0.05 \\ 0.05 & -0.15 & 0.65 & 0.45 \\ 0.15 & 0.05 & 0.45 & 0.35 \end{pmatrix};$$

(ii) The response variable's values are 14, 12, 8, 3.

(iii) The standard error of the regression is 4.1623.

Calculate the standardized residual of the first observation.

(A) 0.65

(B) 0.75

(C) 0.85

(D) 0.95

(E) 1.05

中文題意

4 筆觀察的線性模型：(i) 帽子矩陣

(ii) 反應值為 14、12、8、3；(iii) 迴歸標準誤為 4.1623。求第一筆觀察的標準化殘差。

(A) 0.65　(B) 0.75　(C) 0.85　(D) 0.95　(E) 1.05

（數據、圖表與選項見上方英文題目。）

答案

(C) $r_1 = 0.8493$

解析

第一步：殘差。 $\mathbf{e} = (I - H)\mathbf{y}$：

$$\begin{pmatrix} 0.65 & -0.45 & -0.05 & -0.15 \\ -0.45 & 0.35 & 0.15 & -0.05 \\ -0.05 & 0.15 & 0.35 & -0.45 \\ -0.15 & -0.05 & -0.45 & 0.65 \end{pmatrix} \begin{pmatrix} 14 \\ 12 \\ 8 \\ 3 \end{pmatrix} = \begin{pmatrix} 2.85 \\ -1.05 \\ 2.55 \\ -4.35 \end{pmatrix}.$$

只需要第一個：$\hat{y}_1 = 0.35(14) + 0.45(12) + 0.05(8) + 0.15(3) = 11.15$，$e_1 = 14 - 11.15 = 2.85$。

第二步：標準化。

$$r_1 = \frac{2.85}{4.1623\sqrt{1 - 0.35}} = \frac{2.85}{3.3557} = 0.8493.$$

檢查：殘差和為 0（有截距）；$\sum e_i^2 = 34.65$，$s^2 = 34.65/(4-2) = 17.325$，$s = 4.1623$，和題目一致。

> **易錯**
>
> $I - H$ 的非對角元素是 $-h_{ij}$；只改對角線、忘了變號，殘差就錯了。

練習 **第 5.9 題** ・講義 p.88・回到對應概念

(Continuation of 5.8) You are given:

(i) The first five residuals are $\{-1.515, 1.524, 1.398, -0.633, 0.825\}$.

(ii) The residual standard error is 0.8.

An observation is considered an outlier if the absolute value of its standardized residual is greater than 2. Which of the first 5 observations are outliers?

中文題意

（接 5.8）另知 (i) 前 5 個殘差為 $\{-1.515, 1.524, 1.398, -0.633, 0.825\}$；(ii) 殘差標準誤為 0.8。標準化殘差絕對值大於 2 的觀察視為離群值。前 5 筆中哪些是離群值？

答案

只有第 1 筆

解析

$r_i = e_i/(0.8\sqrt{1-h_{ii}})$：

$$r_1 = \frac{-1.515}{0.8\sqrt{0.8388}} = -2.068, \quad r_2 = \frac{1.524}{0.8\sqrt{0.9192}} = 1.987, \quad r_3 = \frac{1.398}{0.8\sqrt{0.7841}} = 1.973,$$

$$r_4 = \frac{-0.633}{0.8\sqrt{0.9741}} = -0.802, \quad r_5 = \frac{0.825}{0.8\sqrt{0.8693}} = 1.106.$$

只有 $|r_1| > 2$。

易錯

只看原始殘差 e_i/s 會得到 $1.524/0.8 = 1.905$、$1.515/0.8 = 1.894$，以為都沒超過；也有人只看 $|e_i|$ 最大的第 2 筆。必須除以 $s\sqrt{1-h_{ii}}$：槓桿大的點殘差變異數小，同樣的殘差更不尋常。

練習 **第 5.10 題** ・講義 p.88・回到對應概念

A regression model with 4 variables and an intercept is fitted to 32 observations. For the sixth observation, you are given:

(i) The standardized residual is 0.824.

(ii) The leverage is 0.471.

Calculate Cook's distance for the sixth observation, D_6.

中文題意

4 個解釋變數加截距的迴歸模型配適 32 筆觀察。第六筆觀察的標準化殘差為 0.824、槓桿為 0.471。求 Cook 距離 D_6。

答案

$$D_6 = 0.1209$$

解析

$k+1=5$。由 (5.2)：

$$D_6 = r_6^2 \cdot \frac{h_{66}}{(k+1)(1-h_{66})} = 0.824^2 \cdot \frac{0.471}{5(0.529)} = 0.67898 \times 0.17807 = 0.1209.$$

易錯

分母的參數個數是 5（含截距），不是 4。

練習 **第 5.12 題** ・講義 p.89・回到對應概念

You are given the following information about 5 observations from a linear regression:

i	Residual	Leverage
1	0.153	0.305
2	0.274	0.223
3	-0.211	0.190
4	-0.444	0.101
5	0.352	0.176

Using Cook's distance as a measure, which of these five points is most influential?

中文題意

線性迴歸中 5 筆觀察的資料：

以 Cook 距離為準，哪一點最有影響力？

（數據、圖表與選項見上方英文題目。）

答案

第 5 點

解析

把標準化殘差的定義代入 (5.2)：

$$D_i = \frac{e_i^2}{s^2(1-h_{ii})} \cdot \frac{h_{ii}}{(k+1)(1-h_{ii})} = \frac{1}{(k+1)s^2} \cdot \frac{e_i^2 h_{ii}}{(1-h_{ii})^2}.$$

同一個模型的 $(k+1)s^2$ 是共同倍數，只要比較 $e_i^2 h_{ii}/(1-h_{ii})^2$：

i	e_i^2	$h_{ii}/(1-h_{ii})^2$	**乘積**
1	0.02341	0.6315	0.01478
2	0.07508	0.3694	0.02773
3	0.04452	0.2896	0.01289
4	0.19714	0.1250	0.02464
5	0.12390	0.2592	0.03212

第 5 點最大。注意殘差最大的第 4 點因為槓桿只有 0.101，排在第 5 點之後；槓桿最大的第 1 點因為殘差小，排名很後面。

易錯

題目給的是**原始殘差**，$(1-h_{ii})$ 要平方。忘了平方會得到 $e_i^2 h_{ii}/(1-h_{ii}) = 0.0103, 0.0215, 0.0104, 0.0221, 0.0265$：這題第 5 點仍然最大，但第 2、4 點的順序對調了，在別的題目就可能因此選錯。

練習 **第 5.14 題** ・講義 p.89・回到對應概念

[S-F17:36] You are analyzing a database and have fit a multiple regression with 12 continuous explanatory variables and one intercept. You are given the following:

(i) Sum of square errors $= 618$

(ii) The 10th diagonal entry of the hat matrix, $h_{10,10} = 0.35$

(iii) The 10th residual value $= \hat{\varepsilon}_{10} = 9.5$

(iv) Cook's Distance $= D_{10} = 5.0$

Calculate the number of data points this model was fit to.

(A) Less than 200

(B) At least 200, but less than 400

(C) At least 400, but less than 600

(D) At least 600, but less than 800

(E) At least 800

中文題意

（SRM 2017 秋 #36）分析資料庫時配適 12 個連續解釋變數加一個截距的多元迴歸，已知：(i) 誤差平方和 618；(ii) 帽子矩陣第 10 個對角元素 $h_{10,10} = 0.35$；(iii) 第 10 個殘差 $e_{10} = 9.5$；(iv) Cook 距離 $D_{10} = 5.0$。求模型配適的觀察筆數。

（數據、圖表與選項見上方英文題目。）

答案

(C) $n = 550$

解析

$k + 1 = 13$，$s^2 = \dfrac{618}{n - 13}$。標準化殘差的平方：

$$r_{10}^2 = \frac{e_{10}^2}{s^2(1 - h)} = \frac{90.25(n - 13)}{618(0.65)} = 0.224670(n - 13).$$

槓桿因子：$\dfrac{h}{(k+1)(1-h)} = \dfrac{0.35}{13(0.65)} = 0.041420$。代入 (5.2)：

$$5.0 = 0.224670(n-13)(0.041420) = 0.0093058(n-13) \;\Rightarrow\; n-13 = 537.3,\; n \approx 550.$$

易錯

未知的 n 藏在 s^2 的自由度裡；參數個數是 13（12 個變數加截距）。

練習 **第 5.15 題** ・講義 p.89・回到對應概念

A regression model of the form $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ is fitted to 80 observations. You are given that $\bar{x} = 51$ and $\sum_{i=1}^{80}(x_i - \bar{x})^2 = 60{,}919$.

An observation is considered a high leverage observation if its leverage is greater than 2 times average. In other words, an observation x_i is high leverage if $x_i < a$ or $x_i > b$. Determine a and b.

中文題意

迴歸模型 $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ 配適 80 筆觀察，已知 $\bar{x} = 51$、$\sum_{i=1}^{80}(x_i - \bar{x})^2 = 60{,}919$。槓桿大於平均 2 倍的觀察視為高槓桿；換句話說，$x_i < a$ 或 $x_i > b$ 時 x_i 是高槓桿。求 a 與 b。

答案

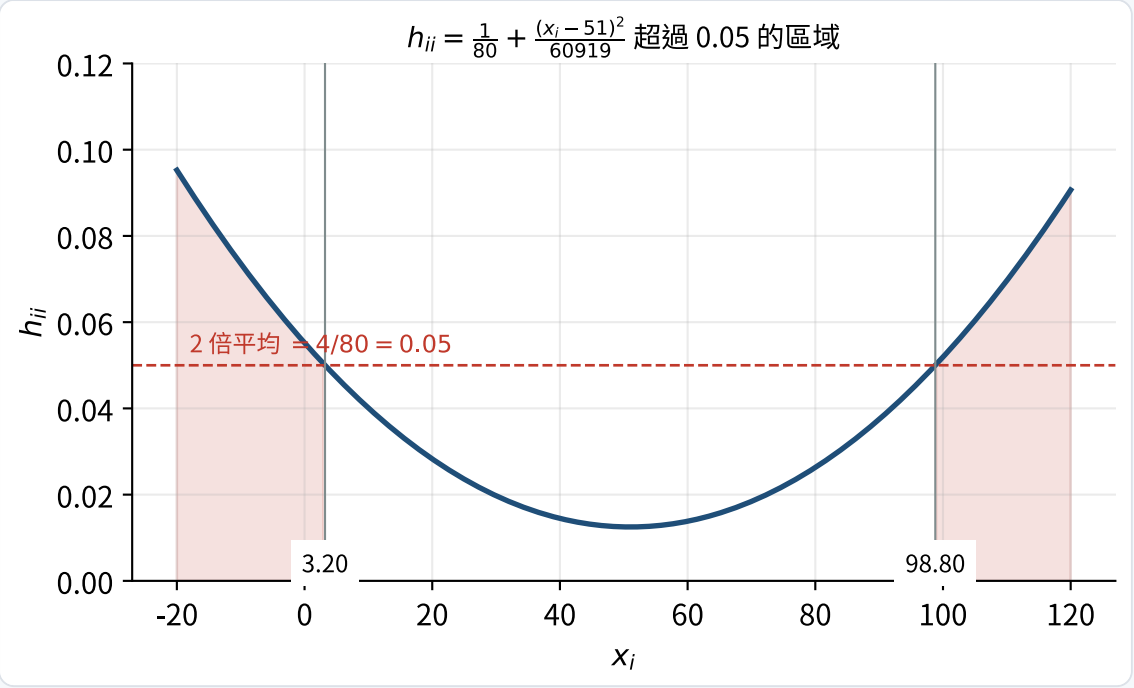
$a = 3.20$, $b = 98.80$

解析

平均槓桿 $= 2/80$，門檻是 $4/80 = 0.05$。由 (5.1)：

$$\frac{1}{80} + \frac{(x_i - 51)^2}{60{,}919} > \frac{4}{80} \;\Rightarrow\; (x_i - 51)^2 > 60{,}919 \times \frac{3}{80} = 2{,}284.46 \;\Rightarrow\; |x_i - 51| > 47.80.$$

所以 $a = 51 - 47.80 = 3.20$、$b = 51 + 47.80 = 98.80$。



槓桿是 x 的二次函數，在 $\bar{x} = 51$ 最低（$1/80$）；超過 0.05 的區域（紅色）就是 $x < 3.20$ 或 $x > 98.80$。

易錯

移項時要先減掉 $1/80$：$4/80 - 1/80 = 3/80$，不是 $4/80$。

練習 **第 5.16 題** ・講義 p.90・回到對應概念

[MAS-I-S19:31] You are fitting a linear regression model of the form:

$$\mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}; \qquad \varepsilon_i \sim N(0, \sigma^2)$$

and are given the following values used in this model:

$$X = \begin{pmatrix} 1 & 0 & 1 & 9 \\ 1 & 1 & 1 & 15 \\ 1 & 1 & 1 & 8 \\ 0 & 1 & 1 & 7 \\ 0 & 1 & 1 & 6 \\ 0 & 0 & 1 & 6 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 21 \\ 32 \\ 19 \\ 17 \\ 15 \\ 15 \end{pmatrix}, \quad \hat{\mathbf{y}} = X(X'X)^{-1}X'\mathbf{y} = \begin{pmatrix} 20.93 \\ 32.03 \\ 19.04 \\ 16.89 \\ 15.04 \\ 15.07 \end{pmatrix},$$

$\hat{\sigma}^2 = 0.012657$. The hat matrix $H = X(X'X)^{-1}X'$ is the same as in question 5.4 (diagonal elements 0.684, 0.975, 0.797, 0.418, 0.443, 0.684). (The question also gives $X'X$, $(X'X)^{-1}$, and $(X'X)^{-1}X'\mathbf{y} = (0.297, 0.032, 3.943, 1.854)'$.)

Calculate how many observations are influential, using a unity threshold for Cook's distance.

(A) 0

(B) 1

(C) 2

(D) 3

(E) 4

中文題意

（MAS-I 2019 春 #31）配適線性迴歸 $\mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}$，$\varepsilon_i \sim N(0, \sigma^2)$，已知 $\hat{\sigma}^2 = 0.012657$。帽子矩陣 H 和 5.4 的完全相同（對角元素 0.684、0.975、0.797、0.418、0.443、0.684）。（題目也給了 $X'X$、$(X'X)^{-1}$ 與 $\mathbf{b} = (0.297, 0.032, 3.943, 1.854)'$。）以 Cook 距離門檻 1 判斷，有幾筆影響點？

(A) 0　(B) 1　(C) 2　(D) 3　(E) 4

（數據、圖表與選項見上方英文題目。）

答案

(B) 1 筆（第 2 筆）

解析

$k+1=4$。殘差 $\mathbf{e}=\mathbf{y}-\hat{\mathbf{y}}=(0.07,-0.03,-0.04,0.11,-0.04,-0.07)$。

第一個因子 $r_i^2=\dfrac{e_i^2}{\hat\sigma^2(1-h_{ii})}$，例如 $r_1^2=\dfrac{0.0049}{0.012657(0.316)}=1.2251$。**第二個因子** $\dfrac{h_{ii}}{4(1-h_{ii})}$，例如第 2 筆 $\dfrac{0.975}{4(0.025)}=9.75$。

i	e_i	h_{ii}	r_i^2	$h_{ii}/[4(1-h_{ii})]$	D_i
1	0.07	0.684	1.2251	0.5411	0.663
2	-0.03	0.975	2.8443	9.75	27.73
3	-0.04	0.797	0.6227	0.9815	0.611
4	0.11	0.418	1.6426	0.1796	0.295
5	-0.04	0.443	0.2270	0.1988	0.045
6	-0.07	0.684	1.2251	0.5411	0.663

只有第 2 筆 $D>1$。它的殘差是六筆中最小的之一，但槓桿 0.975 幾乎是 1，配適線被它拉到自己身上：刪掉它，配適值會大幅改變。

為什麼 H 和 5.4 一樣：5.4 的欄是 $(\mathbf{1},\mathbf{a},\mathbf{c},\mathbf{x})$，這題是 $(\mathbf{c},\mathbf{a},\mathbf{1},\mathbf{x})$，其中 $\mathbf{c}=(1,1,1,0,0,0)'$；兩個設計矩陣的欄位空間相同，所以投影矩陣相同。

易錯

用精確的 $h_{22}=0.9747$ 重算，$D_2=19.25$；h 接近 1 時 $h/(1-h)$ 對四捨五入非常敏感，但結論不變。不要因為第 2 筆的殘差很小就略過它。

練習 **第 5.18 題** ・講義 p.91・回到對應概念

Some authors suggest that a VIF_j of 5 or higher indicates high collinearity of x_j to the other variables in a regression model.

Suppose x_j is regressed against the other explanatory variables in a model. Let $R^2_{(j)}$ be the coefficient of determination for this regression. Which values of $R^2_{(j)}$ indicate high collinearity according to those authors?

中文題意

有些作者認為 $\mathrm{VIF}_j \geq 5$ 表示 x_j 和模型中其他變數高度共線。把 x_j 對其他解釋變數迴歸，決定係數為 $R^2_{(j)}$。依這些作者的標準，$R^2_{(j)}$ 在什麼範圍表示高度共線？

答案

$R^2_{(j)} \geq 0.8$

解析

$$\frac{1}{1-R^2_{(j)}} \geq 5 \;\Leftrightarrow\; 1-R^2_{(j)} \leq 0.2 \;\Leftrightarrow\; R^2_{(j)} \geq 0.8.$$

同理，VIF ≥ 10 對應 $R^2_{(j)} \geq 0.9$。

練習 **第 5.19 題** · 講義 p.91 · 回到對應概念

A linear regression model with an intercept is used to model y as a function of x_1 and x_2. The correlation coefficient of the two explanatory variables is 0.4.

Determine VIF_1.

中文題意

有截距的線性迴歸以 x_1, x_2 預測 y，兩個解釋變數的相關係數為 0.4。求 VIF_1。

答案

$$\mathrm{VIF}_1 = 1.1905$$

解析

x_1 對 x_2 的輔助迴歸是簡單迴歸，R^2 等於相關係數的平方 0.16：

$$\mathrm{VIF}_1 = \frac{1}{1-0.4^2} = \frac{1}{0.84} = 1.1905.$$

兩個變數時 $\mathrm{VIF}_1 = \mathrm{VIF}_2$。

易錯

要先平方：$1/(1-0.4) = 1.667$ 是錯的。

練習 **第 5.20 題** ・講義 p.92・回到對應概念

Auto collision losses are modeled using two categorical variables: USE (business or pleasure) and MILES (less than 10,000 miles driven per year or more than 10,000 miles driven per year). You have 5 observations of the two variables:

USE	1	0	1	1	0
MILES	1	0	1	0	0

You suspect that the two variables are almost collinear. To test this hypothesis, you calculate the VIF. Determine the VIF of MILES.

中文題意

汽車碰撞損失以兩個類別變數建模：USE（商務或休閒）與 MILES（每年行駛少於或多於 10,000 英里）。兩個變數的 5 筆觀察：

你懷疑兩者幾乎共線，因此計算 VIF。求 MILES 的 VIF。

（數據、圖表與選項見上方英文題目。）

答案

$$\text{VIF} = 1.8$$

解析

只有兩個解釋變數，VIF $= 1/(1-r^2)$。令 x 為 USE、y 為 MILES：$\bar{x} = 0.6$、$\bar{y} = 0.4$。

$$\sum (x_i - \bar{x})^2 = 3(0.4^2) + 2(0.6^2) = 1.2, \qquad \sum (y_i - \bar{y})^2 = 2(0.6^2) + 3(0.4^2) = 1.2,$$

$$\sum (x_i - \bar{x})(y_i - \bar{y}) = (0.4)(0.6) + (-0.6)(-0.4) + (0.4)(0.6)$$

$$+(0.4)(-0.4) + (-0.6)(-0.4) = 0.8.$$

$$r^2 = \frac{0.8^2}{1.2 \times 1.2} = \frac{4}{9} = 0.4444, \qquad \text{VIF} = \frac{1}{1 - 4/9} = 1.8.$$

易錯

0/1 指標變數一樣可以算相關係數與 VIF，不必特別處理。

練習 **第 5.22 題** ・講義 p.93・回到對應概念

[MAS-I-S18:32] Two different data sets were used to construct the four regression models below. The following output was produced from the models:

Data Set	Model	Dependent variable	Independent variables	Total Sum of Squares	Residual Sum of Squares
A	1	Y_A	X_{A1}, X_{A2}	359,030	2,823
A	2	X_{A1}	X_{A2}	92,990	7,070
B	1	Y_B	X_{B1}, X_{B2}	275,700	13,240
B	2	X_{B1}	X_{B2}	87,020	34,650

The threshold of the Variance Inflation Factor for variable j (VIF_j) for determining excessive collinearity is $\text{VIF}_j > 5$. Determine which one of the following statements best describes the data.

(A) Collinearity is present in both data sets A and B.

(B) Collinearity is present in neither data set A nor B.

(C) Collinearity is present in data set A only.

(D) Collinearity is present in data set B only.

(E) The degree of collinearity cannot be determined from the information given.

中文題意

（MAS-I 2018 春 #32）用兩組資料建立以下四個迴歸模型：

判斷過度共線的門檻為 $\text{VIF}_j > 5$。下列哪個敘述最能描述這兩組資料？

(A) A、B 都有共線性　(B) A、B 都沒有　(C) 只有 A 有　(D) 只有 B 有　(E) 無法由題目資訊判斷

（數據、圖表與選項見上方英文題目。）

答案

(C) 只有 A

解析

VIF 要用**解釋變數對解釋變數**的輔助迴歸，也就是模型 2。$\text{VIF} = \dfrac{1}{1-R^2} = \dfrac{\text{Total SS}}{\text{Error SS}}$：

$$\text{A：}\ \frac{92{,}990}{7{,}070} = 13.15 > 5, \qquad \text{B：}\ \frac{87{,}020}{34{,}650} = 2.51 < 5.$$

只有兩個解釋變數，所以 X_{A1} 和 X_{A2} 的 VIF 相同，算一個就夠。

易錯

模型 1 的 R^2（A 為 0.992、B 為 0.952）是 y 被解釋的程度，和共線性無關；拿它算「VIF」會得到 A、B 都很大的錯誤結論 (A)。

練習 **第 5.23 題** ・講義 p.93・回到對應概念

[S-S17:32] You are given:

- A linear model includes three explanatory variables: X_1, X_2, and X_3.
- $R^2_{(j)}$ is the coefficient of determination obtained from regressing the jth explanatory variable against all other explanatory variables.
- $R^2_{(1)} = 0.05$, $R^2_{(2)} = 0.83$, and $R^2_{(3)} = 0.47$.
- The threshold of the Variance Inflation Factor for variable j (VIF_j) for determining excessive collinearity is $\text{VIF}_j > 5$.

Determine which of the 3 variables under consideration will exceed the threshold established above.

(A) X_1 only

(B) X_2 only

(C) X_3 only

(D) X_1, X_2, and X_3

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

（SRM 2017 春 #32）線性模型有三個解釋變數 X_1, X_2, X_3，$R^2_{(j)}$ 是第 j 個解釋變數對其他解釋變數迴歸的決定係數：$R^2_{(1)} = 0.05$、$R^2_{(2)} = 0.83$、$R^2_{(3)} = 0.47$。過度共線的門檻為 $\text{VIF}_j > 5$。哪些變數超過門檻？

(A) 只有 X_1　(B) 只有 X_2　(C) 只有 X_3　(D) X_1, X_2, X_3　(E) 以上皆非

答案

(B) 只有 X_2

解析

$$\mathrm{VIF}_1 = \frac{1}{0.95} = 1.053, \qquad \mathrm{VIF}_2 = \frac{1}{0.17} = 5.882, \qquad \mathrm{VIF}_3 = \frac{1}{0.53} = 1.887.$$

或直接用 5.18 的結論：VIF > 5 等價於 $R^2_{(j)} > 0.8$，只有 0.83 超過。

練習 **第 5.24 題** ・講義 p.93・回到對應概念

Use the following information for questions 5.24 and 5.25: For a regression of y on three variables x_1, x_2 and x_3 and an intercept based on 50 observations, you are given

(i) $\sum_i (x_{i3} - \bar{x}_3)^2 = 115.4$

(ii) The error sum of squares when regressing y on the three variables is 142.4.

(iii) The error sum of squares when regressing x_3 on the other two variables and an intercept is 89.7.

Calculate the VIF for x_3.

中文題意

（5.24、5.25 共用）以 50 筆觀察做 y 對 x_1, x_2, x_3 加截距的迴歸，已知：(i) $\sum_i (x_{i3} - \bar{x}_3)^2 = 115.4$；(ii) y 對三個變數迴歸的誤差平方和為 142.4；(iii) x_3 對另兩個變數加截距迴歸的誤差平方和為 89.7。求 x_3 的 VIF。

答案

$$\text{VIF}_3 = 1.2865$$

解析

輔助迴歸的 Total SS 就是 (i) 的 115.4：

$$R^2_{(3)} = 1 - \frac{89.7}{115.4} = 0.22270, \qquad \text{VIF}_3 = \frac{1}{1 - 0.22270} = \frac{115.4}{89.7} = 1.2865.$$

易錯

(ii) 是 y 的迴歸，用不到；不要把 142.4 拿來算 $R^2_{(3)}$。

練習 **第 5.26 題** ・講義 p.93・回到對應概念

For a linear regression with 3 explanatory variables based on 24 observations, you are given:

(i) $\sum_{i=1}^{24}(x_{i1}-\bar{x}_1)^2 = 64.4284.$
(ii) $\sum_{i=1}^{24}(\hat{y}_i-y_i)^2 = 196.0810.$
(iii) The standard error of b_1 is 0.8955.

Calculate VIF_1.

中文題意

3 個解釋變數、24 筆觀察的線性迴歸，已知：(i) $\sum_{i=1}^{24}(x_{i1}-\bar{x}_1)^2 = 64.4284$；(ii) $\sum_{i=1}^{24}(\hat{y}_i-y_i)^2 = 196.0810$；(iii) b_1 的標準誤為 0.8955。求 VIF_1。

答案

$$\text{VIF}_1 = 5.270$$

解析

由 (5.4) 解出 VIF：

$$\text{VIF}_1 = \left(\frac{s_{b_1}\, s_{x_1}\sqrt{n-1}}{s}\right)^2.$$

$s = \sqrt{196.0810/(24-4)} = \sqrt{9.80405} = 3.1311$；$s_{x_1}\sqrt{n-1} = \sqrt{64.4284} = 8.0267$。

$$\text{VIF}_1 = \left(\frac{0.8955 \times 8.0267}{3.1311}\right)^2 = (2.2956)^2 = 5.270.$$

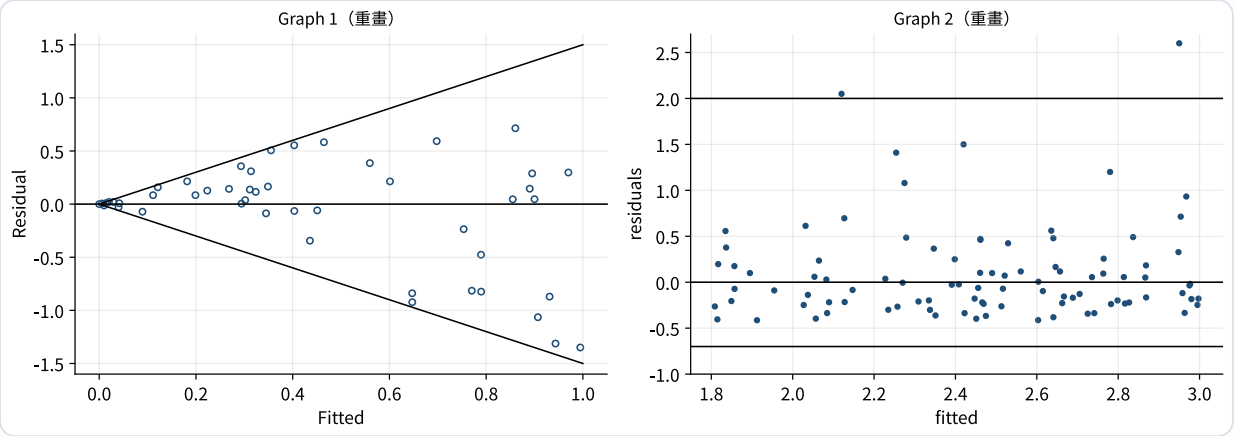
參考答案寫 5.2713（用 196.0310 算的），差別不影響判斷。

易錯

> 「3 個解釋變數」要加上截距，誤差自由度是 $24 - 4 = 20$。

練習 **第 5.27 題** ・講義 p.94・回到對應概念

[S-S16:36] You are given the following two graphs comparing the fitted values to the residuals of two different linear models:



Residuals versus fitted values for the two models (redrawn from the exam figures).

Determine which of the following statements are true.

I. Graph 1 indicates the data is homoscedastic

II. Graph 1 indicates the data is heteroskedastic

III. Graph 2 indicates the data is non-normal

(A) I only

(B) II only

(C) III only

(D) I and II

(E) II and III

中文題意

（SRM 2016 春 #36）兩個不同線性模型的「配適值對殘差」圖如下：

I. Graph 1 顯示資料同質變異（homoscedastic）。

II. Graph 1 顯示資料異質變異（heteroskedastic）。

III. Graph 2 顯示資料不是常態。

哪些敘述正確？

(A) 只有 I　(B) 只有 II　(C) 只有 III　(D) I 與 II　(E) II 與 III

（數據、圖表與選項見上方英文題目。）

答案

(E) II 與 III

解析

I、II：Graph 1 的殘差分散程度隨配適值增加（楔形／漏斗形），表示誤差變異數不是固定的，是異質變異。II 對、I 錯。

III：Graph 2 的寬度大致固定（沒有異質變異），但殘差不對稱：大多數略低於 0，上方有一條長尾（到 2 以上），下方卻在 -0.7 附近就截止。常態誤差應該在 0 上下對稱，所以這張圖顯示右偏、非常態。III 對。

易錯

I 與 II 互斥，(D) 不可能對。殘差對配適值圖主要看異質變異，但分布的不對稱一樣看得出非常態。