SRM · 第 7 章

線性迴歸：選擇預測變數

候選的解釋變數很多時，全部放進模型會過度配適。本章介紹三種挑選變數子集的方法（最佳子集、向前逐步、向後逐步，以及混合法），以及在不同大小的模型之間做選擇的五種工具：交叉驗證、Mallows 的 C_p、AIC、BIC 與調整 R^2。每個準則都會推導它從哪裡來、懲罰有多重。

本章內容

1. 7.1 子集選擇
2. 7.2 選擇最佳模型

本章對應講義第 7 課，讀本是 Frees 5.1～5.2 節與 ISLR 6.1 節。計算題集中在三類：(1) 各種搜尋方法要配適幾個模型；(2) 給一張 RSS 或 R^2 表，走出每種方法選到的模型；(3) 算 C_p、AIC、BIC、調整 R^2。

記號。 n 是觀察筆數，k 是候選解釋變數的總數，d 是某個候選模型裡的解釋變數個數（不含截距），所以這個模型有 $d+1$ 個迴歸係數。RSS（residual sum of squares）就是前幾章的 Error SS。

現代的資料常有非常多的預測變數，甚至多於觀察筆數。變數越多，訓練資料上的誤差越小（變數夠多時甚至為 0），但預測新資料會很差。機械地配出係數並不保證變數和反應真的有關，必須挑出真正有影響的變數。下一章介紹另外兩類減少變數的方法（收縮與降維）。

7.1 子集選擇

一、最佳子集選擇

k 個候選變數，每個可以放或不放，共有 2^k 個模型。全部配適一遍，再挑最好的，叫做**最佳子集選擇**（best subset selection）。「最好」怎麼判斷，要看比較的模型變數個數是否相同：

- **變數個數相同**：RSS 較小（等價地，R^2 較大）的較好。
- **變數個數不同**：不能直接比 RSS，要用交叉驗證，或 C_p、AIC、BIC、調整 R^2 這四個統計量之一（7.2 節）。

> **為什麼變數個數不同時不能比 RSS**
>
> 設模型 B 包含模型 A 的所有變數再多幾個（A **巢狀**（nested）於 B 之中）。B 的最小平方是在比較大的參數集合上求最小值：把 B 多出來的係數設為 0，就得到 A 的任何一組配適，所以
>
> $$\mathrm{RSS}_B = \min_{\text{B 的參數}} \sum_i (y_i - \hat{y}_i)^2 \le \min_{\text{A 的參數}} \sum_i (y_i - \hat{y}_i)^2 = \mathrm{RSS}_A.$$
>
> 不管新變數多麼不相干，RSS 都不會增加，而且幾乎一定會減少。所以比 RSS 一定是「越大的模型越好」，無法反映預測能力。
>
> （兩個**不巢狀**的模型，$d+1$ 個變數的那個 RSS 有可能比 d 個變數的大。但只要巢狀時 RSS 必然下降，就足以說明 RSS 不是比較不同大小模型的好指標。）

最佳子集選擇可以寫成兩階段：

1. 令 $\mathcal{M}_0$ 為只有截距的模型（預測值都是 $\bar{y}$）。
2. 對 $d = 1, 2, \ldots, k$：在 $\binom{k}{d}$ 個恰有 d 個變數的模型中，取 RSS 最小者為 $\mathcal{M}_d$。
3. 用交叉驗證或 C_p、AIC、BIC、調整 R^2，從 $\mathcal{M}_0, \ldots, \mathcal{M}_k$ 中選一個。

「best regressions」程序就是第 2 步：找出指定變數個數的最佳模型。

k 大時 2^k 個模型配不完：$k = 20$ 就超過一百萬（$2^{20} = 1{,}048{,}576$）。這時需要啟發式（heuristic）的方法：向前逐步與向後逐步。

二、向前逐步選擇

向前逐步選擇（forward stepwise selection）：

1. 從空模型（只有截距，$\hat{y} = \bar{y}$）開始。
2. 把 k 個變數各自加入，配出 k 個模型，取 RSS 最小者。
3. 在這個模型上，把剩下 $k-1$ 個變數各自加入，配出 $k-1$ 個模型，取 RSS 最小者。
4. 重複，直到 k 個變數都進入模型。
5. 得到每種大小各一個模型，共 $k+1$ 個，用交叉驗證或四個統計量之一選出最後的模型。

> **要配適幾個模型**
>
> 空模型 1 個；第一步 k 個；第二步 $k-1$ 個；.....；最後一步 1 個。
>
> $$1 + \sum_{i=0}^{k-1} (k-i) = 1 + (k + (k-1) + \cdots + 1) = 1 + \frac{k(k+1)}{2}.$$
>
> $k = 20$ 時是 211 個，遠少於最佳子集的 1,048,576 個。

向前逐步是**貪婪**（greedy）的演算法：每一步只挑眼前最好的，不考慮「現在選一個次好的，之後可能得到更好的模型」。所以不保證選到最佳模型。例如：

變數	RSS	變數	RSS	變數	RSS
無	875	X_1	472	X_1, X_2	420
		X_2	500	X_1, X_3	432
		X_3	491	X_2, X_3	412

一個變數時 X_1 最好，向前法接著只會考慮含 X_1 的 $\{X_1, X_2\}$ 與 $\{X_1, X_3\}$，選到 RSS 420 的 $\{X_1, X_2\}$。$\{X_2, X_3\}$ 的 RSS 412 更低，卻永遠不會被看到。

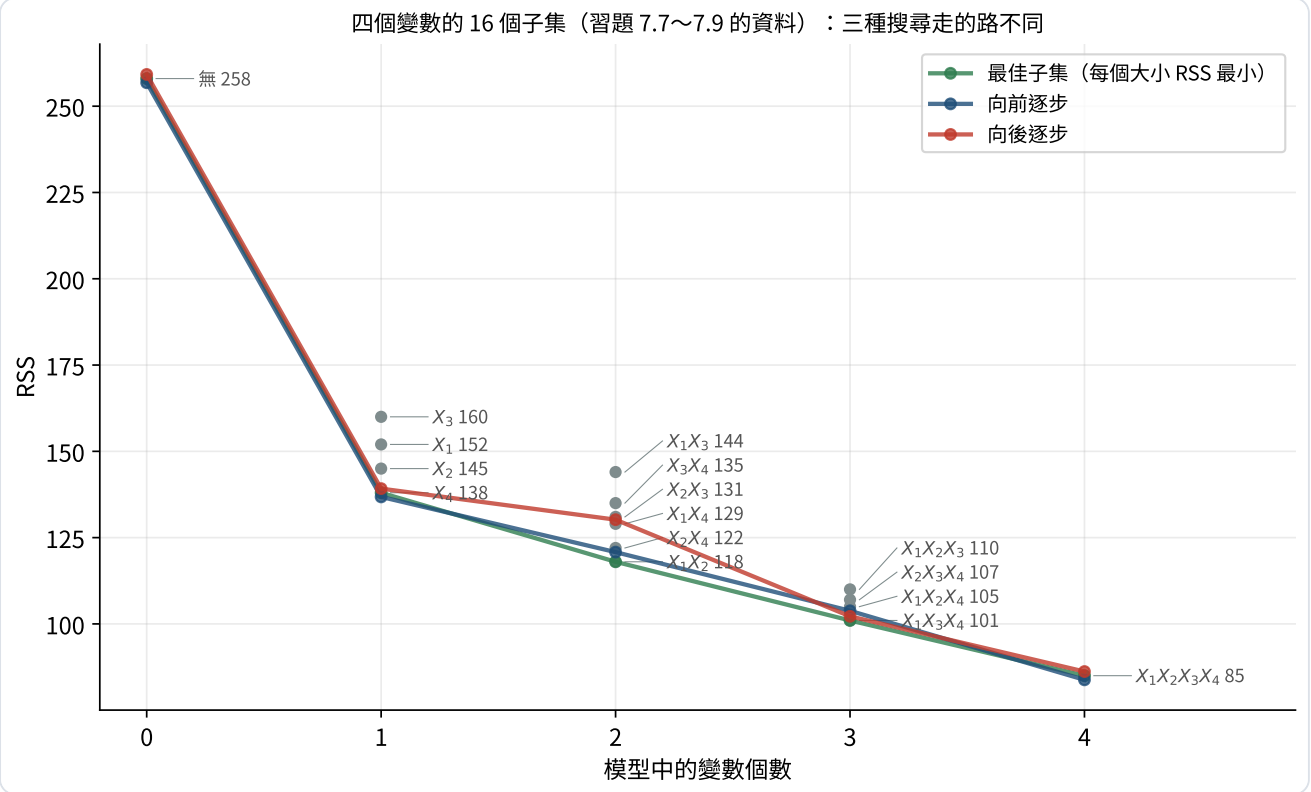
$n < k$ 時仍可使用：只是最多只能做到 $n-1$ 個變數的模型 $\mathcal{M}_{n-1}$（$n-1$ 個變數加截距共 n 個係數，剛好把 n 筆資料配到殘差全為 0；再多就無法唯一估計）。

三、向後逐步選擇

向後逐步選擇（backward stepwise selection）：

1. 從包含全部 k 個變數的完整模型開始。
2. 對每個變數，配出拿掉它、只用其他 $k-1$ 個變數的模型，共 k 個，取 RSS 最小者。
3. 在這個模型上重複：每次拿掉一個變數，配出 $k-1$、$k-2$、.....個模型。
4. 直到沒有變數為止。得到每種大小各一個模型，共 $k+1$ 個，再用交叉驗證或統計量選擇。

配適的模型數同樣是 $1+k(k+1)/2$。同樣不保證選到最佳模型。和向前法不同，$k>n$ **時不能使用**：第一步的完整模型參數比資料還多，算不出有意義的結果。



習題 7.7～7.9 的資料：四個變數的 16 個子集，橫軸是變數個數、縱軸是 RSS。綠線是最佳子集（每個大小 RSS 最小的模型）：X_4、X_1X_2、$X_1X_3X_4$。藍線是向前逐步：先選 X_4，之後只能在含 X_4 的模型裡挑，兩個變數時選 X_2X_4（122），錯過了最佳的 X_1X_2（118），三個變數時選 $X_1X_2X_4$（105），也錯過了 $X_1X_3X_4$（101）。紅線是向後逐步：從全模型拿掉 X_2 得到最佳的 $X_1X_3X_4$，但再拿掉一個只能在 $\{X_1,X_3,X_4\}$ 的子集裡選，得到 X_1X_4（129），同樣錯過 X_1X_2。

四、混合法

混合法（mixed selection，或 hybrid）：像向前法一樣一次加入一個變數，但加入後若有變數不再有幫助，就把它拿掉。步驟：

1. 從只有截距的模型開始。
2. 對每個尚未使用的變數，配出加入它的模型，選 RSS 最好的。
3. 檢查模型中的每個變數。若有變數的 t 比值低於事先設定的門檻，拿掉 t 比值最低的那一個。另一種做法是：若有變數的 p 值高於事先設定的門檻，拿掉 p 值最高的那一個。兩者相似但不完全相同，因為 t 比值換成 p 值還要看自由度。
4. 重複第 2、3 步，直到沒有變數符合加入或刪除的門檻。

常見的逐步迴歸（stepwise regression）就是這種混合法：加入的門檻是 $|t|$ 超過某個值（例如 2），刪除的門檻是 $|t|$ 低於某個值。有些軟體改用 F 檢定，一次只考慮一個變數時 $F = t^2$，兩者等價。

五、類別變數

所有子集選擇方法都是**一次加入或刪除一個參數**。有兩類以上的類別變數，一個類別的指標就是一個參數，所以最後的模型可能只包含**部分**類別的指標；沒被選入的類別，實際上就被併入基準類別（第 2 章的指標變數）。

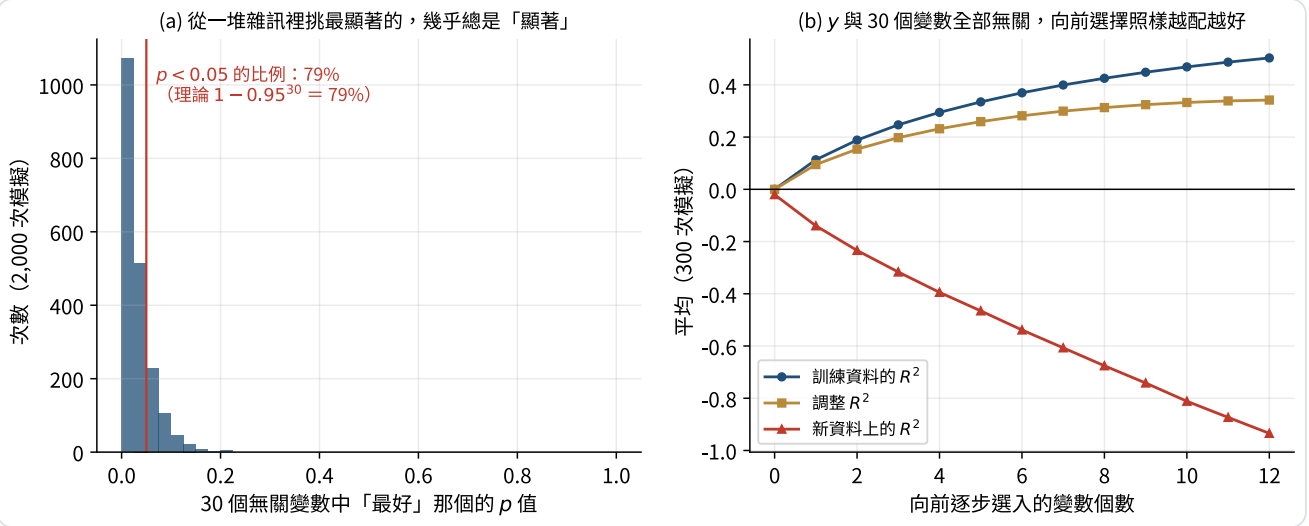
例：「車型」有雙門跑車、轎車、休旅車、廂型車四類，以轎車為基準類別，有三個指標。向前逐步第一步選入了「休旅車」的指標，這個模型實際上把雙門跑車和廂型車都當成基準類別（和轎車同一組）。

計算模型個數時，要先把類別變數換算成指標個數（習題 7.3、7.4）。

六、逐步迴歸的七個缺點

1. **資料窺探**（data snooping）：對同一份資料配適大量模型，總有一些碰巧看起來很好。統計上常用 95% 信賴水準，所以每 20 個錯誤的模型就有 1 個會被接受；試過 100 個模型，大約會找到 5 個看起來不錯的假模型。
2. 忽略了「所有模型都不對」的可能：真正的關係可能是非線性的，資料也可能有離群值或高槓桿點。
3. 只考慮了 2^k 個模型中的一部分，沒被考慮的模型可能更好。
4. 只用 t 比值決定加入或刪除，沒有考慮 s、R^2、調整 R^2 等其他統計量。

5. 這是一連串的檢定，最後模型的真正顯著水準比單次 t 檢定的顯著水準差。若每次加入都有 95% 的把握是對的，兩次都對的機率就低於 95%。
6. 變數一個一個加入，沒有考慮兩個變數**一起**加入的效果（例如第 5 章的抑制變數）。向後法因為一開始所有變數都在模型裡，比較能顧到聯合效果。
7. 自動化程序不會用到研究者的額外知識。例如研究者可能知道 2015 年發生了特殊事件，那一年的資料不尋常。



資料窺探的模擬：$n = 50$ 筆，y 和 30 個候選變數**完全無關**。(a) 2,000 次模擬中，把 30 個變數各自和 y 做簡單迴歸，取最顯著的那一個，它的 p 值有 79% 的時候小於 0.05（若變數彼此獨立，理論值 $1 - 0.95^{30} = 79\%$）。(b) 用向前逐步一路選入 12 個變數：訓練資料的 R^2 一路升到 0.5，調整 R^2 也升到 0.35，但模型在新資料上的 R^2 一路變負，比直接猜平均還差。

這一節的精選習題

★ 精選 **第 7.1 題** ・講義 p.115・回到對應概念

A least squares model is fitted to 62 observations. 22 different predictors are considered. The best predictors are selected using backward stepwise selection.

Determine the number of models that are fitted.

中文題意

以 62 筆觀察配適最小平方模型，考慮 22 個不同的預測變數，用向後逐步選擇挑出最佳的預測變數。求共配適幾個模型。

答案

254 個

解析

先配適完整模型（1 個），接著拿掉 1 個變數的模型 22 個、再拿掉 1 個的 21 個、.....，最後只剩一個變數時拿掉它得到只有截距的模型（1 個）：

$$1+\sum_{i=1}^{22} i = 1+\frac{22(23)}{2} = 1+253 = 254.$$

$n = 62 > k = 22$，完整模型可以配適，向後法可行。

易錯

別忘了起點的那 1 個模型（完整模型）。

★ 精選 **第 7.3 題** ・講義 p.115・回到對應概念

A normal linear model is fitted to 30 observations. The model has the following predictors:

- AGE: Categorical variable with categories "Under 30", "30 to 39", "40 to 49", "50 to 59", "60 and over"
- SEX: Male or female
- BLOOD PRESSURE: Real-valued variable
- NUMBER OF CHILDREN: Integer-valued variable

The best predictors are selected using forward stepwise selection. Determine the number of models that are fitted.

中文題意

以 30 筆觀察配適常態線性模型，預測變數為：AGE（類別：未滿 30、30～39、40～49、50～59、60 以上）、SEX（男或女）、BLOOD PRESSURE（實數）、NUMBER OF CHILDREN（整數）。用向前逐步選擇挑出最佳預測變數。求共配適幾個模型。

答案

29 個

解析

第一步：換算成參數個數。 AGE 有 5 類，需要 4 個指標；SEX 1 個；血壓 1 個；子女數 1 個；共 $k = 7$。

第二步：計數。 只有截距的模型 1 個，接著依序考慮 7、6、5、4、3、2、1 個加入的候選：

$$1 + \sum_{j=0}^{6} (7 - j) = 1 + \frac{7(8)}{2} = 29.$$

$n = 30$ 足夠配適全部 7 個變數。

易錯

把 AGE 當成 1 個變數會得到 $1+4(5)/2=11$。逐步法一次加入一個**參數**（指標），不是一整個類別變數。

★ 精選 **第 7.5 題** ・講義 p.116・回到對應概念

For a normal linear model based on 26 observations, 100 predictors are under consideration. The best predictors are selected using forward stepwise selection.

Determine the number of models that are fitted.

中文題意

常態線性模型以 26 筆觀察為基礎，考慮 100 個預測變數，用向前逐步選擇。求共配適幾個模型。

答案

2,201 個

解析

最多能做到幾個變數。 有截距時，26 筆觀察最多支撐 26 個係數，也就是 25 個預測變數（$\mathcal{M}_{n-1}=\mathcal{M}_{25}$）；再多，$X$ 的欄就不可能線性獨立。

計數。 只有截距 1 個；第 1 步 100 個候選；第 2 步 99 個；.....；第 25 步 $100-24=76$ 個。等差數列的和是首末項平均乘項數：

$$1+\sum_{j=0}^{24}(100-j)=1+\frac{(100+76)(25)}{2}=1+2200=2201.$$

易錯

不能套 $1+k(k+1)/2=5051$；$n<k$ 時向前法在 $n-1$ 個變數就停了。

★ 精選 **第 7.7 題** ・講義 p.116・回到對應概念

Use the following information for questions 7.7 through 7.9: Least squares models are constructed from subsets of four variables $\{X_1, X_2, X_3, X_4\}$. The residual sum of squares (RSS) from each model is:

Variables	RSS	Variables	RSS	Variables	RSS	Variables	RSS
X_1	152	X_1, X_2	118	X_2, X_4	122	X_1, X_3, X_4	101
X_2	145	X_1, X_3	144	X_3, X_4	135	X_2, X_3, X_4	107
X_3	160	X_1, X_4	129	X_1, X_2, X_3	110	X_1, X_2, X_3, X_4	85
X_4	138	X_2, X_3	131	X_1, X_2, X_4	105	None	258

Which three variable model is selected by best subset selection?

中文題意

（7.7～7.9 共用）以四個變數 $\{X_1, X_2, X_3, X_4\}$ 的子集建立最小平方模型，各模型的 RSS：

最佳子集選擇選出的三變數模型是哪一個？

（數據、圖表與選項見上方英文題目。）

答案

$\{X_1, X_3, X_4\}$

解析

最佳子集直接比較所有三變數模型的 RSS：$\{X_1, X_2, X_3\}$ 110、$\{X_1, X_2, X_4\}$ 105、$\{X_1, X_3, X_4\}$ 101、$\{X_2, X_3, X_4\}$ 107。最小的是 101。三種方法的路徑見 7.1 節的圖。

★ 精選 **第 7.8 題** ・講義 p.116・回到對應概念

(Continuation of 7.7) Which three variable model is selected by forward stepwise selection?

中文題意

（接 7.7）向前逐步選擇選出的三變數模型是哪一個？

答案

$\{X_1, X_2, X_4\}$

解析

- 一個變數：RSS 最小的是 X_4（138）。
- 兩個變數，必須含 X_4：$\{X_1, X_4\}$ 129、$\{X_2, X_4\}$ 122、$\{X_3, X_4\}$ 135，選 $\{X_2, X_4\}$。
- 三個變數，必須含 X_2, X_4：$\{X_1, X_2, X_4\}$ 105、$\{X_2, X_3, X_4\}$ 107，選 $\{X_1, X_2, X_4\}$。

它不是最佳的三變數模型（101），因為向前法第一步選了 X_4 之後，第二步沒選到含 X_1, X_3 的組合。

易錯

第二步不能直接選全部兩變數模型中最好的 $\{X_1, X_2\}$（118）：它不含已經選入的 X_4。

觀念題（6 題，仿 SOA 樣題的質性題，含跨章節）

觀念 **觀念題 C7.1-1** 仿 SOA 樣題・回到本節開頭

There are k candidate explanatory variables. Determine which of the following statements is/are true.

I. Best subset selection fits 2^k models.

II. Forward stepwise selection fits $1 + k(k+1)/2$ models when $n > k$.

III. Forward stepwise selection is guaranteed to find, for each model size, the model with the lowest RSS.

(A) III only

(B) I and II only

(C) I and III only

(D) II and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

有 k 個候選變數。下列哪些正確？

I. 最佳子集配適 2^k 個模型。

II. $n > k$ 時向前逐步配適 $1 + k(k+1)/2$ 個模型。

III. 向前逐步保證在每個大小都找到 RSS 最低的模型。

答案

(B)：只有 I、II 正確

解析

I、II 對（第 7 章 7.1 節）。

III 錯：向前逐步是貪婪演算法，第一步選錯之後就回不去（第 7 章 7.1 節的圖與習題 7.8）。

觀念 **觀念題 C7.1-2** 仿 SOA 樣題・回到本節開頭

A data set has $n = 30$ observations and $k = 50$ candidate predictors. Determine which of the following statements is/are true.

I. Forward stepwise selection can be used, producing models with up to $n - 1 = 29$ predictors.

II. Backward stepwise selection can be used.

III. Within best subset selection, models with different numbers of predictors can be compared directly by their RSS.

(A) I only

(B) II only

(C) III only

(D) I and II only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

$n = 30$ 筆觀察、$k = 50$ 個候選變數。下列哪些正確？

I. 可以用向前逐步，最多做到 $n - 1 = 29$ 個變數。

II. 可以用向後逐步。

III. 最佳子集中不同變數個數的模型可以直接比 RSS。

答案

(A)：只有 I 正確

解析

I 對：$\mathcal{M}_{n-1}$ 已經把 n 筆資料配到殘差為 0，再多就無法唯一估計（第 7 章習題 7.5）。

II 錯：向後法要從 50 個變數的完整模型開始，參數比資料多，無法配適。

III 錯：RSS 隨變數增加只減不增，不同大小要用交叉驗證或 C_p、AIC、BIC、調整 R^2。

觀念 **觀念題 C7.1-3** 仿 SOA 樣題・跨章：第 5 章・回到本節開頭

Determine which of the following statements is/are drawbacks of stepwise regression.

I. Fitting many models to the same data (data snooping) makes it likely that some model looks good by chance.
II. Stepwise regression considers the joint effect of adding two variables at the same time.
III. Automatic procedures ignore special knowledge that the investigator may have.

(A) II only
(B) III only
(C) I and II only
(D) I and III only
(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

下列哪些屬於逐步迴歸的缺點？

I. 對同一份資料配適大量模型（資料窺探），某些模型碰巧看起來很好。
II. 逐步迴歸考慮了同時加入兩個變數的聯合效果。
III. 自動化程序忽略研究者的特殊知識。

答案

(D)：只有 I、III 正確

解析

I、III 是缺點 1 與 7。

II 說反了：缺點 6 正是逐步法一次只加一個變數，**忽略**聯合效果（例如抑制變數，第 5 章 5.3 節）。

觀念 **觀念題 C7.1-4** 仿 SOA 樣題・跨章：第 2 章・回到本節開頭

A categorical variable with 4 levels is among the candidate variables in forward stepwise selection. Determine which of the following statements is/are true.

I. Each of its 3 indicator variables may enter the model separately.

II. Levels whose indicators are not selected are effectively merged into the base level.

III. When counting the number of models fitted, the variable counts as 3 candidate parameters.

(A) III only

(B) I and II only

(C) I and III only

(D) II and III only

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

4 個水準的類別變數是向前逐步的候選。下列哪些正確？

I. 它的 3 個指標可以分別進入模型。

II. 指標沒被選入的水準，實際上併入基準水準。

III. 計算配適的模型數時，它算 3 個候選參數。

答案

(E)：I、II、III 都正確

解析

三者都對（第 7 章 7.1 節的車型例子與習題 7.3、7.4）。

觀念 **觀念題 C7.1-5** 仿 SOA 樣題・回到本節開頭

Determine which of the following statements about mixed (hybrid) stepwise selection is/are true.

I. A variable that has entered the model may later be removed.

II. One version removes the variable with the lowest t ratio below a threshold; another version removes the variable with the highest p-value above a threshold.

III. Mixed selection examines all 2^k possible models.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

關於混合式逐步選擇，下列哪些正確？

I. 已進入模型的變數之後可能被移除。

II. 一種做法移除 t 比低於門檻中最低者，另一種移除 p 值高於門檻中最高者。

III. 混合法檢查所有 2^k 個模型。

答案

(A)：只有 I、II 正確

解析

I、II 對（第 7 章 7.1 節）。III 錯：混合法仍是逐步加減，只走過一條路徑上的模型。

觀念 **觀念題 C7.1-6** 仿 SOA 樣題・跨章：第 3 章・回到本節開頭

Determine which of the following statements is/are true.

I. Among models with the same number of predictors, the model with the lowest RSS also has the highest R^2.

II. RSS can be used to compare models with different numbers of predictors, since a lower RSS always indicates a better model.

III. A model with $d+1$ predictors can have a larger RSS than a model with d predictors if the two models are not nested.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

下列哪些正確？

I. 變數個數相同時，RSS 最低的模型 R^2 也最高。

II. RSS 越低越好，所以可以比較不同變數個數的模型。

III. 兩個模型不巢狀時，$d+1$ 個變數的模型 RSS 可能比 d 個的大。

答案

(B)：只有 I、III 正確

解析

I 對：$R^2 = 1 - \text{RSS}/\text{TSS}$，TSS 相同。

II 錯：RSS 對大模型有利，無法反映預測能力。

III 對（例如習題 7.7 中 $\{X_1, X_3\}$ 的 144 比 X_4 的 138 大）。

7.2 選擇最佳模型

上面每種方法都替每個變數個數選出一個模型，接著要在這些大小不同的模型之間做選擇。有兩條路：

1. **交叉驗證**（第 6 章）：直接估計測試誤差。計算量大，但最準確，而且幾乎不需要假設。
2. **調整訓練誤差**：訓練資料上的 RSS 低估了測試誤差，用一個隨參數個數增加的懲罰把它「加回來」。C_p、AIC、BIC、調整 R^2 都屬於這一類。用這些統計量時，RSS 是用**全部資料**算的，不需要留出測試資料。

一、訓練誤差低估了多少

推導：期望的測試誤差平方和比 RSS 多 $2(d+1)\sigma^2$

固定 X，設 $\mathbf{y} = \boldsymbol{\mu} + \boldsymbol{\varepsilon}$，$\mathrm{Var}(\boldsymbol{\varepsilon}) = \sigma^2 I$。用 d 個變數加截距配適，帽子矩陣 H 的跡是 $d+1$（第 5 章）。$\boldsymbol{\mu}$ 不必在模型的欄位空間裡，也就是模型可以有偏差。

訓練誤差。 $\mathbf{y} - \hat{\mathbf{y}} = (I-H)\boldsymbol{\mu} + (I-H)\boldsymbol{\varepsilon}$，交叉項期望值為 0，

$$E(\mathrm{RSS}) = \|(I-H)\boldsymbol{\mu}\|^2 + \sigma^2 \operatorname{tr}(I-H) = \|(I-H)\boldsymbol{\mu}\|^2 + (n-d-1)\sigma^2.$$

測試誤差。 在同樣的 X 上重新抽一組獨立的反應 $\mathbf{y}^* = \boldsymbol{\mu} + \boldsymbol{\varepsilon}^*$，用原來的配適值預測：

$$\mathbf{y}^* - \hat{\mathbf{y}} = \boldsymbol{\varepsilon}^* + (I-H)\boldsymbol{\mu} - H\boldsymbol{\varepsilon},$$

三項兩兩的交叉期望值都是 0，

$$E\|\mathbf{y}^* - \hat{\mathbf{y}}\|^2 = n\sigma^2 + \|(I-H)\boldsymbol{\mu}\|^2 + \sigma^2 \operatorname{tr}(H) = \|(I-H)\boldsymbol{\mu}\|^2 + (n+d+1)\sigma^2.$$

相減。 偏差項 $\|(I-H)\boldsymbol{\mu}\|^2$ 剛好消掉：

$$E(\text{測試 SSE}) - E(\mathrm{RSS}) = 2(d+1)\sigma^2.$$

所以 $\dfrac{1}{n}\big(\mathrm{RSS} + 2(d+1)\hat{\sigma}^2\big)$ 是測試 MSE 的不偏估計（$\hat{\sigma}^2$ 不偏時）。每多一個參數，訓練誤差就多低估 $2\sigma^2$，這就是 C_p 與 AIC 懲罰項的來源。下面 C_p 的公式用 $2d\hat{\sigma}^2$（不算截距），只差一個所有模型共同的常數 $2\hat{\sigma}^2/n$，不影響比較。

二、Mallows 的 C_p

設完整模型有 k 個變數，用它估計誤差變異數：

$$\hat{\sigma}^2 = s^2 = \frac{\mathrm{RSS}_k}{n-k-1}.$$

考慮一個 d 個變數（$d < k$）的子模型，殘差平方和 RSS_d。James 等人的公式（考題寫 formula in James et al.）：

$$C_p = \frac{1}{n}\big(\mathrm{RSS}_d + 2d\hat{\sigma}^2\big) \qquad (7.2)$$

Frees 的公式（考題寫 formula in Frees）：

$$C_p = \frac{\mathrm{RSS}_d}{s^2} - n + 2d \qquad (7.1)$$

兩者看起來很不一樣，但選出的模型相同：(7.1) 去掉與模型無關的 $-n$，把 $2d$ 併進分數得 $\dfrac{\mathrm{RSS}_d + 2ds^2}{s^2}$；再把分母從 s^2 換成 n（兩者都與模型無關）就是 (7.2)。精確地說，(7.1) $= \dfrac{n}{s^2} \times$ (7.2) $- n$，是遞增的線性轉換，排序完全一樣。C_p **越小越好**。

> **C_p 裡的「p」數不數截距**
>
> Mallows 原始的定義是 $C_p = \mathrm{RSS}/s^2 - n + 2p$，$p$ 是係數個數（含截距），模型沒有偏差時 $E(C_p) \approx p$，所以常說「好的模型 C_p 接近 p」。習題解答把 p 當成**解釋變數個數**（習題 7.13 算出 -0.5）；若含截距則每個模型都多 2（變成 1.5）。兩種算法選出的模型一樣，只有數值不同。考試若要算數值，照題目指定的教科書公式。

若 $\hat{\sigma}^2$ 是 σ^2 的不偏估計，(7.2) 的 C_p 是測試 MSE 的不偏估計（上一小節的推導）。

三、AIC 與 BIC

線性迴歸最大化資料的概似。加入變數後，最大概似不可能下降（把新係數設為 0 就回到原模型的概似），幾乎一定會上升，不管新變數有沒有意義。所以直接比概似不行。後面會學到**概似比檢定**（likelihood ratio test），它替「加入變數」設門檻，但只能比較**巢狀**模型。

赤池資訊準則（Akaike information criterion，AIC）與**貝氏資訊準則**（Bayesian information criterion，BIC）是加上懲罰的負對數概似，可以比較**任何**模型，不論是否巢狀。令 l 為最大對數概似、p 為估計的參數個數：

$$\mathrm{AIC} = -2l + 2p, \qquad \mathrm{BIC} = -2l + p \ln n.$$

兩者都**越小越好**。BIC 每個參數的懲罰 $\ln n$ 在 $n \geq 8$ 時就大於 AIC 的 2（$e^2 \approx 7.39$），所以 BIC 選出的模型通常變數比較少。

推導：用各模型自己的 s^2 的線性迴歸 AIC（7.3，Frees 的公式）

k 個解釋變數、常態誤差 $N(0,\sigma^2)$ 的線性迴歸，n 筆觀察的概似是

$$L=\prod_{i=1}^{n}\frac{1}{\sigma\sqrt{2\pi}}\exp\left(-\frac{(y_i-\sum_j\beta_j x_{ij})^2}{2\sigma^2}\right).$$

取對數：

$$l=\ln L=-\frac{\sum_i(y_i-\sum_j\beta_j x_{ij})^2}{2\sigma^2}-n\ln\sigma-n\ln\sqrt{2\pi}.$$

在最小平方估計處，分子就是 RSS，所以

$$-2l=\frac{\mathrm{RSS}}{\sigma^2}+2n\ln\sigma+2n\ln\sqrt{2\pi}=\frac{\mathrm{RSS}}{\sigma^2}+n\ln\sigma^2+n\ln(2\pi).$$

用通常的 $s^2=\mathrm{RSS}/(n-k-1)$ 代替 σ^2，第一項變成 $n-k-1$：

$$-2l=n\ln s^2+n\ln(2\pi)+n-k-1.$$

參數有 $k+1$ 個 β，再加上 σ^2，共 $k+2$ 個，所以加上 $2(k+2)$：

$$\mathrm{AIC}=n\ln s^2+n\ln(2\pi)+n+k+3 \qquad (7.3)$$

比較模型時 $n\ln(2\pi)$ 與 $n+3$ 都是常數，剩下 $n\ln s^2+k$：AIC 在「s^2 下降」與「變數增加」之間取捨。對應的 BIC 只要把懲罰 $2(k+2)$ 換成 $(k+2)\ln n$（習題 7.26）。

James 等人的做法不同：它不用每個模型自己的 s^2，而是像 C_p 一樣用**完整模型**（full model）的 $\hat\sigma^2$ 當作已知的 σ^2。這樣 $n\ln\hat\sigma^2$、$n\ln(2\pi)$ 都是常數，可以丟掉，剩下 $\mathrm{RSS}/\hat\sigma^2$。加上每個參數 2（AIC）或 $\ln n$（BIC）的懲罰，再用變數個數 d 代替參數個數，再整個乘上 $\hat\sigma^2/n$：

$$\mathrm{AIC}=\frac{1}{n}\left(\mathrm{RSS}+2d\hat\sigma^2\right) \qquad (7.4)$$

$$\mathrm{BIC}=\frac{1}{n}\left(\mathrm{RSS}+(\ln n)\,d\hat\sigma^2\right) \qquad (7.5)$$

所以 (7.4) 的 AIC 和 (7.2) 的 C_p **完全相同**，選出的模型也相同；BIC 對加入參數的懲罰較重。考題若要算 AIC 或 BIC，會說明用哪個公式；最可能考的是「$-2l$ 加上 $2p$ 或 $p\ln n$」。

四、調整 R^2

$$\text{調整 } R^2 = 1 - \frac{\mathrm{RSS}_d/(n-d-1)}{\mathrm{TSS}/(n-1)} \qquad (7.6)$$

有時記為 R^2_a。分母 $\mathrm{TSS}/(n-1)$ 和模型無關，分子就是模型的 s^2，所以**調整 R^2 最大，等價於 s^2 最小**。d 增加時 $n-d-1$ 變小，分子變大，調整 R^2 變小，所以 RSS 必須下降得夠多，才值得多加一個變數。用 R^2 表示：

$$\text{調整 } R^2 = 1 - \left(\frac{\mathrm{RSS}_d}{\mathrm{TSS}}\right)\left(\frac{n-1}{n-d-1}\right) = 1 - (1-R^2)\left(\frac{n-1}{n-d-1}\right) \qquad (7.7)$$

調整 R^2 可能是負的（習題 7.34），而且 **越大越好**，和 C_p、AIC、BIC 相反。C_p、AIC、BIC 都有以大樣本為基礎的理論根據；調整 R^2 則是比較隨意（ad hoc）的指標，沒有強的理論支持。

推導：每個準則「多加一個變數」的門檻

在 d 個變數的模型上多加一個變數，RSS 減少 $\Delta = \mathrm{RSS}_d - \mathrm{RSS}_{d+1}$。新變數的 t 統計量滿足（第 4 章的部分 F，分子自由度 1）

$$t^2 = F = \frac{\Delta}{\mathrm{RSS}_{d+1}/(n-d-2)} = \frac{\Delta}{s^2_{d+1}}.$$

調整 R^2：上升 $\Leftrightarrow$ s^2 下降 $\Leftrightarrow$ $\dfrac{\mathrm{RSS}_{d+1}}{n-d-2} < \dfrac{\mathrm{RSS}_{d+1}+\Delta}{n-d-1}$。兩邊乘開：$(n-d-1)\mathrm{RSS}_{d+1} < (n-d-2)\mathrm{RSS}_{d+1} + (n-d-2)\Delta$，即 $\mathrm{RSS}_{d+1} < (n-d-2)\Delta$，也就是

$$t^2 > 1.$$

C_p 與 (7.4) 的 AIC：下降 $\Leftrightarrow$ $\Delta > 2\hat\sigma^2$。**BIC**：下降 $\Leftrightarrow$ $\Delta > (\ln n)\hat\sigma^2$。若 $\hat\sigma^2 \approx s^2_{d+1}$，這兩個條件分別約等於 $t^2 > 2$ 與 $t^2 > \ln n$。

準則	加入一個變數的條件（約略）	方向
調整 R^2	$t^2 > 1$	越大越好，最寬鬆，傾向選大模型
C_p／AIC	$\Delta\text{RSS} > 2\hat{\sigma}^2$，約 $t^2 > 2$	越小越好
BIC	$\Delta\text{RSS} > (\ln n)\hat{\sigma}^2$，約 $t^2 > \ln n$	越小越好，$n = 100$ 時約 $t^2 > 4.6$，最嚴格
5% 的 t 檢定	$t^2 > t^2_{0.025} \approx 4$	作為對照

例題 7A

30 筆觀察、5 個參數（含截距）的線性模型，RSS 為 100，反應變數的不偏樣本變異數為 40，迴歸的殘差變異數為 10。用 James 等人的公式求 C_p、AIC、BIC 與調整 R^2。

$d = 4$ 個變數，$\hat{\sigma}^2 = 10$。

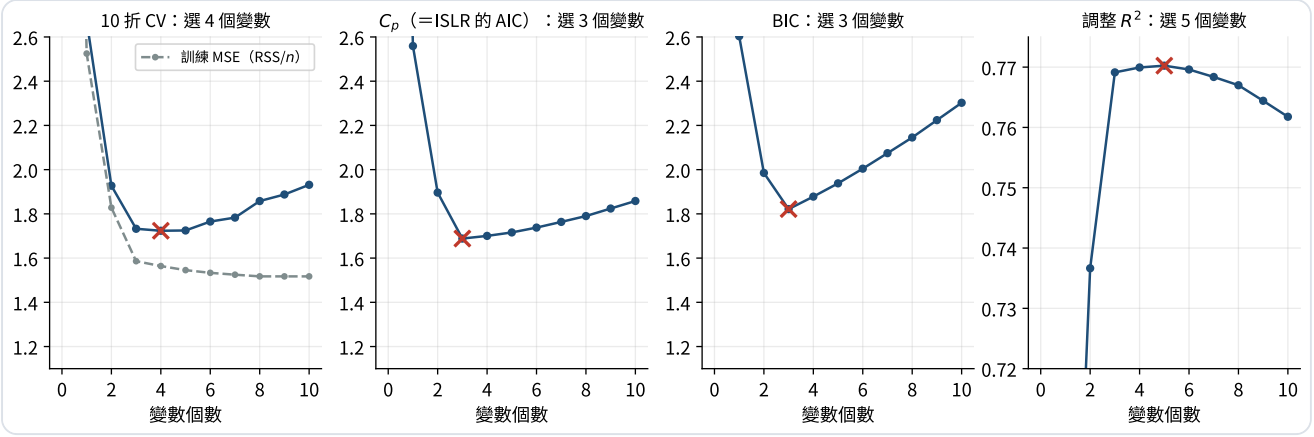
$$C_p = \frac{1}{30}\big(100 + 2(4)(10)\big) = \frac{180}{30} = 6, \qquad \text{AIC} = C_p = 6,$$

$$\text{BIC} = \frac{1}{30}\big(100 + (\ln 30)(4)(10)\big) = \frac{100 + 136.05}{30} = 7.868.$$

TSS$/(n-1)$ 就是反應的樣本變異數 40，所以

$$\text{調整 } R^2 = 1 - \frac{100/(30-4-1)}{40} = 1 - \frac{4}{40} = 0.9.$$

五、用哪一個



模擬：$n = 100$、10 個候選變數（彼此有相關），真正有用的只有 3 個。對每個大小做最佳子集選擇，再用各準則挑大小。訓練 MSE（灰虛線）隨變數個數一路下降。10 折 CV 選 4 個、C_p（即 (7.4) 的 AIC）與 BIC 都選 3 個、調整 R^2 選 5 個。調整 R^2 的曲線在 3 到 7 個變數之間非常平，懲罰最輕，所以傾向選比較大的模型。

- C_p、AIC、BIC 都要估計 σ^2，而且要知道模型的參數個數；交叉驗證兩者都不需要，適用範圍最廣，也最準確，只是計算量大。
- 交叉驗證曲線常常在最低點附近很平。常用**一個標準誤法則**（one-standard-error rule）：先算出每個大小的 CV 估計與它的標準誤，在「CV 值不超過最低點加一個標準誤」的模型中，選最簡單的那個。

考試技巧

- **方向**：C_p、AIC、BIC 越小越好；R^2、調整 R^2 越大越好。
- **同樣大小的模型**比 RSS 或 R^2 就夠了，所有準則的懲罰都相同（習題 7.19 的 II、7.21、7.23）。
- **AIC／BIC 的參數個數**：線性迴歸要算截距與 σ^2，$p = k + 2$；題目直接給「參數個數」或「使用的自由度」時照題目。
- 從 AIC 換算 BIC：減掉 $2p$、加上 $p \ln n$。
- 調整 R^2 的 $n - 1$ 可以從 ANOVA 表的自由度相加得到：迴歸自由度 $+$ 誤差自由度 $= n - 1$。
- 計算模型個數時，先把類別變數換成指標個數；最佳子集 2^k，逐步法 $1 + k(k+1)/2$；n 不夠大時向前法只能做到 $n - 1$ 個變數。

本章公式總表

- 向前／向後逐步的模型個數：$1+k(k+1)/2$；最佳子集：2^k。
- C_p（James 等人）：$\frac{1}{n}\left(\mathrm{RSS}_d+2d\hat{\sigma}^2\right)$ (7.2)；C_p（Frees）：$\frac{\mathrm{RSS}_d}{s^2}-n+2d$ (7.1)。$\hat{\sigma}^2=s^2$ 取自完整模型。
- 一般的 AIC：$-2l+2p$；一般的 BIC：$-2l+p\ln n$（p 為參數個數）。
- 線性迴歸的 AIC（James 等人）：$\frac{1}{n}\left(\mathrm{RSS}_d+2d\hat{\sigma}^2\right)$ (7.4)；（Frees）：$n\ln s^2+n\ln(2\pi)+n+k+3$ (7.3)。
- 線性迴歸的 BIC（James 等人）：$\frac{1}{n}\left(\mathrm{RSS}_d+(\ln n)d\hat{\sigma}^2\right)$ (7.5)。
- 調整 R^2：$1-\frac{\mathrm{RSS}_d/(n-d-1)}{\mathrm{TSS}/(n-1)}=1-(1-R^2)\frac{n-1}{n-d-1}$ (7.6) (7.7)。

這一節的精選習題

★ 精選 **第 7.11 題** ・講義 p.118・回到對應概念

[MAS-I-F18:31] An actuary fits two GLMs, M_1 and M_2, to the same data in order to predict the probability of a customer purchasing an automobile insurance product. You are given the following information about each model:

Model	Explanatory Variables Included in Model	Degrees of Freedom Used	Log Likelihood
M_1	Offered Price; Number of Vehicles; Age of Primary Insured; Prior Insurance Carrier	10	$-11{,}565$
M_2	Offered Price; Number of Vehicles; Age of Primary Insured; Gender of Primary Insured; Credit Score of Primary Insured	8	$-11{,}562$

The actuary wants to evaluate which of the two models is superior. Determine which of the following is the best course of action for the actuary to take.

(A) Perform a likelihood ratio test

(B) Compute the F statistic and perform an F-test

(C) Compute and compare the deviances of the two models

(D) Compute and compare the AIC statistics of the two models

(E) Compute the Chi-squared statistic and perform a Chi-squared test

中文題意

（MAS-I 2018 秋 #31）精算師對同一份資料配適兩個 GLM，M_1 與 M_2，預測顧客購買汽車保險的機率：

精算師想判斷哪個模型較好。最好的做法是：

(A) 概似比檢定　(B) 算 F 統計量做 F 檢定　(C) 計算並比較兩個模型的離差（deviance）　(D) 計算並比較兩個模型的 AIC　(E) 算卡方統計量做卡方檢定

（數據、圖表與選項見上方英文題目。）

答案

(D)

解析

兩個模型**不巢狀**：M_2 沒有 M_1 的「前一家保險公司」，又多了 M_1 沒有的兩個變數。概似比檢定與離差的比較只適用於巢狀模型，(A)、(C) 不行；F 檢定是線性模型用的，(B) 不行；(E) 與此無關。AIC 可以比較任何模型。

順便算出來：$\text{AIC}_1 = 2(11{,}565) + 2(10) = 23{,}150$，$\text{AIC}_2 = 2(11{,}562) + 2(8) = 23{,}140$，$M_2$ 較好（對數概似較高、參數又較少）。

★ 精選 **第 7.15 題** ・講義 p.119・回到對應概念

Various normal linear models are fitted to 60 observations. The models with the lowest residual sum of squares (RSS) for each fixed number of explanatory variables are:

Number of Explanatory Variables	0	1	2	3	4
Lowest RSS	326	314	303	293	284

Determine the number of explanatory variables in the model selected by Mallow's C_p.

中文題意

以 60 筆觀察配適多個常態線性模型。每個固定解釋變數個數下 RSS 最低的模型：

Mallows 的 C_p 選出的模型有幾個解釋變數？

（數據、圖表與選項見上方英文題目。）

答案

2 個

解析

完整模型是 4 個變數的那個：$\hat{\sigma}^2 = \dfrac{284}{60-5} = 5.163636$。用 James 等人的 $C_p = \frac{1}{60}(\mathrm{RSS}_d + 2d\hat{\sigma}^2)$：

d	$\mathrm{RSS}_d + 2d\hat{\sigma}^2$	C_p
0	326	5.4333
1	$314 + 10.327 = 324.327$	5.4055
2	$303 + 20.655 = 323.655$	5.3942
3	$293 + 30.982 = 323.982$	5.3997

d	$\text{RSS}_d + 2d\hat{\sigma}^2$	C_p
4	$284 + 41.309 = 325.309$	5.4218

最小的是 $d = 2$。

捷徑：多加一個變數的懲罰是 $2\hat{\sigma}^2 = 10.33$，RSS 下降超過 10.33 才值得。RSS 的下降依序是 12、11、10、9，前兩次超過、第三次（10）不到，所以停在 2。

易錯

$\hat{\sigma}^2$ 要用最大的模型，而且自由度是 $60 - 4 - 1 = 55$。

★ 精選 **第 7.16 題** ・講義 p.119・回到對應概念

In a linear model with an intercept, variables are selected using subset selection. The model is based on 100 observations. The total sum of squares is 4184. The RSS when all 15 predictors are included in the model is 252. Mallow's C_p is used to select the best model among models with different numbers of predictors.

- The RSS for the best model with 5 predictors is 474.
- The RSS for the best model with 6 predictors is less than x.
- The model with 6 predictors is selected.

Determine the highest possible value for x.

(A) 422

(B) 430

(C) 442

(D) 454

(E) 468

中文題意

有截距的線性模型用子集選擇挑變數，以 100 筆觀察為基礎。總平方和為 4184，15 個預測變數全部放入時 RSS 為 252。用 Mallows 的 C_p 在不同變數個數的模型中選擇。5 個預測變數的最佳模型 RSS 為 474；6 個預測變數的最佳模型 RSS 小於 x；結果選中 6 個預測變數的模型。求 x 最大可能值。

(A) 422　(B) 430　(C) 442　(D) 454　(E) 468

答案

(E) 468

解析

用哪個 C_p 公式都一樣。用 Frees 的 $C_p = \mathrm{RSS}_d/s^2 - n + 2d$：$d$ 加 1，懲罰項增加 2，所以 RSS/s^2 必須減少超過 2，即 RSS 必須減少超過 $2s^2$。

s^2 來自全部 15 個變數的模型：$s^2 = \dfrac{252}{100 - 15 - 1} = 3$，所以 RSS 必須減少超過 6：

$$\mathrm{RSS}_6 < 474 - 6 = 468.$$

易錯

總平方和 4184 用不到；s^2 用完整模型而不是 5 或 6 個變數的模型。

★ 精選 **第 7.23 題** ・講義 p.122・回到對應概念

[MAS-I-S19:39] Two actuaries were given a dataset and asked to build a model to predict claim frequency using any of 5 independent predictors $\{1, 2, 3, 4, 5\}$ as well as an intercept $\{I\}$.

- Actuary A chooses their model using Best Subset Selection
- Actuary B chooses their model using Forward Stepwise Regression
- Actuary C chooses their model using Backwards Stepwise Regression
- When evaluating the models they all used R-squared to compare models with the same number of parameters, and AIC to compare models with different numbers of parameters.

The models, their parameters and R^2 are the same as in question 7.21; the AIC of each model is:

Model	1	2	3	4	5	6	7	8	9	10	11	12	13	
AIC	1.9	1.4	1.2	1.6	1.7	1.8	1.0	0.5	0.8	0.0	1.0	0.9	0.2	

Model	17	18	19	20	21	22	23	24	25	26	27	28	29	
AIC	1.3	1.5	1.4	1.0	0.8	0.2	0.6	1.2	1.1	1.3	1.6	2.1	1.8	

AIC_j is the AIC of the model chosen by Actuary j. Determine the correct ordering of the AIC values of the three selected models.

(A) $\text{AIC}_A < \text{AIC}_B < \text{AIC}_C$

(B) $\text{AIC}_A = \text{AIC}_B < \text{AIC}_C$

(C) $\text{AIC}_A < \text{AIC}_C < \text{AIC}_B$

(D) $\text{AIC}_A = \text{AIC}_C < \text{AIC}_B$

(E) The answer is not given by (A), (B), (C), or (D)

> **中文題意**

（MAS-I 2019 春 #39）同 7.21 的設定，但多了精算師 C 用向後逐步迴歸。三人都用 R^2 比較參數個數相同的模型、用 AIC 比較參數個數不同的模型。所有模型的 R^2 與 7.21 相同，AIC 如下：

AIC_j 是精算師 j 所選模型的 AIC。三個 AIC 的正確排序是：

(A) $\text{AIC}_A < \text{AIC}_B < \text{AIC}_C$　(B) $\text{AIC}_A = \text{AIC}_B < \text{AIC}_C$　(C) $\text{AIC}_A < \text{AIC}_C < \text{AIC}_B$　(D) $\text{AIC}_A = \text{AIC}_C < \text{AIC}_B$　(E) 以上皆非

（數據、圖表與選項見上方英文題目。）

答案

(A) $0 < 0.2 < 0.4$

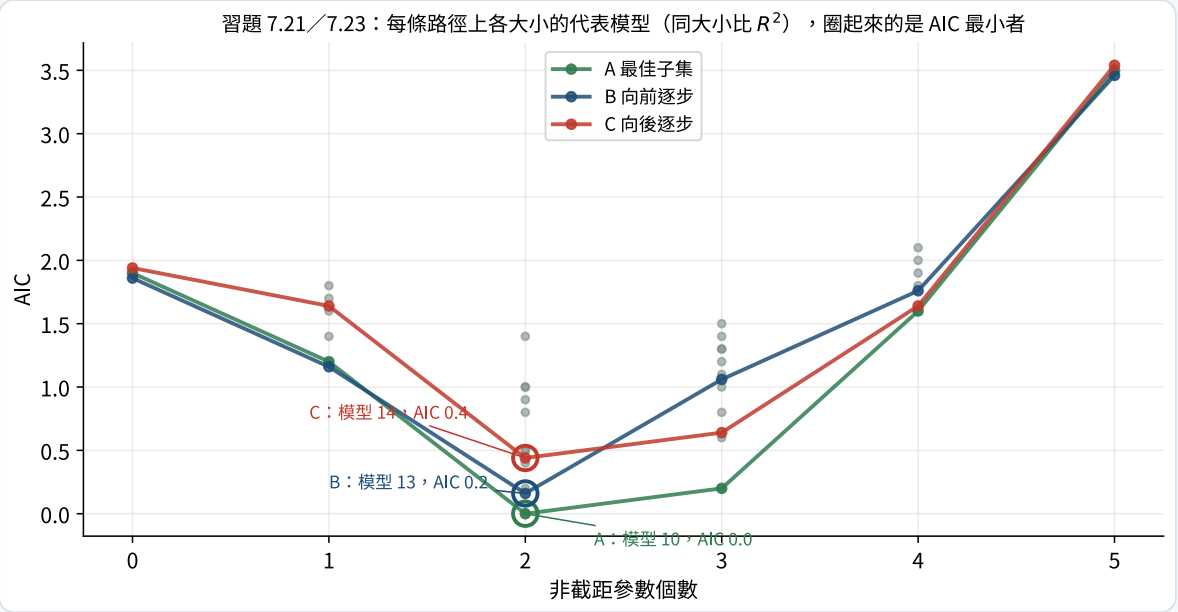
解析

A（最佳子集）：各大小 R^2 最高的模型 1、3、10、22、27、32，AIC 1.9、1.2、0.0、0.2、1.6、3.5，選模型 10，$\text{AIC}_A = 0$。

B（向前）：路徑 1 → 3 → 13 → 25 → 29 → 32（同 7.21），AIC 1.9、1.2、0.2、1.1、1.8、3.5，選模型 13，$\text{AIC}_B = 0.2$。

C（向後）：從模型 32 開始。 - 拿掉一個：四變數模型 27～31 中 R^2 最高的是 27（I,1,2,3,4，0.88），即拿掉 5。 - 在 $\{1,2,3,4\}$ 中拿掉一個：模型 17（0.73）、18（0.71）、20（0.75）、23（0.78），選 23（I,2,3,4），即拿掉 1。 - 在 $\{2,3,4\}$ 中拿掉一個：模型 11（0.61）、12（0.62）、14（0.66），選 14（I,3,4）。 - 在 $\{3,4\}$ 中拿掉一個：模型 4（0.55）、5（0.52），選 4。 - 最後模型 1。

路徑 32 → 27 → 23 → 14 → 4 → 1 的 AIC 為 3.5、1.6、0.6、0.4、1.6、1.9，選模型 14，$\text{AIC}_C = 0.4$。



三條路徑在各大小選到的代表模型及其 AIC。三人都在兩個非截距參數的地方停下，但因為路徑不同，選到的是三個不同的模型：A 的模型 10（I,1,5）、B 的模型 13（I,2,5）、C 的模型 14（I,3,4）。

易錯

向後法每一步只能從**目前模型**拿掉一個變數，不能跳到別的組合；在每一步比的是 R^2 不是 AIC。

★ 精選 **第 7.34 題** ・講義 p.124・回到對應概念

For a linear regression model $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \beta_4 x_{i4} + \varepsilon_i$ with 9 observations you are given that $s^2 = 20$. The values of $\hat{y}_i$ are 1, 2, 3, 4, 5, 6, 7, 8, 9.

Determine adjusted R^2.

中文題意

9 筆觀察的線性迴歸 $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \beta_4 x_{i4} + \varepsilon_i$，已知 $s^2 = 20$，配適值 $\hat{y}_i$ 為 1、2、3、4、5、6、7、8、9。求調整 R^2。

答案

調整 $R^2 = -1/7 = -0.1429$

解析

Error SS：$d = 4$，誤差自由度 $9 - 5 = 4$，Error SS $= 20(4) = 80$。

Regression SS：有截距時 $\bar{\hat{y}} = \bar{y}$（殘差和為 0），$\bar{\hat{y}} = 5$，所以

$$\text{Regression SS} = \sum (\hat{y}_i - \bar{y})^2 = 16 + 9 + 4 + 1 + 0 + 1 + 4 + 9 + 16 = 60.$$

TSS $= 140$，$R^2 = 60/140 = 3/7$。

$$\text{調整 } R^2 = 1 - \left(1 - \frac{3}{7}\right) \frac{9 - 1}{9 - 4 - 1} = 1 - \frac{4}{7} \cdot 2 = -\frac{1}{7}.$$

調整 R^2 可以是負的：模型的 $s^2 = 20$ 比反應本身的樣本變異數 $140/8 = 17.5$ 還大，表示這 4 個變數比直接用 $\bar{y}$ 預測還差。

易錯

Regression SS 是配適值對**平均**的離差平方和，不是 $\sum \hat{y}_i^2$；不要以為調整 R^2 一定在 0 與 1 之間。

觀念題（6 題，仿 SOA 樣題的質性題，含跨章節）

觀念 **觀念題 C7.2-1** 仿 SOA 樣題・跨章：第 6 章・回到本節開頭

[Modeled on SRM Sample #61] Determine which of the following statements is/are true.

I. Adjusted R^2, like AIC and BIC, has a strong theoretical justification based on asymptotic arguments.

II. Cross-validation provides a direct estimate of the test error.

III. C_p, AIC, and BIC estimate the test error indirectly, by adjusting the training error for model size.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

下列哪些正確？

I. 調整 R^2 和 AIC、BIC 一樣，有大樣本理論的強力支持。

II. 交叉驗證直接估計測試誤差。

III. C_p、AIC、BIC 依模型大小調整訓練誤差，間接估計測試誤差。

答案

(C)：只有 II、III 正確

解析

I 錯：調整 R^2 是比較隨意（ad hoc）的指標，沒有強的理論根據。

II、III 對（第 7 章 7.2 節、習題 7.19）。

觀念 **觀念題 C7.2-2** 仿 SOA 樣題・回到本節開頭

Determine which of the following statements is/are true.

I. BIC penalizes each parameter by $\ln n$.

II. For $n \geq 8$, BIC tends to select models with fewer variables than AIC.

III. For least squares regression, the AIC formula of James et al. is identical to their C_p formula.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

下列哪些正確？

I. BIC 對每個參數罰 $\ln n$。

II. $n \geq 8$ 時 BIC 傾向選變數較少的模型。

III. 最小平方迴歸中，James 等人的 AIC 公式和 C_p 公式完全相同。

答案

(D)：I、II、III 都正確

解析

I 對。II 對：$\ln 8 = 2.08 > 2$。III 對：(7.2) 與 (7.4) 是同一個式子（第 7 章 7.2 節）。

觀念 **觀念題 C7.2-3** 仿 SOA 樣題・跨章：第 4 章・回到本節開頭

A single variable is added to a linear regression; let t be its t statistic in the larger model. Determine which of the following statements is/are true.

I. Adjusted R^2 increases if and only if $t^2 > 1$.

II. Among adjusted R^2, C_p, and BIC (with $n = 100$), adjusted R^2 is the most stringent criterion for adding a variable.

III. With $\hat{\sigma}^2$ fixed from the full model, C_p decreases if and only if the RSS decreases by more than $2\hat{\sigma}^2$.

(A) III only

(B) I and II only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

加入一個變數，t 為它在大模型中的 t 統計量。下列哪些正確？

I. 調整 R^2 上升若且唯若 $t^2 > 1$。

II. 在調整 R^2、C_p、BIC（$n = 100$）中，調整 R^2 加入變數的標準最嚴格。

III. $\hat{\sigma}^2$ 取自完整模型固定不變時，C_p 下降若且唯若 RSS 減少超過 $2\hat{\sigma}^2$。

答案

(E)：只有 I、III 正確

解析

I、III 對（第 7 章 7.2 節的門檻推導）。

II 錯：調整 R^2 最寬鬆（約 $t^2 > 1$）；C_p 約 $t^2 > 2$；$n = 100$ 的 BIC 約 $t^2 > 4.6$，最嚴格。

觀念 **觀念題 C7.2-4** 仿 SOA 樣題・跨章：第 11,14 章・回到本節開頭

Determine which of the following statements is/are true.

I. AIC can be used to compare models that are not nested.

II. A likelihood ratio test can be used to compare models that are not nested.

III. Without a penalty, comparing maximized loglikelihoods always favors the larger of two nested models.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

下列哪些正確？

I. AIC 可以比較不巢狀的模型。

II. 概似比檢定可以比較不巢狀的模型。

III. 沒有懲罰時，比較最大對數概似總是偏好兩個巢狀模型中較大的那個。

答案

(B)：只有 I、III 正確

解析

I 對（第 7 章習題 7.11）。II 錯：概似比檢定與離差比較需要巢狀（第 14 章）。III 對：大模型把多出來的係數設為 0 就回到小模型，最大概似不會更低。

觀念 **觀念題 C7.2-5** 仿 SOA 樣題・回到本節開頭

Determine which of the following statements is/are true.

I. Mallows' C_p uses an estimate of σ^2 from the full model with all candidate variables.

II. Computing C_p requires splitting the data into a training set and a validation set.

III. The Frees formula for the AIC of a linear regression uses each model's own residual variance s^2.

(A) I and II only

(B) I and III only

(C) II and III only

(D) I, II, and III

(E) The correct answer is not given by (A), (B), (C), or (D).

中文題意

下列哪些正確？

I. Mallows 的 C_p 用全部候選變數的完整模型估計 σ^2。

II. 計算 C_p 需要把資料分成訓練集與驗證集。

III. Frees 的線性迴歸 AIC 公式用每個模型自己的殘差變異數 s^2。

答案

(B)：只有 I、III 正確

解析

I 對。II 錯：C_p、AIC、BIC、調整 R^2 都用全部資料算 RSS，不需要留出驗證資料（第 7 章 7.2 節）。III 對：(7.3) 式 $n \ln s^2 + \cdots$。

觀念 **觀念題 C7.2-6** 仿 SOA 樣題・跨章：第 3 章・回到本節開頭

Determine which of the following statements about model selection criteria is NOT true.

(A) A lower C_p indicates a better model.

(B) A lower BIC indicates a better model.

(C) A higher adjusted R^2 indicates a better model.

(D) A higher AIC indicates a better model.

(E) For models with the same number of parameters, all of these criteria select the model with the lowest RSS.

中文題意

關於選模準則，下列哪一個**不正確**？

(A) C_p 越低越好。

(B) BIC 越低越好。

(C) 調整 R^2 越高越好。

(D) AIC 越高越好。

(E) 參數個數相同時，這些準則都選 RSS 最低的模型。

答案

(D)

解析

AIC 是負對數概似加懲罰，越**低**越好。(E) 對：參數個數相同時懲罰相同，只剩 RSS（或概似）在比較（第 7 章習題 7.19 的 II）。

章末其餘習題（25 題，★ 精選題已放在各節後面）

練習 **第 7.2 題** ・講義 p.115・回到對應概念

[SRM Sample Question #54] For a regression model of executive compensation, you are given:

(i) The following statistics:

Coefficients	Estimate	Std. Error	t-statistic	p-value
(INTERCEPT)	$-28{,}595.5$	220.5	-129.7	< 0.001
AGEMINUS35	7,366.3	12.5	588.1	< 0.001
TOPSCHOOL	50.0	119.7	0.4	0.676
LARGECITY	147.9	119.7	1.2	0.217
MBA	2,490.9	119.7	20.8	< 0.001
YEARSEXP	15,286.6	7.2	2132.8	< 0.001

(ii) The acceptable significance level is $\alpha = 0.10$.

Determine which variable or variables should be removed first prior to rerunning the model.

(A) (INTERCEPT)

(B) AGEMINUS35, MBA, and YEARSEXP

(C) TOPSCHOOL

(D) TOPSCHOOL and LARGECITY

(E) YEARSEXP

中文題意

（SRM 樣題 #54）高階主管薪酬的迴歸模型：

可接受的顯著水準為 $\alpha = 0.10$。重新配適模型之前，應先移除哪個（些）變數？

(A) 截距　(B) AGEMINUS35、MBA、YEARSEXP　(C) TOPSCHOOL　(D) TOPSCHOOL 與 LARGECITY　(E) YEARSEXP

（數據、圖表與選項見上方英文題目。）

答案

(C) TOPSCHOOL

解析

TOPSCHOOL（0.676）與 LARGECITY（0.217）的 p 值都超過 0.10。但向後刪除**一次只移除一個**，移除 p 值最大的 TOPSCHOOL，然後重新配適。一個看似不顯著的變數，可能在另一個變數移除後變得顯著（兩者相關時，係數與標準誤都會改變）。

易錯

(D) 一次刪兩個是常見的錯誤；截距通常不在刪除考慮之列。

練習 **第 7.4 題** ・講義 p.115・回到對應概念

A normal linear model is used to estimate the sales of oranges. The explanatory variables are various characteristics of the oranges:

- SIZE: Small, medium, large
- TYPE: Navel, temple, juice
- STATE: Florida, Arizona, California
- SEASON: Fall, winter, spring, summer

The best explanatory variables are selected using backward stepwise selection. Determine the number of models that are fitted.

中文題意

用常態線性模型估計柳橙的銷售量，解釋變數為柳橙的特徵：SIZE（小、中、大）、TYPE（臍橙、坦普橙、果汁橙）、STATE（佛羅里達、亞利桑那、加州）、SEASON（秋、冬、春、夏）。用向後逐步選擇挑出最佳解釋變數。求共配適幾個模型。

答案

46 個

解析

SIZE、TYPE、STATE 各 3 類，各需 2 個指標；SEASON 4 類需 3 個；共 $k = 2 + 2 + 2 + 3 = 9$。

$$1 + \sum_{j=0}^{8} (9 - j) = 1 + \frac{9(10)}{2} = 46.$$

練習 **第 7.6 題** ・講義 p.116・回到對應概念

[MAS-I-F19:40] You have $p = 10$ independent variables and would like to select a linear model to fit the data using the following two procedures:

- Best Subset Selection (BSS)
- Forward Stepwise Selection (FSS)

Let N_i be the maximum number of models fit by model selection procedure i. Calculate $\dfrac{N_{\text{FSS}}}{N_{\text{BSS}}}$.

(A) Less than 0.005

(B) At least 0.005, but less than 0.010

(C) At least 0.010, but less than 0.050

(D) At least 0.050, but less than 0.100

(E) At least 0.100

中文題意

（MAS-I 2019 秋 #40）有 $p = 10$ 個自變數，要用以下兩種程序選擇線性模型：最佳子集選擇（BSS）與向前逐步選擇（FSS）。令 N_i 為程序 i 最多要配適的模型數。求 $N_{\text{FSS}}/N_{\text{BSS}}$。

（數據、圖表與選項見上方英文題目。）

答案

(D) 0.0547

解析

BSS 考慮所有子集：每個變數放或不放，$2^{10} = 1024$ 個。FSS：$1 + 10 + 9 + \cdots + 1 = 1 + 55 = 56$ 個。比值 $56/1024 = 0.0547$。

練習 **第 7.9 題** ・講義 p.116・回到對應概念

(Continuation of 7.7) Which two variable model is selected by backward stepwise selection?

中文題意

（接 7.7）向後逐步選擇選出的兩變數模型是哪一個？

答案

$\{X_1, X_4\}$

解析

- 從四個變數（85）開始，拿掉一個：三變數模型中 RSS 最小的是 $\{X_1, X_3, X_4\}$（101），也就是拿掉 X_2。
- 從 $\{X_1, X_3, X_4\}$ 再拿掉一個：$\{X_1, X_3\}$ 144、$\{X_1, X_4\}$ 129、$\{X_3, X_4\}$ 135，選 $\{X_1, X_4\}$。

最佳的兩變數模型其實是 $\{X_1, X_2\}$（118），但 X_2 第一步就被拿掉了。三種方法在兩變數時選到三個不同的模型：最佳子集 $\{X_1, X_2\}$、向前 $\{X_2, X_4\}$、向後 $\{X_1, X_4\}$。

練習 **第 7.10 題** ・講義 p.117・回到對應概念

[MAS-I-F19:39] An actuary has a dataset with one dependent variable, Y, and five independent variables, $\{X_1, X_2, X_3, X_4, X_5\}$. She is trying to determine which subset of the predictors best fits the data, and is using a Forward Stepwise Selection procedure with no stopping rule. Below is a subset of the potential models:

Model	RSS	Independent variables (p-value)
1	9,823	X_1 (0.0430), X_2 (0.0096)
2	7,070	X_1 (0.0464), X_2 (0.0183), X_3 (0.0456)
3	6,678	X_1 (0.0412), X_2 (0.0138), X_4 (0.0254)
4	4,800	X_1 (0.0444), X_2 (0.0548), X_5 (0.0254)
5	3,475	$X_1, \ldots, X_5$

(Each model has dependent variable Y.) The procedure just selected Model 1 as the new candidate model. Determine which of the following independent variable(s) will be added to the model in the next iteration of this procedure.

(A) No variables will be added

(B) X_3 only

(C) X_4 only

(D) X_5 only

(E) X_3, X_4, and X_5

中文題意

（MAS-I 2019 秋 #39）精算師的資料有一個應變數 Y 與五個自變數 $\{X_1, \ldots, X_5\}$，用沒有停止規則的向前逐步選擇找最佳子集。部分候選模型：

程序剛選了模型 1 作為新的候選模型。下一步會加入哪個（些）自變數？

(A) 不加入　(B) 只有 X_3　(C) 只有 X_4　(D) 只有 X_5　(E) X_3, X_4, X_5

（數據、圖表與選項見上方英文題目。）

答案

(D) 只有 X_5

解析

向前逐步一次只加一個變數，(A)、(E) 都不對（題目說沒有停止規則，所以一定會加）。在模型 1 上分別加入 X_3, X_4, X_5 得到模型 2、3、4，選 RSS 最小的模型 4（4,800），也就是加入 X_5。

易錯

p 值與這一步無關：模型 4 中 X_2 的 p 值 0.0548 雖然變大，向前逐步仍然只看 RSS。模型 5 一次加了三個變數，不是這一步的候選。

練習 **第 7.12 題** ・講義 p.118・回到對應概念

Use the following information for questions 7.12 and 7.13: A normal linear model is fitted to 25 observations. The model has 4 explanatory variables and an intercept. The RSS is 132 and the estimated residual variance of the regression is 8.

Calculate Mallow's C_p using the formula in James et al.

中文題意

（7.12、7.13 共用）以 25 筆觀察配適常態線性模型，有 4 個解釋變數與截距，RSS 為 132，迴歸的估計殘差變異數為 8。用 James 等人（ISLR）的公式求 Mallows 的 C_p。

答案

$C_p = 7.84$

解析

$d = 4$，$\hat{\sigma}^2 = 8$（模型自己就是完整模型）：

$$C_p = \frac{1}{n}\left(\mathrm{RSS} + 2d\hat{\sigma}^2\right) = \frac{1}{25}\left(132 + 2(4)(8)\right) = \frac{196}{25} = 7.84.$$

檢查：$s^2 = 132/(25-5) = 6.6$，題目給的 8 和它不同，表示 8 來自另一個更大的完整模型；依題目用 8。

練習 **第 7.13 題** ・講義 p.118・回到對應概念

(Continuation of 7.12) Calculate Mallow's C_p using the formula in Frees.

中文題意

（接 7.12）用 Frees 的公式求 Mallows 的 C_p。

答案

$C_p = -0.5$（參考答案的算法）

解析

$$C_p = \frac{\text{RSS}}{s^2} - n + 2d = \frac{132}{8} - 25 + 2(4) = 16.5 - 25 + 8 = -0.5.$$

若依 Mallows 原始定義、p 算入截距（$p = 5$），則 $16.5 - 25 + 10 = 1.5$。兩種算法對所有模型差一樣的常數 2，選模型的結果相同（7.2 節的說明）。

練習 **第 7.14 題** ・講義 p.118・回到對應概念

A linear regression is fitted to 20 observations. The model has 5 explanatory variables and an intercept. The RSS is 84.

Calculate Mallow's C_p for the full model using the formula in James et al.

中文題意

以 20 筆觀察配適線性迴歸，模型有 5 個解釋變數與截距，RSS 為 84。用 James 等人的公式求完整模型的 Mallows C_p。

答案

$C_p = 7.2$

解析

完整模型自己估計 $\hat{\sigma}^2$：$s^2 = \dfrac{84}{20-5-1} = 6$。

$$C_p = \frac{1}{20}\big(84 + 2(5)(6)\big) = \frac{144}{20} = 7.2.$$

練習 **第 7.17 題** ・講義 p.119・回到對應概念

Various normal linear models are fitted to 29 observations. The models with the lowest residual sum of squares (RSS) for each fixed number of explanatory variables are:

Number of Explanatory Variables	0	1	2	3	4
Lowest RSS	162	145	140	136	132

Determine the number of explanatory variables in the model selected by Mallow's C_p.

中文題意

以 29 筆觀察配適多個常態線性模型。每個固定解釋變數個數下 RSS 最低的模型：

Mallows 的 C_p 選出的模型有幾個解釋變數？

（數據、圖表與選項見上方英文題目。）

答案

1 個

解析

$\hat{\sigma}^2 = \dfrac{132}{29-5} = 5.5$，懲罰 $2\hat{\sigma}^2 = 11$。

d	$C_p = \frac{1}{29}(\mathrm{RSS}_d + 11d)$
0	$162/29 = 5.586$
1	$156/29 = 5.379$
2	$162/29 = 5.586$
3	$169/29 = 5.828$

d	$C_p = \frac{1}{29}(\mathrm{RSS}_d + 11d)$
4	$176/29 = 6.069$

最小在 $d = 1$。捷徑：RSS 的下降 17、5、4、4，只有第一次超過 11。

練習 **第 7.18 題** ・講義 p.119・回到對應概念

For a linear regression model with 100 observations, you are given:

- The model has 10 variables and an intercept.
- The residual sum of squares is 64.8.
- The estimated variance of the residual term is 5.5.

Calculate AIC and BIC using the formulas in James et al.

中文題意

100 筆觀察的線性迴歸模型，有 10 個變數與截距，RSS 為 64.8，殘差項的估計變異數為 5.5。用 James 等人的公式求 AIC 與 BIC。

答案

AIC $= 1.748$，BIC $= 3.181$

解析

$$\mathrm{AIC} = \frac{1}{n}\left(\mathrm{RSS} + 2d\hat{\sigma}^2\right) = \frac{64.8 + 2(10)(5.5)}{100} = \frac{174.8}{100} = 1.748,$$

$$\mathrm{BIC} = \frac{1}{n}\left(\mathrm{RSS} + (\ln n)d\hat{\sigma}^2\right) = \frac{64.8 + 4.6052(10)(5.5)}{100} = \frac{64.8 + 253.28}{100} = 3.181.$$

練習 **第 7.19 題** ・講義 p.120・回到對應概念

[SRM Sample Question #61] A linear model has been fit to a dataset containing six predictor variables, F, G, H, I, J, and K. Determine which of the following statements regarding using Akaike information criterion (AIC) or Bayesian information criterion (BIC) to select an optimal set of predictor variables for this linear model is/are true.

I. AIC and BIC provide a direct estimate of the test error.

II. When choosing between the subsets F, G, H and I, J, K, AIC and BIC will always select the same subset.

III. For large sample sizes ($n > 7$), the number of variables selected by BIC will be less than or equal to the number selected by AIC.

(A) None of I, II, or III is true

(B) I and II only

(C) I and III only

(D) II and III only

(E) The answer is not given by (A), (B), (C), or (D)

中文題意

（SRM 樣題 #61）對含六個預測變數 F、G、H、I、J、K 的資料配適線性模型。以下關於用 AIC 或 BIC 挑選最佳預測變數集合的敘述，哪些正確？

I. AIC 與 BIC 直接估計測試誤差。

II. 在子集 $\{F, G, H\}$ 與 $\{I, J, K\}$ 之間選擇時，AIC 與 BIC 一定選同一個。

III. 樣本大（$n > 7$）時，BIC 選出的變數個數小於或等於 AIC 選出的個數。

(A) 都不對　(B) 只有 I、II　(C) 只有 I、III　(D) 只有 II、III　(E) 以上皆非

答案

(D)

解析

I. 錯。AIC、BIC 是**間接**估計：對訓練誤差加上懲罰。直接估計測試誤差的是驗證集與交叉驗證。

II. 對。兩個子集的變數個數都是 3，AIC 對兩者加相同的懲罰，BIC 也是，所以兩者都只比較概似（或 RSS），結果一樣。

III. 對。BIC 每個參數罰 $\ln n$；$n > 7$ 即 $n \geq 8$ 時 $\ln n \geq \ln 8 = 2.08 > 2$，比 AIC 的 2 重，所以 BIC 選的模型不會比 AIC 選的大。

> **易錯**
>
> III 的推理需要「BIC 選的模型不比 AIC 大」：若 BIC 選了比 AIC 更大的模型 B，則 AIC 在 B 與 AIC 自己選的 A 之間會更偏好 B（懲罰差較小），矛盾。

練習 **第 7.20 題** ・講義 p.120・回到對應概念

A linear regression model has n observations and 8 predictors. You are testing a model having a subset of the 8 predictors. The subset has 4 predictors. You are given:

- Both models have intercepts.
- The training RSS of the original model is 82.8.
- The training RSS of the subset model is 116.2.
- The variance of the residuals is estimated using the original model.
- AIC and BIC of the subset model are calculated using the formulas in James et al.
- The AIC of the subset model is 105.2458.

Calculate the BIC of the subset model.

中文題意

線性迴歸模型有 n 筆觀察與 8 個預測變數。你在測試一個用其中 4 個預測變數的子模型。已知：兩個模型都有截距；原模型的訓練 RSS 為 82.8；子模型的訓練 RSS 為 116.2；殘差的變異數用原模型估計；子模型的 AIC 與 BIC 用 James 等人的公式計算；子模型的 AIC 為 105.2458。求子模型的 BIC。

答案

參考答案印 110.9638；依參考答案自己的算式應為 119.96（見解析）

解析

$\hat{\sigma}^2 = \dfrac{82.8}{n-9}$（8 個變數加截距）。

題目本身的問題。 照 (7.4) 的 $\mathrm{AIC} = \frac{1}{n}(116.2 + 8\hat{\sigma}^2)$，數值大約是 $116.2/n$，對任何合理的 n 都遠小於 105.2458，所以這組數字和 (7.4) 不相容。參考答案其實用的是

$$\text{AIC} = \frac{n-9}{n}\left(116.2 + \frac{2(4)(82.8)}{n-9}\right) = \frac{116.2(n-9)+8(82.8)}{n},$$

也就是 (7.4) 再乘上 $n-9$。

照參考答案的算式解 n。

$$105.2458n = 116.2n - 1045.8 + 662.4 = 116.2n - 383.4 \;\Rightarrow\; n = \frac{383.4}{10.9542} = 35.$$

BIC。 同一個寫法把懲罰的 2 換成 $\ln 35 = 3.5553$：

$$\text{BIC} = \frac{26}{35}\left(116.2 + \frac{(\ln 35)(4)(82.8)}{26}\right) = \frac{26}{35}(116.2 + 45.289) = 119.96.$$

也可以只算差額：$\text{BIC} - \text{AIC} = \dfrac{(\ln n - 2)(4)(82.8)}{n} = \dfrac{1.5553(331.2)}{35} = 14.718$，$105.2458 + 14.718 = 119.964$。參考答案印的 110.9638 與這個值只差一個數字，應是誤植。

易錯

這題的重點是：AIC 與 BIC 只差在懲罰係數（2 對 $\ln n$），由 AIC 求出 n 後，加上懲罰的差額就得到 BIC。

練習 **第 7.21 題** ・講義 p.121・回到對應概念

[MAS-I-F18:39] Two actuaries were given a dataset and asked to build a model to predict claim frequency using any of 5 independent predictors $\{1, 2, 3, 4, 5\}$ as well as an intercept $\{I\}$.

- Actuary A chooses their model using Best Subset Selection
- Actuary B chooses their model using Forward Stepwise Regression
- When evaluating the models they both used R-squared to compare models with the same number of parameters, and AIC to compare models with different numbers of parameters.

Below are statistics for all candidate models:

Model	# of Non-Intercept Parameters	Parameters	R^2	Log-likelihood	Model	# of Non-Intercept Parameters	Pa
1	0	I	0	0.05	17	3	
2	1	I,1	0.56	1.3	18	3	
3	1	I,2	0.57	1.4	19	3	
4	1	I,3	0.55	1.2	20	3	
5	1	I,4	0.52	1.15	21	3	
6	1	I,5	0.51	1.1	22	3	
7	2	I,1,2	0.61	2.5	23	3	
8	2	I,1,3	0.64	2.75	24	3	
9	2	I,1,4	0.63	2.6	25	3	
10	2	I,1,5	0.69	3	26	3	
11	2	I,2,3	0.61	2.5	27	4	
12	2	I,2,4	0.62	2.55	28	4	

Model	# of Non-Intercept Parameters	Parameters	R^2	Log-likelihood	Model	# of Non-Intercept Parameters	Pa
13	2	I,2,5	0.68	2.9	29	4	
14	2	I,3,4	0.66	2.8	30	4	
15	2	I,3,5	0.64	2.75	31	4	
16	2	I,4,5	0.6	2.45	32	5	I

AIC_j is the AIC of the model chosen by Actuary j. Calculate the absolute value of the difference between AIC_A and AIC_B.

(A) Less than 0.15

(B) At least 0.15, but less than 0.30

(C) At least 0.30, but less than 0.45

(D) At least 0.45, but less than 0.60

(E) At least 0.60

中文題意

（MAS-I 2018 秋 #39）兩位精算師要用 5 個自變數 $\{1, 2, 3, 4, 5\}$ 與截距 $\{I\}$ 建立理賠頻率模型。精算師 A 用最佳子集選擇，精算師 B 用向前逐步迴歸。兩人都用 R^2 比較參數個數相同的模型、用 AIC 比較參數個數不同的模型。所有候選模型的統計量（第二欄是非截距參數個數）：

AIC_j 是精算師 j 所選模型的 AIC。求 $|\text{AIC}_A - \text{AIC}_B|$。

（數據、圖表與選項見上方英文題目。）

答案

(B) 0.2

解析

AIC $= -2l + 2p$，p 是參數個數（非截距個數加 1）。

精算師 A（最佳子集）：每個大小取 R^2 最高者：模型 1、3（0.57）、10（0.69）、22（0.79）、27（0.88）、32。AIC：

模型	1	3	10	22	27	32
$2p-2l$	$2-0.1$	$4-2.8$	$6-6$	$8-7.8$	$10-8.4$	$12-8.5$
AIC	1.9	1.2	**0**	0.2	1.6	3.5

最小 0（模型 10）。

精算師 B（向前逐步）：從 I 開始；一個變數時 R^2 最高的是 2（模型 3）；含 2 的兩變數模型 7、11、12、13 中最高的是 13（I,2,5，0.68）；含 2,5 的三變數模型 19、24、25 中最高的是 25（0.75）；含 2,4,5 的四變數模型 29、31 中最高的是 29（0.87）；最後 32。AIC：

模型	1	3	13	25	29	32
$2p-2l$	$2-0.1$	$4-2.8$	$6-5.8$	$8-6.9$	$10-8.2$	$12-8.5$
AIC	1.9	1.2	**0.2**	1.1	1.8	3.5

最小 0.2（模型 13）。

差 $|0-0.2|=0.2$。B 第一步選了 2，就永遠到不了不含 2 的模型 10。

易錯

不要對所有 32 個模型直接比 AIC：題目規定同樣大小先用 R^2 篩選。（這題剛好兩者的結果一樣，但 7.23 的 B、C 就不同了。）

練習 **第 7.22 題** ・講義 p.121・回到對應概念

You have fit 5 models using linear regression. The loglikelihoods of the models are

Variables in Model	Loglikelihood
X_1, X_2	-15.785
X_1, X_2, X_4	-14.472
X_1, X_3, X_4	-13.015
X_1, X_3, X_4, X_5	-12.500
X_2, X_3, X_4, X_5	-12.021

Using the Akaike Information Criterion, which model is preferred?

中文題意

用線性迴歸配適了 5 個模型，對數概似如下：

依 AIC，哪個模型較好？

（數據、圖表與選項見上方英文題目。）

答案

$\{X_1, X_3, X_4\}$

解析

用 Frees 的 AIC $= -2l + 2p$，線性迴歸的參數個數 $p =$ 變數個數 $+$ 截距 $+\sigma^2$。參數個數相同時，對數概似高的 AIC 一定較小，所以第 2 個模型輸給第 3 個、第 4 個輸給第 5 個，只需比較三個：

$$\{X_1, X_2\}:\ 2(15.785) + 2(4) = 39.570$$

$$\{X_1, X_3, X_4\}:\ 2(13.015) + 2(5) = 36.030$$

$$\{X_2, X_3, X_4, X_5\}:\ 2(12.021) + 2(6) = 36.042$$

第三個模型最小。用 James 等人的算法，參數個數少 1 或 2，但對所有模型相同，結論一樣。

易錯

$\{X_1, X_3, X_4\}$ 與 $\{X_2, X_3, X_4, X_5\}$ 只差 0.012：後者多一個參數，對數概似只高 0.994，不到 AIC 要求的 1（$-2l$ 要降超過 2 才抵得過懲罰）。

練習 **第 7.24 題** ・講義 p.122・回到對應概念

You have fit 5 models based on 70 observations using linear regression. The loglikelihoods of the models are

Variables in Model	Loglikelihood
X_1, X_2	-120.1
X_1, X_2, X_4	-119.5
X_1, X_3, X_4	-118.2
X_1, X_3, X_4, X_5	-116.6
X_1, X_2, X_3, X_4, X_5	-113.8

Which model is preferred based on BIC?

中文題意

以 70 筆觀察用線性迴歸配適了 5 個模型，對數概似如下：

依 BIC，哪個模型較好？

（數據、圖表與選項見上方英文題目。）

答案

$\{X_1, X_2\}$

解析

Frees 的 BIC $= -2l + p \ln n$，$p =$ 變數個數 $+2$（截距與 σ^2），$\ln 70 = 4.2485$。第 2 個模型和第 3 個參數一樣多但概似較低，可以略過。

$$\{X_1, X_2\}:\ 240.2 + 4(4.2485) = 257.194$$

$$\{X_1, X_3, X_4\}:\ 236.4 + 5(4.2485) = 257.642$$

$$\{X_1, X_3, X_4, X_5\}:\ 233.2 + 6(4.2485) = 258.691$$

$$\{X_1, \ldots, X_5\}:\ 227.6 + 7(4.2485) = 257.339$$

最小的是 $\{X_1, X_2\}$（257.194）。

易錯

若用 AIC（每個參數罰 2），全模型 $227.6 + 14 = 241.6$ 最小；BIC 的懲罰重得多，選了最小的模型。

練習 **第 7.25 題** ・講義 p.123・回到對應概念

For a regression model based on 50 observations, you are given:

(i) The model has 3 variables and an intercept.

(ii) The residual standard error is 82.4.

Calculate the AIC for the model using the formula in Frees.

中文題意

以 50 筆觀察為基礎的迴歸模型：(i) 有 3 個變數與截距；(ii) 殘差標準誤為 82.4。用 Frees 的公式求 AIC。

答案

$\text{AIC} = 589.05$

解析

由 (7.3)，$n = 50$、$k = 3$：

$$\text{AIC} = n \ln s^2 + n \ln(2\pi) + n + k + 3 = 50 \ln(82.4^2) + 50 \ln(2\pi) + 50 + 3 + 3$$

$$= 50(8.82317) + 50(1.83788) + 56 = 441.159 + 91.894 + 56 = 589.05.$$

易錯

是 $\ln s^2$，不是 $\ln s$；82.4 是標準誤，要先平方。

練習 **第 7.26 題** ・講義 p.123・回到對應概念

A regression is performed based on 28 observations. The form of the regression is

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \beta_4 x_{i4} + \varepsilon_i$$

The AIC, using the formula in Frees, is 111.03. Determine the BIC.

中文題意

以 28 筆觀察做迴歸 $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \beta_4 x_{i4} + \varepsilon_i$。用 Frees 的公式算出的 AIC 為 111.03。求 BIC。

答案

BIC $= 119.02$

解析

AIC $= -2l + 2p$、BIC $= -2l + p \ln n$，兩者的 $-2l$ 相同。參數個數 $p = 5$ 個係數 $+\sigma^2 = 6$：

$$\text{BIC} = \text{AIC} - 2p + p \ln n = 111.03 - 12 + 6 \ln 28 = 99.03 + 6(3.3322) = 119.02.$$

易錯

σ^2 也算一個參數；只算 5 個會得到 $111.03 - 10 + 5 \ln 28 = 117.69$。

練習 **第 7.27 題** ・講義 p.123・回到對應概念

[S-F15:39] You are given the following output from five candidate models:

Model #	Included Parameters	R^2	AIC	BIC
1	Gender	0.0162	7532	7899
2	Age	0.0230	7524	7865
3	Age + Gender	0.0390	7508	7885
4	Age + Gender + Income	0.0755	7469	7645
5	Age + Gender + Income + Uninsured	0.0762	7471	7659

Determine which statement is correct based on the selection criteria above.

(A) Model 1 is the best according to R^2.

(B) Model 1 is the best according to AIC.

(C) Model 4 is the best according to R^2.

(D) Model 4 is the best according to AIC.

(E) Model 5 is the best according to BIC.

中文題意

（SRM 2015 秋 #39）五個候選模型的結果：

依上述準則，哪個敘述正確？

(A) 依 R^2 模型 1 最好　(B) 依 AIC 模型 1 最好　(C) 依 R^2 模型 4 最好　(D) 依 AIC 模型 4 最好　(E) 依 BIC 模型 5 最好

（數據、圖表與選項見上方英文題目。）

答案

(D)

解析

R^2 越大越好：模型 5（0.0762）最好，(A)、(C) 錯。AIC、BIC 越小越好：AIC 最小 7469、BIC 最小 7645，都是模型 4，(B)、(E) 錯，(D) 對。

易錯

R^2 在巢狀模型間只增不減，所以永遠是最大的模型最好，不能用來選模型大小。

練習 **第 7.28 題** · 講義 p.123 · 回到對應概念

You are given the following ANOVA table from a regression:

Source	Sum of Squares	df
Regression	348	3
Error	21	12

Determine adjusted R^2.

中文題意

迴歸的 ANOVA 表：迴歸平方和 348、自由度 3；誤差平方和 21、自由度 12。求調整 R^2。

答案

調整 $R^2 = 0.9289$

解析

$n - 1 = 3 + 12 = 15$，$\text{TSS} = 348 + 21 = 369$。

$$\text{調整 } R^2 = 1 - \frac{\text{RSS}/(n-d-1)}{\text{TSS}/(n-1)} = 1 - \frac{21/12}{369/15} = 1 - \frac{1.75}{24.6} = 0.9289.$$

對照 $R^2 = 348/369 = 0.9431$。

練習 **第 7.29 題** ・講義 p.123・回到對應概念

[120-81-98:9] You are given:

(i) The regression sum of squares is 1115.11, with 2 degrees of freedom.

(ii) The error sum of squares is 138.89, with 5 degrees of freedom.

Calculate the adjusted R^2.

(A) 0.84

(B) 0.89

(C) 0.93

(D) 0.97

(E) 1.00

中文題意

（120-81-98:9）迴歸平方和 1115.11、自由度 2；誤差平方和 138.89、自由度 5。求調整 R^2。

(A) 0.84　(B) 0.89　(C) 0.93　(D) 0.97　(E) 1.00

答案

(A) 0.845

解析

$n-1=2+5=7$，TSS $=1254$：

$$\text{調整 } R^2=1-\frac{138.89/5}{1254/7}=1-\frac{27.778}{179.143}=1-0.15506=0.845.$$

易錯

$R^2=1115.11/1254=0.889$ 是選項 (B)。

練習 **第 7.30 題** ・講義 p.123・回到對應概念

[120-83-98:4] You fit the regression model $Y_i = \alpha + \beta X_i + \varepsilon_i$ to 11 observations. You are given that $R^2 = 0.85$.

Determine adjusted R^2.

(A) 0.77

(B) 0.79

(C) 0.80

(D) 0.81

(E) 0.83

中文題意

（120-83-98:4）以 11 筆觀察配適 $Y_i = \alpha + \beta X_i + \varepsilon_i$，$R^2 = 0.85$。求調整 R^2。

(A) 0.77　(B) 0.79　(C) 0.80　(D) 0.81　(E) 0.83

答案

(E) 0.8333

解析

$d = 1$，由 (7.7)：

$$\text{調整 } R^2 = 1 - (1 - 0.85) \cdot \frac{11 - 1}{11 - 1 - 1} = 1 - 0.15 \cdot \frac{10}{9} = 0.8333.$$

練習 **第 7.31 題** ・講義 p.124・回到對應概念

[MAS-I-F18:30] An actuary uses statistical software to run a regression of the median price of a house on 12 predictor variables plus an intercept. He obtains the following (partial) model output:

Residual standard error: 4.74 on 493 degrees of freedom Multiple R-squared: 0.7406 F-statistic: 117.3 on 12 and 493 DF p-value: < 2.2e-16

Calculate the adjusted R^2 for this model.

(A) Less than 0.70

(B) At least 0.70, but less than 0.72

(C) At least 0.72, but less than 0.74

(D) At least 0.74, but less than 0.76

(E) At least 0.76

中文題意

（MAS-I 2018 秋 #30）以統計軟體做房價中位數對 12 個預測變數加截距的迴歸，部分輸出：殘差標準誤 4.74，自由度 493；Multiple R-squared 0.7406；F 統計量 117.3，自由度 12 與 493；p 值 $< 2.2 \times 10^{-16}$。求調整 R^2。

（數據、圖表與選項見上方英文題目。）

答案

(C) 0.7343

解析

誤差自由度 $n - d - 1 = 493$，$d = 12$，所以 $n = 506$、$n - 1 = 505$：

$$\text{調整 } R^2 = 1 - (1 - 0.7406) \cdot \frac{505}{493} = 1 - 0.2594(1.02434) = 0.7343.$$

練習 **第 7.32 題** ・講義 p.124・回到對應概念

[4-S00:31] You fit the following model to 48 observations:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \varepsilon_i$$

You are given the following ANOVA table:

Source	Sum of Squares	df
Regression	103,658	3
Error	69,204	44

Calculate the adjusted R^2.

(A) 0.57

(B) 0.58

(C) 0.59

(D) 0.60

(E) 0.61

中文題意

（4-S00:31）以 48 筆觀察配適 $Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \varepsilon_i$。ANOVA 表：迴歸平方和 103,658、自由度 3；誤差平方和 69,204、自由度 44。求調整 R^2。

(A) 0.57　(B) 0.58　(C) 0.59　(D) 0.60　(E) 0.61

答案

(A) 0.572

解析

TSS $= 103{,}658 + 69{,}204 = 172{,}862$，$n - 1 = 47$：

$$\text{調整 } R^2 = 1 - \frac{69{,}204/44}{172{,}862/47} = 1 - \frac{1572.82}{3677.91} = 1 - 0.42764 = 0.572.$$

易錯

$R^2 = 103{,}658/172{,}862 = 0.600$ 是選項 (D)。

練習 **第 7.33 題** ・講義 p.124・回到對應概念

For a linear regression model of the form $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i$ you are given:

(i) $F = 96$

(ii) Adjusted $R^2 = 0.95$

(iii) $\sum (\hat{y}_i - \bar{y})^2 = 1000$

(iv)

$$(X'X)^{-1} = \begin{pmatrix} 3 & 8 & 12 \\ 8 & 2 & 0 \\ 12 & 0 & 1 \end{pmatrix}.$$

Determine the width of the shortest 95% symmetric confidence interval for β_1.

中文題意

線性迴歸 $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i$，已知：(i) $F = 96$；(ii) 調整 $R^2 = 0.95$；(iii) $\sum (\hat{y}_i - \bar{y})^2 = 1000$；(iv) 求 β_1 最短的 95% 對稱信賴區間的寬度。

（數據、圖表與選項見上方英文題目。）

答案

寬度 $= 14.885$

解析

未知的 n 要先由 F 與調整 R^2 解出來。

第一步：用調整 R^2 表示 $1 - R^2$。 $d = 2$：

$$0.95 = 1 - (1 - R^2)\frac{n-1}{n-3} \;\Rightarrow\; 1 - R^2 = \frac{0.05(n-3)}{n-1}. \qquad (*)$$

第二步：用 F。 分子分母同除以 TSS：

$$F = \frac{R^2/2}{(1-R^2)/(n-3)} = \frac{(n-3)}{2} \cdot \frac{R^2}{1-R^2} = 96.$$

由 $(*)$，$\dfrac{R^2}{1-R^2} = \dfrac{1}{1-R^2} - 1 = \dfrac{n-1}{0.05(n-3)} - 1$。代入：

$$\frac{n-3}{2}\left(\frac{n-1}{0.05(n-3)} - 1\right) = \frac{20(n-1)-(n-3)}{2} = \frac{19n-17}{2} = 96 \;\Rightarrow\; n = 11.$$

第三步：s^2。 $1 - R^2 = \dfrac{0.05(8)}{10} = 0.04$，$R^2 = 0.96$。Regression SS $= 1000$，所以 TSS $= 1000/0.96$、

$$\text{Error SS} = \text{TSS}(1-R^2) = 1000 \cdot \frac{0.04}{0.96} = 41.667, \qquad s^2 = \frac{41.667}{11-3} = 5.2083.$$

第四步：信賴區間。 $\widehat{\text{Var}}(b_1) = s^2[(X'X)^{-1}]_{22} = 5.2083(2) = 10.4167$，$t_{0.025,8} = 2.306$：

$$\text{寬度} = 2(2.306)\sqrt{10.4167} = 2(2.306)(3.2275) = 14.885.$$

易錯

β_1 對應 $(X'X)^{-1}$ 的第 2 個對角元素（第 1 個是截距）；t 的自由度是 $n-3=8$。

練習 **第 7.35 題** ・講義 p.125・回到對應概念

You are given the following regression models:

(A) $y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik} + \varepsilon_i$

(B) $y_i^* = \beta_0^* + \beta_1^* x_{i1} + \cdots + \beta_k^* x_{ik} + \varepsilon_i^*$, where $y_i^* = 2y_i$.

Which of the following statements are true?

1. The standard error of the regression will be the same in both models.
2. The adjusted R^2 will be the same in both models.
3. Both models will have the same F statistic.

中文題意

有以下兩個迴歸模型：(A) $y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik} + \varepsilon_i$；(B) $y_i^* = \beta_0^* + \beta_1^* x_{i1} + \cdots + \beta_k^* x_{ik} + \varepsilon_i^*$，其中 $y_i^* = 2y_i$。下列哪些敘述正確？

1. 兩個模型的迴歸標準誤相同。
2. 兩個模型的調整 R^2 相同。
3. 兩個模型的 F 統計量相同。

答案

只有 2、3

解析

$\mathbf{b}^* = (X'X)^{-1}X'(2\mathbf{y}) = 2\mathbf{b}$，配適值與殘差也都乘 2，所以 Total SS、Regression SS、Error SS 全部乘 4。 1. 錯：$s = \sqrt{\text{Error SS}/(n-k-1)}$ 乘 2。 2. 對：調整 R^2 是 $\text{Error SS}/\text{Total SS}$ 的函數，4 倍消掉。 3. 對：$F = \dfrac{\text{Reg SS}/k}{\text{Error SS}/(n-k-1)}$，4 倍消掉。

易錯

同理 t 統計量、R^2 也都不變；係數與標準誤都乘 2。