概念 01

為什麼接受偏誤：懲罰、預算與尺度

預測理賠時，兩欄保額與收入若幾乎同步變動，很多組斜率可產生相近的訓練預測。最小平方法只問殘差平方和（RSS）哪一組最小，可能用很大的正負係數互相抵銷，稍微更換樣本就大幅改變估計。收縮（shrinkage）要求改善擬合的同時，也為過大係數付出成本。

對新點 x、固定 $f(x)$、零均值且與訓練樣本獨立的誤差，$E[(Y-\hat{f}(x))^2]=\sigma^2+\mathrm{Var}(\hat{f}(x))+[E\hat{f}(x)-f(x)]^2$。壓小係數往往提高偏誤，但降低抽樣變異；適度限制可改善測試誤差。這是典型取捨，不保證每一資料集的曲線必為 U 形。用訓練集內的交叉驗證挑強度，不用測試集挑。

固定預算的寫法是最小化 RSS，條件 $P(\beta)\le s$。拉格朗日式為 $RSS+\lambda[P(\beta)-s]$；固定 s 時最後一項為常數，所以得到懲罰寫法 $RSS+\lambda P(\beta)$。λ 大表示處罰強、s 小表示預算緊，兩者方向相反。截距通常不懲罰：將所有反應值加同一常數，本應只改變平均水準，不該改變斜率的限制。

若將 x_j 乘十，保持相同預測需把其係數除十，懲罰會無端變小，因此不同單位要先調整。講義的尺度公式 x_{ij}/s_j 使用 $s_j^2=\sum_i(x_{ij}-\bar{x}_j)^2/n$；常用的中心化標準分數為 $(x_{ij}-\bar{x}_j)/s_j$。有截距時，中心化可由截距吸收，但題目若直接問「轉換後數值」必須區分兩種定義。訓練及驗證資料應使用同一組訓練取得的縮放參數。

★ 精選 · 8.5

資料 4,5,5,6,8,10,11,12。以講義的「除以用 n 計算的標準差」慣例，第一筆尺度化值是多少？

參考解答

約 1.394。

解析

平均 7.625，平方離差和 65.875、變異 8.234375。$4/\sqrt{8.234375} = 1.394$。若另要求中心化 z 分數，則為 $(4 - 7.625)/\sqrt{8.234375} \approx -1.263$。

概念 02

嶺迴歸：為什麼平方懲罰會穩定斜率

嶺迴歸（ridge）最小化 $\|y - X\beta\|^2 + \lambda \sum_j \beta_j^2$，此處 X, y 已中心化，截距另行估計。對斜率微分為 $-2X^\top(y - X\beta) + 2\lambda\beta = 0$，移項即

$$\hat{\beta}_R = (X^\top X + \lambda I)^{-1} X^\top y.$$

即使 $X^\top X$ 因共線性不可逆，$\lambda > 0$ 時加上正數能使矩陣可逆。沿 $X^\top X$ 的特徵方向，普通最小平方的非零特徵值 d 變成分母 $d + \lambda$，原估計乘上 $d/(d+\lambda)$。最不穩定的小 d 方向受抑制最多。當 $\lambda = 0$，在滿秩條件下回到 OLS；$\lambda \to \infty$ 時所有受懲罰斜率趨零，截距仍可保留。

單一解釋變數含截距時，$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$，將它代入平方和後，對斜率微分得 $\hat{\beta}_1 = S_{xy}/(S_{xx} + \lambda)$，其中 $S_{xy} = \sum_i (x_i - \bar{x})(y_i - \bar{y})$。分母比普通迴歸多 λ，但有限懲罰通常不會讓斜率剛好為零。**即：嶺迴歸保留所有方向，只對資料證據較弱的方向多縮一點。**

★ 精選 · 8.3

模型一截距 5、斜率 (1.1,0.8)、RSS=4；模型二截距 3、斜率 (1,0.1)、RSS=9。在哪些 λ 下 ridge 偏好二？

參考解答

$\lambda > 5/0.84 \approx 5.95238$。

解析

比較 $9 + 1.01\lambda < 4 + 1.85\lambda$；等號時並列。

★ 精選 · 8.10

八筆無截距迴歸、設計矩陣為單位矩陣，反應 (3,−5,10,14,−12,7,3,−4)。用 ridge，$\lambda = 2$，求全部斜率。

參考解答

(1,−5/3,10/3,14/3,−4,7/3,1,−4/3)。

解析

此設計下每項為 $y_j/(1+2)$。

★ 精選 · 8.14

表格列為第二斜率 1 至 4、欄為第一斜率 1 至 4。RSS 各列：56/52/46/52；48/41/34/30；42/37/31/33；36/40/44/48。何種最小懲罰能使 (3,2) 成最優解？

參考解答

0.6。

解析

目標為 $34+13\lambda$。與更低 RSS 的 (4,2)、(3,3)、(4,3) 比較，分別需 $\lambda \geq 4/7, 3/5, 1/8$。取最大 3/5，此時也優於其餘格。

★ 精選 · 8.18

$(x, y) = (1, 2), (2, 5), (3, 12), (4, 13), (5, 18)$，模型有不受罰的截距。ridge 取 $\lambda = 4$，求斜率。

參考解答

$20/7 \approx 2.8571$。

解析

$S_{xx} = 55 - 15^2/5 = 10$，$S_{xy} = 190 - 15(50)/5 = 40$，故 $40/(10 + 4)$。

概念 03

Lasso：絕對值懲罰與軟閾值

Lasso 最小化 $RSS + \lambda \sum_j |\beta_j|$。嶺迴歸用的是 $\|\beta\|_2^2 = \sum_j \beta_j^2$，不要把這個懲罰誤認成有平方根的 $\|\beta\|_2$。Lasso 改用 $\|\beta\|_1$，在零點有折角，因此一部分斜率真的可以等於零；幾何上，L1 預算形狀在座標軸上有角，RSS 等高線可能先在角上碰到它。這就是它能作特徵選取的原因。

看最清楚的例子：沒有截距且 $X = I$ 時，每個係數獨立最小化 $(y_j - b)^2 + \lambda|b|$。若 $b > 0$，一階條件 $2(b - y_j) + \lambda = 0$；若 $b < 0$ 則為 $2(b - y_j) - \lambda = 0$。只有解的符號符合假設時才可採用；兩邊都不成立時最小點在零。故

$$\hat{b}_j = \operatorname{sign}(y_j)\max\{|y_j| - \lambda/2, 0\}.$$

同一設計下 ridge 是 $y_j/(1+\lambda)$，不是把同一常數從每個非零值減掉。若目標函數以 $RSS/2$ 或 RSS/n 定義，門檻中的二分之一會隨慣例改變。含單一中心化 X 時，把 y_j 替成 S_{xy}，在分子做相同軟閾值，再除以 S_{xx}。多變數高度相關時不可逐欄直接套用正交設計的簡式，lasso 選哪一欄也可能對樣本敏感。

★ 精選 · 8.9

八筆無截距迴歸、設計矩陣為單位矩陣，反應 (3,−5,10,14,−12,7,3,−4)。用 lasso，$\lambda = 10$，求全部斜率。

參考解答

(0,0,5,9,−7,2,0,0)。

解析

套軟閾值 5。絕對值不超過 5 者成零；其餘向零縮 5。

★ 精選 · 8.12

兩模型 RSS 分別 26、50，斜率分別 (−1.7,2.5,1.2)、(0,3.1,0)。lasso 何時嚴格偏好模型二？

參考解答

$\lambda > 24/2.3 \approx 10.4348$。

解析

比較 $50 + 3.1\lambda < 26 + 5.4\lambda$。

★ 精選 · 8.19

$(x, y) = (1, 2), (2, 5), (3, 12), (4, 13), (5, 18)$，模型有不受罰的截距。lasso 取 $\lambda = 4$，求斜率。

參考解答

3.8。

解析

中心化後正半軸一階條件為 $2(10b - 40) + 4 = 0$；解為正，符合假設。

概念 04

主成分迴歸：先把 X 壓縮，再解釋 Y

主成分迴歸（PCR）先將中心化、適當縮放的原變數轉成少數新特徵 $Z_m = \sum_j \phi_{jm} X_j$。單位長度的 ϕ_1 最大化投影變異；其後成分依序在垂直方向最大化剩餘變異。因此這**不是**要求權重加總為 1 的加權平均。若中心為 (5,9)、方向為 (0.6,0.8)，觀察 (5.5,8.5) 的分數為 $0.6(0.5) + 0.8(-0.5) = -0.1$。

再回歸 $y = \theta_0 + \sum_{m=1}^{M} \theta_m Z_m + \epsilon$。代回 Z_m，原斜率為 $\beta_j = \sum_m \phi_{jm}\theta_m$；所以少估 M 個方向，並非把不重要的原始欄位逐一刪掉。少數高變異方向能減少共線方向的估計變異，但若真正與 Y 有關的是低變異方向，模型會有偏。用交叉驗證選 M；不要只看解釋 X 的比例來判定預測效果。所有非零方向都保留時，預測落回同一 OLS 投影空間。

★ 精選 · 8.23

PCR 判斷：I 成分是原欄位的加權平均；II 權重平方和為一，選出變異最小方向；III 第二成分與第一成分不相關。

參考解答

僅 III（D）。

解析

線性組合不必是凸加權平均；最大化而非最小化投影變異。

概念 05

偏最小平方法與高維資料

偏最小平方法（PLS）同樣合成變數，但第一方向使用反應值。教材做法以每欄 X_j 對 Y 的簡單迴歸斜率作權重：$w_j = S_{X_jY}/S_{X_jX_j}$。若已縮放到相同變異，這等同選擇與 Y 有大共變異的方向。形成 $Z_1 = Xw$，再從每一欄扣掉它在 Z_1 的線性投影，對剩餘變動重複。方向的整體縮放只改變新特徵的單位，迴歸係數可以補回；不同軟體的正規化慣例可能不同。

PCR 的第一步不使用 Y，因此新軸對 X 的變異最有代表性。PLS 因選軸時使用 Y，對反應常能降低偏誤，但同時也有機會追逐 Y 的雜訊、增加估計變異；兩者誰贏要由樣本外驗證決定。

維度災難指特徵越多，固定樣本在特徵空間越稀疏。若 p 接近或超過 n，設計矩陣秩有限；可能出現多組係數給同一個訓練預測，甚至 RSS 為零。此時漂亮的訓練 R^2 並非泛化證據。收縮、降維與子集選擇都是控制有效複雜度的方法，調參與評估必須留在正確的樣本切分內。

★ 精選 · 8.25

五筆資料已知 $\sum X_1 = 15, \sum X_1^2 = 55, \sum X_2 = 18, \sum X_2^2 = 82, \sum Y = 45, \sum X_1 Y = 158, \sum X_2 Y = 148$。不先標準化，求講義定義的第一 PLS 方向係數。

參考解答

2.3 與約 −0.81395。

解析

分別作簡單迴歸。第一係數 $(158 - 15 \times 45/5)/(55 - 15^2/5) = 23/10$；第二係數 $(148 - 18 \times 45/5)/(82 - 18^2/5) = -14/17.2$。

TERMS

本章中英術語

中文	English	解題時的意思
嶺迴歸	ridge regression	用斜率平方和懲罰估計。
套索迴歸	lasso regression	用絕對值和處罰斜率，可使部分係數為零。
偏最小平方法	partial least squares	降維時連同反應資訊一起選取方向。

練習 · 8.1

在典型 ridge 偏誤與變異取捨示意圖中，逐漸提高懲罰時測試 MSE 是持平、遞減、遞增、先降後升或先升後降？

參考解答

典型答案先降後升（D）。

解析

初期降低變異可能勝過偏誤增加，懲罰過強後過度收縮使誤差回升。這是常見圖形，不是對任一資料集的單調定理。

練習 · 8.2

斜率為 2.5、−3.1、0.8，截距 11.5；$\lambda = 3$，求 ridge 懲罰。

參考解答

49.5。

解析

$3(2.5^2 + 3.1^2 + 0.8^2) = 49.5$；不加入截距。

練習 · 8.4

截距 9.2、四斜率 (3.4,−2.4,0.8,2.1)，$\lambda = 5$，求 lasso 懲罰。

參考解答

43.5。

解析

絕對值和為 8.7，乘 5。負係數不能抵銷正係數。

練習 · 8.6

找 ridge 錯誤敘述：A 無限大懲罰使斜率趨零；B 最小化 RSS 加平方懲罰；C 對縮放不具 OLS 的等變性；D 截距不受罰；E 收縮的優點是降低偏誤。

參考解答

E。

解析

收縮通常以增加偏誤換降低變異，並非藉降低偏誤改善預測。

練習 · 8.7

求向量 (3,−1,4,1,−6,−9) 的 L2 範數。

參考解答

12。

解析

$\sqrt{9+1+16+1+36+81} = \sqrt{144}$；ridge 懲罰用範數的平方。

練習 · 8.8

求向量 $(3,-1,4,1,-6,-9)$ 的 L1 範數。

參考解答

24。

解析

各元素絕對值相加：$3+1+4+1+6+9$。

練習 · 8.11

判斷 I 懲罰趨無限時得到不受限 ridge 解；II lasso 的非零係數一定不少於 ridge；III 可用交叉驗證選 ridge 強度。

參考解答

只有 III（C）。

解析

不受限是零懲罰；lasso 可以把部分斜率直接設零。

練習 · 8.13

表格列為第二斜率 1 至 4、欄為第一斜率 1 至 4。RSS 各列：56/52/46/52；48/41/34/16；42/37/31/33；36/40/44/48。ridge 預算 12，選斜率。

參考解答

(2,2)。

解析

限制 $b_1^2 + b_2^2 \le 12$ 排除任一個 4，也排除 3 搭 2；可行者最低 RSS 是 41。

練習 · 8.15

斜率限整數 1–3，ridge 預算 $s = 5$。對可行的 (1,1)、(1,2)、(2,1)，截距 1 時 RSS 各為 3924/1977/1858；截距 2 時 3949/1822/1907；截距 3 時 3784/1671/1827。求三係數之和。

參考解答

6（B）。

解析

截距不受罰。預算使只有列出的三對可行；跨截距最低 RSS 為 1671，係數為 (截距 3，斜率 1、2)。

練習 · 8.16

ridge 預算 s 增加時，曲線 X 下降、曲線 Y 先下降再上升。辨別為何種統計量。

參考解答

X 為平方偏誤，Y 為測試 MSE（A）。

解析

放寬預算相當於減少懲罰。這個示意例中，平方偏誤下降，估計變異逐漸上升，測試誤差先改善再惡化。

練習 · 8.17

lasso 的懲罰強度增加，X 先降後升，Y 整體上升。判讀 X、Y。

參考解答

X 是測試 MSE，Y 是訓練 MSE（B）。

解析

X 反映偏誤與變異取捨；Y 則衡量逐漸限制模型所增加的訓練損失。

練習 · 8.20

列為第二斜率 0–3，欄為第一斜率 0–3。RSS 各列 82/77/70/62；74/70/65/61；69/63/62/60；67/60/59/58。lasso 預算 3，選係數。

參考解答

(3,0)。

解析

只考慮 $b_1 + b_2 \le 3$ 的格子（均非負），可行格中最低 RSS=62。

練習 · 8.21

列為第二斜率 0–3，欄為第一斜率 0–3。RSS 各列 82/77/70/67；74/70/65/62；69/64/62/57；67/63/59/56。lasso 懲罰 4，選係數。

參考解答

(1,2)。

解析

每格加 $4(b_1+b_2)$，此格 $64+4(3)=76$ 最低。RSS 最低的 (3,3) 懲罰後為 80。

練習 · 8.22

兩斜率皆為 1–5 整數，lasso 預算為 5。可行 RSS：第一斜率 1 時依第二斜率 1–4 為 2855.0/370.3/464.4/357.2；第一斜率 2 時為 1059.1/488.4/216.3；第一斜率 3 時為 657.0/220.0；第一斜率 4 時為 368.4。求選定的第一斜率除以第二斜率。

參考解答

2/3（B）。

解析

可行三角區最低為 216.3，位於 (2,3)，符合 $2+3=5$。

練習 · 8.24

判斷 PLS：I 是使用反應資訊的成分方法；II 不一定像 PCA 那樣最大化 X 的投影變異；III 典型比較中 PLS 對 Y 的偏誤比 PCR 更高。

參考解答

I、II (C) 。

解析

PLS 使用 Y 選方向，常能降低對反應的偏誤，但也可能提高估計變異。這不是對所有資料集的絕對排序。

練習 · 8.26

相對於全變數 OLS，子集選取或收縮可能帶來哪些優點？I 模型更簡單；II 改善預測；III 更易解讀。

參考解答

三項均是可能優點（D）。

解析

刪去不必要變數可簡化解釋；穩定估計有機會改善樣本外表現。並非每種方法在每個樣本都實現全部三項。

練習 · 8.27

Lasso、PLS、PCA、ridge 四者，有幾種本身會選取原始變數？

參考解答

一種，lasso（B）。

解析

PLS、PCA 以線性組合降維；ridge 通常保留所有斜率。

練習 · 8.28

哪項關於 PCR 不正確？A 常建議先標準化；B 它是原始特徵選取法；C 仰賴高變異方向含反應資訊；D 可減少過度擬合；E 第一軸最大化投影變異。

參考解答

B。

解析

PCR 選成分數，不是逐一刪原變數；每個保留方向仍可能由所有原變數構成。