概念 01

先問要預測誰：平均反應與新觀察值

公司問「同樣年齡、同樣保額的保戶，平均賠多少？」與「下一張這樣的保單會賠多少？」兩問的點預測都可用 $\hat{y}_* = x_*^\top \hat{\beta}$，區間卻不同。第一問的不確定性來自母體係數未知。第二問還有新保戶本身的隨機損失；即使掌握真實係數，也不可能把個人的偶然性估掉。

固定設計、線性條件平均、獨立且同變異的誤差下，$\operatorname{Var}(\hat{\beta} \mid X) = \sigma^2 (X^\top X)^{-1}$。令 $h_* = x_*^\top (X^\top X)^{-1} x_*$。估計平均時，常數向量的線性組合給出 $\operatorname{Var}(\hat{y}_* \mid X) = \sigma^2 h_*$。新觀察為 $Y_* = x_*^\top \beta + \varepsilon_*$，若它與訓練誤差獨立，從 $Y_* - \hat{y}_*$ 展開變異，交叉項消失：

$$\operatorname{Var}(Y_* - \hat{y}_* \mid X, x_*) = \sigma^2 (1 + h_*).$$

額外的 1 代表新個體的誤差，不是多估了一個截距。若問「未來觀察值給定真實參數的變異」，則只是 σ^2，同樣不能與預測誤差變異混用。

★ 精選 · 9.2

五筆資料依序為 (5,4,10)、(4,2,9)、(2,5,15)、(3,3,8)、(9,11,12)，每列是兩特徵及反應。求新點 (6,4) 的預測；講義提供四位小數的逆矩陣。

參考解答

用題附的取整矩陣乘 $X^{\top}y=(54,248,289)^{\top}$ 得係數約 $(10.732,-1.2135,1.1385)$，代入約 8.005。若從原始資料保留全精度重算，約 7.96。

解析

兩條計算路徑的差異是先四捨五入逆矩陣；設計向量第一格是截距的 1。

★ 精選 · 9.6

比較：各模型預測必相同 / 新觀察依相同模型生成 / 點估一定更可靠 / 寬區間更有資訊 / 區間排除點估計。何者成立？

參考解答

第二項，B。

解析

預測要能把訓練期規律用在新觀察上。若母體或政策制度改變，即便估計精密也可能失準。

★ 精選 · 9.9

個別反應預測：$x_* = (1, 18, 10)^\top$，殘差均方 20.439；對稱逆矩陣的上三角逐列為 (0.4465,−0.0426,−0.0064)、(0.0169,−0.0112)、(0.0125)。求預測誤差變異。

參考解答

$h_* = 1.4785$，所以 $20.439(1 + 1.4785) = 50.658$（約）。

解析

若只問擬合平均的變異，應改為 20.439 乘 1.4785；原題解答採個別預測口徑。

概念 02

從標準誤得到兩種區間

若模型含截距與 p 個斜率，$s^2 = RSS/(n-p-1)$。在獨立常態誤差等經典條件下，以 $t^* = t_{1-\alpha/2,n-p-1}$ 表示雙尾臨界值，則

$$CI: \quad \hat{y}_* \pm t^* s\sqrt{h_*}, \qquad PI: \quad \hat{y}_* \pm t^* s\sqrt{1+h_*}.$$

簡單迴歸把截距選在 $\bar{x}$ 重新寫成 $\hat{y}_* = \bar{y} + \hat{\beta}_1(x_* - \bar{x})$。中心化後，$\bar{y}$ 與斜率估計的共變異為零，變異分別為 σ^2/n 與 σ^2/S_{xx}。因此 $h_* = 1/n + (x_* - \bar{x})^2/S_{xx}$。離樣本中心越遠，斜率誤差會被更大的距離放大；外推還可能碰到模型關係本身改變，這不會自動反映在區間中。

例如 $\hat{y} = 100, s = 10, h_* = 0.04, t^* \simeq 2$，平均區間半寬約 4，個別預測半寬約 20.4。在固定預測位置、設計提供足夠資訊時，隨樣本量成長，平均區間可以縮小，個別區間仍須容納新觀察的變異。**即：多收資料可以更清楚知道平均值，不能讓下一個保戶不再有偶然損失。**

CA 複習例 | 區間如何隨新點移動？ 換一個離樣本均值更遠的 x，中心改由新的點預測決定，半寬也會增加。把新點拿進訓練資料重新估平均的標準誤，是在回答另一個問題。即使有非常多觀察，對單一人的預測也仍須保留新的誤差項。

★ 精選 · 9.3

簡單迴歸 n=25，平均 x=223，截距 47.26、斜率 5；迴歸平方和 23958920、誤差平方和 5245。求 x=100 的 95% 個別預測上界。

參考解答

約 579.4。$S_{xx}=23958920/25=958356.8$；$s=\sqrt{5245/23}=15.10$。中心為 547.26，個別預測標準誤 $s\sqrt{1+1/25+(100-223)^2/S_{xx}}=15.52$，再加 $2.069(15.52)$。

解析

簡單迴歸有截距時，解釋平方和等於斜率平方乘 Sxx。

★ 精選 · 9.4

n=10、平均 x=7.1、殘差標準誤 3.7981，x=3 的個別預測誤差變異為 17.3568，求 x 的不偏樣本變異數。

參考解答

約 18.10。由 $17.3568/3.7981^2 = 1 + 1/10 + 16.81/S_{xx}$ 得 $S_{xx} \approx 162.9$，再除以 9。

解析

預測變異中的 1 必須保留；最後求的是樣本變異數，不是偏差平方和。

★ 精選 · 9.5

判斷：① 若隨機誤差恆為零則兩區間相等；② 個別預測區間至少與平均區間一樣寬；③ 預測區間估計條件平均的範圍。

參考解答

①②對、③錯，原題選 E。

解析

①指沒有隨機誤差，不是恰好觀察到一次殘差為零。③描述的是平均信賴區間。

★ 精選 · 9.7

評分對客訴的迴歸截距 14.37632、斜率 0.75461。n=30，客訴平均 66.6、標準差 13.3147572，殘差均方 6.993。當客訴為 50，求個別 95% 上界。

參考解答

約 57.75，B。點預測 52.10682；$S_{xx} = 29(13.3147572)^2$。個別預測標準誤為 $\sqrt{6.993[1 + 1/30 + (50 - 66.6)^2/S_{xx}]} = 2.757$。加上 $t_{.975,28}(2.757)$。

解析

6.993 是殘差均方，不必先平方。

★ 精選 · 9.8

同一新點求平均信賴區間及個別預測區間。問 ① 樣本大時前者寬趨零；② 後者寬趨零；③ 後者較寬。

參考解答

一般固定設計資訊持續增加、誤差變異為正時，①③成立，C。

解析

平均估計的不確定性可以縮小，個別衝擊不會因資料多而消失。

★ 精選 · 9.10

n=15、三個斜率，h*=5.662、s=1.290，點預測 26.500。求 95% 個別預測區間。

參考解答

自由度 11，$26.5 \pm 2.201 \times 1.290\sqrt{1+5.662}$，約為 (19.17,33.83)。

解析

新點的 h* 可超過 1；訓練觀察自身帽子矩陣的對角線才受 0 到 1 限制。

★ 精選 · 9.11

同圖有三條區間帶：第 1 帶較寬，第 2 帶較窄，兩者都沿迴歸線，另有第 3 帶。判斷第 1、2 帶何者估平均、何者預測個體。

參考解答

第 1 為 PI、第 2 為 CI，原題 B。

解析

同一信賴水準、同一位置時，比較半寬公式即可，不需要根據有幾個點落在帶外猜答案。

TERMS

本章中英術語

中文	English	解題時的意思
信賴區間	confidence interval	此處指給定特徵的母體平均反應區間。
預測區間	prediction interval	容納下一筆觀察自身波動的區間。
外推	extrapolation	預測值所在區域超出訓練資料涵蓋範圍。

練習 · 9.1

模型截距 10.29，兩斜率為 −0.29、0.91。當兩個特徵為 10、5 時，預測多少？

參考解答

$10.29 - 0.29(10) + 0.91(5) = 11.94$。

解析

這是點預測；不能把它當成一定會實現的個別值。