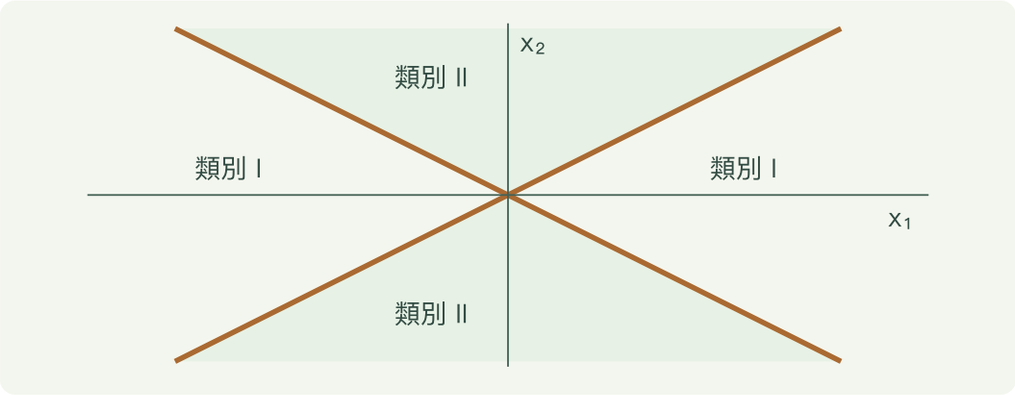
概念 01

先知道理論下限：貝氏分類器與決策邊界



原題 15.4 的邊界有兩條。從原點沿橫軸向左右移動，是第 I 類機率較高的區域；原點的分式本身未定義。

若已知每一類的真實條件機率 $p_j(x) = P(Y = j \mid X = x)$，預測類別 a 的錯誤機率就是 $1 - p_a(x)$。在錯分代價相同時，選最大的條件機率可讓錯誤最小。因此貝氏分類器是 $a^*(x) = \arg\max_j p_j(x)$，其全體錯誤率為

$$R^* = E_X\left[1 - \max_j p_j(X)\right].$$

外層平均不能略過，常見客群應比罕見客群有更大的權重。即使條件機率完全已知，只要同一客群中有不同結果，最佳規則也可能猜錯。這就是分類的不可約誤差。兩類等代價的邊界在 $p = 1/2$；多類的邊界須有兩類並列**最高**，兩條機率曲線相交卻都低於第三類時不是決策邊界。若漏判高風險客戶的成本特別高，應最小化期望成本，不一定使用 1/2。

★ 精選 · 15.1

1、2、3、4 年以上四組各有 450、240、200、110 張保單，續保率分別 40%、60%、70%、75%。按年數預測續保，求最佳分類錯誤率。

參考解答

$0.45(.40) + .24(.40) + .20(.30) + .11(.25) = .3635$。

解析

第一組預測不續，其餘組預測續。先找各組較少數事件的機率，再依人數加權。

★ 精選 · 15.2

棋手七組占比分別 .01、.05、.10、.20、.30、.20、.14。勝率依序 .99、.90、.79、.50、.32、.15、.03；和率 .01、.05、.12、.30、.37、.36、.13，其餘為負。求貝氏錯誤率。

參考解答

0.4395。各組最可能結果依序為勝、勝、勝、勝、和、負、負；各組錯誤率為 .01、.10、.21、.50、.63、.51、.16，乘各組占比後相加。

解析

必須算出輸的機率再比較三類；不能只比較贏和和棋。

★ 精選 · 15.3

讀書時數 $H \sim U(100, 900)$，通過率 $h/(150+h)$。求最佳分類錯誤率。

參考解答

約 0.2632。分界為 150。$R^* = \frac{1}{800}[\int_{100}^{150} \frac{h}{150+h} dh + \int_{150}^{900} \frac{150}{150+h} dh]$。第一個積分用 $h/(150+h) = 1 - 150/(150+h)$，得 $[50 - 150\log(1.2) + 150\log(3.5)]/800$。

解析

積的是預測錯的機率；分界兩側預測類別不同。

★ 精選 · 15.4

兩類中，第 I 類機率為 $x_1^2/(x_1^2+4x_2^2)$。求邊界與分類區域。

參考解答

邊界 $x_2 = \pm x_1/2$，原點公式未定義。當 $|x_1| > 2|x_2|$ 時預測 I，反之為 II。

解析

令機率等於 1/2，移項得到平方相等，所以有兩條線，不能只取正根。

★ 精選 · 15.5

收入 $x > 0$。Susan 與 Jack 的條件機率為 $x/(100+x)$ 與 $(100x+3600)/(100+x)^2$，其餘選 Mae。求三人之間的決策邊界。

參考解答

Mae 機率為 $6400/(100+x)^2$。同乘正分母後比較 x^2+100x、$100x+3600$、6400：$0 < x < 28$ 選 Mae，$28 < x < 60$ 選 Jack，$x > 60$ 選 Susan；28、60 並列。

解析

Susan 與 Mae 在約 44.34 相交，但此處 Jack 更高，不是分類邊界。

概念 02

沒有真實機率時，用近鄰投票

在新點 x 附近找 K 個最近的**訓練觀察**，稱為 $N_K(x)$。以該區域中類別 j 出現的比例估條件機率：

$$\hat{p}_j(x) = \frac{1}{K} \sum_{i \in N_K(x)} \mathbf{1}(y_i = j).$$

常用歐氏距離 $d(x,z) = \sqrt{\sum_l (x_l - z_l)^2}$。只需排序時可以比較平方距離。里程用公尺或公里，本來不該改變風險；但距離會受單位支配，故應依問題決定尺度並用訓練集的統計量標準化。對等距點、平票應先約定處理方式；用奇數 K 只保證二分類投票不平手，不會消除距離並列。

$K = 1$ 時邊界能繞著單一點轉，靈活、低偏差但對樣本敏感；K 增大時局部平均平滑，變異下降但可能掩蓋小區域的真正差異。$K = n$ 時所有點的預測都一樣。**即：K 決定願意把多遠的人當成相似，應以驗證集或交叉驗證選 K。**

CA 複習例 | 訓練錯誤與真正預測不同。 影片用出發時間、氣溫預測通勤是否超過 26 分鐘。找三近鄰時，先找距離最近的三筆，再依長、短通勤的票數決定類別。若評估訓練錯誤，當前觀察可成為自己的鄰居；影片的四筆投票例錯一筆，錯誤率為 25%。這個數字不是未來通勤的錯誤率，後者應以留出資料估計。

★ 精選 · 15.6

K 增大時，① 方法更靈活、② 訓練錯誤通常增加、③ 測試錯誤通常持續減少。何者正確？

參考解答

僅②。

解析

增加 K 會平滑邊界；訓練誤差沒有必然逐一步單調的保證，測試誤差常有最佳中間值。

★ 精選 · 15.7

A 類座標為 (1,2)、(1,6)、(2,2)、(4,1)，B 類為 (3,4)、(4,5)、(5,3)。以 K=3 判斷 (3,3)。

參考解答

B。最近的三點是 (3,4)、(2,2)、(5,3)，平方距離依序 1、2、4，B 得兩票。

解析

找鄰居時看座標距離，決定類別時才看標記。

★ 精選 · 15.8

x 為 1、2、4、7、11、12、15，類別為 0、0、1、0、1、0、1。以 K=3 求預測為 0 的範圍。

參考解答

$x < 6.5$ 或 $8 < x < 11$；端點須依等距處理規則。

解析

連續移動 x，當第三近鄰被替換，票數才可能改變。6.5 時 2 與 11 等距；8 時 4 與 12 等距；11 時 7 與 15 等距。

★ 精選 · 15.12

訓練 (x,類別)：(−1.6,T)、(−1.5,F)、(−.6,T)、(−.3,T)、(.4,F) 兩筆、(.7,T)、(1.2,T)、(1.3,T)、(2.1,F)。測試 (−1.3,F)、(.9,F)、(1.2,T)。已知 $p_F(x) = e^{-x^2}$，求 K=3 測試錯誤率減去在這些 x 的貝氏錯誤率。

參考解答

約 0.3779，B。三筆 KNN 都預測 T，錯兩筆，故 $2/3$。三筆的 $p_F < 0.5$，平均最小錯誤率為 $\left(e^{-1.69} + e^{-.81} + e^{-1.44}\right)/3 \simeq .2888$。兩者相減。

解析

貝氏誤差是給定 x 的理論錯誤機率，不是用三個實現結果數錯了幾筆。

概念 03

連續反應要平均，不是投票

分類與迴歸都從同一批鄰居取資訊。若希望某區域內的連續反應平方誤差最小，求 $\min_a \sum_{i \in N_K(x)} (y_i - a)^2$。微分得到 $2Ka - 2\sum y_i = 0$，二階導數 $2K > 0$，所以 $\hat{f}(x) = \sum_{i \in N_K(x)} y_i / K$。此式沒有線性斜率，也不會因新點非常遠而任意線性外推。

訓練 MSE 可把當前點列為自己的鄰居；留一驗證必須先移除當前點，兩者結果不同。若特徵很多，局部附近的樣本會變稀，距離的辨別能力可能變差，詳見維度災難。

★ 精選 · 15.15

x=4、7、12、14、15、21、22，反應 3、8、15、22、30、40、53。只用 x=4、12、14、15、22 訓練 K=2。求訓練、測試 MSE。

參考解答

訓練預測依訓練順序為 9、18.5、26、26、41.5，平方差總和除以 5 得 42.5；測試 x=7、21 預測 9、41.5，$[(9-8)^2+(41.5-40)^2]/2=1.625$。

解析

這一次測試集只有兩筆，測試誤差低於訓練並不矛盾；不代表未來所有資料表現都同樣好。

TERMS

本章中英術語

中文	English	解題時的意思
貝氏錯誤率	Bayes error rate	真實條件機率已知、零一損失下的最低分類錯誤率。
決策邊界	decision boundary	最佳預測類別切換的特徵位置。
近鄰	nearest neighbors	依指定特徵距離最接近預測點的訓練觀察。

練習 · 15.9

沿用 15.8 的資料，K=7 時求這七筆的分類錯誤率。

參考解答

$3/7$。七點全投票，四筆為 0，因此每一筆都預測 0。

解析

即使點的位置不同，全樣本當鄰居時結果相同。

練習 · 15.10

(3,2) 到八點依序距離 1.5、7.5、4.2、3.1、9.2、1.0、7.3、1.1；標記 P、N、U、U、N、U、N、P。用 K=1、3、7 分別預測。

參考解答

依序 U、P、U，即 D。

解析

最近一筆 U；前三筆 U、P、P；七筆只排除最遠的 N，故 U 有 3 票，N 與 P 各 2 票。

練習 · 15.11

新點 (0,5) 最近五筆距離為 0、1.4、2.0、2.8、2.8，依序標記 Yes、No、No、Yes、Yes。估 K=5 的 Yes 機率。

參考解答

$3/5 = 0.6$，C。

解析

距離為零的觀察仍是一票；本題使用等權 KNN，並非依距離倒數加權。

練習 · 15.13

150 點分三類，95 點訓練、55 點測試。K 從 70 增到 95，測試錯誤快速上升，為什麼？

參考解答

C。K 接近 95 時，不同位置幾乎使用同一批訓練鄰居；到 95 時全部預測成多數類。

解析

這是過度平滑的欠擬合，不表示任意增加 K 都必然變差。

練習 · 15.14

x=5、8、15、22、30，反應為 4、1、10、16、30。求 x=12 的三近鄰迴歸估計。

參考解答

$(10+1+4)/3=5$。最近的 x 為 15、8、5。

解析

平均的是反應，不是解釋變數。