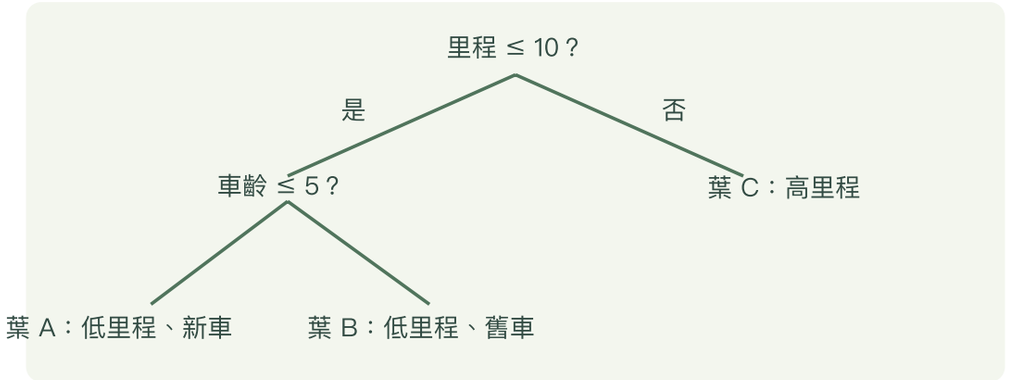
概念 01

用問題劃出區域：從樹讀到預測



自設示意：落入葉 A 要同時通過兩個條件。里程門檻出現於根節點，並不代表它對所有區域都有相同的線性效果。

問題：同一個價格變動對不同客群可能有不同效果，要怎麼讓模型自己找到這些組合？決策樹（decision tree）從所有資料所在的根節點開始，每一步問一個是非問題。被繼續分割的地方是內部節點，連線是分支，停止分割的地方是終端節點（葉）。一筆資料只會沿一條路走到一個葉。

對數值變數，一次切割只看某個 X_j 是否小於門檻 s；對類別變數，判斷是否屬於指定的類別集合。前者在數值空間裡畫出平行於座標軸的邊界，後續切割只作用於目前區域，因此葉為這些條件的交集。以房屋為例，先問住宅型態，再只對某一類問面積門檻，便表示「面積的作用依型態而異」。可用不同順序問出相同區域，樹的結構與統計因果關係是兩回事。

迴歸樹給區域 R 一個固定預測 c。若目標是最小化區域內殘差平方和（RSS），微分得 $\frac{d}{dc}\sum_{i\in R}(y_i-c)^2 = 2n_R(c-\bar{y}_R)$，二階導數為 $2n_R > 0$，故最佳常數就是區域的平均。分類樹若以每筆錯判代價相同為前提，預測類別 k 會錯 $n_R - n_{Rk}$ 筆，故選區域內最多數的類別。**即：樹用條件決定「跟誰比」，再用同一葉的資料決定「猜什麼」。**

★ 精選 · 16.2

汽座銷量樹：首問架位是否差或中等；若否，改問價格是否至少 110，是則葉值 9.2、否則 12（千件）。架位好、價格 120、年齡 57、廣告 12，預測多少？

參考解答

9.2 千件（D）。

解析

架位好→首問否；120≥110→是；直接讀此葉。年齡與廣告不在所走路徑。

★ 精選 · 16.8

九筆 (R, X, Y, Z) 為 (4.75,M,A,2)、(4.67,F,A,4)、(4.67,M,D,1)、(4.56,F,D,3)、(4.53,M,B,2)、(3.91,F,C,2)、(3.90,F,B,5)、(3.90,M,D,5)、(3.89,M,B,1)。$Z \le 3$ 者依 Y 是否 A 或 B 分到 T1/T2；其他依 X 是否 F 分到 T3/T4。求四葉預測。

參考解答

依次為 4.39、4.38、4.29、3.90（A，四捨五入）。

解析

T1 平均 (4.75+4.53+3.89)/3；T2 平均 (4.67+4.56+3.91)/3；T3 平均 (4.67+3.90)/2；T4 僅一筆 3.90。

概念 02

如何長樹：遞迴二分與分割收益

對目前區域 R，試每個變數和能將資料分成兩個非空集合的切點，令 $L = R \cap \{X_j < s\}$、$H = R \cap \{X_j \geq s\}$。葉的最佳預測剛剛已求出，所以可直接比較各候選的 $RSS_L + RSS_H$。排序後相鄰不同觀察值之間的任何切點給出同一種分組，不必試無窮多個實數。

為什麼訓練 RSS 不會因切割而上升？把 $y_i - \bar{y}_R$ 改寫為 $(y_i - \bar{y}_L) + (\bar{y}_L - \bar{y}_R)$，左區第一項加總為零，右區亦然。因此

$$RSS_R - (RSS_L + RSS_H) = \frac{n_L n_H}{n_L + n_H}(\bar{y}_L - \bar{y}_H)^2 \geq 0.$$

新葉平均越不同、且兩邊都有足夠觀察，切割收益越大。演算法每次選當下最佳切割，因此是貪婪法：沒有保證選到所有可能樹中的最佳者。達到節點最小樣本數、最大深度等條件就停止。若切到每個葉只有一筆，訓練資料看起來完美，卻容易把隨機誤差當訊號；同一批資料小幅改變，整個分割順序可能跟著改變。

★ 精選 · 16.5

四筆 (X, Y) 為 (3,8)、(6,6)、(0,8)、(1,5)。以平方損失做一次遞迴二分，兩組各有哪些點？

參考解答

只把 (0,8) 分到第一組；其餘三點同組。

解析

排序後可用 0.5、2、4.5 三個代表切點。第一案 RSS 為 $(5-19/3)^2+(8-19/3)^2+(6-19/3)^2=14/3$；後兩案分別為 6.5、6。因此第一案最小。

★ 精選 · 16.6

六筆 (X_1, X_2, Y) 為 (1,0,1.2)、(2,1,2.1)、(3,2,1.5)、(4,1,3.0)、(2,2,2.0)、(1,1,1.6)。I–V 分別測試 $X_1 < 1, X_1 < 4, X_2 < 0, X_2 < 1, X_2 < 2$。哪個首切點最佳？

參考解答

II，切在 $X_1 < 4$（B）。

解析

I、III 使一邊為空。II 把反應 3.0 單獨成葉，剩餘平均 1.68，RSS=0.548；IV、V 分別為 1.412、1.9325。比較的是兩葉總 RSS。

概念 03

成本複雜度剪枝與交叉驗證

「葉越多，訓練誤差越低」不是選模型的理由。先長出一棵大樹，再比較其子樹 T 的目標 $C_\alpha(T) = RSS(T) + \alpha|T|$；$|T|$ 是葉數而非內部節點數。把一棵含 k 個葉的子樹改成單葉，RSS 增加 ΔRSS，卻省下 $\alpha(k-1)$ 的懲罰。只要 $\alpha \geq \Delta RSS/(k-1)$，小樹就不比原樹差。每一步刪除這個比值最小的分枝，得到最弱連結剪枝的巢狀子樹路徑。$\alpha = 0$ 時沒有複雜度罰則，α 越大越偏好簡單樹。

在訓練集內做交叉驗證：每折用其他折重新長樹、剪枝，在被留出的折計算損失；選擇平均驗證誤差合適的 α，再以全部訓練資料重擬。最後用未曾參與調參的測試集評估。若用測試結果挑葉數，同一份資料就兼做選擇與評估，會高估泛化能力。

例：已分開的兩葉 RSS 是 13.2，合併時 13.875，少一葉的代價是 0.675；$\alpha > 0.675$ 時值得合併，等號時兩樹並列。**即：剪枝把「這次多切一刀能少犯多少錯」與「多留一個葉的成本」放在同一尺度上比。**

CA 複習例 | 剪掉的是整個子樹。 從大樹移除一個內部切分，兩個或更多葉子會變成一個區域，原來不同的預測必須合併。比較殘差平方和增加多少，以及少掉幾個終端節點；驗證資料用來選懲罰程度，而不是證明最大或最小的樹一定最好。

★ 精選 · 16.9

完整樹有五葉，RSS 分別為 82、81、11、20、58。S 合併前兩葉後 RSS=251，X 合併後兩葉後 RSS=86；T 合併後三葉後 RSS=209。根的 RSS=486。$\alpha = 9$，選 I 不剪、II 剪 S、III 剪 T、IV 剪 X、V 同剪 S 與 X。

參考解答

剪 X（IV，D）。

解析

I–V 的 RSS 加每葉 9 的成本依次為 297、376、399、296、375。剪 X 使 RSS 增 8，卻省 9，淨成本少 1。

★ 精選 · 16.11

相鄰兩葉的反應值為 (2,3,3,4,5) 與 (2,4,6)。若此為最適合剪的分枝，最小何值的 α 可接受合併？

參考解答

0.675（臨界點兩樹同成本）。

解析

兩葉平均 3.4、4，總 RSS=13.2；合併平均 3.625、RSS=13.875。僅少一葉，故臨界懲罰為 13.875−13.2。

概念 04

分類樹：純度、熵、偏差與錯誤率

令 $p_{mk} = n_{mk}/n_m$ 為葉 m 中類別 k 的樣本比例。猜最多數類別的錯誤率為 $E_m = 1 - \max_k p_{mk}$。它只看最大比例，無法靈敏地辨認其他類別分布的改變。另一做法是依類別比例隨機猜，再與另一獨立抽出的標籤比較；兩者恰好相同的機率是 $\sum_k p_{mk}^2$。因此基尼不純度為 $G_m = 1 - \sum_k p_{mk}^2 = \sum_k p_{mk}(1 - p_{mk})$。對二元分類即 $2p(1-p)$。

若用模型給真實類別的機率衡量預測，機率越小，損失 $-\log p$ 越大。葉內平均此損失得到熵 $H_m = -\sum_k p_{mk} \ln p_{mk}$，規定 $0 \ln 0 = 0$。純葉只有單一類，兩個不純度都為零；多類均勻時較高。評估切割必須以各葉樣本比重加權，例如兩葉占 60%、40%，不能直接取兩個熵的算術平均。

例：父節點 16 A、4 B，錯誤率 0.2、基尼 0.32；切成 10 A 與 6 A、4 B 兩組，兩葉仍猜 A，整體錯誤率未變，加權基尼卻降為 $0.5(0) + 0.5[2(0.6)(0.4)] = 0.24$。因此長樹可用基尼或熵找有潛力的分割；若最後關心命中率，可以用驗證分類錯誤率挑剪枝大小。

分類樹偏差來自葉內對數概似：$D = -2\sum_{m,k} n_{mk} \ln p_{mk} = 2\sum_m n_m H_m$；講義的平均殘差偏差將它除以 $n - |T|$。迴歸樹對應值為 $RSS/(n - |T|)$。應先看題目要「每葉加總」「全樹加權」或「每自由度平均」，三種答案不相同。

★ 精選 · 16.10

預測考試初次通過。在 $(X_1, X_2) = (0,0), (1,0), (0,1), (1,1)$ 四組，「通過 / 未通過」人數依次為 5/20、10/10、7/9、6/4。應依哪個變數先切？

參考解答

依 X_1。

解析

X_1 切割兩葉為 (12,29)、(16,14)；X_2 切割為 (15,30)、(13,13)。分別計算 $\sum_m (n_m/71) 2p_m(1-p_m)$ 得 0.4494 與 0.4648，前者較低。

★ 精選 · 16.18

100 張保單有 30 張失效。切法一的兩葉為 20 張中 12 張失效、80 中 18；切法二為 10 中 8、90 中 22。依基尼、熵、錯判數，是否分別偏好切法一？

參考解答

三項皆否（E）；三種準則均偏好切法二。

解析

依葉大小加權，切法一、二的基尼為 0.3750、0.3644；自然對數熵為 0.5611、0.5506。各葉猜多數類，錯判數分別為 8+18=26 與 2+22=24。

概念 05

袋裝法、袋外誤差與變數重要度

單棵深樹偏差通常低，但估計易因抽樣波動而改變。袋裝法（bagging）用 bootstrap：從 n 筆資料有放回抽 n 次，重做 B 組，分別擬合深樹。在同一個 x 上，迴歸取 $\hat{f}_{bag}(x) = B^{-1}\sum_b \hat{f}_b(x)$；分類可採多數投票。每次抽樣後放回，某筆會重複出現，另一些筆可能完全沒抽到。

若各樹預測變異為 v、兩兩相關係數為 ρ，展開平均的變異得到 $v[B + B(B-1)\rho]/B^2 = v[\rho + (1-\rho)/B]$。樹數增加能壓低不共享的波動，但相關部分留下來。固定學習規則時，多加樹主要讓平均更穩，不是像加深單棵樹那樣持續增加擬合自由度。

某筆一次沒被抽到的機率 $1 - 1/n$，整組 n 次都沒被抽到的機率 $(1-1/n)^n \to e^{-1} \approx 0.368$。對每一筆只用沒有抽到它的樹產生袋外（OOB）預測；再將各筆的平方誤差或錯判指標平均，估計樣本外表現。重要度可用某特徵在各樹分割時造成的 RSS 或基尼下降量加總並平均，也可置換袋外資料該特徵後觀察損失增幅。前者量到訓練切割貢獻，後者量到預測依賴；相關特徵會分攤或遮蔽重要度，兩者都不能單憑排序下因果結論。

概念 06

隨機森林與提升法：同樣多棵樹，改進方式不同

隨機森林（random forest）除了 bootstrap，還在**每個節點**從 p 個變數不放回抽 m 個，再從其中找最佳切割。單一強預測變數沒有進入這次候選集的機率為 $(p-m)/p$。這使所有樹不必都靠同一強變數開頭，可降低前述 ρ；太小的 m 也可能讓單樹變弱，故以驗證衡量取捨。若 $m=p$，其餘設定相同就回到袋裝法；分類常見起點為 $\sqrt{p}$，並非必須。

提升法（boosting）讓新樹補上一輪未學到的部分。以平方損失為例，$\frac{1}{2}(y-f)^2$ 對目前預測 f 的負梯度為 $y-f$，所以用殘差當下一棵樹 h_b 的反應。從 $f_0=0$（或常數平均）出發，更新 $f_b=f_{b-1}+\lambda h_b$，殘差變成 $r_i^{(b)}=r_i^{(b-1)}-\lambda h_b(x_i)$。逐輪相加得到 $f_B=f_0+\lambda\sum_{b=1}^{B}h_b$，不是平均 B 棵樹。

調整三項：B 控制輪數，用驗證集或交叉驗證選停止點；$0<\lambda\le 1$ 控制步長，越小常需越多輪；每樹有 d 次二元分割、$d+1$ 葉。$d=1$ 時每棵樹只依賴單一變數，加總仍為加法模型；更深的路徑才能形成交互作用。袋裝與森林可平行估計，提升必須逐輪更新。單樹較易呈現規則，集成通常提高穩定性或準確度，代價是解釋不再是一條簡單路徑。

★ 精選 · 16.13

森林每次自 p 個特徵抽 m 個。I 若 $m = p$ 等同袋裝；II 不考慮最強特徵的機率為 $(p-m)/p$；III 典型設定為 $p/2$。

參考解答

I、II 正確（B）。

解析

不放回等機率抽樣使入選機率 m/p。分類常見的經驗起點是平方根，不是固定一半，更不是定理。

★ 精選 · 16.23

提升迴歸的學習率 0.2，新資料 $X_1, \ldots, X_7 = (N, 6, Y, 4, 0.5, 0.25, 6)$。四樹依序沿路徑：① X2≥1、X3=Y、X1≠Y→3.14；② X4≥2.67、X3=Y、X4≥3、X7<8→3.5；③ X7<6.5、X1≠Y→2.81；④ X6<1→0.34。初始值為零，求預測。

參考解答

1.958，低於 2（A）。

解析

每棵樹是殘差修正，將縮小後的貢獻相加：$0.2(3.14 + 3.5 + 2.81 + 0.34) = 1.958$。不要再除以 4。

TERMS

本章中英術語

中文	English	解題時的意思
遞迴二分	recursive binary splitting	在當前區域選變數與切點，分出兩個子區域。
袋外觀察	out-of-bag observation	在某棵樹的自助抽樣訓練集中未被抽中的資料。
提升法	boosting	依序加入弱模型，修正目前模型尚未解釋的部分。

練習 · 16.1

判斷：I 決策樹易解讀；II 可圖示；III 一般較容易向非技術人員解釋單樹而非線性迴歸。

參考解答

三項皆是（E）。

解析

一筆資料可沿條件走到葉節點，不需同時解釋多個係數。這是溝通優點，不代表預測一定較準。

練習 · 16.3

比較三張車險的預估對數賠款。年齡類別 1 直接落在 8.146；類別 5 且車齡至少 2.5 時，車齡小於 3.5 落在 7.771，否則 8.028。I=(1,4)、II=(5,5)、III=(5,3)，由低到高排序。

參考解答

III < II < I（E）。

解析

依序得 8.146、8.028、7.771。題目要比較對數，指數化是單調轉換，不會改變順序。

練習 · 16.4

鴨重迴歸樹先分年齡是否大於 7.5；年輕母鴨 0.80、年輕公鴨 0.90；年長公鴨翼展大於 5.3 時為 1.25 公斤。X=(7歲、公、5.5)、Y=(5歲、母、5.8)、Z=(8歲、公、5.7)。比較三者。

參考解答

Y < X < Z（C）。

解析

X=0.90，Y=0.80，Z=1.25。翼展只在年長公鴨分枝起作用。

練習 · 16.7

樹的首問是 $X_1 < t_1$（假走 A）；真時再問 $X_2 < t_2$（假走 B）；剩下再問 $X_1 < t_3$（真走 C、假走 D）。對應的二維分區是什麼？

參考解答

原題圖 B。

解析

$X_1 \geq t_1$ 全屬 A；其餘 $X_2 \geq t_2$ 屬 B。在 $X_2 < t_2$ 且 $X_1 < t_1$ 中，$X_1 < t_3$ 為 C，其餘為 D。先畫根切線，再只在被切的區域內畫下一條線。

練習 · 16.12

判斷 I 遞迴二分可能過度擬合；II 分裂越多通常變異越小；III 成本複雜度參數為零時可留下很大的樹。

參考解答

I、III 正確（C）。

解析

切割通常降低訓練誤差、增加對樣本的敏感度；零懲罰時不會因多一葉而付出成本。

練習 · 16.14

三區域的 A/B/C 類樣本數依次為 I：72/22/6，II：55/25/10，III：20/32/28。求區域 I 分類錯誤率。

參考解答

0.28。

解析

選多數類 A，錯判 22+6 筆，除以該區 100 筆。

練習 · 16.15

三區域的 A/B/C 類樣本數依次為 I：72/22/6，II：55/25/10，III：20/32/28。求區域 II 基尼指數。

參考解答

約 0.5370。

解析

總數 90，$G = 1 - [(55/90)^2 + (25/90)^2 + (10/90)^2] = 0.537037$。

練習 · 16.16

三區域的 A/B/C 類樣本數依次為 I：72/22/6，II：55/25/10，III：20/32/28。求區域 I 的自然對數熵。

參考解答

約 0.738436。

解析

$H = -0.72\ln 0.72 - 0.22\ln 0.22 - 0.06\ln 0.06$。對數底數若換成 2，數值會變，排序不變。

練習 · 16.17

分類樹先以 $X_1 < 21$ 分出第一葉；剩餘樣本依 $X_2 = Y$ 分兩葉。七筆 $(X_1, X_2, \text{標籤})$ 為 (12,Y,T)、(23,N,F)、(4,Y,F)、(32,Y,F)、(22,N,T)、(30,Y,T)、(18,N,T)。三種指標分別對各葉直接加總，大小關係為何？

參考解答

熵 > 基尼 > 錯誤率（A）。

解析

三葉 T 比例為 2/3、1/2、1/2。錯誤率總和=4/3，基尼=4/9+1/2+1/2=13/9，熵約 2.0228。本題是「各葉加總」而非通常的樣本數加權。

練習 · 16.19

判斷 I 易解釋方法通常更有彈性；II 重視解釋時 lasso 相對袋裝具優勢；III 提高彈性必改善未見資料的準確度。

參考解答

只有 II（B）。

解析

線性 lasso 的係數及變數選取較易說明；多樹平均難以逐項解釋。訓練誤差改善不保證測試誤差改善。

練習 · 16.20

判斷 I 森林若每次考慮全部特徵則為袋裝；II 同一棵樹每一節點都使用同一特徵子集；III 降低樹間相關性是森林相對袋裝的一項優點。

參考解答

I、III（C）。

解析

在每個節點重新抽特徵，並非每棵樹只抽一次。樹間相關下降可降低平均預測的變異，並非每一資料集都保證勝出。

練習 · 16.21

散點呈近似拋物線。判斷何者能合理支持模型選擇：A 數值變數足以指定森林、B 非直線就該用森林、C 異變異必排除 GLM、D 有關聯就該用森林、E GLM 可納入多項式關係。

參考解答

E。

解析

在 GLM 的線性預測式中加入 x^2，仍對係數線性，對 x 則是曲線。僅憑數值型或相關性不足以決定最佳方法。

練習 · 16.22

測試誤差隨樹數而變，曲線 I 早早穩定於較高值，II 也趨穩但較低，III 隨迭代仍逐漸改善。題目要推測最可能對應的集成方法。

參考解答

I 袋裝、II 隨機森林、III 提升（C）。

解析

袋裝與森林是對同類估計取平均，增加樹數主要減少模擬誤差；提升逐輪修正殘差。曲線形狀只是本題線索，不是唯一可辨識演算法的定理。

練習 · 16.24

三個連續平面分類區域中，I 的兩類由軸平行矩形構成，II、III 的分界含非軸平行邊。有限棵節點的一棵分類樹能在哪個整個平面上恰好零誤差？

參考解答

只有 I（A）。

解析

有限次軸向切割只會形成有限個軸平行矩形；斜邊或曲線可用階梯逼近，但不能在整個連續區域精確重現。

練習 · 16.25

就本課方法的典型彈性與解釋性取捨，選正確說法：A 普通線性迴歸高度彈性；B lasso 比同特徵的未懲罰線性模型更彈性；C 深樹袋裝彈性低；D 高彈性且易解釋是此處比較方法的典型組合；E 以上皆非。

參考解答

E。

解析

線性模型受函數形式限制，lasso 再限制係數；袋裝多棵深樹可表示複雜預測。這是課本比較各方法的通常特性，不是排除任何易解釋的複雜模型。

練習 · 16.26

判斷 I 袋裝與森林主要不同在各次切割可考慮的變數數；II 單棵樹常較森林高變異；III 森林降低樹間相關是可能勝過袋裝的原因。

參考解答

三項皆正確（D）。

解析

多樹平均有助穩定；隨機限制候選變數能降低單一重要變數反覆支配各棵樹造成的相關。