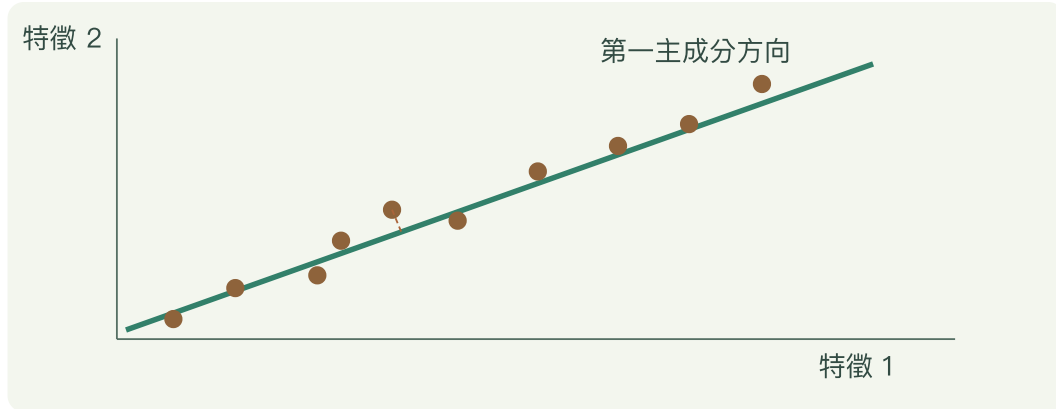
概念 01

中心化、負荷量與分數



原創示意：分數是沿軸的座標，重建誤差是點與軸的垂直距離。軸的正負號可同時翻轉，重建位置不變。

問題：若收入與保額高度相關，用兩個數字描述每位保戶是否重複？主成分分析（PCA）不看反應值，只在解釋變數間尋找資料雲展開的方向。先將每欄減去其平均，記中心化矩陣為 X，第 i 列便是該人相對於平均保戶的位置。中心化不改變變異數，卻讓第一方向通過資料中心。

給一單位方向 $\phi = (\phi_1, \ldots, \phi_p)^\top$。觀察 i 的座標為內積 $z_i = x_i^\top \phi$，稱為分數（score）；係數 ϕ_j 稱負荷量（loading），是方向對各欄位的權重。各欄已中心化，因此 $\bar{z} = 0$。注意是平方和等於 1，不是權重和等於 1。若不限制長度，把所有權重乘十就能把分數變異放大一百倍，問題便沒有有限答案。

令 $S = X^\top X/(n-1)$，分數的樣本變異為 $z^\top z/(n-1) = \phi^\top S \phi$。最大化它且要求 $\phi^\top \phi = 1$，拉格朗日式為 $\phi^\top S\phi - \lambda(\phi^\top \phi - 1)$，微分給 $S\phi = \lambda\phi$。故第一個負荷向量取最大特徵值的單位特徵向量，分數的變異就是特徵值。後續方向加上與先前方向垂直的限制，依特徵值遞減選取；分數之間不相關，因 $\operatorname{Cov}(z_a, z_b) = \phi_a^\top S \phi_b = \lambda_b \phi_a^\top \phi_b = 0$。不相關不等於獨立。

中心化後各列和為零，秩最多 $\min(p, n-1)$，所以至多這麼多個非零主成分。舉例，第一方向為 $(0.9143, 0.4050)$，第一筆中心化資料 $(-24, -21)$ 的分數約 -30.45。負號是指投影在選定方向的反側，不是離線的距離；在二維中離 PC1 直線的距離為另一個分數的絕對值。**即：負荷量指定尺要朝哪裡放，分數是每個人在這把尺上的刻度。**

★ 精選 · 17.2

100 筆四變數資料取 PC1、PC2。下列何者必然成立：I 兩組分數平方和相等；II 兩負荷向量內積為零；III 兩負荷向量的平方長度總和為 1。

參考解答

只有 II（B）。

解析

第一方向變異可大於第二，不必相等；每向量長度都是 1，兩者平方長度的和為 2。

★ 精選 · 17.3

兩變數五筆資料 (1,5)、(2,7)、(4,4)、(6,3)、(9,1)，PC1 負荷 (−0.8297,0.5583)。求第一筆分數。

參考解答

3.37928。

解析

欄平均為 (4.4,4)，內積為 $-0.8297(1-4.4)+0.5583(5-4)$。若直接用原值，會漏掉移動原點。

★ 精選 · 17.5

兩筆資料為（溫度, X1, X2）=(5,4,6)、(10,8,2)。第一方向兩負荷中，第一個為 $1/\sqrt{2}$，第二個為負。求第一筆分數。

參考解答

約 −2.828。

解析

不使用溫度；中心化後是 (−2,2)，單位長度決定第二個負荷為 $-1/\sqrt{2}$。因此分數 $= -4/\sqrt{2}$。

概念 02

雙標圖如何解讀

雙標圖（biplot）把觀察分數和變數方向放在同一張圖。橫、縱是 PC1、PC2。觀察點的座標是 (z_{i1}, z_{i2})；變數 j 的箭頭由其在兩軸的負荷決定。二者常使用不同邊上的刻度，不能直接把箭頭長度與分數的數字相比。觀察點接近表示「在所顯示的方向上」相似，省略成分仍可能使原資料有差異。

把一筆中心化資料在兩軸上的分數，乘以同一變數在這兩軸上的負荷再加總，就得到該變數的二維近似值。箭頭同向通常表示沿圖中方向有相似變化，若採以變數與成分相關為箭頭的相關雙標圖，且前兩成分解釋得好，夾角餘弦可近似原變數相關。一般軟體會以不同方式縮放分數與負荷；沒有指定尺度時不能把角度當作精確相關係數，也不能保證某人某個原始特徵一定高於平均。

★ 精選 · 17.9

購物雙標圖的衣物與布品箭頭幾乎同向；食物與其他類別有不同方向，Abigael 第一成分分數負，Bradley 的兩分數皆正。判斷 I 衣物與布品有相似變動；II、III 可分別斷定兩人食品消費高於平均。

參考解答

只有 I 有圖形支持（E）。

解析

同向箭頭支持這兩變數在顯示空間的共同變動；僅憑一人一、二成分分數，不能斷定某單項原始金額高於平均，其他特徵與未顯示成分也會影響解讀。

概念 03

最小距離、低秩重建與符號

沿單位方向 ϕ 重建中心化觀察 x_i，其正交投影是 $(x_i^\top \phi)\phi = z_i\phi$。依畢氏定理，殘差平方長度 $\|x_i - z_i\phi\|^2 = \|x_i\|^2 - z_i^2$。對所有人加總，第一項固定，故最大化分數變異恰好等於最小化垂直於直線的平方距離。不同於迴歸只量反應座標上的垂直誤差，PCA 對各變數一視同仁。

保留 M 個正交方向時，對中心化資料的重建是 $\hat{x}_{ij} = \sum_{m=1}^{M} z_{im}\phi_{jm}$。要回到原尺度須加上原欄平均，若先做標準化還要乘回欄標準差。保留所有非零成分則重建精確；只留一部分時，殘差平方總和對應捨棄特徵值的和乘上 $n-1$。例：兩個分數為 $-25.5751, -26.0207$，第一變數負荷為 $0.16741, 0.90061$，其中心化值的二成分近似為 -27.716。

同時把一個方向及其所有分數乘 -1，乘積不變，重建、解釋變異與距離也不變。只有該成分的一些負荷翻號就不是同一方向。若特徵值並列，該子空間內還可以旋轉，不能宣稱每個方向除了符號外都唯一。

★ 精選 · 17.1

判斷 PCA 是否 (I) 給最靠近資料的低維線性空間、(II) 第一成分為平方垂距最小的線、(III) 在給定維度下保留最多變異、(IV) 可用於視覺化。

參考解答

四項皆是（E）。

解析

投影變異最大等價於重建平方距離最小；前兩個方向可作二維圖。

★ 精選 · 17.11

三變數資料的 X1 在前兩個成分之負荷為 −0.85956、0.25890；第 3 筆分數為 −22.5603、−45.9338。用兩個成分近似該筆中心化 X1。

參考解答

約 7.4997。

解析

$(-22.5603)(-0.85956) + (-45.9338)(0.25890)$。用的是同一個變數跨成分的負荷，不是取第一成分的整欄。

★ 精選 · 17.12

三成分中 X1 的前兩負荷為 −0.97932、0.03669。第 4 筆分數 (−37.1131,15.4973,14.6442)，中心化 X1=34；第 5 筆分數 (−46.5435,−14.2271,15.3719)。求第五筆 X1。

參考解答

約 42。

解析

設第 3 負荷 u，第 4 筆滿足 $34 = (-37.1131)(-0.97932) + 15.4973(0.03669) + 14.6442u$，故 $u \approx -0.1990$。套入第 5 筆的相同重建公式。

概念 04

尺度與標準化

換單位會改變 PCA。若將某變數乘 a，它的變異數乘 a^2，與別欄的共變異乘 a；協方差矩陣的特徵方向於是可能翻轉。以金額和件數一起分析時，即使完全沒有改變保戶風險，光把元改寫成千元就可能改變主成分。

標準化 $u_{ij} = \left(x_{ij} - \bar{x}_j\right)/s_j$ 使每一欄變異為 1，此時 PCA 用的是原資料的相關矩陣。標準化和中心化不同：中心化只移原點，不消除尺度差異。若所有變數原本共用有經濟意義的尺度，且希望變動金額大的欄位多占權重，保留原尺度也合理。若某欄變異為零，不能除以其標準差，需先移除或單獨處理。用於未來樣本時，保存訓練集平均、標準差及負荷向量，不能用測試集重新估計它們。

★ 精選 · 17.10

同四欄資料的未標準化及標準化雙標圖中，X1 與 X2 同向，X3 在未縮放圖中主導變異但縮放後明顯減弱。第 24 筆與 X4 箭頭大致同向。判斷 I X1 與 X2 比與 X3 更相關；II 題圖支持 X3 原變異最大；III 可斷言第 24 筆 X4 明顯大於平均。

參考解答

依題圖判讀 I、II（B）。

解析

I、II 是兩圖合看支持的相對趨勢；若只給一般雙標圖，箭頭長度不等於未縮放變數的精確變異。III 忽略未顯示成分，不能只由方向斷定其原始值。

概念 05

解釋變異比例、陡坡圖與預測

每個方向解釋的變異是 λ_m，全部原變數總變異是 $\mathrm{tr}(S) = \sum_j S_{jj} = \sum_r \lambda_r$，因此

$$\mathrm{PVE}_m = \frac{\lambda_m}{\sum_r \lambda_r} = \frac{\sum_i z_{im}^2}{\sum_{i,j} x_{ij}^2}.$$

使用 n 或 $n-1$ 定義變異，只要分子與分母一致，比例不變。現有二變數例的平方和為 5610 與 1520，若分母都用 20，總變異 356.5；第一成分變異 330.31，所以可保留約 92.65% 的變異。標準化後總變異應是變數個數 p。

單一成分的 PVE 隨成分次序不增，累積值 $\sum_{m=1}^{M} \mathrm{PVE}_m$ 不減。可選達到指定累積門檻的最小 M；或看陡坡圖（scree plot）的彎折處，當邊際貢獻迅速縮小便停止，後者是經驗判斷而非唯一最優解。若用主成分迴歸（PCR），再以訓練資料的成分預測 Y，成分數應另以預測驗證挑選；高變異方向可能和 Y 無關。**即：PCA 保留的是 X 的資訊量，不保證它剛好是預測 Y 所需的資訊。**

CA 複習例 | PVE 的分母為什麼可消掉？ 若所有特徵已中心化，總樣本變異為 $\sum_{ij} x_{ij}^2/(n-1)$，主成分 m 的變異為 $\sum_i z_{im}^2/(n-1)$。兩者做比時 $n-1$ 正好約掉。因此使用同一分母慣例時，改以 n 算兩個變異不會改變比例；只改其中一邊則不行。

★ 精選 · 17.14

四筆標準化資料 (−0.577,1,−1)、(−0.577,1,1)、(−0.577,−1,1)、(1.732,−1,−1)，PC1 負荷 (0.707,−0.500,−0.500)。求其 PVE。

參考解答

約 60.5%，落在 58% 至未滿 63%（C）。

解析

分數依次約 −0.408、−1.408、−0.408、2.225。平方和約 7.264，除以 4 得 1.816；三欄標準化變異總和約 3，因此 $1.816/3 \approx 0.605$。

★ 精選 · 17.17

100 筆四欄資料，相關矩陣中 $r_{14} = -1, r_{12} = 0.93, r_{13} = 0.08, r_{23} = 0.10$。哪種累積 PVE 圖符合？

參考解答

第三個成分即達 100%、第四個增量為零的圖 C。

解析

標準化的 X4 與 X1 互為相反數，故至少有一個零特徵值。其餘三欄的相關子矩陣非奇異，確有三個非零成分。

TERMS

本章中英術語

中文	English	解題時的意思
負荷量	loading	主成分方向在原始變數座標下的權重。
分數	score	單一觀察在該主成分方向的座標。
解釋變異比例	proportion of variance explained	單一主成分變異占資料總變異的比例。

練習 · 17.4

兩欄均已中心化。觀察 (4,10) 的 PC1 分數是 8，第一欄負荷已知為正，求它。

參考解答

第一負荷約 0.8975。

解析

設為 a, b，$4a + 10b = 8$、$a^2 + b^2 = 1$。代入 $b = (8 - 4a)/10$ 得 $116a^2 - 64a - 36 = 0$；取正根。

練習 · 17.6

已中心化的二變數觀察 $(0.4, x_2)$ 分數 0.12，第一負荷 −0.6、第二正，求 x_2。

參考解答

0.45（E）。

解析

第二負荷 $\sqrt{1-0.6^2}=0.8$；解 $-0.6(0.4)+0.8x_2=0.12$。

練習 · 17.7

四欄資料的 PC1 前三個負荷為 0.68、0.65、0.32，第四負荷為負。求中心化觀察 (2,−1,3,5) 的分數。

參考解答

約 1.107（C，最接近 1.1）。

解析

第四負荷取 $-\sqrt{1-0.68^2-0.65^2-0.32^2}\approx -0.1127$。將四個座標與負荷逐項相乘相加。

練習 · 17.8

五張圖為同一二維資料畫出兩軸：I 互相垂直且第一軸沿最長方向；II 交換第一、第二軸；III 軸不垂直；IV 第一軸未沿主要變異方向；V 用曲線作軸。何者可代表 PCA？

參考解答

I（A）。

解析

主軸必為穿過中心的直線、彼此正交，且第一軸投影變異最大，排除其餘四者。

練習 · 17.13

X 與 Y 的 PC1 負荷逐項互為相反數；W 與 X 僅部分符號不同；Z 的負荷大小也不同。判斷 I 符號慣例可解釋 X/Y；II 標準化設定可解釋 Z/Y；III 符號慣例可解釋 W/X。

參考解答

I、II（B）。

解析

整向量翻號才代表同一直線。標準化改變協方差矩陣，可導致完全不同的方向與係數大小。

練習 · 17.15

判斷 I 新增一個成分的個別 PVE 不會下降；II 累積 PVE 不會下降；III 所有成分一起用一定最好理解；IV 陡坡圖能輔助選擇成分數。

參考解答

II、IV（E）。

解析

特徵值依序遞減或相等；每項非負，累積才單調不減。保留全部可能犧牲可解釋性。

練習 · 17.16

500 筆、五個預測變數，給定第一成分分數平方和 750、總變異 4，求第一成分 PVE。

參考解答

按給定總變異為 0.375（C）。

解析

以 $1/n$ 計第一成分變異 $750/500 = 1.5$，再除 4 得 0.375。若五欄均使用相同分母標準化至變異 1，總變異應為 5，該替代假設的答案為 0.30；作答要說明採用哪個給定條件。

練習 · 17.18

四點為 (−2,1)、(−1,−2)、(−1,0)、(4,1)。PC1 負荷 (0.973402,0.229106)。求 PVE。

參考解答

約 0.81944。

解析

資料已中心化；各欄平方和總計 28。四個內積約 −1.718、−1.432、−0.973、4.123；平方和約 22.9443，PVE=22.9443/28。

練習 · 17.19

四變數取四主成分，判斷 I 負荷唯一；II 每個成分負荷平方和為 1；III 四成分解釋全部變異。

參考解答

II、III（D）。

解析

至少有整向量符號不唯一，重根時子空間內方向也不唯一。完整正交基底保留所有投影，不損失變異。

練習 · 17.20

陡坡圖顯示 PC1 解釋超過 60% 但未達 80%，PC2 貢獻略高於 20%。至少要幾個才能達 80%？

參考解答

兩個（B）。

解析

一個不足；前兩個累積超過 80%。題意是累計，不是尋找個別 PVE 超過 80% 的方向。

練習 · Quiz 17-1

第一筆 (−24,−21) 對第一主軸投影分數約 −30.45，求到該主軸直線的垂距。

參考解答

約 9.48。

解析

直角三角形的斜邊平方為 $24^2 + 21^2$，投影長平方約 30.45^2，相減再開根號即垂距。在二維中亦等於第二分數絕對值。