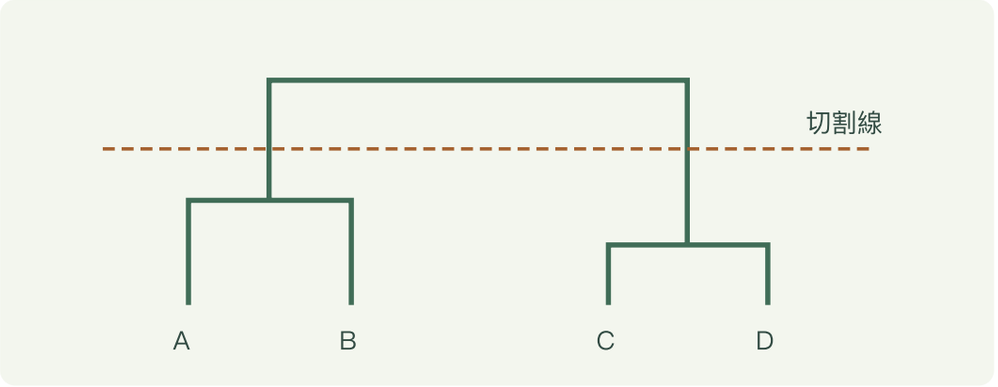
概念 01

群集要回答的問題：觀察、特徵與距離



橫線穿過兩個尚未合併的分支，所以得到 {A,B} 與 {C,D}。比較合併高度要沿縱軸讀，不是比較葉子左右的距離。

問題：有各保戶的年齡、理賠頻率與平均賠款，沒有既定的客群標籤，能否找出消費或風險型態相似的群體？群集分析（clustering）是無監督學習；輸出是分組而非預測既有標籤。將資料矩陣轉置也能對變數分群，此時同一欄在不同保戶上的變化型態才是比較對象。

歐氏距離 $d(i,j)=\sqrt{\sum_h (x_{ih}-x_{jh})^2}$ 衡量數值位置差異。變數從元改為分，該維度距離平方放大一萬倍，因此計算前要比較單位、是否標準化以及是否應按業務重要性加權。若重視消費項目的相對型態，另一選擇是相關距離 $1-r_{ij}$：兩個人的消費向量即使總額不同，也可能高度相關。只有兩個非定值特徵時，兩向量的樣本相關只能為 ± 1，不適合靠此分辨多種相似程度；常數向量的相關更無法定義。

PCA 在找投影軸，群集在分辨哪些觀察是同群。先把資料投影到少數主成分再分群，可能去除雜訊，也可能丟掉對分群重要的低變異方向。若保留完整正交基底且不另改尺度，歐氏距離才不因轉軸改變。

★ 精選 · 18.3

判斷 I 混合模型是 K 平均與階層法的混成；II 標準化只對階層法更重要；III 在少數 PC 上與在全部原始欄分群可能不同。

參考解答

僅 III（C）。

解析

混合模型用機率分布建模；兩種距離方法都受單位影響。截斷主成分改變點距離，群別可變。

概念 02

K 平均：目標、成對公式與中心

先決定 K，尋找互不重疊且覆蓋全部觀察的非空群 $C_1, \ldots, C_K$。若群內各點彼此靠近，就稱該群同質。講義使用群內成對平方距離（含有序的兩種方向）：

$$W(C) = \frac{1}{|C|} \sum_{i \in C} \sum_{i' \in C} \|x_i - x_{i'}\|^2 = 2 \sum_{i \in C} \|x_i - \bar{x}_C\|^2.$$

為什麼有 2？把 $x_i - x_{i'}$ 寫成 $(x_i - \bar{x}_C) - (x_{i'} - \bar{x}_C)$。展開平方後，交叉項的兩個中心化總和皆為零，兩組自身平方項各重複 $|C|$ 次，約去分母得到右式。軟體常報右式去掉因子 2 的群內平方和 WCSS。兩者最優分群相同，但考試問「數值」時要按照指定定義。

若群的代表點是 a，$\sum_i \|x_i - a\|^2 = \sum_i \|x_i - \bar{x}_C\|^2 + |C|\|a - \bar{x}_C\|^2$，所以最佳代表點就是算術平均（質心）。已知各質心時，將每一筆分給距離最小者才可降低總損失。交替做「更新質心 → 依最近質心重新指派」，直到指派不再改變。每步不會增加目標，但只保證局部解；實務常多組初始化並比較相同 K 的最終值。若一群變空要有重新初始化規則。

注意 K 越大最佳 WCSS 不會增加：允許增加一個群，相當於多一個可調整的中心。$K = n$ 時每點單獨成群，損失為零但沒有摘要作用。可綜合肘部圖、重抽樣穩定性、群間分離程度和實際可解釋性來選 K；不能從最小訓練平方和單獨決定。

★ 精選 · 18.6

A={(0,0),(1,2),(2,0),(3,2)}；B={(0,3),(1,5),(2,4)}。求講義有序配對定義下的群內目標總和。

參考解答

26。

解析

兩質心為 (1.5,1)、(1,4)。到質心的平方和分別 9、4，有序成對目標為 $2(9+4)=26$。

★ 精選 · 18.7

點依次是 (5,5),(4,6),(3,0),(5,3),(5,1),(3,6),(2,5)，初始群標籤 2,2,1,1,2,1,2。求第 5 點到最終第 2 群中心的歐氏距離。

參考解答

約 4.743（E）。

解析

初始中心 (3.667,3)、(4,4.25)，重分後第 2 群含 1,2,6,7，中心 (3.5,5.5)；第 1 群中心 (4.333,1.333)，再指派不變。即使第 5 點屬第 1 群，題目要的是它到第 2 群的距離 $\sqrt{(5-3.5)^2+(1-5.5)^2}=\sqrt{22.5}$。

★ 精選 · 18.8

群 1 的點是 (1,3),(0,4),(6,2)，群 2 是 (5,2),(1,6)。求初始分群總群內變異。

參考解答

77.333（C）。

解析

第一群三對平方距離 2、26、40，第二群一對為 32；有序配對後合計 $2[(2+26+40)/3+32/2]$。

★ 精選 · 18.11

判斷 I 群數就選樣本數 n；II 依最小總群內變異選 K；III 最合適 K 依目的而定，沒有普遍唯一方法。

參考解答

只有 III（C）。

解析

增加群數能使訓練損失下降到零，故依其單一最小值會選出沒有摘要價值的單點群。

★ 精選 · 18.12

A={(2,−1),(−1,2),(−2,1),(1,2)}；B={(4,0),(4,−1),(0,−2),(0,−5)}；C={(−1,0),(3,8),(−2,0),(0,0)}。一次更新後最少的一群有幾點？

參考解答

3 點（D）。

解析

先算中心 (0,1)、(2,−2)、(0,2)。每點比三個中心的距離後，新 C 含 (−1,2)、(1,2)、(3,8)，新 A 四點，新 B 五點；最小群為 C。

概念 03

階層式分群、連結方式與樹狀圖

凝聚型階層分群起初每點自成一群，找當前最接近的兩群合併、重算它與各剩餘群的距離，反覆直到只剩一群。合併不能撤回，所以早期選擇影響未來。第 $n-K$ 次合併結束後剩 K 群；毋須事先決定 K 就可先建整棵樹。

給定點距離 $d(i,j)$，單一連結是 $\min_{i\in A, j\in B} d(i,j)$，只要有一個橋接點就可接起很長的鏈。完整連結取最大值，要求最遠兩點也不能太遠，傾向較緊湊的群。平均連結是 $\frac{1}{|A||B|}\sum_{i\in A}\sum_{j\in B} d(i,j)$，必須平均所有跨群配對；質心連結才是 $d(\bar{x}_A, \bar{x}_B)$。兩者通常不同。以 A={0,10}、B={11} 為例，單一、完整、平均距離分別為 1、11、6。

樹狀圖（dendrogram）的垂直合併高度代表該次連結距離；水平排列可交換整枝，不能以相鄰標籤斷言最近。典型單調樹切得越低，群數只增不減。質心法例外：若先合併 (0,0)、(40,0)，高度為 40，質心 (20,0) 到第三點 (20,38) 卻只有 38，便發生高度倒置（inversion）。同距離若未規定如何破除平手，樹也可能不唯一。

即：K 平均直接找某個固定群數的緊密配置；階層式分群找的是一整套逐層包含的分組，並不逐個群數重新最佳化。

CA 複習例 | 切割高度為什麼能改變群數？ 水平切線以下已合併的分支算同群；越往下切，保留越多尚未合併的分支。不同高度只是在讀同一棵樹。相反地，K 平均若改 K，就改變最佳化的中心個數，需要重新配適。

★ 精選 · 18.14

四點 $x_1=(-1,0), x_2=(1,1), x_3=(2,-1), x_4=(5,10)$。完整連結下 {1,2} 與 {4} 距離？

參考解答

約 11.662（E）。

解析

跨群距離 $\sqrt{136}$ 與 $\sqrt{97}$；完整連結取最大值。

★ 精選 · 18.17

一維點 29,36,41,44,45,49,55,64,69。單一連結切成三群。

參考解答

{29}、{36,41,44,45,49,55}、{64,69}。

解析

排序後相鄰距離為 7,5,3,1,4,6,9,5；單一連結會依小間隔串接。切成三群時留下最大兩間隔 9、7。

★ 精選 · 18.18

一維點 29,36,41,44,45,49,55,64,69。完整連結切成三群。

參考解答

{29,36}、{41,44,45,49,55}、{64,69}。

解析

先形成 {41,44,45}、{64,69}、{49,55}、{29,36}。相鄰群最遠距離依次 16、14、20，因此中間兩群先合併。

★ 精選 · 18.20

一維點 13,40,60,71；完整連結與平均連結各建一樹，求最後合併高度之差的絕對值。

參考解答

14（B）。

解析

均先合併 60、71。完整法使 40 與 13 合併，最後距離 71−13=58。平均法使 40 與 {60,71} 合併，再與 13 合併，高度 $(27+47+58)/3=44$。

概念 04

選擇與驗證：穩定不等於真實存在

分群流程仍會在沒有天然群組的連續資料上輸出群組，因此要問結果是否可重現及可解釋。先明定對象與特徵、標準化方式與距離，再比較初始化、連結準則、群數或切樹高度。離群點會拉動 K 平均質心；階層法初始每點自成一群，異常點可能長時間單獨成群，最後也會被併入，不等於自動排除。

混合模型另假設資料由多個機率分布生成，可為每個點估計屬於各群的機率，與 K 平均的硬指派不同。重新抽樣、移除極端點或換合理的尺度後若群組大幅改變，應報告此敏感性；即使分組穩定，仍須檢查它是否符合問題目的，而非把演算法分出的標籤當成真實類型。

TERMS

本章中英術語

中文	English	解題時的意思
質心	centroid	同群觀察的逐欄平均位置。
連結準則	linkage	將兩群各點距離轉為群間距離的規則。
樹狀圖	dendrogram	以高度表示合併程度的階層式分群圖。

練習 · 18.1

群集分析、邏輯斯迴歸與嶺迴歸，哪些是監督學習？

參考解答

後兩者（D）。

解析

兩種迴歸均需反應變數訓練；群集只用特徵。

練習 · 18.2

判斷 I 可依 p 欄對 n 筆觀察分群；II 亦可依 n 筆上的表現對 p 欄分群；III 群集常用於無監督探索。

參考解答

三項皆是（E）。

解析

矩陣方向決定分群單位，兩種方向都不需既有類別標籤。

練習 · 18.4

判斷 I K 平均必須先標準化；II 它找同質子群；III 它找解釋原資料大部分變異的低維表示。

參考解答

只有 II（B）。

解析

標準化取決於單位和目的；低維表示是 PCA 的目的。

練習 · 18.5

找出錯誤敘述：A 探索資料結構；B 找出同質子群；C 屬無監督；D 目的是降維並保留變異；E K 平均須預設群數。

參考解答

D。

解析

分群可以摘要觀察，但並非求最大變異的投影軸。

練習 · 18.9

成績 99,98,95,93,91,89,87,85,79,77；初始高群 >90、中群 80–89、低群 <80。用 K 平均找最終分群。

參考解答

高：99,98,95,93；中：91,89,87,85；低：79,77。

解析

初始中心 95.2、87、78；91 離 87 較近所以改群，重算為 96.25、88、78。再次指派不變。

練習 · 18.10

初始 A={(0,0),(1,4),(2,2)}，B={(1,2),(−2,4),(0,2)}，C={(−1,0),(5,3),(−1,−3)}。做一次中心更新與重新指派。

參考解答

新 A={(1,2),(2,2),(5,3)}；B={(1,4),(−2,4),(0,2)}；C={(0,0),(−1,0),(−1,−3)}。

解析

起始質心依次 (1,2)、(−1/3,8/3)、(1,0)，比較每點到三質心的平方距離，取最小即可，不須開根號。

練習 · 18.13

群一 (5,15),(6,12),(6,20)，群二 (9,12),(11,4),(11,16)。求初始有序配對群內目標。

參考解答

約 221.33（C）。

解析

無序配對平方距離第一群為 10、26、64，第二群 68、20、144。各除群大小 3 再乘 2，得 $2(332)/3$。

練習 · 18.15

四點 $x_1 = (-1, 0), x_2 = (1, 1), x_3 = (2, -1), x_4 = (5, 10)$。平均連結下 {1,2} 與 {4} 距離？

參考解答

約 10.7554。

解析

取 $(\sqrt{136} + \sqrt{97})/2$，不是先算兩群的質心。

練習 · 18.16

五個一維觀察依序 9、15、4、2、18。用完整連結，第一個觀察（9）在哪一高度第一次合併？

參考解答

7（C）。

解析

2 與 4 在高度 2 合併，15 與 18 在 3 合併。9 到第一群之最大距離 7，到第二群為 9，故在 7 合併。

練習 · 18.19

A={(1,0),(2,1)}、B={(3,1),(3,−2)}，求平均連結距離。

參考解答

約 2.3067。

解析

$[\sqrt{5}+1+\sqrt{8}+\sqrt{10}]/4$，四對等權。

練習 · 18.21

判斷 I K 平均及階層法都必須先指定群數；II K 平均一定較不受離群點影響；III 教材版 K 平均需初始化，階層法不需隨機分派。

參考解答

只有 III（C）。

解析

階層法先建樹再切。兩者對離群點都可能敏感；K 平均常用隨機初始群或質心，但也可選確定性初始化。

練習 · 18.22

判斷 I 固定 K 就能保證 K 平均每次一樣；II 固定距離與連結準則時，階層分群可重現；III 切樹成五群必等於 K=5 的 K 平均。

參考解答

只有 II（B；同距離時也要固定破同分規則）。

解析

K 平均可能到不同局部解；兩種方法的目標與形成群組的方式不同。

練習 · 18.23

哪項適用 K 平均而非凝聚式階層法？A 不同人做一輪結果必同；B 每次迭代群數變多；C 各種 K 都只跑一次；D 先初始化資料點的群歸屬；E 皆非。

參考解答

D。

解析

教材演算法從一組起始群或等價質心開始，反覆重新指派；階層法則自單點逐步合併。

練習 · 18.24

判斷 I 在單調樹狀圖切得更低不會使群數更少；II K 平均一定要先畫圖才能選 K；III 固定群數時階層法有可能比 K 平均分得差。

參考解答

I、III（C）。

解析

畫圖有用卻非必要；階層法不能撤銷過去合併，因此未必在特定 K 下達到最佳群內平方和。

練習 · 18.25

判斷階層分群：I 極端離群點可不分派任何群；II 樹狀圖能切出不同群數；III 資料微幅改變可能改變結果。

參考解答

II、III（D）。

解析

每點起初自成一群，沒有被排除。早期合併順序一變，後續結構也可能改變。

練習 · 18.26

A={(8,2),(9,7),(12,5)}，B={(10,3),(11,1)}。求平均連結歐氏距離。

參考解答

約 3.80（C）。

解析

六個距離是 $\sqrt{5}, \sqrt{17}, \sqrt{8}, \sqrt{10}, \sqrt{40}, \sqrt{17}$。其總和除以 6。

練習 · 18.27

一維點 21,30,40,51,63,76 用單一連結合併，切為兩群。哪一群包含 21？

參考解答

{21,30,40,51,63}（E）；另一群為 {76}。

解析

相鄰間距 9,10,11,12,13。要兩群即停止於最後一條距離 13 的連結之前。